Sacar el máximo provecho a tus datos utilizando toda la información disponible:

La Estadística Bayesiana

Mª Asunción Martínez Mayoral y Javier Morales Socuéllamos

CENTRO DE INVESTIGACIÓN OPERATIVA

UNidad de Asesoramiento Estadístico y apoyo a la TOma de Decisiones

(UNAETOD; http://cio.umh.es/UNAETOD/principal.htm)

La Estadística Bayesiana

Historia:

- Nacimiento: Thomas Bayes 1702-1761, clérigo y científico/matemático vocacional (probabilidad inversa en seguros).
- Edad “Media”: Problemas técnicos. La Estadística Frecuentista se implanta.
- Edad “Moderna”: MCMC y el impulso de la Estadística Bayesiana.
- Edad “Post-Moderna”: Aplicaciones en todos los ámbitos.

Fundamentos:

- Está construida sobre la base de que la información e incertidumbre que tenemos sobre todo lo desconocido es expresable en términos de distribuciones de probabilidad.
- No se acude a la idea del muestreo repetido para justificar las buenas (o malas) propiedades de los estimadores.

Elementos de un análisis frecuentista

Parámetro característica poblacional de interés fija (Ej: proporción de personas con afecciones hepáticas, efecto medio de un tratamiento, ...)

Datos observaciones de la característica de interés sobre un sector de la población (Ej: si padece o no una afección hepática, efecto observado en una variable chivata,...)

Verosimilitud A partir del modelo de los datos concluimos sobre los valores más verosímiles de los parámetros.

Veamos qué es lo que no proporciona un análisis frecuentista.

Ejemplo:

En un estudio clínico sobre la efectividad de un nuevo fármaco, se ha tratado a $n = 40$ enfermos, de los cuales $X = 36$ han manifestado una mejoría relevante (clínicamente).

Información de los Datos:

Experimento Binomial $\rightsquigarrow X \sim Bi(40, p)$ VEROSIMILITUD para p

Se quiere contrastar que la proporción P de pacientes que experimentan una mejoría con el fármaco es superior a $0{,}8$, esto es,

$$\begin{aligned} H_0 &: p \leq 0{,}8 \\ H_1 &: p > 0{,}8. \end{aligned}$$

Utilizando el test clásico, basado en el estadístico máximo verosímil $\hat{p} = X/n$, se obtiene un p–valor igual a $0{,}05$, lo que no nos permite concluir el contraste en ningún sentido.

De hecho, el p–valor NO es la probabilidad de H_0, sino la probabilidad de que la proporción muestral de mejora sea tan o más extrema que la observada.

En términos frecuentitas no concluimos con probabilidades para el parámetro de interés, sino con probabilidades para su estimador, y por tanto no podemos contestar:

- ¿Cuál es la probabilidad de que P tenga un valor superior a 0.8?
- ¿Cuál es la probabilidad de que P tenga un valor entre 0.7 y 0.9?
- Si se decide repetir el experimento con otros 50 enfermos, ¿cuál es la probabilidad de que mejoren más de 40?

RAZONAR EN TÉRMINOS DE PROBABILIDAD

En un análisis Bayesiano, la incertidumbre sobre el parámetro se expresa en términos de una distribución de probabilidad.

... En la MODELIZACIÓN

Parámetro $\rightarrow$ La información previa sobre él (exista o no), siempre se puede formular en términos de una distribución de probabilidad (valores factibles, incertidumbre,...): DISTRIBUCIÓN A PRIORI.

Datos $\rightarrow$ relacionados con el parámetro de interés a través de una distribución de probabilidad para la variable observada: VEROSIMILITUD.

PAB: Introducción

Ejemplo: Se está experimentando una nueva técnica quirúrgica en enfermos cardíacos para reducir el número de muertos durante el proceso post-operatorio. Se dispone de información proporcionada por:

- Hospital A con técnica antigua: 31 muertos en 215 operaciones
- Hospital B con técnica nueva: 29 muertos en 256 operaciones

Se desea:

- Estudiar la tasa de mortalidad en cada hospital.
- Comparar las tasas de ambos hospitales.

La información proporcionada por el experimento se puede expresar como:

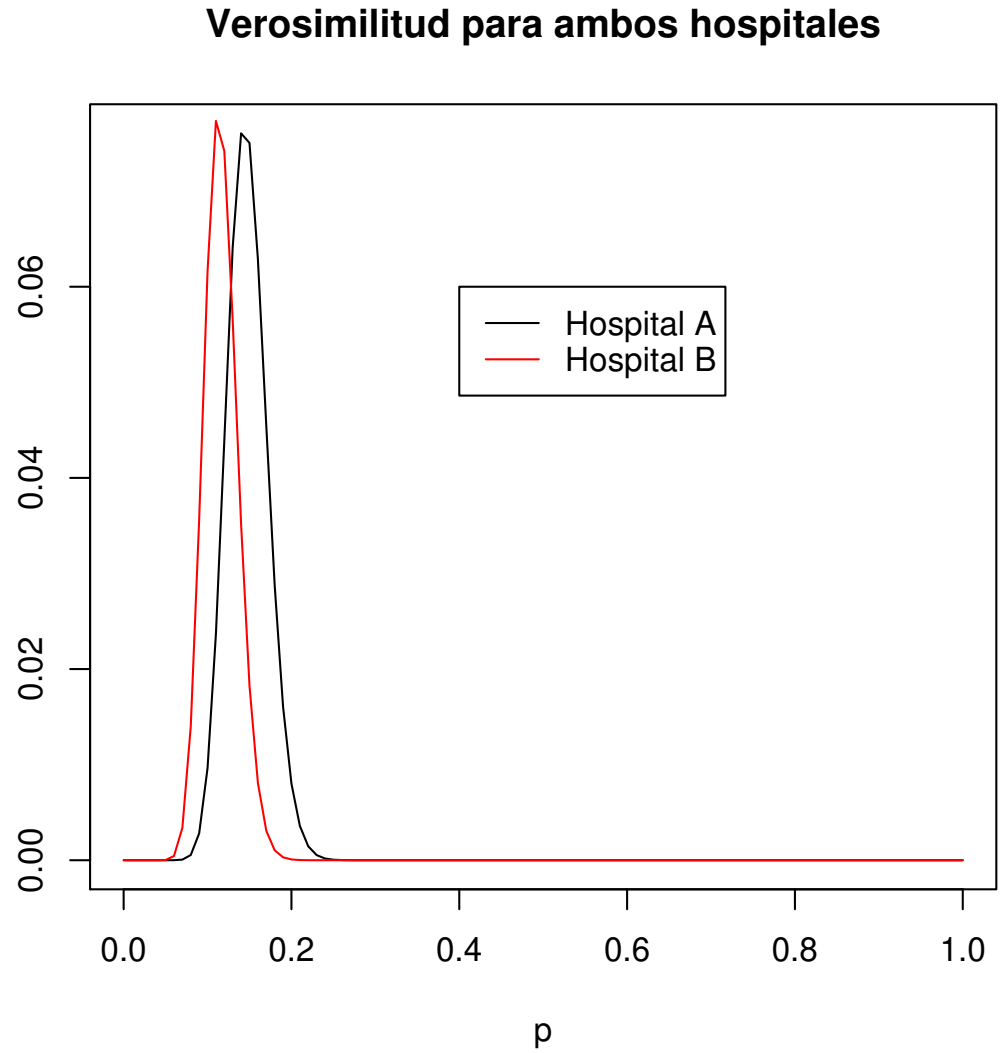
Exitus Hospital A $A_i \overset{iid}{\sim} Br(p_A), \quad i = 1, \ldots, n_A$ operaciones

Exitus Hospital B $B_i \overset{iid}{\sim} Br(p_B), \quad i = 1, \ldots, n_B$ operaciones

resumen nº exitus $\Rightarrow Y_A = \sum_{i=1}^{n_A} A_i \sim Bin(n_A, p_A); \quad Y_B = \sum_{i=1}^{n_B} B_i \sim Bin(n_B, p_B).$

VEROSIMILITUD para cada hospital $\equiv$ MODELO

$$l(y_{n_A} \mid p_A) \propto p_A^{y_{n_A}} (1 - p_A)^{n_A - y_A}; \qquad l(y_{n_B} \mid p_B) \propto p_B^{y_{n_B}} (1 - p_B)^{n_B - y_B}$$


Verosimilitud para ambos hospitales
Hospital A
Hospital B
0.00
0.02
0.04
0.06
0.0
0.2
0.4
0.6
0.8
1.0
p

PAB: Distribución a priori

Los método bayesianos requieren el establecimiento de una distribución a priori sobre los parámetros desconocidos, pero

¿cómo conseguimos esa distribución previa?

Dos posibilidades:

- Información a priori objetiva, es decir, a priori se desconoce nada sobre el parámetro de interés.
  Un análisis objetivo proporciona resultados tan objetivos como los producidos por un análisis frecuentista.
- Información a priori subjetiva en términos de una distribución de probabilidad obtenida a partir de:
  - Información de expertos en el área.
  - Información de experimentos previos.

Para el hospital A establecemos la información previa sobre p_A a partir de:

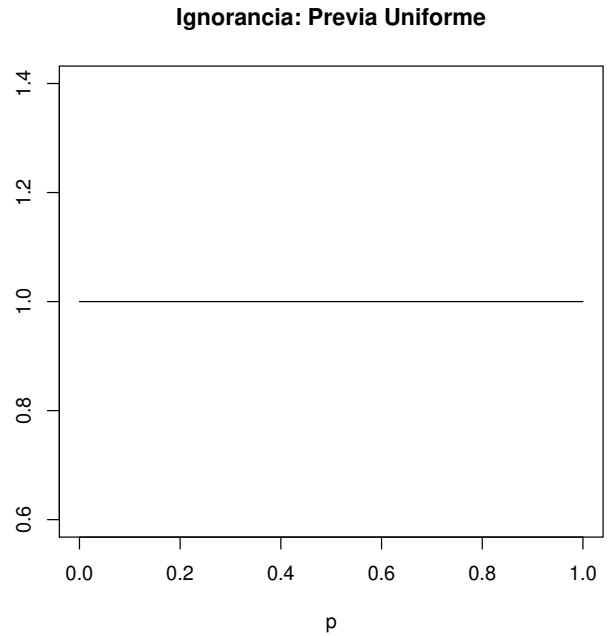
- Ignorancia (Noinf): sabemos que p_A es una probabilidad.
- Información de expertos (Exp): Cirujanos cardiovasculares con mucha experiencia se atreven a prever cuántas operaciones son necesarias para que se produzca un fallecimiento.
- Información de estudios previos (EstPrev): Datos procedentes de otros hospitales/estudios.

INCERTIDUMBRE $\equiv$ PROBABILIDAD

Lo que sabemos lo expresamos a través de una distribución de probabilidad

A priori no informativa

p es una probabilidad: $p \in [0,1] \quad \Rightarrow \quad p \sim Un(0,1) \equiv Be(1,1).$



En general, una **distribución Beta** es válida para modelizar la información disponible sobre una proporción.

$$p \sim Beta(\alpha,\beta) \propto p^{\alpha-1}(1-p)^{\beta-1}, \text{ con } E(p) = \frac{\alpha}{\alpha+\beta}; \; Var(p) = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$$

Información del experto

INFO: "*Hay que realizar 7 operaciones para que fallezca un individuo*".

- **ExpSenc** Interpreta los éxitos/fracasos.

$$\leadsto E(p) = 1/7 \Rightarrow p \sim Beta(1;6)$$

Y si INFO sólo es creíble en términos medios, $E(p)$, ¿cuál es la confianza del experto en INFO?

- **ExpSeg** Está muy seguro.

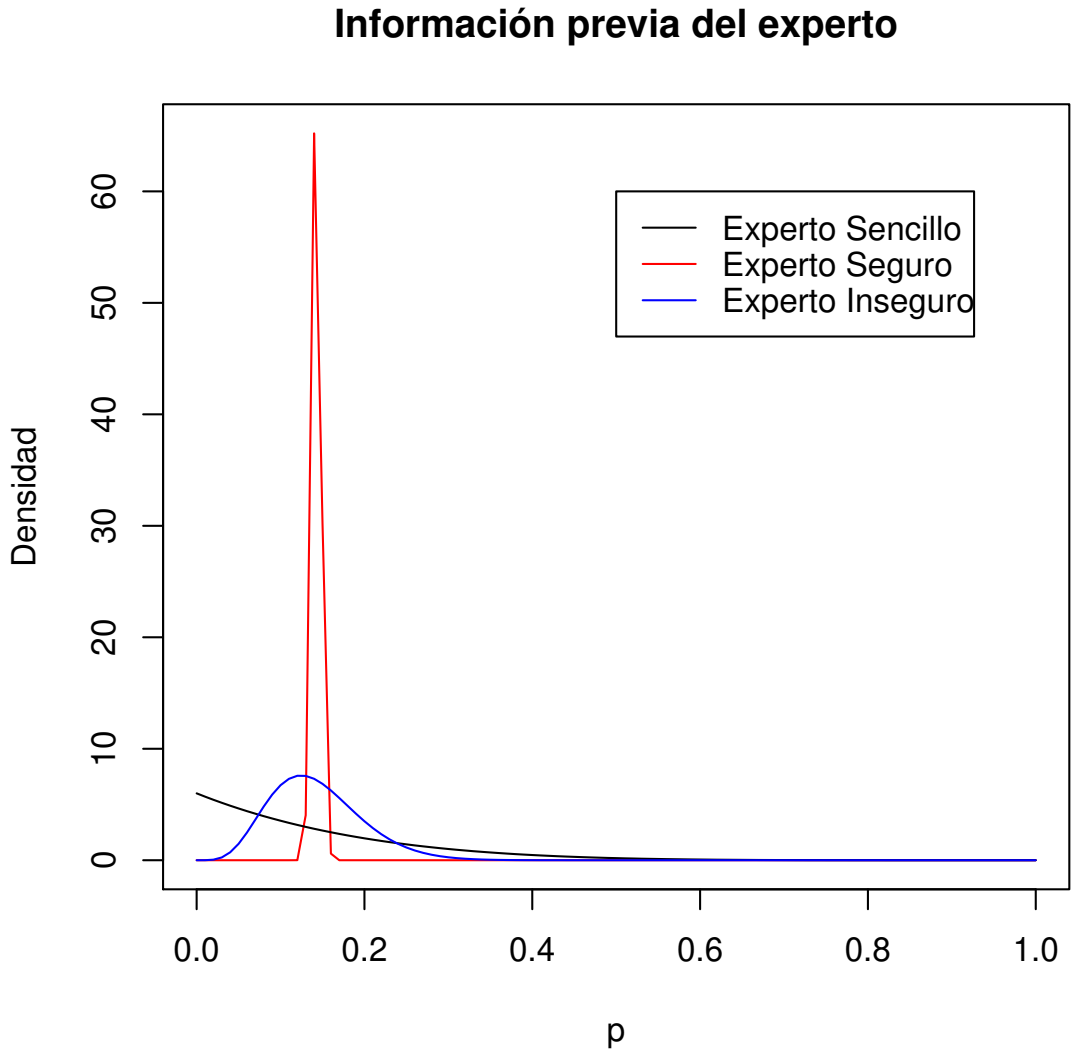
$$\leadsto sd(p) = 0{,}1E(p) \Rightarrow p \sim Beta(599{,}86; 3599{,}14)$$

$$\approx 600 \text{ muertes en } 4200 \text{ operaciones.}$$

- **ExpInseg** Está muy poco seguro.

$$\leadsto sd(p) = E(p) \Rightarrow p \sim Beta(5{,}86; 35{,}14) \approx 6 \text{ muertes en } 41 \text{ operaciones.}$$

Obtenemos la a priori despejando por el método de los momentos.


Información previa del experto
Experto Sencillo
Experto Seguro
Experto Inseguro
Densidad
0
10
20
30
40
50
60
0.0
0.2
0.4
0.6
0.8
1.0
p

Información de estudios previos

"*En otro hospital se ha usado el mismo procedimiento quirúrgico y se han observado 18 muertes en 148 operaciones*"

- **EstPrev** Interpreta los éxitos/fracasos.

$$\rightsquigarrow E(p) = 18/148 \Rightarrow p \sim Be(18, 130)$$

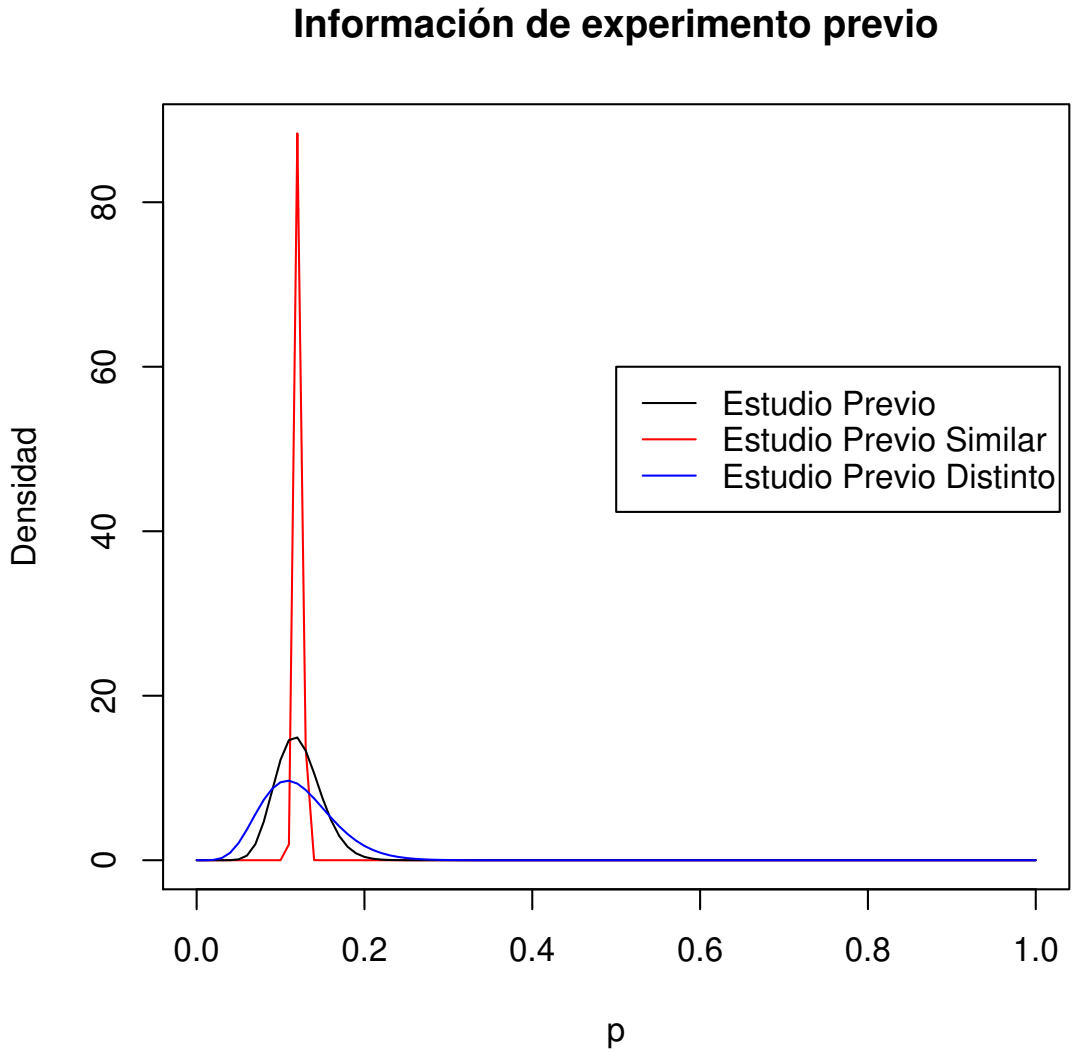
Pero, ¿qué variación se espera respecto del otro hospital?

- **EstPrevSim** El número de muertes se espera que sea muy similar.

$$\rightsquigarrow sd(p) = 0{,}1E(p) \Rightarrow p \sim Beta(722{,}10; 5215{,}17)$$

- **EstPrevDist** El número de muertes puede ser distinto.

$$\rightsquigarrow sd(p) = E(p) \Rightarrow p \sim Beta(7{,}10; 51{,}28)$$


Información de experimento previo
Densidad
0
20
40
60
80
0.0
0.2
0.4
0.6
0.8
1.0
p
Estudio Previo
Estudio Previo Similar
Estudio Previo Distinto

PAB: Distribución Posterior

¿Qué hacemos con la información proporcionada por el modelo y la distribución a priori?

Combinamos la información con el teorema de Bayes

$$Pr(par|datos) = \frac{Pr(par, datos)}{Pr(datos)} = \frac{Pr(datos|par)Pr(pars)}{Pr(datos)}$$

Basamos nuestras conclusiones sobre los parámetros de interés

$\rightsquigarrow$ DISTRIBUCIÓN POSTERIOR

Hospital A:

$$\pi(p_A|y_A) = \frac{f(y_A|p_A)\pi(p_A)}{\int f(y_A|p_A)\pi(p_A)\,dp} \propto f(y_A|p_A)\pi(p_A).$$

Veamos qué forma tiene la distribución posterior:

- Verosimilitud:

$$f(y_A|p_A) \propto p_A^{y_a}(1-p_A)^{n_A-y_A}$$

- Distribución a priori: en todos los casos presentados la distribución a priori es una distribución Beta, por tanto:

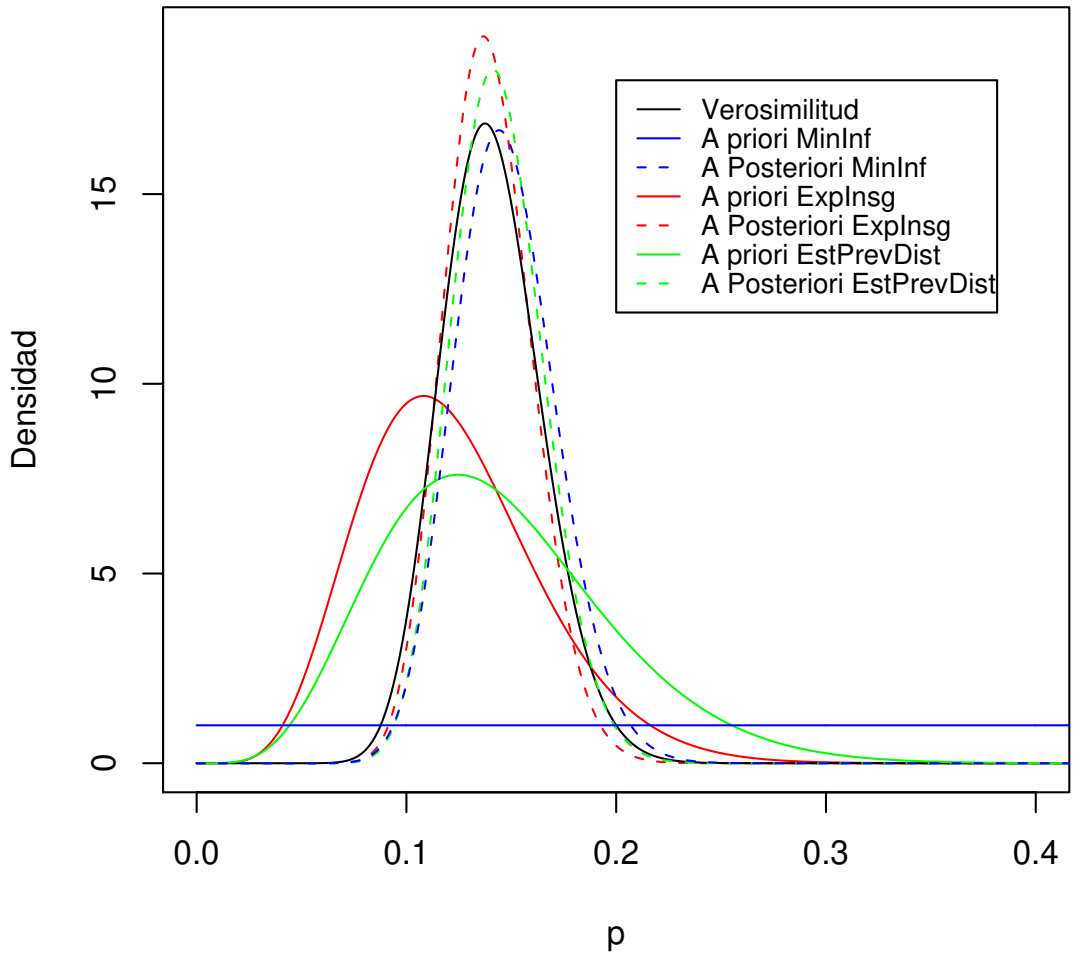
$$\pi(p_A) \propto p_A^{\alpha-1}(1-p_A)^{\beta-1},$$

con α y β los correspondientes parámetros de la distribución a priori.

Así,

$$\begin{aligned}\pi(p_A \mid y_A) \propto & f(y_A|p_A)\pi(p_A) \propto p_A^{\alpha-1}(1-p_A)^{\beta-1}p_A^{y_a}(1-p_A)^{n_A-y_A} \\ & = p_A^{\alpha+y_A-1}(1-p_A)^{n_A-y_A+\beta-1} = Be(p_A \mid \alpha+y_A; n_A-y_A+\beta)\end{aligned}$$

Distribuciones a priori y a posteriori



Inferencia

¿Qué información contiene la distribución posterior?

- ✓ Estimación puntual
  Media, mediana, moda,etc...

- ✓ Precisión de la estimación
  Varianza, desviación típica

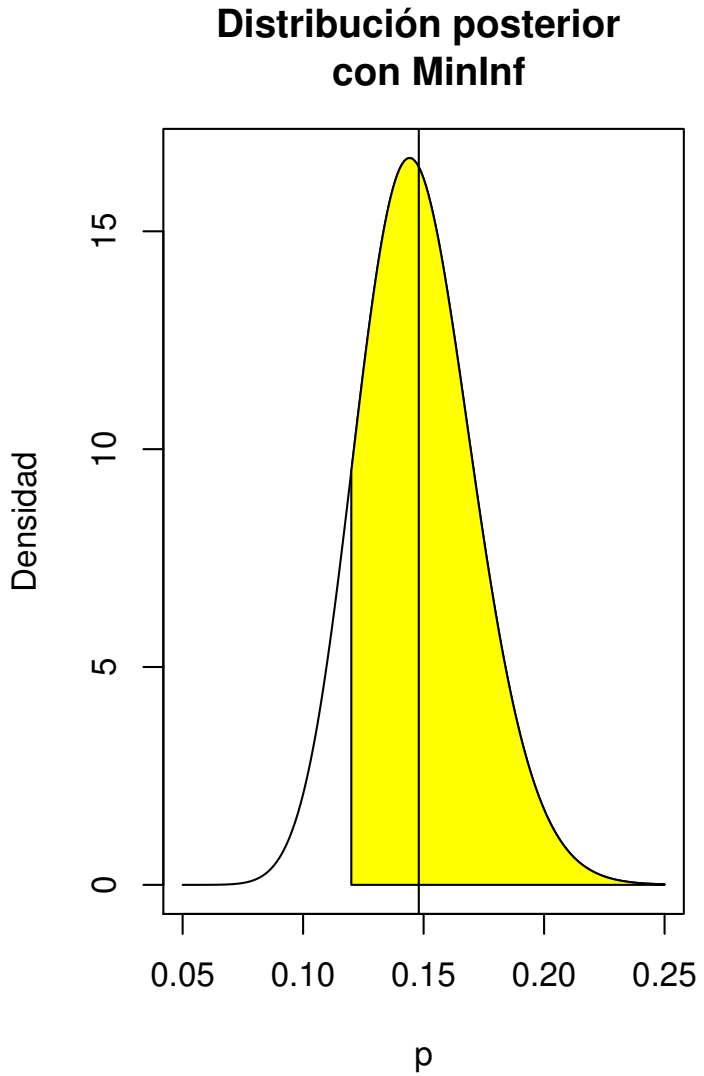
- ✓ Rango de valores más creíbles $=$ más probables
  Obtenido a partir de los cuantiles $\alpha/2$ y $1-\alpha/2$ de la distribución a posteriori.

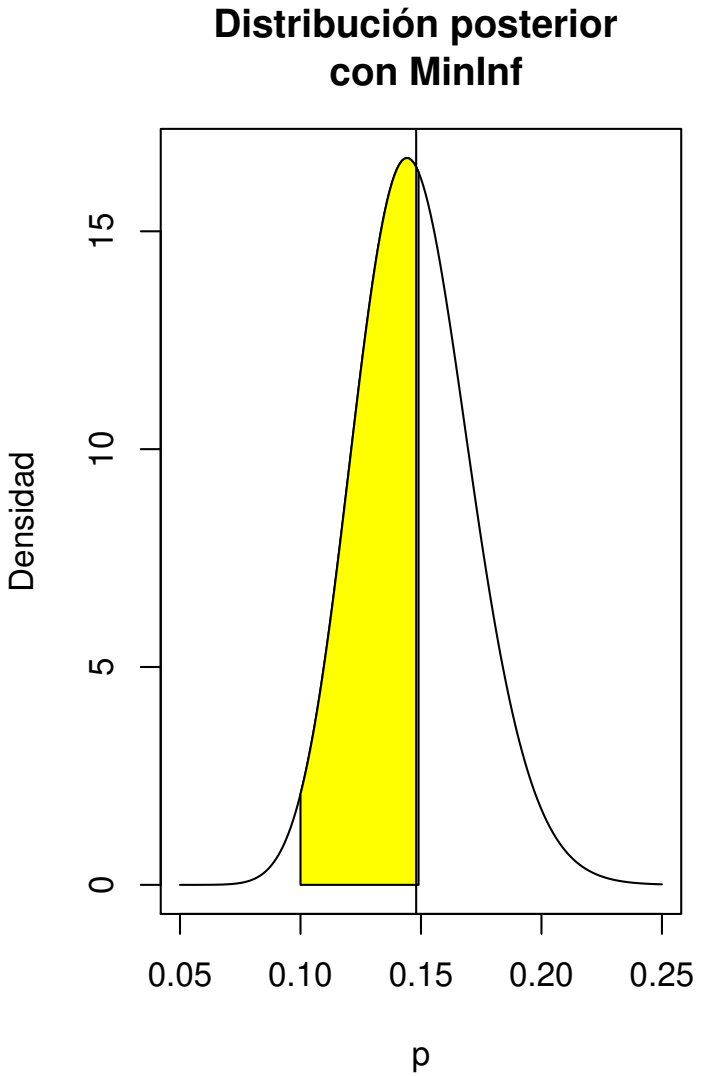
- ✓ Probabilidad de cualquier hipótesis sobre p_a
  Obtenida a partir del cuantil correspondiente de la distribución posterior.

Inferencias posteriores:

A priori	Media	sd	RC 0.95	$Pr(p_A \geq 0{,}12)$	$Pr(0{,}10 \leq p_A \leq 0{,}15)$
Mininf	0.148	0.024	(0.104 , 0.198)	0.88	0.54
ExpSenc	0.144	0.024	(0.101 , 0.193)	0.85	0.59
ExpSeg	0.143	0.005	(0.133 , 0.153)	0.99	0.90
ExpInseg	0.144	0.022	(0.104 , 0.189)	0.87	0.61
EstPrev	0.135	0.018	(0.102 , 0.172)	0.80	0.78
EstPrevSim	0.122	0.004	(0.114 , 0.131)	0.72	1
EstPrevDist	0.139	0.021	(0.101 , 0.183)	0.82	0.68

Gráficamente:





Inferencia: Contraste de Hipótesis

Plantear un contraste de hipótesis conlleva asumir supuestos a priori sobre el parámetro testado (probabilidad a priori), coherentes con el test,

Contraste $\rightsquigarrow$ evaluar probabilidades a priori,

$$Pr(H_0)/Pr(H_1)$$

Resolución

- En términos de probabilidades a posteriori,

  Aceptar H_0 si $Pr(H_0 \mid datos) > Pr(H_1 \mid datos)$

- En términos del Factor Bayes a favor de H_0,

$$B_{01} = \frac{Pr(H_0 \mid datos)/Pr(H_1 \mid datos)}{Pr(H_0)/Pr(H_1)}$$

Aceptar H_0 si B_{01} resulta suficientemente grande.

Planteamos el contraste $H_0 : p_A \leq 0{,}13$ vs $H_1 : p_A > 0{,}13$. El cálculo de probabilidades a priori y posteriori de resulta muy fácil:

$$Pr(H_0) = \int_0^{0,13} \pi(p_A) dp_A; \qquad Pr(H_1) = 1 - Pr(H_0)$$

$$Pr(H_0|datos) = \int_0^{0,13} \pi(p_A \mid y_A) dp_A; \qquad Pr(H_1 \mid datos) = 1 - Pr(H_0 \mid datos)$$

A priori	$Pr(H_0)$	$Pr(H_0 \mid datos)$	B_{01}
Mininf	0.87	0.76	0.47
ExpSenc	0.43	0.72	3.29
ExpSeg	0.99	0.99	1.24
ExpInseg	0.55	0.73	2.19
EstPrev	0.36	0.60	2.67
EstPrevSim	0.03	0.04	1.43
EstPrevDist	0.38	0.66	3.10

PAB: Predicción

Además de inferir sobre el parámetro de interés o alguna transformación, es posible predecir observaciones. La predicción se puede realizar de dos formas:

- Utilizando sólo la información previa sobre la población (parámetro) $\rightsquigarrow$ **distribución predictiva a priori**. Antes de realizar el experimento será posible inferir sobre cuáles son los valores más (y menos) probables a observar.
- Utilizando la información actualizada tras realizar el experimento $\rightsquigarrow$ **distribución predictiva a posteriori**. Con ella es posible inferir sobre cuál es el valor más (y menos) probable a observar si repetimos el experimento en el futuro (en iguales condiciones).

La distribución predictiva es la herramienta esencial para el diseño y planificación de un experimento futuro.

Estamos interesados en predecir el número de fallecimientos en 50 operaciones, antes y después de introducir la nueva técnica quirúrgica, y cuál es la probabilidad de que se produzcan más de 7 exitus en 50 operaciones.

La distribución **predictiva a priori** se obtiene con:

$$m(y_{pred}) = \int f(y_{pred} \mid p_A)\pi(p_A)dp_A,$$

que en el ejemplo que nos ocupa viene dada por la densidad Beta-Binomial:

$$BB(y_{pred} \mid \alpha, \beta, n) = \frac{\Gamma(n+1)}{\Gamma(y_{pred}+1)\Gamma(n-y_{pred}+1)} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \frac{\Gamma(\alpha+y_{pred})\Gamma(\beta+n-y_{pred})}{\Gamma(\alpha+\beta+n)},$$

con α y β los parámetros de la distribución a priori y n el tamaño muestral del experimento a realizar.
La distribución **predictiva a posteriori** se obtiene:

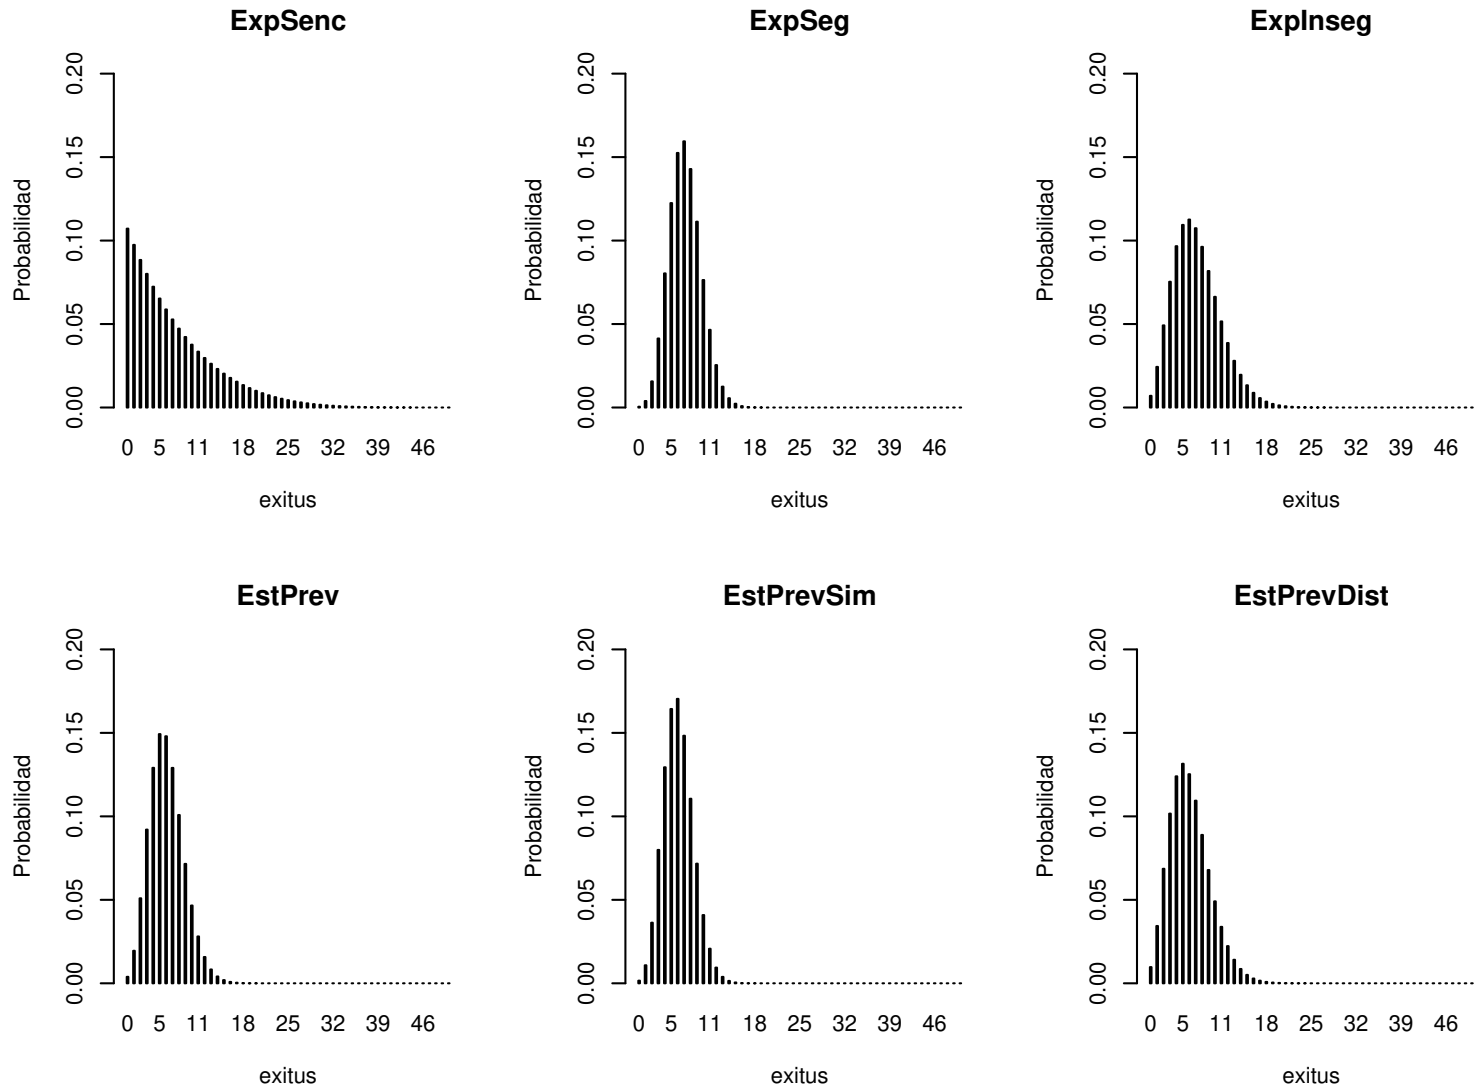
$$m(y_{pred} \mid y_A) = \int f(y_{pred} \mid p_A)\pi(p_A \mid y_A)dp_A = BB(y_{pred} \mid \alpha+y_A, \beta+n_A-y_A, n),$$

con α y β los parámetros de la distribución posterior.

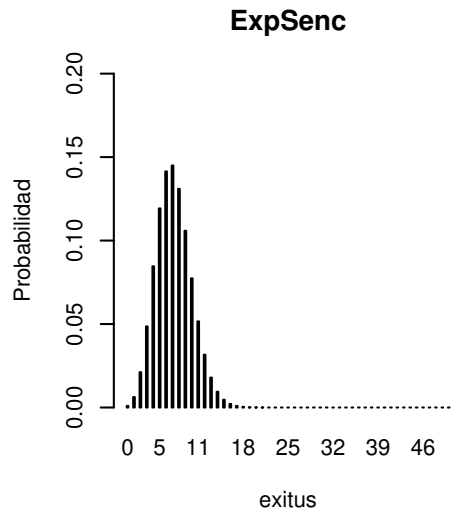
Resultados:

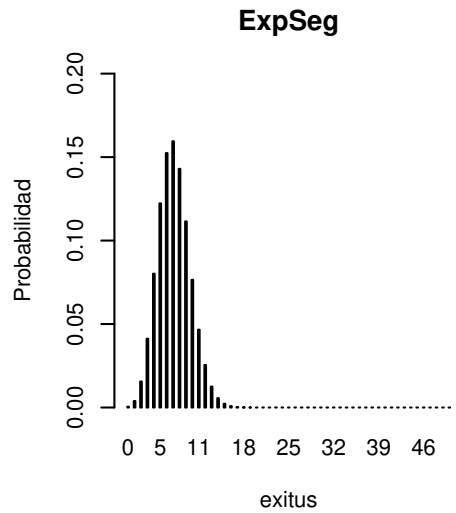
	$m(y_{pred})$		$m(y_{pred} \mid y_A)$		
	Media	SD	Media	SD	$Pr(y_{pred} \geq 7 \mid y_A)$
MinInf	25	14.72	7.37	2.77	0.15
ExpSec	7.14	6.60	7.20	2.74	0.17
ExpSeg	7.14	2.49	7.14	2.49	0.10
ExpInseg	7.15	3.64	7.20	2.71	0.16
EstPrev	6.08	2.66	6.75	2.57	0.21
EstPrevSim	6.08	2.32	6.12	2.33	0.28
EstPrevDist	6.08	3.12	6.97	2.66	0.19

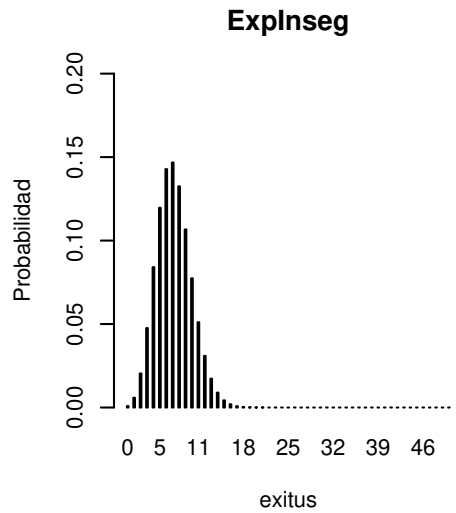
Predictiva a priori:

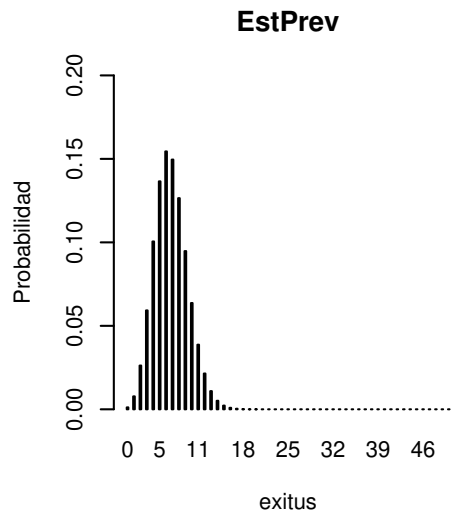


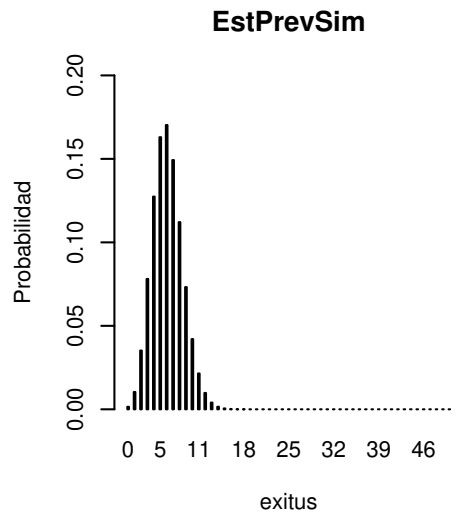
Predictiva a posteriori:

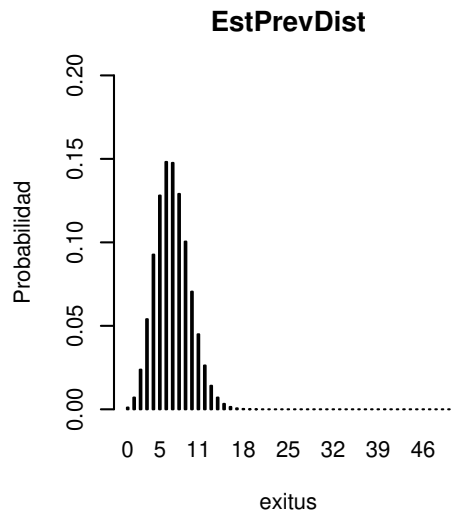












PAB: Transformaciones

Estamos interesados en comparar p_A y p_B. Para ello necesitamos al distribución posterior de $p_A - p_B$, pero ¿cómo podemos obtenerla?

Asumiendo que ambos hospitales son independientes:

$$\pi(p_A, p_B \mid y_A, y_B) = \pi(p_A \mid y_A)\pi(p_B \mid y_B).$$

Para obtener la distribución posterior de $p_A - p_B$ basta con simular M valores de las correspondientes distribuciones posteriores $\pi(p_A \mid y_A)$ y $\pi(p_B \mid y_B)$:

$\{p_{A1}, \ldots, p_{AM}\}; \{p_{B1}, \ldots, p_{BM}\}$ de forma que $\{p_{A1} - p_{B1}, \ldots, p_{AM} - p_{BM}\}$

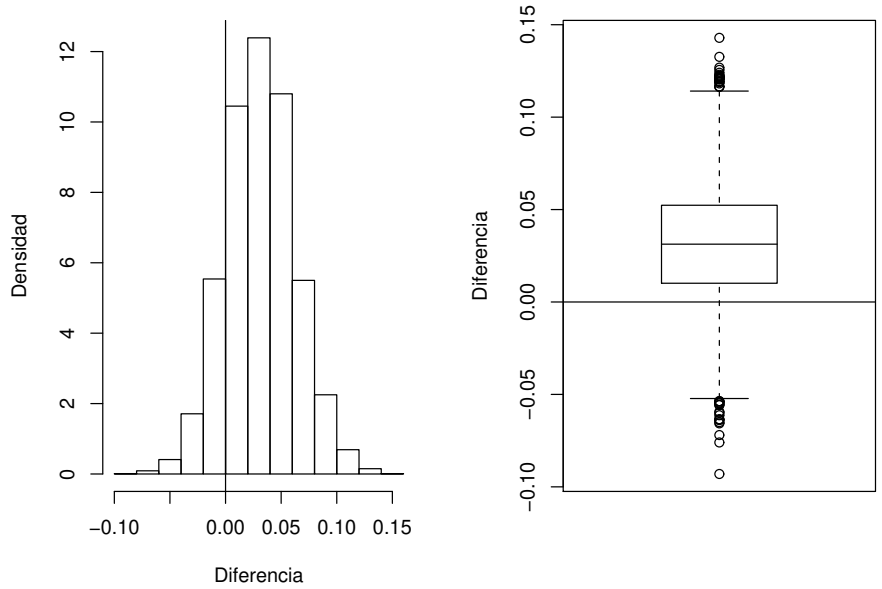
es una muestra de $\pi(p_A - p_B \mid y_A, y_B)$.

Una vez obtenida la muestra, un simple análisis empírico de la simulación sirve para caracterizar la correspondiente distribución.

Veamos qué ocurre en el caso de que asumamos previas mínimo-informativas para cada hospital. En ese caso las distribuciones posteriores son:

$$\pi(p_A \mid y_A) = Be(32, 185); \qquad \pi(p_B \mid y_B) = Be(32, 185)$$

5000 simulaciones	Media	SD	RC 0.95	$Pr(p_A - p_B \geq 0)$
Diferencia	0.0314	0.0310	(-0.027,0.094)	0.845



PAB: Modelo Normal

Un mejorador de plantas desea estudiar el rendimiento de dos variedades diferentes de trigo. Para ello elige doce estaciones experimentales distintas y en cada una de ellas siembra una parcela con la variedad A y otra parcela con la variedad B. La variable de interés es "cantidad de toneladas de trigo tras la siembra". Asumimos normalidad:

$$R_{A_i} \sim N(\mu_A, \sigma_A^2); \qquad R_{B_i} \sim N(\mu_B, \sigma_B^2); \quad i = 1, \ldots, 12, (n_A = n_B = 12)$$

El objetivo principal es comparar el rendimiento de ambas variedades en términos de producción.

No tenemos información sobre la producción esperada ni su variabilidad de ambas variedades, y por tanto, asumimos distribuciones a priori mínimo-informativas:

$$\pi(\mu_A, \sigma_A^2) \propto 1/\sigma_A^2; \qquad \pi(\mu_B, \sigma_B^2) \propto 1/\sigma_B^2$$

Modelo Normal: Distribución posterior

Al igual que en el ejemplo anterior, las distribuciones posteriores vienen dadas por

$$\pi(\mu_A, \sigma_A^2 \mid R_A) \propto l(R_A \mid \mu_A, \sigma_A^2)\pi(\mu_A, \sigma_A^2),$$

$$\pi(\mu_B, \sigma_B^2 \mid R_B) \propto l(R_B \mid \mu_B, \sigma_B^2)\pi(\mu_B, \sigma_B^2).$$

Si denotamos por r_A, r_B las medias muestrales respectivas, y por s_A^2, y s_B^2 las varianzas muestrales, las distribuciones posteriores vienen dadas por:

$$\pi(\mu_A, \sigma_A^2 \mid R_A) = N\left(\mu_A \mid r_A, \frac{\sigma_A^2}{n_A}\right) GaI\left(\sigma_A^2 \mid \frac{n_A}{2}, \frac{(n_A - 1) * s_A^2}{2}\right) = \pi(\mu_A \mid \sigma_A^2, r_A)\pi(\sigma_A^2 \mid s_A^2)$$

$$\pi(\mu_B, \sigma_B^2 \mid R_B) = N\left(\mu_B \mid r_B, \frac{\sigma_B^2}{n_B}\right) GaI\left(\sigma_B^2 \mid \frac{n_B}{2}, \frac{(n_A - 1) * s_B^2}{2}\right) = \pi(\mu_B \mid \sigma_B^2, r_B)\pi(\sigma_B^2 \mid s_B^2)$$

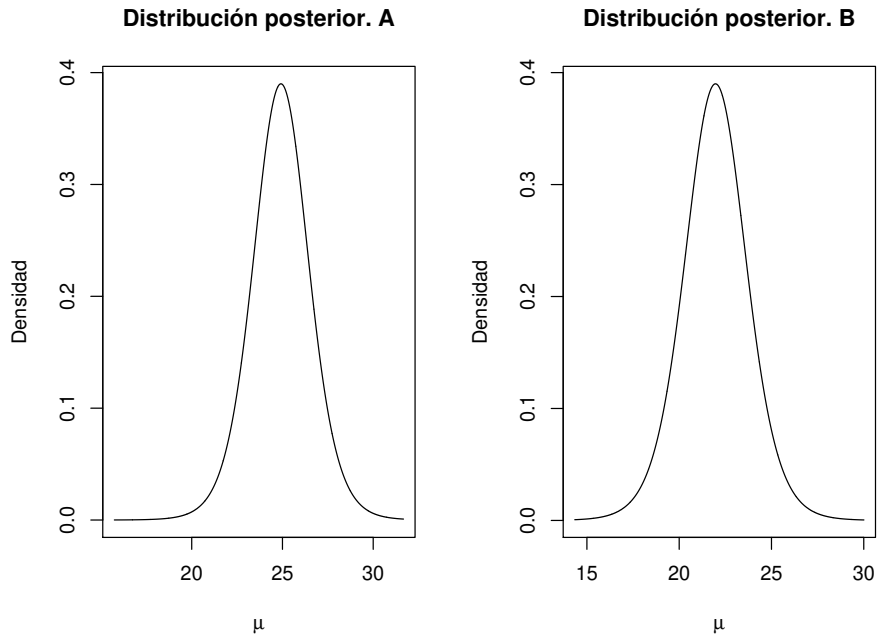
donde $GaI(x \mid \alpha, \beta)$ es la función de densidad de una distribución Gamma Inversa cuya media es $\beta/(\alpha - 1)$, y $N(x \mid \mu, \sigma^2)$ la de una distribución Normal con media μ y varianza σ^2.

Modelo Normal: Inferencia

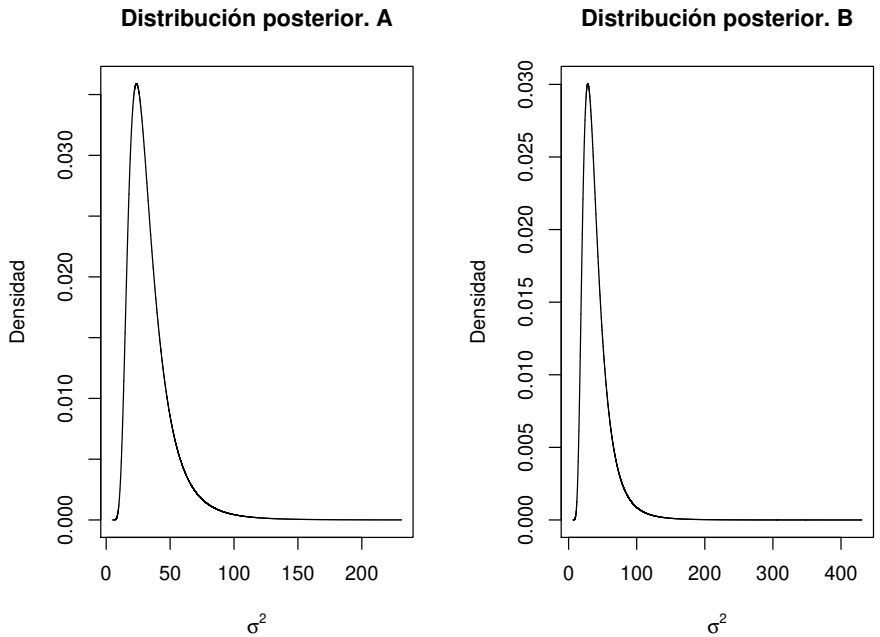
En general para obtener inferencias de la distribución posterior conjunta, y de las distribuciones predictivas, la forma más sencilla es proceder mediante simulación utilizando el método de composición.

- Posterior
  - Generar $\sigma_{ij}^2 \sim \pi(\sigma_i^2 \mid s_i^2), \qquad j = 1, \ldots, M, \quad i = A, B$
  - Generar $\mu_{ij} \sim \pi(\mu_i \mid \sigma_i^2, r_i)$
- Predictiva posterior
  - Generar $\sigma_{ij}^2 \sim \pi(\sigma_i^2 \mid s_i^2)$
  - Generar $\mu_{ij} \sim \pi(\mu_i \mid \sigma_i^2, r_i)$
  - Generar $R_k \sim N(R \mid \mu_{ij}, \sigma_{ij}^2), \qquad k = 1, \ldots, n$

μ	Media	SD	RC 0.95
variedad A	24.87	1.711	(21.48 , 28.24)
variedad B	21.97	1.879	(18.19 , 25.77)

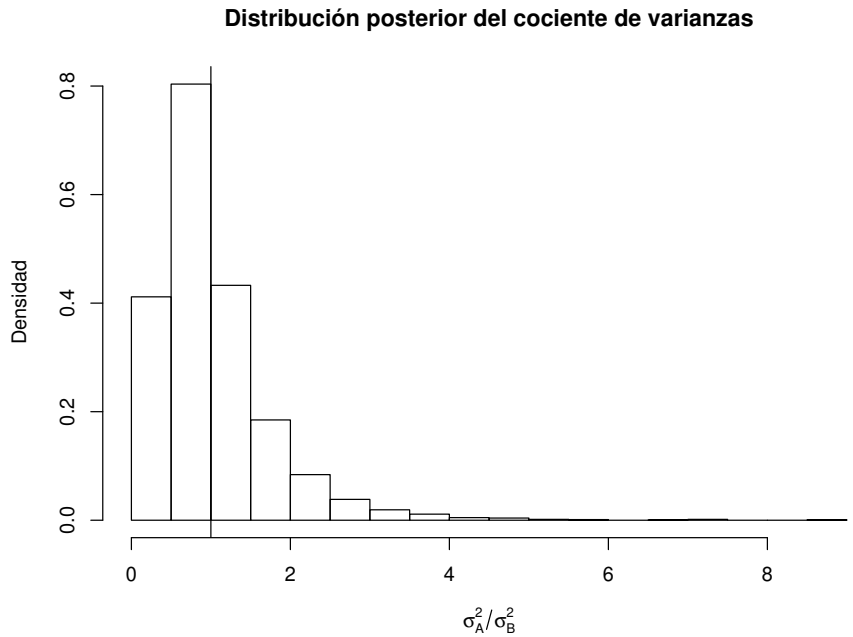


σ^2	Media	SD	RC 0.95	HPD 0.95
variedad A	34.24	18.45	(14.03 , 81.9)	(11.09 , 69.68)
variedad B	40.73	21.99	(16.92 , 95.57)	(12.64 , 81.71)



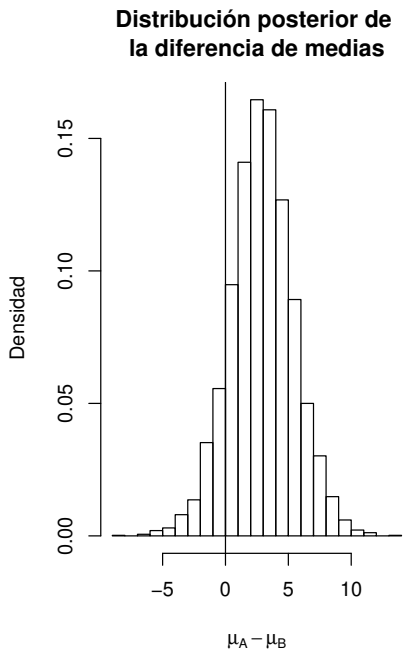
Antes de comparar las medias comparamos las varianzas con el test habitual σ_A^2/σ_B^2:

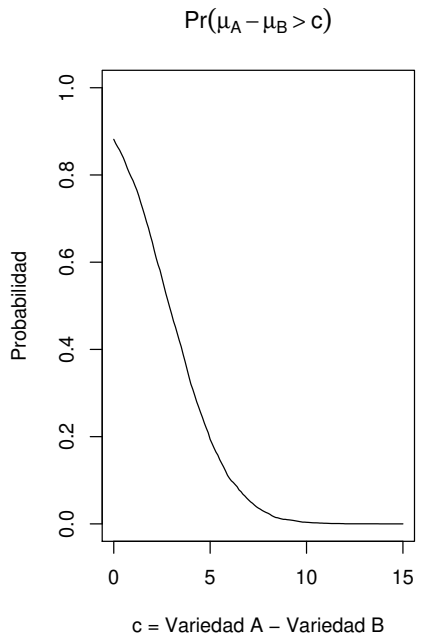
	Media	SD	HPD 0.95
σ_A^2/σ_B^2	1.026	0.73	(0.12 , 2.37)



Comparación de medias:

	Media	SD	HPD 0.95
$\mu_A - \mu_B$	2.90	2.54	(-2.09 , 7.89)





Modelo Normal: Análisis Predictivo

Una vez realizado el experimento estamos interesados en saber cuál será la producción de las parcelas para el año que viene, si las condiciones experimentales se mantienen:

Predictiva a posteriori	Media	SD	RC 0.95
variedad A	24.92	2.39	(20.16 , 29.67)
variedad B	21.97	2.61	(16.77 , 27.16)

