Sacar el máximo provecho a tus datos utilizando toda la información disponible:

La Estadística Bayesiana

Mª Asunción Martínez Mayoral y Javier Morales Socuéllamos

CENTRO DE INVESTIGACIÓN OPERATIVA

UNidad de Asesoramiento Estadístico y apoyo a la TOma de Decisiones

(UNAETOD; http://cio.umh.es/UNAETOD/principal.htm)

Modelos Jerárquicos Bayesianos

- Quizás la herramienta Bayesiana más potente y flexible.
- Permiten combinar información proveniente de diversas poblaciones ligadas entre sí respecto de alguna característica, y extraer información conjuntamente sobre las características compartidas, aprovechando toda la información disponible. El resultado es que al utilizar mucha más información (datos), aumenta la precisión de las estimaciones. (p.e. modelos multi-nivel y meta-analíticos).
  Las soluciones tradicionales, sin embargo, pasan por asumir:
  - igualdad entre poblaciones, de modo que se sobre-estima la precisión de las estimaciones.
  - independencia, que impide ligar información reduciendo los tamaños muestrales.
- Los efectos aleatorios son incorporados de un modo natural, y así como derivadas las inferencias sobre ellos.

Escarabajos. Objetivos

Bliss (1935) publicó unos datos con el número de escarabajos muertos tras una exposición durante cinco horas a diferentes concentraciones de disulfato de carbono.

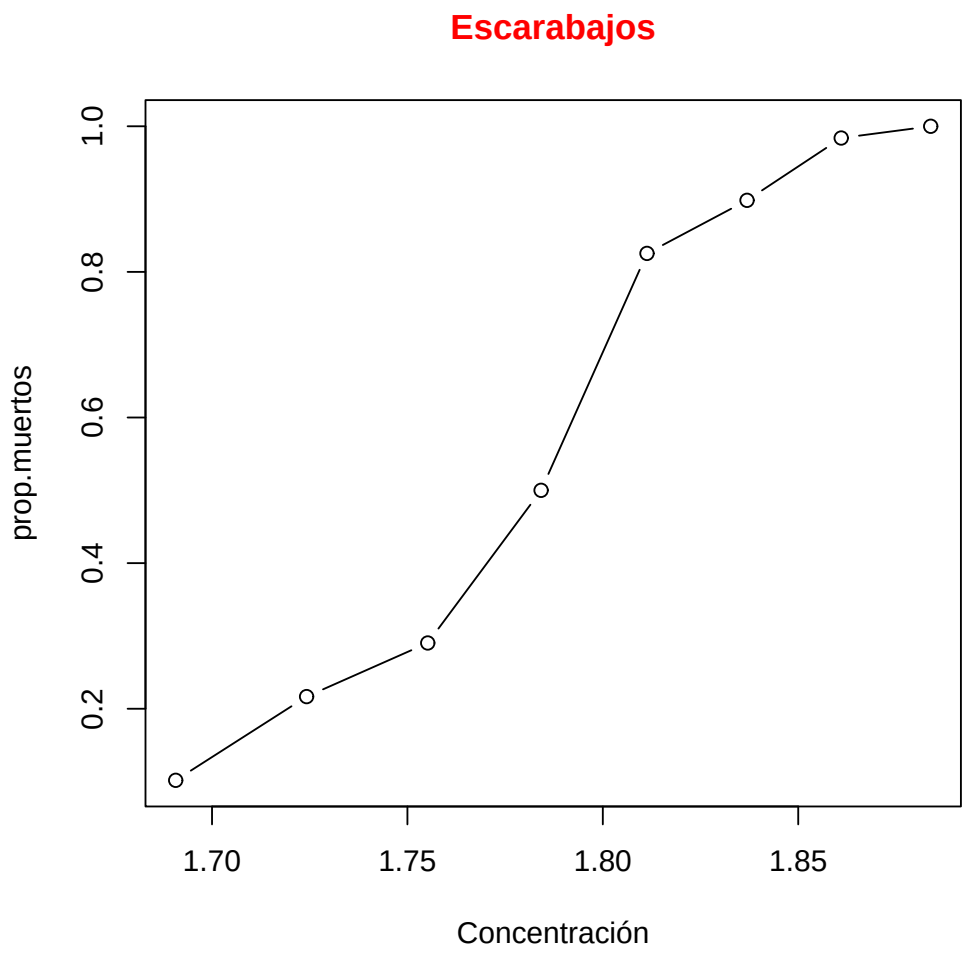
OBJETIVOS:

- Estudiar el efecto del tóxico como 'exterminador' de escarabajos.
- Determinar la dosis necesaria para garantizar una mortalidad alta.
- Comparar los resultados ante diversas alternativas de análisis al especificar la relación entre concentración y proporción de muertos:

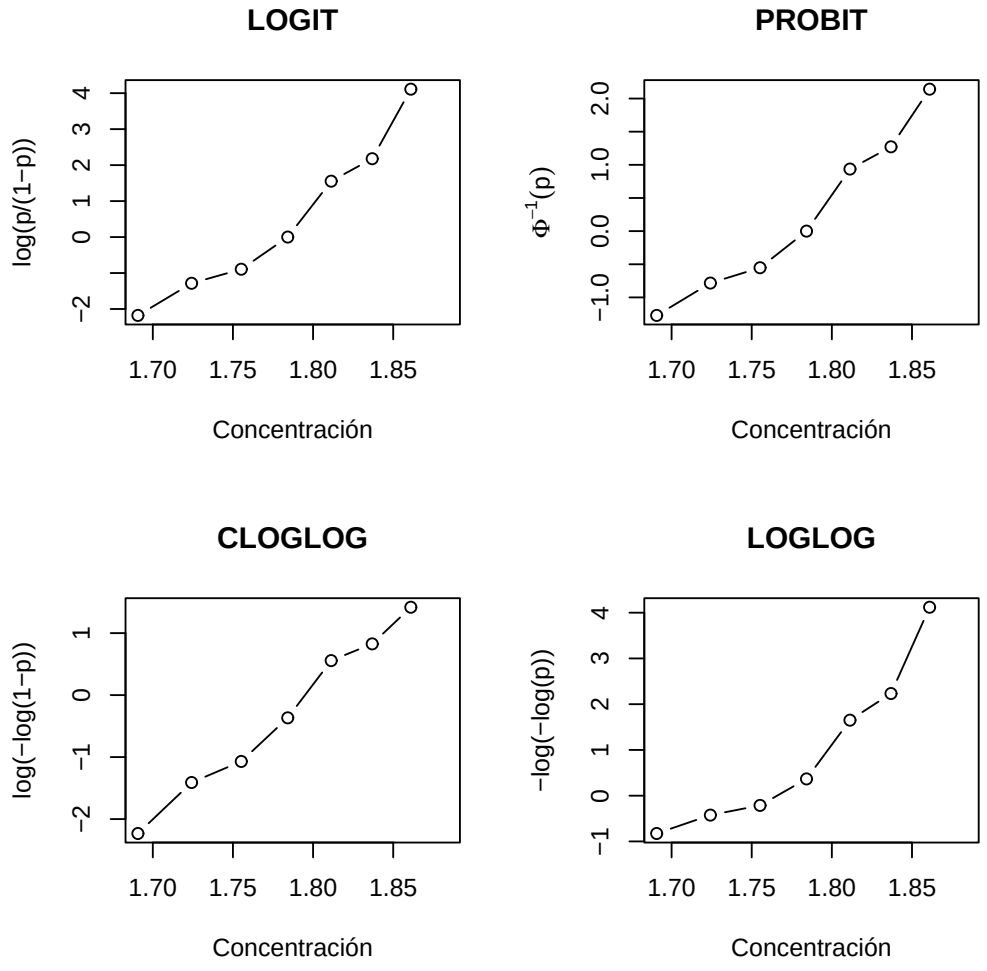
$$p \sim \alpha + \beta conc = \eta$$

logit	$log(p/(1-p)) = \eta$	$p = e^{\eta}/(1+e^{\eta})$
probit	$\Phi^{-1}(p) = \eta$	$p = \Phi(\eta)$
cloglog	$log(-log(1-p)) = \eta$	$p = 1 - e^{-e^{\eta}}$
loglog	$-log(-log(p)) = \eta$	$p = e^{-e^{-\eta}}$

Escarabajos. Datos



Escarabajos. Links



Escarabajos. Modelización

- Logit y Loglog proporcionan básicamente la misma linealización.
- A la vista de los Gráficos, el link que linealiza mejor la relación *concentración*$\sim$*prop.muertos* es el cloglog.

$$cloglog(p) = \alpha + \beta\, conc = \alpha^* + \beta(conc - \bar{conc})$$

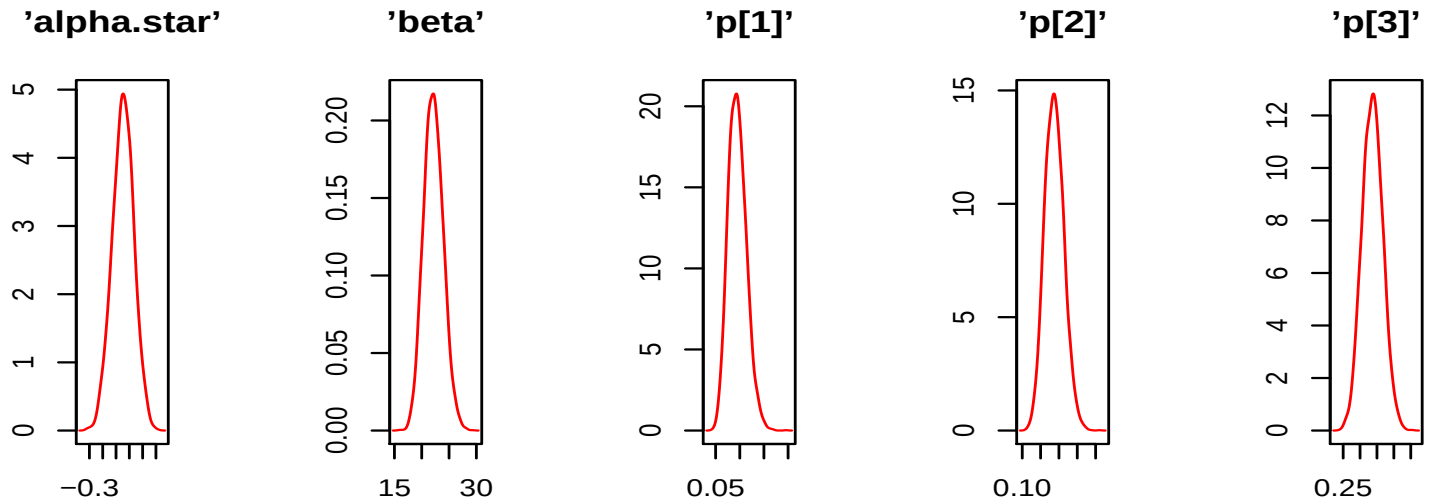
$$\alpha = \alpha^* - \beta\bar{conc}$$

- El DIC (criterio bayesiano de comparación de modelos basado en la variabilidad sin explicar) corrobora como mejor ajuste el proporcionado por el modelo 'cloglog'.

	Dbar	Dhat	DIC	pD: (complejidad)
logit	39.38	37.43	41.34	1.95
probit	38.34	36.32	40.36	2.02
cloglog	31.60	29.65	33.55	1.95

Escarabajos. Inferencia

Obtenemos una distribución posterior para cada uno de los parámetros del modelo.

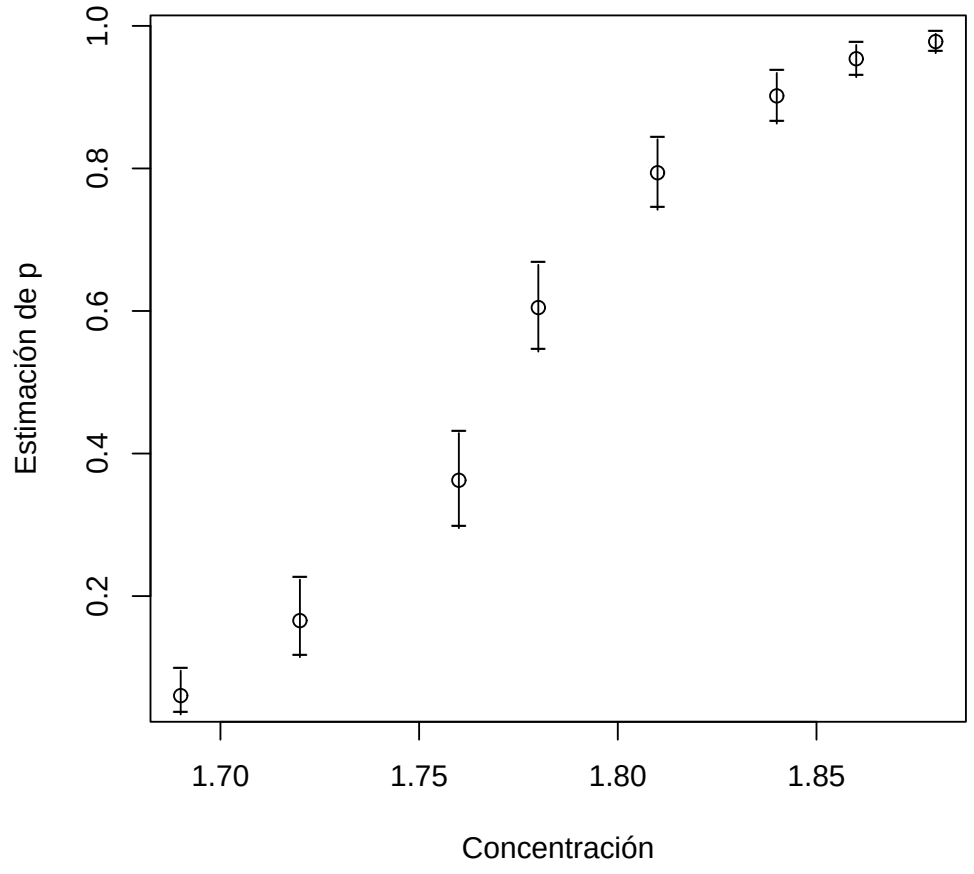


con las que podemos calcular estimaciones e intervalos creíbles:

	mean	sd	MC error	val2.5pc	median	val97.5pc	start	sample
α^*	0.74	0.14	0.00	0.48	0.74	1.02	1001	5000
β	34.30	2.86	0.06	29.00	34.30	40.23	1001	5000
p[1]	0.06	0.02	0.00	0.03	0.06	0.10	1001	5000
p[2]	0.17	0.03	0.00	0.11	0.16	0.22	1001	5000
p[3]	0.36	0.03	0.00	0.30	0.36	0.43	1001	5000
p[4]	0.60	0.03	0.00	0.54	0.61	0.66	1001	5000
p[5]	0.79	0.03	0.00	0.74	0.79	0.84	1001	5000
p[6]	0.90	0.02	0.00	0.86	0.90	0.93	1001	5000
p[7]	0.95	0.01	0.00	0.93	0.95	0.97	1001	5000
p[8]	0.98	0.01	0.00	0.96	0.98	0.99	1001	5000

Escarabajos

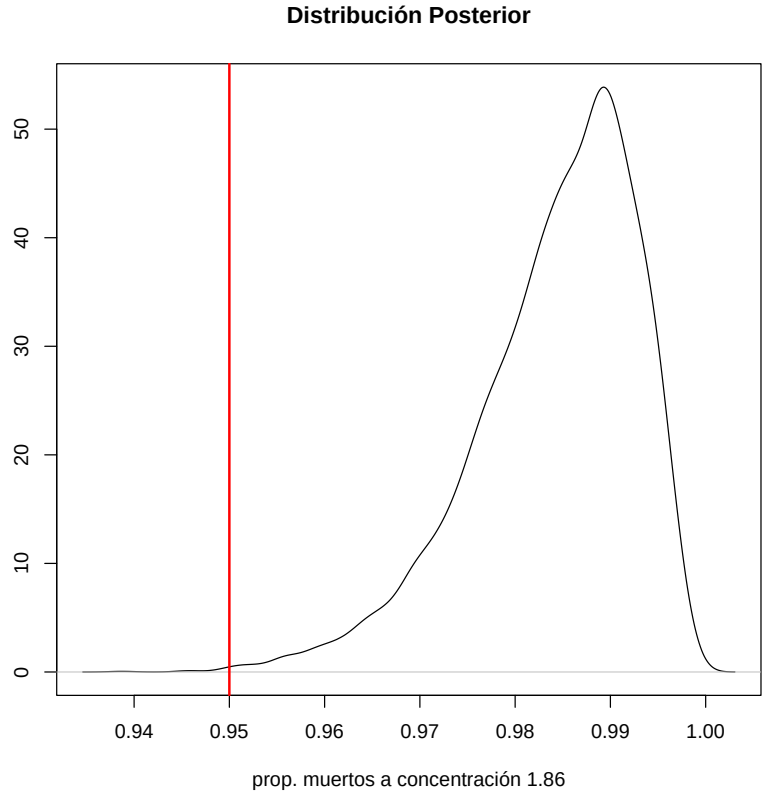
Apreciamos el efecto del aumento de la concentración de tóxico sobre la probabilidad de muerte, que crece con ella.



Podemos calcular otras probabilidades de interés:

- ¿Cuál es la probabilidad de que a concentración $1{,}86$, el porcentaje esperado de escarabajos muertos supere el 95 %?

$$Pr(p[7] \geq 0{,}95|datos) = 0{,}9988$$



- ¿Cuál es la dosis letal LD_p: dosis necesaria para tener un porcentaje de muertos de al menos $p100\,\%$?

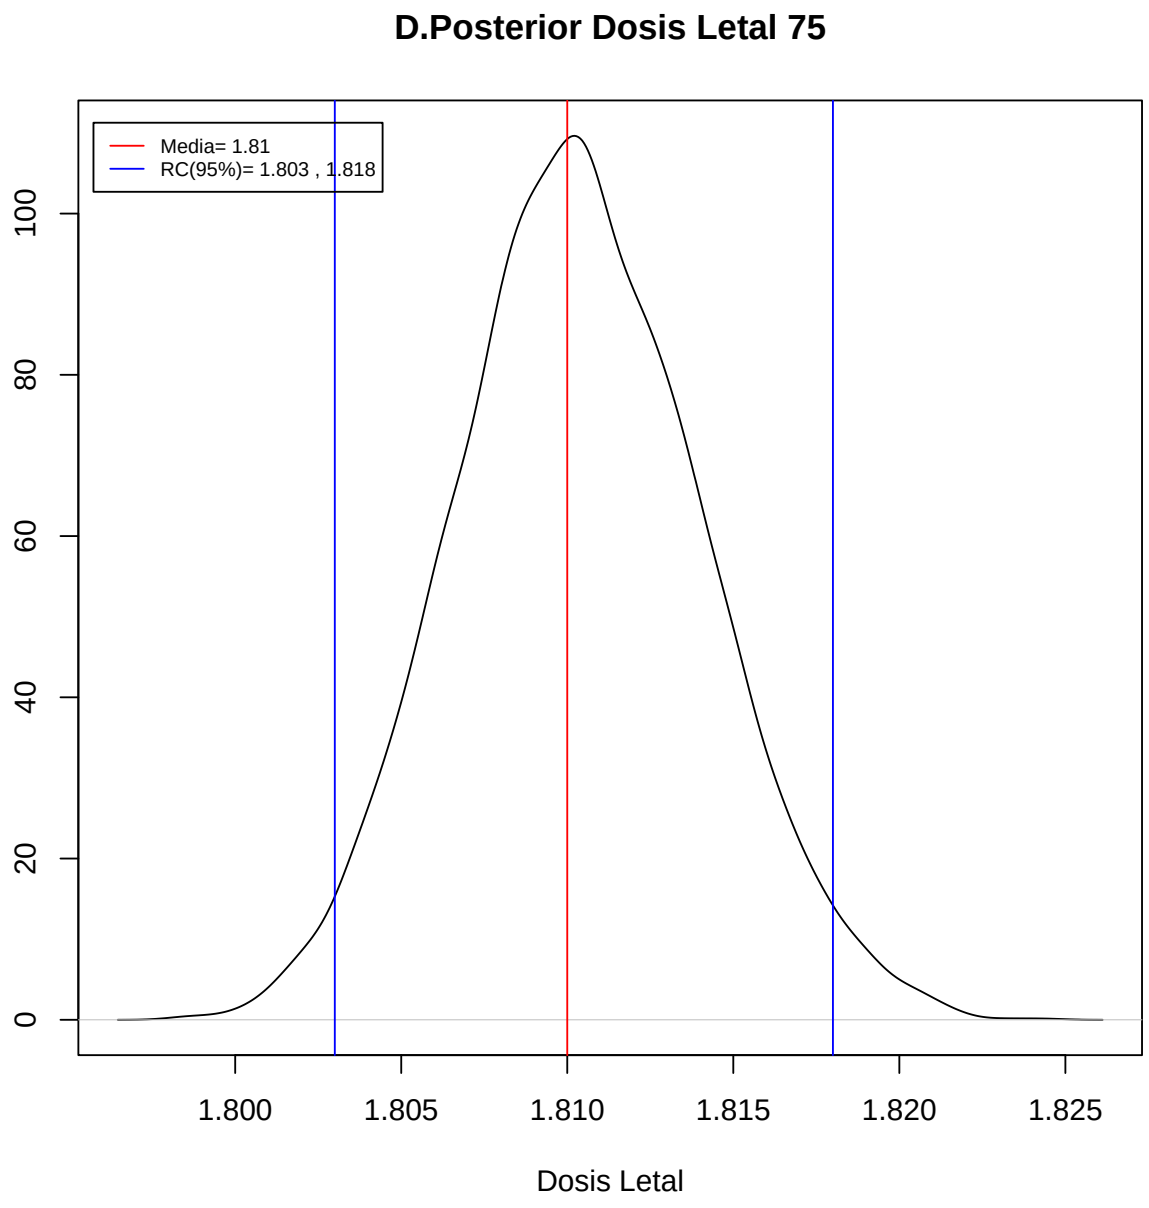
$$cloglog(p) = \alpha + \beta\, LD_p$$

De modo que LD_p es una cantidad desconocida sobre la que tenemos información actualizada con los datos:

$$LD_p = \frac{cloglog(p) - \alpha}{\beta}$$

y utilizando las simulaciones, obtenemos las correspondientes a su distribución posterior.

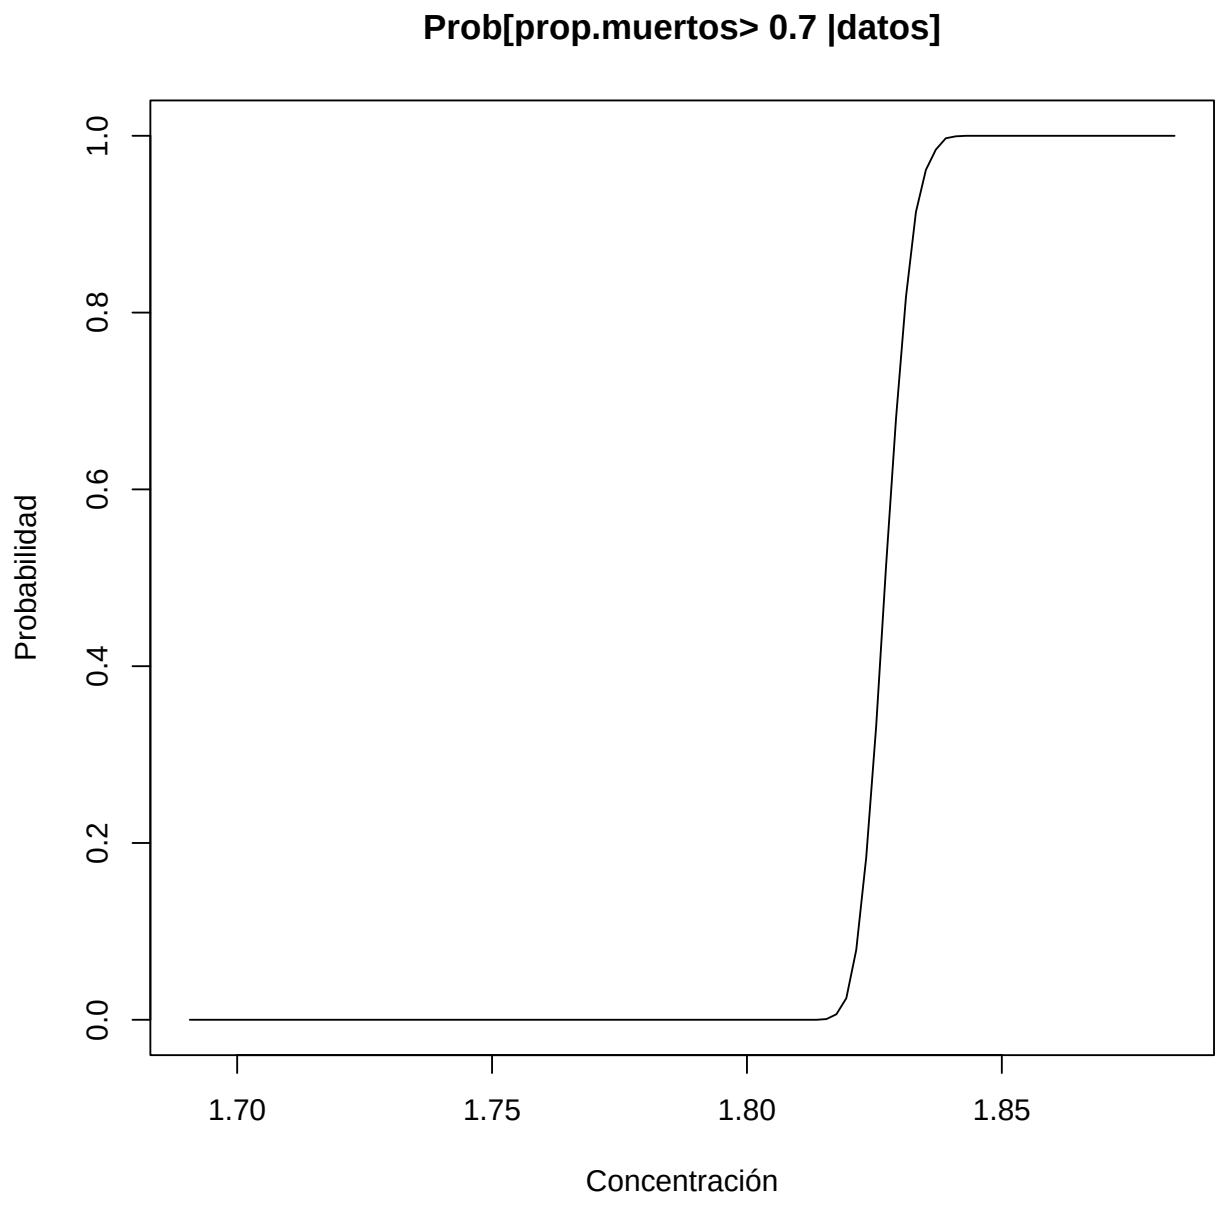
Escarabajos. Inferencia



Escarabajos. Inferencia

- ¿Cuál es la probabilidad que el porcentaje de muertos supere el 70 % en función de la concentración administrada?
  - Sabemos cómo predecir p la proporción de muertos en función de la concentración de tóxico $conc$.
  - Sabemos cómo calcular, para una concentración dada, $conc$, la probabilidad de que la proporción de muertos exceda un determinado valor (0.7).
  - Resolvemos esto para un grid de valores de la concentración en el rango observado.

Escarabajos. Inferencia



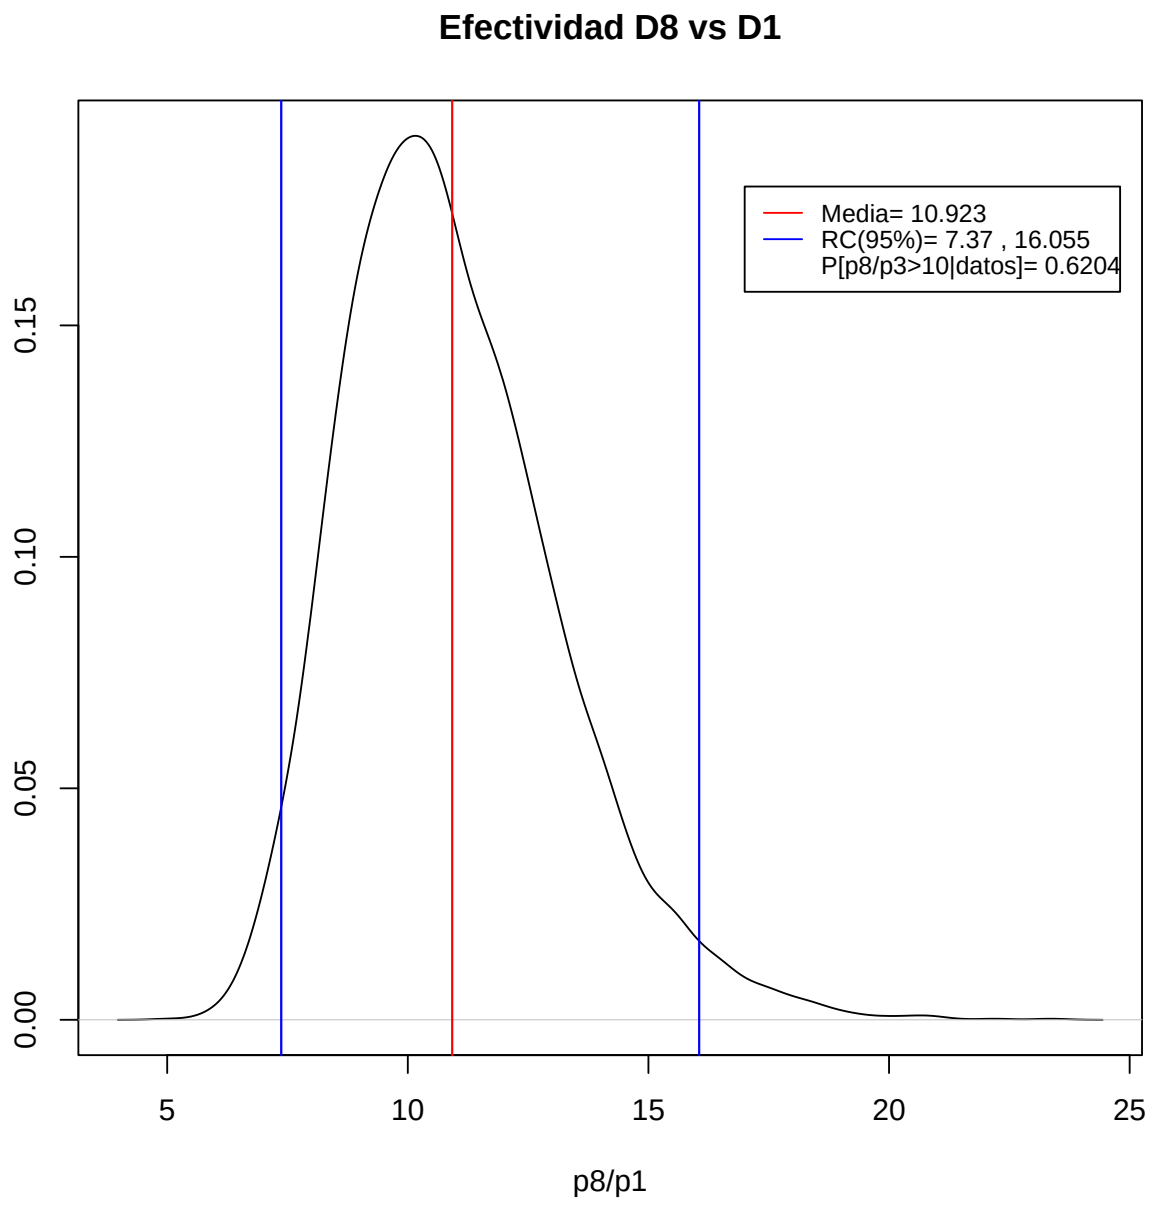
- ¿Qué conclusiones se extraen de la efectividad (medida en términos de proporción de escarabajos muertos) de la concentración más alta aplicada respecto de las más baja?
  Planteamos el cociente p_8/p_1 y utilizamos las simulaciones generadas para cada una de dichas proporciones a partir de la distribución posterior.
  La estimación y región creíble 0.95 resultan:

$$E(p_8/p_1|datos) = 10{,}923; \qquad RC(0{,}95) = (7{,}37; 16{,}06)$$

... y además podemos calcular cualquier probabilidad:

$$Pr[p_8 > 10p_1|datos] = 0{,}6204$$

Escarabajos. Inferencia

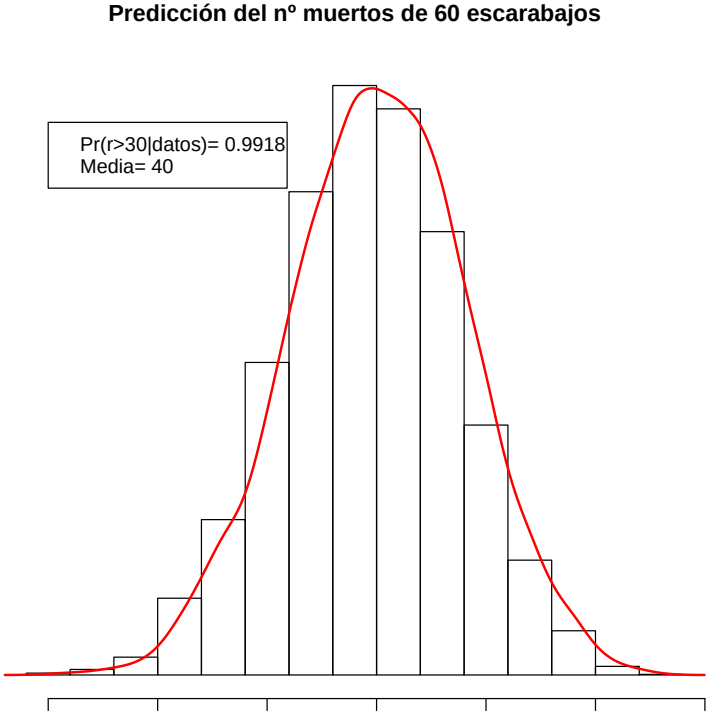


Escarabajos. Predicción

- ¿Cuántos escarabajos muertos podemos predecir a una concentración $conc_0 = 1{,}8$ de un total de $n = 60$?
  Es fácil predecir con simulación:

$$p_{conc_0} = 1 - exp(-exp(\alpha + \beta\ conc_0))$$

$$r_{conc_0} \sim Bin(n, p_{conc_0})$$



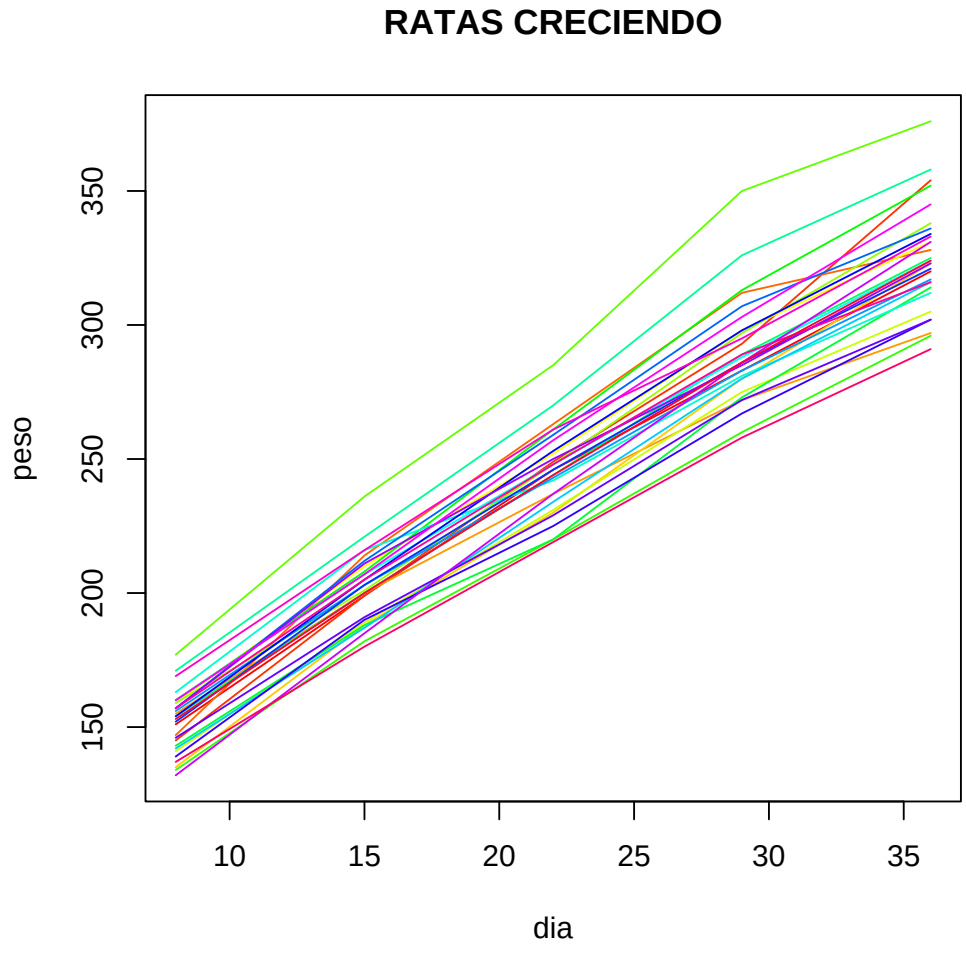
Ratas

En un experimento con ratas (Gelfand et al, 1990) se anotó su peso cada semana después de nacer, hasta que transcurrieron 36 días.

OBJETIVOS:

- Estudiar la evolución del peso de las ratas durante el primer mes de vida.
- Considerar las características intrínsecas y diferenciadoras de cada individuo en el análisis.
- Concluir en términos del prototipo en la población de ratas.

Ratas. Datos



Ratas. Modelización

- El objetivo es predecir el peso en función de la edad de los individuos, luego cabe plantear un modelo de regresión.
- Asumimos en principio, normalidad en los pesos.
- Podemos asumir independencia entre (los pesos de) las ratas del experimento.
- Existe relación entre todos los pesos observados sobre el mismo individuo.
- Queremos tener en cuenta la variabilidad entre individuos respecto a cómo se produce su crecimiento (pesos al nacer distintos y ritmos de crecimiento distintos).
- Todos los individuos del experimento proceden de la misma población: son ratas del mismo ’clan’.

Ratas. Modelización

Hablamos de un modelo de efectos aleatorios para predecir el peso, Y, en función de la edad del individuo, x:

$$Y_{ij} \sim N(\alpha_i + \beta_i(x_j - \bar{x}), \sigma_c^2) \tag{1}$$

y ligamos los individuos con

$$\alpha_i \sim N(\alpha_c, \sigma_\alpha^2)$$

$$\beta_i \sim N(\beta_c, \sigma_\beta^2)$$

De modo que el peso esperado para el 'prototipo' de la población se expresaría:

$$E(Y) = \alpha_c + \beta_c(x - \bar{x}),$$

donde $\bar{x}$ es la media de edades observadas, y la variabilidad entre los pesos de los individuos de la población la recoge el parámetro σ_c^2.

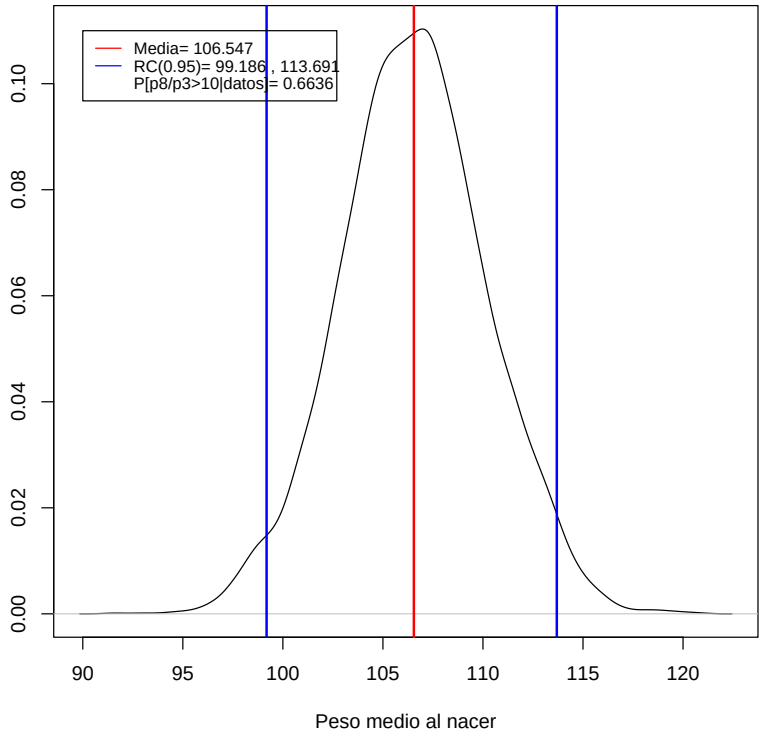
Ratas. Inferencia

Obtenemos una distribución posterior para cada uno de los parámetros del modelo, con las que podemos calcular estimaciones, errores e intervalos creíbles.

	mean	sd	MC error	val2.5pc	median	val97.5pc	start	sample
α_c	242.60	2.74	0.04	237.30	242.60	248.00	1001	5000
β_c	6.19	0.11	0.00	5.97	6.19	6.40	1001	5000
τ_α	0.0049	0.0013	0.00	0.0027	0.0048	0.0079	1001	5000
τ_β	4.09	1.55	0.04	1.98	3.82	7.73	1001	5000
τ_c	0.03	0.00	0.00	0.02	0.03	0.04	1001	5000

- ¿Cuál es el peso medio al nacer?

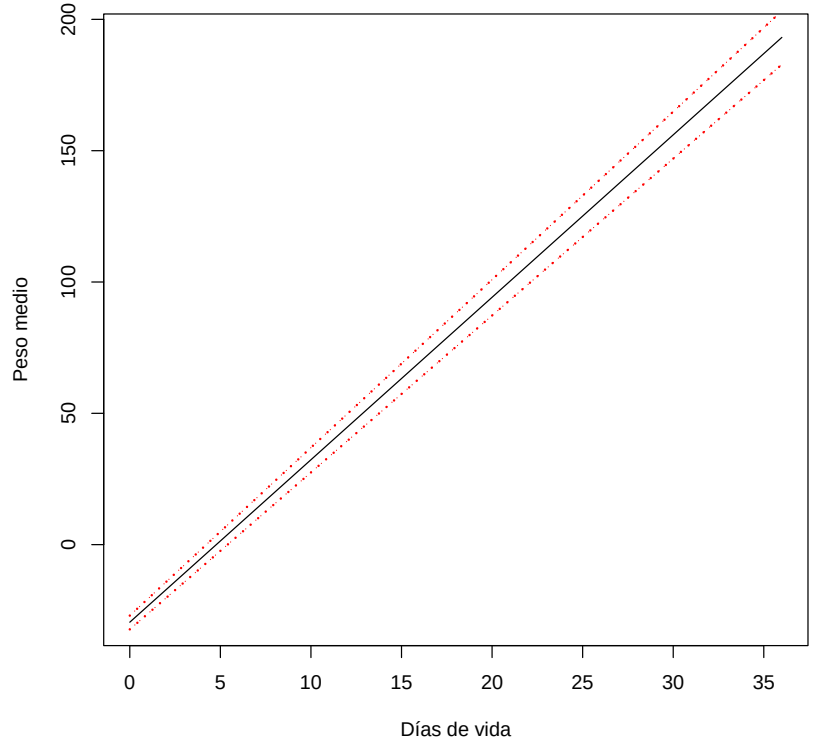
$$x = 0 \rightsquigarrow E(Y) = \alpha_c - \beta_c \, \bar{x}.$$



Ratas. Inferencia

- Estamos interesados en cómo crece un individuo medio (prototipo) de la población.

$$E(Y) = \alpha_c + \beta_c(x - \bar{x}),$$

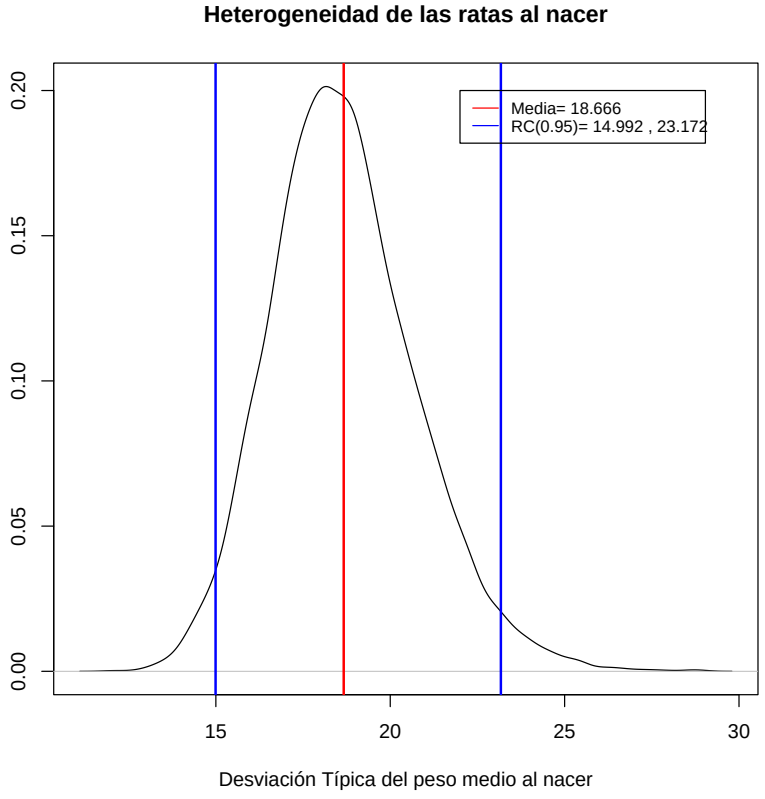


Ratas. Inferencia

- ¿Qué podemos decir sobre la heterogeneidad de las ratas al nacer?

$$Var(\alpha_i - \beta_i\ \bar{x}) = \sigma_\alpha^2 + \bar{x}^2\sigma_\beta^2.$$

Y cuando actualizamos información con los datos, obtenemos:



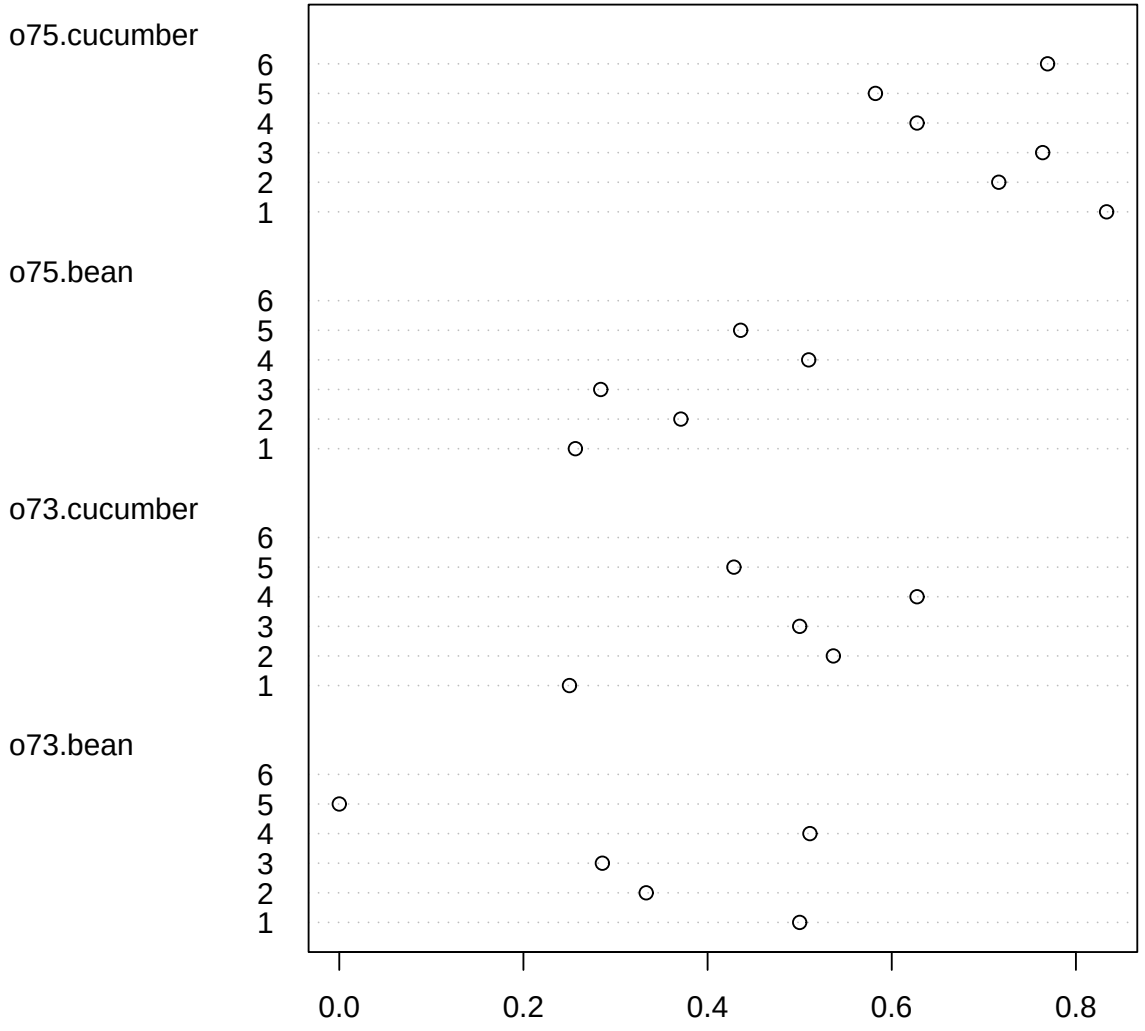
Semillas

Se hizo un experimento agronómico (Crowder, 1978) en el que se observó el número de semillas que germinaron en cada una de las 21 series consideradas, confeccionadas según un diseño factorial 2×2 por semilla (O.aegyptiaco 75 y O.aegyptiaco 73) y tipo de extracto de raíz (root extract): judía y pepino.

OBJETIVOS:

- Estudiar la evolución del peso de las ratas durante el primer mes de vida.
- Considerar las características intrínsecas y diferenciadoras de cada individuo en el análisis.
- Concluir en términos del prototipo en la población de ratas.

Semillas. Datos



Semillas. Modelización

Tenemos las siguientes consideraciones sobre los datos:

- Independencia entre los resultados observados en todas las series.
- Se espera un efecto común en la germinación según el tipo de semilla y extracto utilizados.
- Se reconoce variabilidad entre las series sometidas a un mismo tratamiento (semilla y extracto común): efectos aleatorios.
- La respuesta observada consiste en conteos sobre un total: respuesta binomial, con p la probabilidad de que la semilla germine.
- Es posible que el tipo de extracto no afecte de la misma forma a la germinación de las dos semillas consideradas: interacción semilla:extracto.

Semillas. Modelización

Planteamos un modelo de efectos aleatorios para predecir el número de semillas germinadas en cada serie, r de un total de n, en función del tipo de semilla y de extracto, aceptando diferencias entre las series. Creamos variables dummy para identificar los dos tipos de semillas, $x_1 = 1$ si OA73, y los dos tipos de extracto, $x_2 = 1$ si pepino. Así el modelo queda:

$$r_i \sim Bin(n_i, p_i) \tag{2}$$

$$logit(p_i) = \alpha_0 + \alpha_1 x_{1i} + \alpha_2 x_{2i} + \alpha_{12} x_{1i} x_{2i} + b_i$$

y los efectos aleatorios

$$b_i \sim N(0, \sigma_b^2)$$

De modo que la proporción esperada de germinación se determinaría en función del tipo de semilla x_1 y extracto x_2 utilizados con:

$$E(r) = \alpha_0 + \alpha_1 x_1 + \alpha_2 x_2 + \alpha_{12} x_1 x_2.$$

Obtenemos una distribución posterior para cada uno de los parámetros del modelo, con las que podemos calcular estimaciones, errores e intervalos creíbles.

	mean	sd	MC error	val2.5pc	median	val97.5pc	start	sample
α_0	-0.55	0.20	0.01	-0.94	-0.55	-0.16	1001	5000
α_1	0.08	0.32	0.01	-0.58	0.09	0.68	1001	5000
α_{12}	-0.82	0.44	0.01	-1.70	-0.81	0.01	1001	5000
α_2	1.36	0.28	0.01	0.81	1.35	1.94	1001	5000
σ_b^2	0.28	0.15	0.01	0.03	0.27	0.61	1001	5000

Semillas. Inferencia

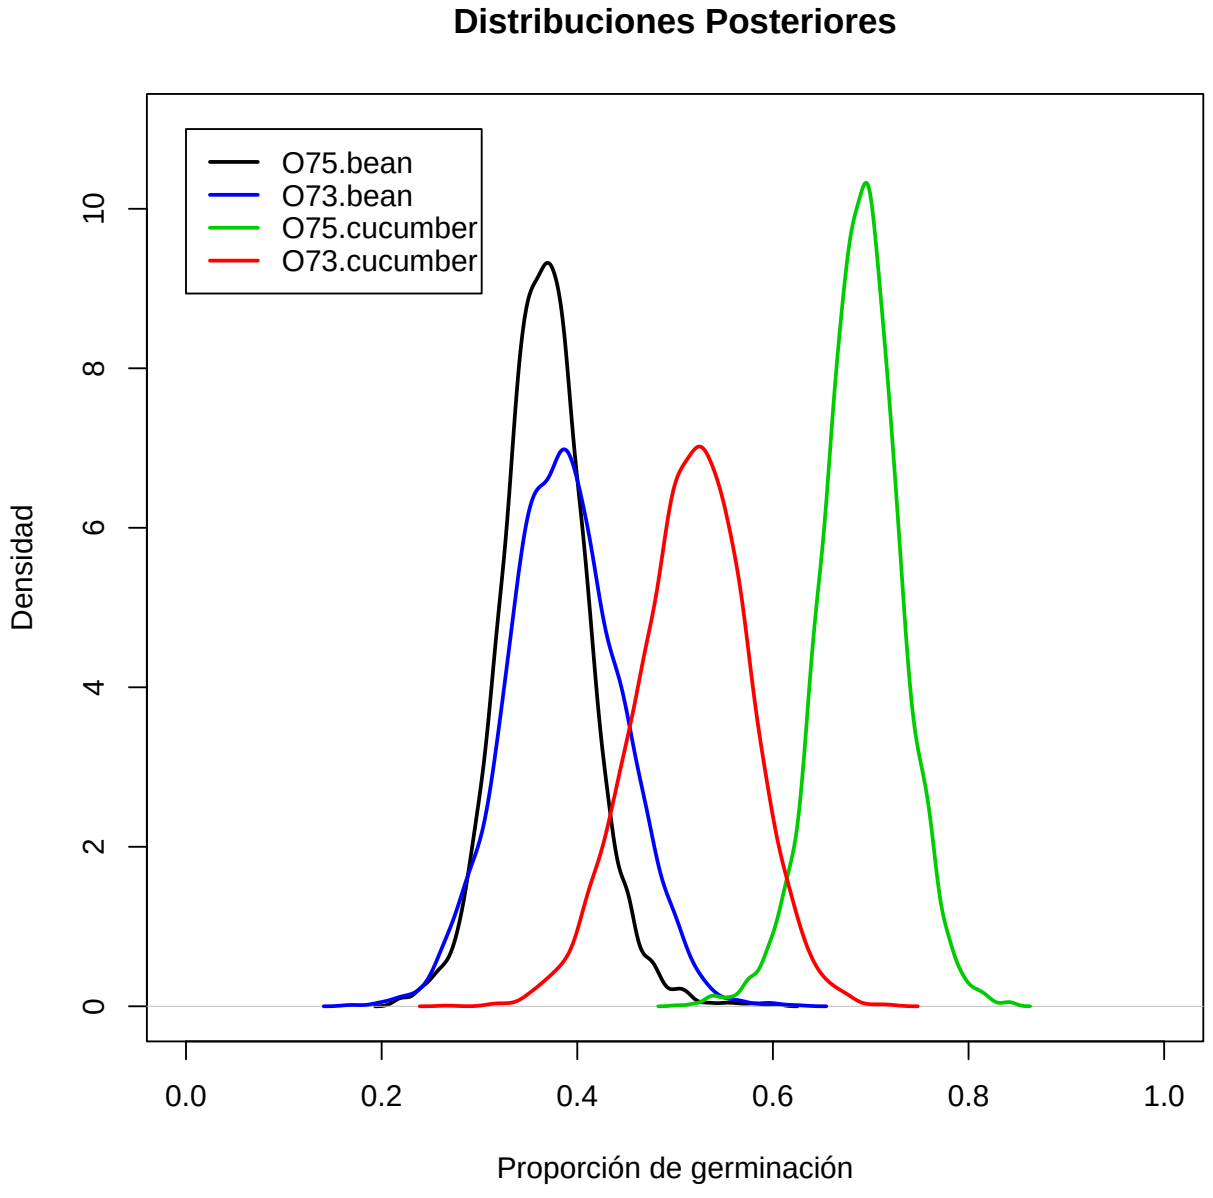
- Dado que el 0 está contenido en las regiones creíbles de α_1, α_2 y α_{12}, podemos concluir que efectivamente reconocemos que el tipo de semilla y el tipo de extracto afectan a la germinación. Además, para una misma semilla, el tipo de extracto utilizado hace variar la proporción de semillas germinadas.
- La variabilidad entre las series de semillas consideradas, σ_b^2, no es despreciable (0.28).

Semillas. Inferencia

- ¿Cuál es la proporción de semillas que se espera que germinen en cada tratamiento?

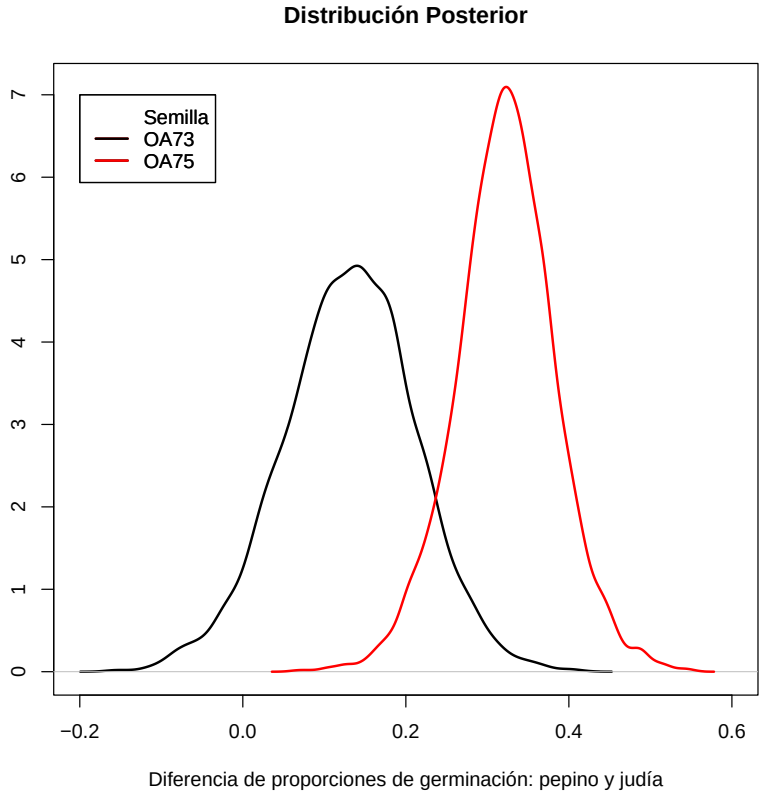
	O75.bean	O73.bean	O75.cucumber	O73.cucumber
media	0.37	0.39	0.69	0.52
RC(0.95)	(0.28,0.46)	(0.27,0.5)	(0.6,0.77)	(0.4,0.62)

Semillas. Inferencia



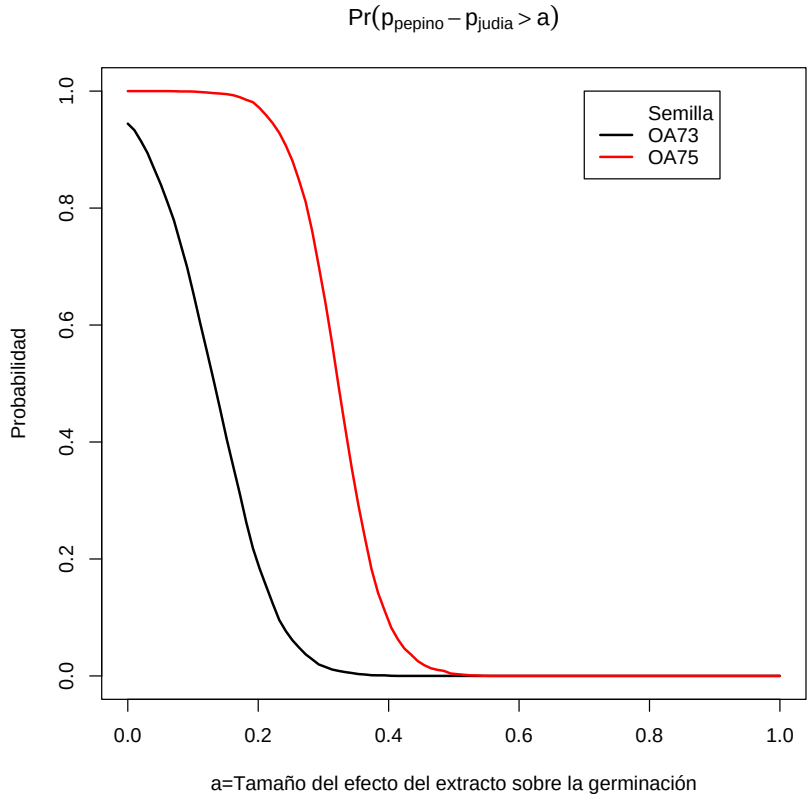
Semillas. Inferencia

- En términos de proporción de semillas que germinan, ¿cómo afecta el extracto a la germinación?
  Podemos concluir con $p_{\text{pepino}} - p_{\text{judía}}$ para cada uno de los tipos de semillas, OA73 y OA75.



Semillas. Inferencia

- Queremos calcular la probabilidad de que se aprecie un efecto más o menos grande del extracto sobre la germinación, para cada uno de los tipos de semillas.



Conclusiones

- Con los modelos jerárquicos Bayesianos podemos modelizar de un modo muy flexible, relaciones muy complejas o imposibles de acoplar en un modelo frecuentista.

Conclusiones

- Con los modelos jerárquicos Bayesianos podemos modelizar de un modo muy flexible, relaciones muy complejas o imposibles de acoplar en un modelo frecuentista.
- Podemos aprovechar toda la información relacional, además de la muestral, para obtener conclusiones más fiables.

Conclusiones

- Con los modelos jerárquicos Bayesianos podemos modelizar de un modo muy flexible, relaciones muy complejas o imposibles de acoplar en un modelo frecuentista.
- Podemos aprovechar toda la información relacional, además de la muestral, para obtener conclusiones más fiables.
- Tenemos herramientas computacionales para resolver los análisis, si bien no son triviales.

Conclusiones

- Con los modelos jerárquicos Bayesianos podemos modelizar de un modo muy flexible, relaciones muy complejas o imposibles de acoplar en un modelo frecuentista.
- Podemos aprovechar toda la información relacional, además de la muestral, para obtener conclusiones más fiables.
- Tenemos herramientas computacionales para resolver los análisis, si bien no son triviales.
- Las conclusiones son mucho más lógicas y naturales, y resuelven las dudas u objetivos comúnmente planteados en las investigaciones.

Conclusiones

- Con los modelos jerárquicos Bayesianos podemos modelizar de un modo muy flexible, relaciones muy complejas o imposibles de acoplar en un modelo frecuentista.
- Podemos aprovechar toda la información relacional, además de la muestral, para obtener conclusiones más fiables.
- Tenemos herramientas computacionales para resolver los análisis, si bien no son triviales.
- Las conclusiones son mucho más lógicas y naturales, y resuelven las dudas u objetivos comúnmente planteados en las investigaciones.
- ¿Qué os vamos a decir....? ¡¡¡Es que trabajamos en esto!!!