Análisis Estadísticos con R

Mª Asunción Martinez Mayoral
Javier Morales Socuéllamos

Análisis Estadísticos con R

Mª Asunción Martinez Mayoral
Javier Morales Socuéllamos

Índice general

Tema 1. El proyecto R **1**

1.1. ¿Qué es R? 1

1.1.1. Motivos para usar R 1

1.1.2. Cómo descargarnos R desde internet 2

1.2. Principios Básicos de Uso 3

1.3. Creación y manipulación de objetos 4

1.3.1. Clases de objetos 4

1.3.2. Operadores Lógicos 4

1.3.3. Vectores, Secuencias y Factores 5

1.3.4. Matrices y Arrays 7

1.3.5. Listas 7

1.3.6. Operaciones con vectores, matrices y listas 8

1.3.7. Data Frames 8

1.4. Ejercicios 10

Tema 2. Descripción numérica y gráfica de datos **11**

2.1. Generación de variables aleatorias 11

2.1.1. Distribuciones de Probabilidad 11

2.2. Medidas de localización y dispersión 12
2.2.1. Datos individualizados 13
2.2.2. Datos agrupados 14
2.2.3. Varias medidas de dispersión y forma 15
2.3. Descripción gráfica de datos 17
2.3.1. Gráficos para Datos Discretos 17
2.3.2. Gráficos para Datos continuos 17
2.3.3. Gráficos multidimensionales 18
2.4. Gráficos para estudiar la distribución de los datos 19
2.5. Ejercicios 22

Tema 3. Estimación y Contraste de Hipótesis Univariantes 31

3.1. Estimación puntual 31
3.1.1. Estimación máximo verosímil 31
3.2. Intervalos de confianza 33
3.2.1. Media y varianza de una población normal 33
3.2.2. Medias y varianzas en dos poblaciones normales 36
3.2.3. IC sobre proporciones 41
3.2.4. IC de la media de una Poisson 42
3.3. Contraste de hipótesis paramétricos 42
3.3.1. Contrastes de la media y varianza de una población 45
3.3.2. Diferencia de medias y comparación de varianzas 48
3.3.3. Comparación de K medias y varianzas 51
3.3.4. Comparación de proporciones 54
3.3.5. Cálculo del tamaño muestral para resolver un contraste . . 56
3.4. Contraste de hipótesis no paramétricos 60

3.4.1. Contrastes sobre medias y varianzas 60
3.5. Contrastes de bondad de ajuste 65
3.6. Ejercicios Tema 3 67

Tema 4. Asociación entre variables **75**

4.1. Asociación entre variables categóricas 75
4.1.1. Tablas de contingencia 75
4.1.2. Contraste de asociación/independencia 76
4.2. Asociación entre variables continuas 77
4.2.1. Correlación lineal 77
Contraste de Hipótesis 78
4.3. Ejercicios Tema 4 79

Índice de cuadros

2.1. Distribuciones de probabilidad en la librería BASE. 12

Índice de figuras

4.1. Correlación lineal. 80
4.2. Relaciones linealizables. 81
4.3. Transformaciones para conseguir linealidad. 82

TEMA 1

El proyecto R

1.1. ¿Qué es R?

Los ejemplos numéricos que aparecen en el libro han sido desarrollados enteramente con R. R es un proyecto GNU (software libre) que posee implementadas una gran variedad de librerías, entre las que destacan las de gráficas y técnicas estadísticas. Entre ellas se encuentran: el modelo de regresión lineal y no lineal, pruebas estadísticas de todo tipo, análisis de series temporales, análisis multivariante, etc.

Para acceder a este software debemos conectarnos a CRAN. CRAN es una red ftp de servidores de internet alrededor del mundo que almacenan versiones del código y documentación de R idénticas y actualizadas. En las siguientes secciones veremos cómo podemos descargarnos dicho programa desde la red CRAN a través de dos vías distintas.

1.1.1. Motivos para usar R

R es un paquete estadístico tan potente o más que otros actualmente de moda en el panorama mundial dentro del contexto del uso de la Estadística. La ventaja fundamental que presenta frente a otros, y que lo hace del todo atractivo, es su gratuidad total de uso. Esto implica que desde un punto de vista empresarial de minimización de costes resulte más adecuada su adquisición que otro tipo de software existente en el mercado actual. Al mismo tiempo cabe destacar la continua actualización y mejora que se viene produciendo de R, y de las cuales, nos podemos beneficiar descargando las actualizaciones de manera sencilla a través de internet. Sin embargo, el interface de R difiere del típico usado en otras muchas aplicaciones para Windows (como con el SPSS, por ejemplo). En concreto, para comunicarnos con R lo tendremos que hacer a través de la utilización de una línea de comandos.

1.1.2. Cómo descargarnos R desde internet

Aunque las formas de descargarse R y sus múltiples librerías son variadas, hemos optado por mostrar dos de ellas. Mediante la primera haremos uso de la web oficial del proyecto R: www.r-project.org. La segunda opción necesita la conexión a la redIRIS (Interconexión de los Recursos InformáticoS) patrocinada por el Plan Nacional de I+D. Evidentemente, en ambos casos necesitamos estar conectados a internet.

1. **Con el navegador de internet**. La dirección URL a la que debemos dirigirnos es http://www.r-project.org. En el menú de la izquierda seleccionamos *Download CRAN*. Elegimos como servidor el español (Spain). Para descargarnos R, pinchamos sobre *Windows (95 and later)* → *Base* → *fichero.exe*. Donde *fichero.exe* denota al programa ejecutable que contiene la última versión de R. Éste es el archivo que debéis descargaros a vuestro disco duro. Una vez completado el proceso de descarga, bastará con pinchar dos veces sobre el archivo y aceptar todas las opciones por defecto. Se instalará el programa y aparecerá un icono de acceso en el escritorio de vuestro ordenador. Asimismo, las librerías son accesibles desde este mismo entorno en *Windows (95 and later)/Contributed extension packages*.

2. **Vía ftp**. Haremos uso de cualquier cliente ftp (CuteFTP, WSFTP,...). El nombre del servidor ftp es: *ftp.rediris.es*. En usuario y contraseña debemos introducir, en ambos casos, *anonymous*. Dentro de la carpeta *mirror* buscaremos *CRAN*. Una vez hayamos entrado en *CRAN* pincharemos dos veces sobre la carpeta denominada *bin*. Dentro de bin seleccionamos *windows*. Y dentro de la subcarpeta *base* encontraremos el fichero ejecutable .exe conteniendo la última versión de R. Como con el método anterior, una vez completado el proceso de descarga, bastará con pinchar dos veces sobre el archivo y aceptar todas las opciones por defecto. Indicar que se os instalará en el sistema la versión correspondiente, apareciendo un icono identificativo en el escritorio de vuestro ordenador.

   Las librerías de R se encuentran en *bin*, dentro de la versión correspondiente en la carpeta *contrib*.

Existe la posibilidad de actualizar todas las librerías de R automáticamente por Internet. Para ello bastará con ejecutar el icono de R de vuestro escritorio y, posteriormente, ir al menú *Packages*. Bajo este menú se encuentra la opción *Update packages from CRAN*. Al seleccionar ésta, comenzará la descarga de librerías. En la siguiente Sección se cuenta cómo cargar una librería en concreto para poder ser utilizada por R.

Ha llegado el momento de comenzar a dar nuestros primeros pasos con R.

1.2. Principios Básicos de Uso

En esta sección mostraremos los comandos básicos de uso de R que aparecen en los menús del programa, así como diversas funciones de interés para el desarrollo de los ejemplos y ejercicios del libro. No obstante, nos gustaría señalar que para obtener información más pormenorizada sobre las funciones implementadas en R, deberá acudirse a la ayuda que el propio programa contiene.

Operación	**Menú**
Consulta de ayuda sobre una función concreta	?funcion help("funcion") Help/R functions (text)
Consulta de ayuda sobre funciones que contienen una "cadena" de caracteres	apropos("cadena") Help/Apropos
Consulta de ayuda sobre funciones relacionadas con una "cadena" de caracteres	help.search("cadena") Help/Search help
Consulta de ayuda html	Help/Html help/Search Engine...
Especificar directorio de trabajo	File/Change dir
Ejecutar fichero de código .r Abrir Editor y crear fichero ASCII (p.e.sintaxis) Abrir Editor y fichero ASCII (p.e.sintaxis) Ejecutar sintaxis Guardar fichero ASCII de edición Visualizar fichero ASCII (p.e.datos)	File/Source R Code File/New Script File/Open Script Pulsar botón derecho ratón Run Line or selection (Ctrl+R) Cursor en editor File/Save File/Display File(s)
Inspección de objetos creados Salvar objetos creados en un fichero.RData Cargar objetos guardados en un fichero.RData	objects(), ls() File/Save Workspace File/Load Workspace
Guardar historia de comandos a file.RHistory Cargar objeto .RData	File/Save History File/Load Workspace source("fichero.R")
Volcado de resultados a un fichero	sink("fichero.out") ... sink() cat(...,file="fichero")
Guardar gráfico	Cursor sobre gráfico File/Save as/
Inspección bases de datos disponibles Cargar base de datos disponible	data() data(nombre base de datos)
Inspección de librerías cargadas Instalar librerías Cargar librerías instaladas Consulta de ayuda sobre librerías	search() Packages/Install package(s) ... Packages/Load package library(librería) Help/Html help/Packages

1.3. Creación y manipulación de objetos

Para crear un objeto es preciso utilizar el operador de asignación `<-`, subrayado, o directamente el comando *assign()*. En las últimas versiones de R también funciona "=", pero conviene usarlo con cautela, pues no siempre funciona.

```
x<-5
x=5
assign("x",5)
```

1.3.1. Clases de objetos

Los tipos de objetos en R son:

Vectores	vector()
Factores (*cualitativos*)	factor(),gl()
Listas	list()
(admite elementos de distinto tipo)	
Matrices	matrix(ncol,nrow), array(dim)
Bases de datos	data.frame()
(matriz con columnas de distinto tipo)	

En general, salvo los factores, todos los objetos admiten elementos de tipo numérico, carácter, complejo o lógico. Los factores sólo aceptan elementos numéricos o caracteres.

Para inspeccionar y/o modificar los atributos de un objeto se utiliza el comando `attribute`. Todo objeto tiene dos atributos intrínsecos: tipo y longitud. Los tipos básicos de los objetos son: "logical", "integer", "numeric", "complex", "character" y "list". Para inspeccionar el tipo de un objeto se utilizan los comandos `typeof` y `mode`.

```
attributes(objeto)

typeof(objeto)
mode(objeto)
```

1.3.2. Operadores Lógicos

El símbolo # identifica como comentario todo lo que sigue en la misma línea.

>	mayor que	<	menor que
>=	mayor o igual que	<=	menor o igual que
==	igual que	! =	distinto de
|	uno u otro	&	uno y otro

1.3.3. Vectores, Secuencias y Factores

Un vector es una colección ordenada de números, símbolos lógicos, caracteres o complejos.

```
x <-1:30
c(1, 1.5, 2, 2.5, 3, 3.5, 4, 4.5, 5)
seq(1, 5, by=0.5)
seq(1, 5, length=20)
seq(length=9, from=1, to=5)
z <- scan() # e introducimos los números que queremos
# pulsando al final dos veces la tecla Intro
rep(1, 30)
sequence(c(10,5))
```

Es posible leer datos sin formato de ficheros externos con el comando `scan( file, what, sep, skip, nlines, flush)`. Donde *file* es el nombre del archivo externo, *what* identifica al tipo de dato que va a ser leído, *sep* identifica al separador de los datos, *skip* es el número de líneas del fichero de entrada que debe saltar R antes de empezar a leer los datos, *nlines* es el número máximo de líneas que deben ser leídas y, por último, *flush* es un valor lógico indicando si aparecen en el fichero comentarios al final de cada línea.

```
cat("Probamos a leer cosas","2 3 5 7", "11 13 17",
file="prueba.data", sep="\n")
pp <- scan("prueba.data")
scan("prueba.data", skip = 1)
scan("prueba.data", skip = 1, nlines=1)
str(scan("prueba.data", what = list("","","")))
str(scan("prueba.data", what = list("","",""), flush = TRUE))
unlink("prueba.data") # Borra el fichero.
```

Las funciones `gl()` y `factor()` generan factores, esto es, vectores cuyos elementos son de tipo cualitativo y que sirven para identificar grupos o categorías de clasificación. Es posible identificar los niveles y asignarles etiquetas.

```
# Un factor con 3 niveles, cada uno repetido 5 veces
gl(3, 5)
# un factor con 3 niveles, que salta al nivel siguiente
# cada 5 observaciones y tiene una longitud total de 30
gl(3, 5, length=30)
gl(2, 6, labels=c("Macho", "Hembra"))

factor(rep(1:2,5),levels=c(1,2),labels=c("Blanco","Negro"))
```

Podemos categorizar variables de tipo numérico con el comando `cut()`, y particionar los elementos de un vector en función de los niveles de un factor con `split()`:

```
edad<- c(7,15,84,45,21,11,35,57,71,55,62,12,35,36,25,44,45,80,18)
edad.f <- cut(edad,breaks=c(0,15,30,50,75,100))

x<-seq(1,5,length=6)
grupos<-gl(2,3)
split(x,grupos)
```

Selección de elementos de un vector/factor, con corchetes:

```
x[2]
x[(1:15)*2]
x[x>10]
x[x<3 | x>27]
x[x<20 & x>15]

# Prescindir del primer elemento de x
x[-1]

# Selección a través de un objeto de dimensiones similares:
color <- gl(2,15,30,labels=c("Blanco","Rojo"))
x[color=="Rojo"]
```

Los datos faltantes se identifican con `NA`:

```
x  <-  c(1,5,6,2,NA)
is.na(x)
y <- x[!is.na(x)]
x[is.na(x)] <- 999
```

1.3.4. Matrices y Arrays

Un array es una colección de entradas de datos del mismo tipo, ya sea numérico, categórico o lógico.

Las matrices son un caso particular de arrays. Los arrays son matrices multidimensionales. La selección de elementos se hace con corchetes.

```
matrix(1:8,ncol=4)
matrix(ncol=2,nrow=2)
mat<-matrix(1:8,ncol=2,byrow=T)
dimnames(mat)<-list(c("F1","F2","F3","F4"),c("Q1","Q2")); mat

# Se pueden crear pegando vectores y matrices, por filas o columnas
cbind(1:6,7:8)
rbind(1:6,7:9)

# Un array tridimensional
a<-array(c(1:8,11:18,111:118),dim= c(2,4,3)
# una matriz con 2 filas y 3 columnas
b<-array(dim=c(2,3))

# Selección de elementos
a[1,1,2]
a[,,2]
```

1.3.5. Listas

En una lista podemos mezclar elementos de diferentes tipos. La selección de elementos se hace con doble corchete o con el nombre del elemento precedido de $:

```
lista  <- list(array=a,matriz=mat,vector=x)

lista[[1]]
names(lista)
lista$array}

# Concatenar varias listas en una sola:
lista.A <- list(xA=1:5,yA=c("rubio","moreno"))
lista.B<- list(xB=85,yB=gl(2,1,10,labels=c("ojo","oreja")))
lista.AB <-  c(lista.A,lista.B)
```

1.3.6. Operaciones con vectores, matrices y listas

Las operaciones habituales (suma, resta, multiplicación, división) se denotan con sus respectivos símbolos (+,-,*,/).

Otras operaciones de interés son:

v*z	producto interno de los vectores v y z
A+B	suma las matrices A y B
A-B	resta las matrices A y B
A*B	multiplica las matrices, elemento a elemento
A %B	divide las matrices, elemento a elemento
A %* %B	producto matricial
t(A)	matriz transpuesta de A
solve(A)	matriz inversa de A
solve(A,b)	resuelve la ecuación Ax=b
svd()	proporciona la descomposición en valores singulares
qr()	obtiene la descomposición QR
eigen()	calcula valores y vectores propios
sort(v)	ordena el vector v
diag(v)	proporciona una matriz diagonal el vector v
diag(A)	extrae un vector con los elementos de la diagonal de la matriz A
tapply(v,factor,función)	aplica la *función* sobre los valores del vector *v* clasificado en las categorías del *factor*
sapply(split(v,factor),fun))	tiene el mismo efecto que la anterior tapply
lapply(lista,fun)	calcula la función fun en cada uno de los elementos de una lista
apply(A,index,fun)	aplica la función fun sobre cada una de las filas (index=1) o columnas (index=2) de la matriz A

1.3.7. Data Frames

Una hoja de datos es una lista que pertenece a la clase data.frame. Están caracterizadas por lo siguiente:

- las componentes han de ser vectores, factores, matrices numéricas, listas u otras hojas de datos.
- Las matrices, listas y hojas de datos contribuyen a la nueva hoja de datos con tantas variables como columnas, elementos o variables posean, respectivamente.
- Los vectores numéricos y los factores se incluyen sin modificar; los vectores no numéricos se fuerzan a factores cuyos niveles son los únicos valores que aparecen en el vector.

- Los vectores que constituyen la hoja de datos deben tener todos la misma longitud, y las matrices el mismo número de filas.

Las hojas de datos pueden tratarse generalmente como matrices cuyas columnas pueden tener diferentes modos y atributos. Pueden imprimirse en forma matricial y se pueden extraer sus filas o columnas según la indexación de matrices.

```
clima.cont <- c("no","no","si")
ciudades <-  c("Sevilla","Alicante","Albacete")
temp.max <-  c(41,35,39)
ciudad.datos <- data.frame(ciudades,clima.cont,temp.max)
```

Es posible cargar datos disponibles en R como hojas de datos (data.frame). Una vez cargadas, podemos trabajar con sus variables directamente, utilizando el comando `attach(dataframe)`. Para olvidar estas variables, basta utilizar `detach(dataframe)`.

```
data(infert)
infert$education
attach(infert)
education
detach(infert)
```

Podemos leer datos con formato de base de datos con el comando `read.table(file, header)`, donde *file* es el nombre del fichero y *header* es un valor lógico indicando si el fichero contiene el nombre de las variables en la primera línea.

```
df <-  data.frame(pelo=c("rubio","moreno"),talla=c(1.69,1.85),
CI=c(140,110))
sink(file="prob")
df
sink()
read.table("prob",header=T)
unlink("prob")
```

1.4. Ejercicios

Inicialmente especifica el directorio de trabajo en que quieres trabajar.

1. Crear un vector de datos (var X) en el que los 10 primeros datos identifiquen a un tipo de individuos (A), los 4 siguientes a otro (B) y los restantes a un tercero (C).

2. Sean los datos:

```
ctl <-  c(4.17,5.58,5.18,6.11,4.50,4.61,5.17,4.53,5.33,5.14)
trt <-  c(4.81,4.17,4.41,3.59,5.87,3.83,6.03,4.89,4.32,4.69)
```

   que identifican las mediciones correspondientes a individuos de dos grupos: control (ctl) y tratamiento (trt). Crear un vector con todos los datos y un factor que identifique individuos de uno y otro grupo.

3. Transforma en data.frame los datos de los Ejercicios 1 y 2. Direcciónalo a un fichero externo y comprueba cómo quedó (sin salir de R).

4. Construye una matriz A cuya diagonal esté constituida por la secuencia de enteros del 1 al 6. Construye otra matriz B de idéntico tamaño en la que la primera fila sean todo 1, la segunda todo 2, y así hasta la última, con todos los elementos igual a 6. Construye un vector b de dimensión 6 con la diagonal de la matriz B. Realiza las siguientes operaciones:

   a) b'(A+B)

   b) b'(AB)

   c) $A^{-1}B$

   d) Resuelve (A+B)x=b

   e) A los elementos iguales a cero en la matriz A asígnales un valor muestreado al azar de entre los números del 0 al 9. (Nota: utiliza el comando *sample()*).

   f) Selecciona la segunda fila de B, llámala b2 y calcula b'b2 y b2'A.

5. Guarda la sintaxis y los objetos generados en la sesión. Sal de R y vuelve a acceder a R cargando todo lo que ejecutaste anteriormente. Comprueba que todo funciona.

TEMA 2

Descripción numérica y gráfica de datos

2.1. Generación de variables aleatorias

2.1.1. Distribuciones de Probabilidad

R dispone las distribuciones de probabilidad más comunes ya implementadas en la librería BASE. En otras librerías disponemos de otras tantas. Para cada una de ellas (distrib), disponemos de 4 versiones:

generador de números aleatorios	rdistrib
función densidad/probabilidad	ddistrib
función distribución	pdistrib
función inversa distribución (cuantiles)	qdistrib

La Tabla 2.1 muestra las distribuciones de probabilidad disponibles en la librería BASE.

```
# Dividimos la ventana gráfica en 2 filas y 1 columna
op<-par(mfrow=c(2,1))
# Simulamos y representamos 500 datos normales y 500 datos Cauchy:
x.norm <- rnorm(500)
hist(x.norm,freq=F,main="Distribución Normal",col=c("blue1","blue4"),
xlim=c(-40,40))
x.cauch<-rcauchy(500)
hist(x.cauch,200,freq=F,main="Distribución Cauchy",col=rainbow(5),
xlim=c(-40,40))
par(op) # Recuperamos la configuración gráfica inicial
```

Distribución	función R
Normal	rnorm(n, mean=0, sd=1)
exponencial	rexp(n, rate=1)
gamma	rgamma(n, shape, scale=1)
Poisson	rpois(n, lambda)
Weibull	rweibull(n, shape, scale=1)
Cauchy	rcauchy(n, location=0, scale=1)
beta	rbeta(n, shape1, shape2)
'Student' (t)	rt(n, df)
Fisher–Snedecor (F)	rf(n, df1, df2)
Pearson χ^2	rchisq(n, df)
binomial	rbinom(n, size, prob)
geométrica	rgeom(n, prob)
hypergeométrica	rhyper(nn, m, n, k)
logística	rlogis(n, location=0, scale=1)
lognormal	rlnorm(n, meanlog=0, sdlog=1)
binomial negativa	rnbinom(n, size, prob)
uniforme	runif(n, min=0, max=1)
Estadístico de Wilcoxon's	rwilcox(nn, m, n), rsignrank(nn, n)

Cuadro 2.1: Distribuciones de probabilidad en la librería BASE.

2.2. Medidas de localización y dispersión

La **variable aleatoria empírica** $\hat{X}_n$ es una variable aleatoria que tiene a $F_n(x)$ como su función de distribución y que está basada meramente en los datos observados, sin ninguna presunción paramétrica. Una primera inspección de los datos consiste en describirlos a través de su distribución empírica y sus características. de localización y dispersión.

En función de cómo nos vengan dados los datos, los descriptores empíricos se calcularán de una u otra forma. Partimos de dos situaciones básicas:

1. disponemos de una muestra de valores individualizados $x_1, \ldots, x_n$

2. sólo nos proporcionan el resumen de una muestra agrupada por intervalos, esto es, intervalos (c_{j-1}, c_j), con $j = 1, \ldots, r$, y el número de observaciones n_j contenidas en cada intervalo, con $n = \sum_{j=1}^{r} n_j$.

2.2.1. Datos individualizados

Momento no centrado: El estimador empírico del momento no centrado de orden k, $E(X^k)$, es:

$$\hat{\mu}'_k = \frac{1}{n}\sum_{j=1}^{n} x_j^k. \tag{2.1}$$

Momento centrado . El estimador empírico del momento centrado de orden k, $E[(X - E(X))^k]$, es:

$$\hat{\mu}_k = \frac{1}{n}\sum_{j=1}^{n}(x_j - \bar{x})^k, \tag{2.2}$$

con $\bar{x}$ la media muestral de los datos, $\bar{x} = \hat{\mu}'_1$.

Mediana . Es el valor que ocupa la posición $(n+1)/2$ en la muestra ordenada.

Percentiles . El percentil p100 de una distribución $F(x)$ es cualquier número π_p tal que

$$F(\pi_{p-}) \leq p \leq F(\pi_p),$$

con $F(\pi_{p-}) = lim_{h\downarrow 0} F(\pi_p - h)$

En datos individualizados, supongamos la muestra ordenada $x_{(1)}, \ldots, x_{(n)}$, para la que disponemos de las probabilidades acumuladas $F_n(x_{(i)})$, $i = 1, \ldots, n$. En función de dichas probabilidades podemos determinar entre qué valores $x_{(g)}$ y $x_{(g+1)}$ está el percentil π_p en cuestión. En concreto, calculamos:

$$\begin{aligned} g &= \lfloor 1 + (n-1)p \rfloor \\ h &= 1 + (n-1)p - g \\ \hat{\pi}_p &= (1-h)x_{(g)} + h x_{(g+1)}, \end{aligned} \tag{2.3}$$

con la consideración $x_{(n)} = x_{(n+1)}$ y $\lfloor .. \rfloor$ denotando la parte entera por defecto.

```
x <- rgamma(50,1,3)
summary(x)
mean(x);median(x)
quantile(x);quantile(x,c(0.35,0.9))
sd(x);var(x);range(x)
min(x);which.min(x); x[which.min(x)]
pmin(x[1:5],x[5:10])
```

```
max(x);which.max(x); x[which.max(x)]
pmax(x[4:8],x[2:6])

library(e1071)
moment(x,2,center=F) # momento no centrado de orden 2
```

2.2.2. Datos agrupados

Siendo $n = \sum_{j=1}^{r} n_j$, calculamos:

Momento no centrado de orden k

$$\hat{\mu}'_k = \frac{1}{n} \sum_{j=1}^{r} \frac{n_j (c_j^{k+1} - c_{j-1}^{k+1})}{(k+1)(c_j - c_{j-1})}. \tag{2.4}$$

En particular, para el momento de orden uno (la media) tenemos:

$$\hat{\mu}'_1 = E(\hat{X}) = \sum_{j=1}^{r} \frac{n_j (c_j + c_{j-1})}{2n}. \tag{2.5}$$

Moda .- Una vez hemos identificado el intervalo modal, $I_m = (c_{j-1}, c_j) = I_j$, como aquel con máxima frecuencia absoluta, $n_m = n_j$, aplicamos la siguiente fórmula:

$$Moda = c_{j-1} + (c_j - c_{j-1}) \, \frac{n_j - n_{j-1}}{2n_j - n_{j-1} - n_{j+1}} \tag{2.6}$$

Mediana .- Una vez hemos identificado el intervalo en el que se halla la mediana, $I_{me} = (c_{j-1}, c_j) = I_j$, aplicamos la fórmula:

$$Mediana = c_{j-1} + \frac{(n-1)/2 - \sum_{i=j+1}^{r} n_i}{n_j} \, (c_j - c_{j-1}) \tag{2.7}$$

Percentiles En función de las frecuencias relativas acumuladas, $F_n(c_j) = \sum_{i=1}^{j} n_i/n$, determinamos en qué intervalo (c_{j-1}, c_j) está el percentil π_p en cuestión. Mediante interpolación y a partir de la igualdad $p = F_n(\pi_p)$ en la fórmula 2.9, obtenemos:

$$\hat{\pi}_p = \frac{p(c_j - c_{j-1}) - c_j F_n(c_{j-1}) + c_{j-1} F_n(c_j)}{F_n(c_j) - F_n(c_{j-1})}. \tag{2.8}$$

```
# Queremos agrupar x en intervalos cuyos extremos son los cuartiles:
cj<-as.vector(quantile(x)) # puntos de corte
x.cat<-cut(x,b=cj,include.lowest =T)
summary(x.cat)
table(x.cat)          # Tabla de frecuencias
nj<-tabulate(x.cat)   # vector de frecuencias absolutas


# Queremos calcular la varianza en datos agrupados.
# Para ello utilizamos el resultado  Var(X)=E(X^2)-E(X)^2.
cj.j<-cj[-1]            # vector con todos los extremos menos c0
cj.j1<-cj[-length(cj)]  # vector con todos los extremos menos cr
n<-sum(nj)              # número de datos
e.x2.cat<-sum(nj*(cj.j^3 - cj.j1^3)/(3*(cj.j-cj.j1)))/n  # E(X^2)
e.x.cat<-sum(nj*(cj.j+cj.j1))/(2*n)                      # E(X)
var.x.cat<-e.x2.cat-e.x.cat^2                            # Var(X)

# Ahora queremos calcular el percentil 30
Fn.cj<-c(0,cumsum(nj/n)); Fn.cj     # Frec.relat.acumuladas
p<-0.3
index.p<-which(Fn.cj==Fn.cj[Fn.cj>=p][1]); index.p
# el percentil p está en el intervalo index.p (index.p en {1,2,..,r})
# vector con los extremos de dicho intervalo:
cj.p<-cj[c(index.p-1,index.p)]
# vector de probabilidades acumuladas en los extremos:
Fn.cj.p<-Fn.cj[c(index.p-1,index.p)]
# Fórmula para el cálculo del percentil en datos agrupados:
numerador<-p*(cj.p[2]-cj.p[1])-cj.p[2]*Fn.cj.p[1]+cj.p[1]*Fn.cj.p[2]
perc.p<-numerador/(Fn.cj.p[2]-Fn.cj.p[1]);perc.p
```

2.2.3. Varias medidas de dispersión y forma

En general disponemos de varias medidas de forma y dispersión comunes para datos agrupados o individualizados, que son:

- La varianza $\mu_2 = \sigma^2$ se puede obtener a partir de los momentos no centrados de orden 1 y 2, esto es, $\sigma^2 = \mu'_2 - \mu^2$.
- La desviación estándar es $\sigma = \sqrt{\sigma^2}$. No sirve para comparar grupos respecto a su variabilidad cuando éstos tienen medias muy diferentes.

- El coeficiente de variación es σ/μ. La distribución exponencial tiene CV=1. Usamos el coeficiente de variación para comparar la variabilidad en grupos con diferentes medias, esto es, la variabilidad relativa.

- El coeficiente de asimetría es $\gamma_1 = \mu_3/\sigma^3$. Una distribución simétrica tiene un coeficiente de asimetría de cero. Una asimetría positiva identifica distribuciones de probabilidad asimétricas con la mayor parte de la probabilidad acumulada en valores pequeños.

- La curtosis es $\gamma_2 = \mu_4/\sigma^4 - 3$. Una curtosis pequeña próxima a cero implica que la distribución está muy apuntada en el centro. Un valor (absoluto) grande indica que la distribución está muy dispersa en torno a la media y tiene una forma achatada.

```
# Librería con las funciones para el cálculo de asimetría y curtosis
library(e1071)
# Consideramos dos distribuciones asimétricas (Betas)
# y las comparamos con la normal (simétrica).
nsim<-5000
s1<-skewness(rbeta(nsim,2,3))
s2<-skewness(rbeta(nsim,3,2))
s3<-skewness(rnorm(nsim,0.5,0.5))
s1;s2;s3

# Y los pintamos:
par(mfrow=c(2,1))
plot(x<-seq(-1,2,0.05),dbeta(x,2,3),type="l",main="Simetría",
xlab="",ylab="")
lines(x,dbeta(x,3,2),col="blue")
lines(x,dnorm(x,0.5,0.5),col="red")
legend(-1,1.6,c("Be(2,3)","Be(3,2)","N(0,1)"),lty=rep(1,3),
col=c("black","blue","red"))
legend(1.5,1.7,c("Asimetría",round(c(s1,s2,s3),2)))

# Consideramos una distribución normal y una Student, más achatada.
k1<-kurtosis(rnorm(nsim));k2<-kurtosis(rt(nsim,3))
k1;k2
# Y las pintamos:
plot(x<-seq(-5,5,0.05),dnorm(x),type="l",main="Curtosis",
xlab="",ylab="")
lines(x,dt(x,3),col="green3",lwd=2)
```

```
legend(-4.5,0.4,c("N(0,1)","St(4)"),lty=rep(1,2),
col=c("black","green3"))
legend(3,0.4,c("Curtosis",round(c(k2,k1),2)))
```

2.3. Descripción gráfica de datos

2.3.1. Gráficos para Datos Discretos

- Diagramas de puntos
- Diagramas de barras
- Diagramas de quesos

```
x <- rbinom(100,5,0.3)
par(mfrow=c(2,2))
# Diagrama de puntos
dotplot(x)
plot(x,type="h")
# Diagrama de barras
barplot(table(x),col=rainbow(length(table(x))))
# Diagrama de quesos
pie(table(x))
```

2.3.2. Gráficos para Datos continuos

- Diagramas de cajas (con bigotes)
- Diagramas de tallos y hojas
- Diagramas de puntos *stripchart*

```
y <- rnorm(100)
y.f<-rbinom(100,5,0.3)

stem(y) # Gráfico de  tallos y hojas

par(mfrow=c(2,2))
# Gráficos de cajas
boxplot(y)
```

```
boxplot(y~y.f)
boxplot(split(y,y.f),col="cyan")

# Gráficos de puntos
stripchart(y); m <- mean(par("usr")[1:2])
text(m, 1.04, "stripchart método overplot")
stripchart(y,method="jitter",add=T,at=1.2)
text(m, 1.35, "stripchart método jitter")
stripchart(round(y,1),method="stack",add=T,at=0.7)
text(m, 0.85, "stripchart método stack")


library(lattice)
dotplot(y.f~y)
stripplot(y.f~y)
bwplot(y.f~y)  # Bow and whiskers
yy<-rnorm(100,y)
xyplot(yy~y|y.f) # Gráficos condicionados
```

2.3.3. Gráficos multidimensionales

Cuando queremos representar varias variables conjuntamente para detectar relaciones entre ellas, disponemos de diversos tipos de gráficos:

- Gráficos de tendencias para tablas de contingencia
- Gráficos de dispersión
- Gráficos condicionados.

```
# Gráficos de tendencias para tablas de contingencia
data(VADeaths)
dotchart(VADeaths, main = "Death Rates in Virginia - 1940")

# Gráficos de dispersión para revisar relaciones entre variables
data(iris)
razas<-unclass(iris$Species)
plot(iris[1:2],pch=21,bg = c("red", "green3", "blue")[razas])
pairs(iris[1:4], main = "Anderson's Iris Data -- 3 species",
pch = 21, bg = c("red", "green3", "blue")[razas])
```

```
data(swiss)
pairs(swiss, panel = panel.smooth, lwd = 2, cex= 1.5, col="blue")

# Gráficos condicionados
data(quakes)
coplot(lat ~ long | depth, data = quakes)
```

2.4. Gráficos para estudiar la distribución de los datos

Histogramas .

```
y<-rnorm(500)
hist(y)
hist(y,5)
```

Gráficos qqplot .- Tenemos dos modalidades:

- cuantiles empíricos versus cuantiles teóricos
- comparación de dos distribuciones empíricas

```
# Comparación de los cuantiles muestrales con los de una Normal
qqnorm(y);qqline(y)
# Comparación de los cuantiles muestrales de dos muestras
y.t<-rt(500,3)
qqplot(y,y.t,xlab="Distribución Normal",ylab="Distribución St(3)")
qqline(y)
# Comparación de los cuantiles muestrales con
# los de una distribución dada
library(lattice)
qqmath(y,distribution=qt,df=5)
qqmath(y,distribution=qgamma,shape=3,rate=5)
```

Distribuciones y densidades . Distinguimos entre datos individualizados y datos agrupados:

✓ Datos individualizados

- Función de Distribución empírica

$$F_n(x) = \frac{\#\{x_j \leq x\}}{n}$$

```
# Simulamos puntos de la distribución logística
x<-rlogis(500,2,3)
# Librería con la función de distribución empírica
library(stepfun)
Fn.x<-ecdf(x)
summary(Fn.x)
plot(Fn.x,main="Función Distribución Empírica")
plot(Fn.x,add=T,verticals=T,col.v="orange",col.h="blue")
x.seq<-seq(min(x),max(x),length=4)
# Y podemos evaluar Fn en cualquier punto:
points(x.seq,Fn.x(x.seq),pch=21,bg="red3")
abline(v=x.seq,col="red3")
abline(h=Fn.x(x.seq),col="red3")
```

- Función de densidad empírica.- Es útil cuando tenemos datos discretos y pretendemos evaluar la función puntual de probabilidad empírica.

$$f_n(x) = \frac{\#\{x_j = x\}}{n}$$

- Estimador kernel de la densidad, útil para estimar la función de densidad empírica de datos continuos. La idea básica de estos estimadores es la interpolaciones a través de ojivas superpuestas sobre histogramas. Un estimador kernel tiene la forma general:

$$\hat{f}(x) = \frac{1}{b}\sum_{j=1}^{n} K\left(\frac{x - x_j}{b}\right),$$

donde $K()$ es una función kernel que se decide de antemano y b es la amplitud de las bandas (intervalos) que se elige para afinar en la estimación.

```
par(mfrow=c(1,1))
x<-rgamma(500,4,3)
hist(x,freq=F)
# Estimador kernel de la densidad
lines(density(x))
bw.x<-density(x)$bw; bw.x  # amplitud de la banda
# Podemos modificar la banda para la estimación
lines(density(x,bw=bw.x/2),col="red")
lines(density(x,bw=bw.x*2),col="blue")
```

✓ Datos agrupados

- Función de Distribución empírica

$$F_n(x) = \begin{cases} 0, & x \leq c_0 \\ \frac{(c_j - x)F_n(c_{j-1}) + (x - c_{j-1})F_n(c_j)}{c_j - c_{j-1}}, & c_{j-1} < x \leq c_j \\ 1, & x > c_r. \end{cases} \tag{2.9}$$

```
library(stepfun)
x.cat<-cut(x,quantile(x))
Fn.x.cat<-ecdf(x.cat)
plot(Fn.x.cat,main="F.D.empírica datos agrupados",verticals=T)
```

- Función de densidad empírica

$$f_n(x) = \begin{cases} 0, & x \leq c_0 \\ \frac{F_n(c_j) - F_n(c_{j-1})}{c_j - c_{j-1}} = \frac{n_j}{n(c_j - c_{j-1})}, & c_{j-1} < x \leq c_j \\ 0, & x > c_r. \end{cases} \tag{2.10}$$

2.5. Ejercicios

1. Vamos a corroborar la aproximación asintótica a la normalidad de la distribución binomial. Para ello consideraremos diversos casos de una distribución $Bi(n, p)$:

   a) $p = 0{,}1$, $n = 5, 10, 30, 50, 100$

   b) $p = 0{,}3$, $n = 5, 10, 30, 50, 100$

   c) $p = 0{,}5$, $n = 5, 10, 30, 50, 100$

   d) $p = 0{,}7$, $n = 5, 10, 30, 50, 100$

   e) $p = 0{,}9$, $n = 5, 10, 30, 50, 100$

   Simula 100 datos en cada uno de los supuestos y represéntalos con histogramas. Superpón, en cada uno de los gráficos, una curva que represente la función de densidad normal de la correspondiente aproximación asintótica. Compara y comenta los resultados. ¿Cuándo se aprecia la convergencia asintótica?

2. Corrobora la aproximación asintótica a normalidad de la distribución Poisson $Po(\lambda n)$. Realiza el ejercicio de manera análoga al ejercicio anterior con diferentes valores de λ: $\lambda = (0{,}1), (0{,}5), 1, 5, 20$ y $n = 5, 10, 30, 50, 100$.

3. Programa la función de distribución y la de densidad empíricas para datos agrupados.

4. Programa la obtención de la moda en datos agrupados.

5. Disponemos de un conjunto de estaturas de los individuos de tres ciudades. Los datos son:

   Elche: 1.65, 1.55, 1.78
   Alicante: 1.81, 1.90, 1.5, 1.52
   Albacete: 1.95, 1.6, 1.72, 1.8

   Define y construye dos variables, estatura y ciudad, de forma que ciudad sea un factor de clasificación. Obtén una descriptiva de las estaturas, tanto globalmente como por ciudades.

6. En el fichero *SC2-1.dat* tenemos la edades de 50 miembros de un grupo de individuos de una asociación de vecinos, interesados en programas educativos para mayores. Las políticas de los programas de servicios sociales del ayuntamiento requieren que alrededor del 50 % de los participantes en un programa social sean mayores a 50 años.

a) Utiliza los datos para construir la distribución de frecuencias relativas con 7 intervalos iguales y con 13 intervalos iguales. Representa ambas distribuciones.

b) La comunidad de vecinos, ¿tiene derecho a un programa educativo, de acuerdo con la política que el ayuntamiento tiene al respecto sobre requisitos de los participantes?

c) ¿Qué distribución de frecuencias te ayuda mejor a contestar el apartado anterior, la basada en 7 intervalos o la basada en 13?

d) Supón que el director de los servicios sociales del ayuntamiento quisiera saber cuál es la proporción de vecinos, en ese barrio, entre 45 y 50 años. ¿Con qué distribución podrías estimar mejor dicha proporción?

7. Un estudio sobre los hábitos de los consumidores americanos de televisión por cable originó los datos en el fichero *2-10.dat*. ¿Qué puedes decir sobre dichos hábitos?

8. La Agencia de Protección Medioambiental en USA tomó muestras de agua de 12 ríos y afluentes diferentes que iban a parar al Lago Erie. Estas muestras fueron testadas en el laboratorio de la EPA y clasificadas en función del residuo contaminado sólido. Los resultados del test están en el fichero *2-15.dat*.

   a) Determina el número de muestras que tenían un contenido en residuos contaminantes entre 30.0 y 39.9, entre 40.0 y 49.9, entre 50.0 y 59.9, y entre 60.0 y 69.9. Representa la distribución de frecuencias.

   b) Si 45.0 es el número utilizado por la EPA para indicar contaminación excesiva, ¿cuántas muestras resultaron excesivamente contaminadas?

   c) En promedio, ¿cuál es la tasa de contaminación observada?

   d) ¿Cuál es la tasa de contaminación más frecuente?

9. Una compañía de venta de bicicletas tomó una muestra sobre las ventas durante un día y obtuvo los datos en el fichero *sc2-3.dat*, concernientes a tiempo transcurrido (en días) desde un pedido hasta que es servido al cliente.

   a) Construye y representa una distribución de frecuencias para estos datos.

   b) ¿Qué puedes decir sobre la efectividad en la gestión de los pedidos?

   c) Si la empresa quiere asegurar que la mitad de sus pedidos los va a resolver en menos de 10 días, ¿puedes decir si, a la vista de los datos, consigue su propósito?

d) ¿Cuánto tiempo tarda en resolver el 80 % de los pedidos?

10. La OCU muestreó en 30 ciudades el IPC a principios y a finales de diciembre, con el fin de investigar cómo se modificaban los precios con la campaña de Navidad. Los cambios, en porcentajes, aparecen en el fichero *2-19.dat*.

    a) Construye una distribución de frecuencias con 4 clases de igual tamaño [-0.5,-0.2], [0.1,0.2], [0.3,0.6] y [0.7,1.0]. Represéntala.

    b) ¿Cuántas ciudades muestreadas tenían precios que, o no cambiaron o se incrementaron menos de un 1.0 %?

    c) Estos datos, ¿son discretos o continuos? Justifica la respuesta.

11. Telepizza decidió elaborar un informe sobre los hábitos de sus clientes durante los sábados en cierta ciudad. Para ello observaron lo que ocurría un sábado cualquiera y, entre otras cosas, clasificaron a los clientes en función del dinero gastado. Los datos aparecen en el fichero *2-23.dat*.

    a) El detalle con que se hizo la clasificación, ¿lo consideras útil? Construye una distribución de frecuencias más informativa, agrupando intervalos, sin perder demasiada información. Representa dicha distribución.

    b) ¿Cuál es el tipo de cliente más frecuente? ¿Cuánto se suele gastar dicho cliente aproximadamente un sábado en Telepizza?

    c) ¿Cuál es el tope de dinero que llegan a gastarse el 90 % de los clientes un sábado en Telepizza?

12. Una potente empresa de venta de automóviles monitorizó el número de ventas de sus 40 empleados durante el pasado mes. Los datos están en el fichero *2-31.dat*.

    a) Construye una distribución de frecuencias que nos permita obtener una información clara sobre las características de los 40 empleados.

    b) Un vendedor con menos de 7 coches vendidos al mes se considera "inaceptable". ¿Qué porcentaje de empleados recibiría ese apelativo en función de sus ventas del mes pasado?

    c) ¿Cuántas ventas realizó el "empleado del mes¿ ¿Cuántos empleados quedaron a dos coches (vendidos) de distancia?

13. En un periódico, el tiempo requerido para confeccionar la primera página en la imprenta se apuntó durante 50 días. Los datos (en décimas de minuto) están en el fichero *2-40.dat*.

a) Construye y representa la distribución de frecuencias usando intervalos de 0.8 minutos.

b) ¿Cuánto tiempo suele costar la confección de la primera página?

c) ¿Qué porcentaje de días se consigue terminar la página en menos de 24 minutos?

14. El gerente de un hospital encargó un estudio sobre el tiempo que un paciente ha de esperar en urgencias antes de ser atendido. Los datos (en minutos de espera) del fichero *2-49.dat* se recogieron un día cualquiera.

    a) Construye y representa la distribución de frecuencias y obtén unas primeras conclusiones sobre la situación actual a la vista de la misma.

    b) ¿Qué porcentaje de pacientes tardaron menos de una hora en ser atendidos?

    c) ¿Cuál es el número de minutos que con más frecuencia ha de esperar un paciente para ser atendido?

    d) ¿Cuál es el tope máximo de tiempo que hubieron de esperar el 50 % de los pacientes de urgencias?

15. La Tienda del Campo vende equipamientos a compañías agrícolas en países en desarrollo. Recientemente en la Tienda tuvieron un incendio que destruyó la mayor parte de los pedidos. Afortunadamente, al finalizar cada mes hacían copia de seguridad de los pedidos y transacciones efectuadas, de ahí que disponen de las cifras de ventas durante los últimos dos meses. Los datos están en el fichero *2-74.dat*.

    a) Construye y representa dos distribuciones de frecuencias para las ventas de los últimos dos meses. Confecciona una distribución con 3 clases y la otra con 9 clases y compáralas.

    b) Utiliza el apartado anterior para dar información sobre la tendencia de ventas y en consecuencia intentar estimar el tamaño de la demanda durante el mes actual.

    c) Proporciona alguna medida de variabilidad que nos ayude a saber cuáles son las cifras más probables para el número de ventas durante este mes.

16. Disponemos de los tiempos de espera de coches que están atravesando un largo túnel taponado debido a un accidente por la mañana. Se recogió información sobre el número de minutos de espera en cola de 3000 conductores consecutivos en la cabecera del túnel. Los datos están en el fichero *2-75.dat*.

a) Construye la distribución de frecuencias y dibuja la ojiva.

b) ¿Qué porcentaje de conductores tuvo que esperar más de 4 minutos en cola? ¿Y más de 8 minutos?

c) Da una medida aproximada de cuánto hubieron de esperar los 3000 conductores en la cola.

d) ¿Cuánto tiempo hubieron de esperar la mayoría de los coches?

e) Los datos del tráfico en dicho túnel se recogieron otro día normal (fichero 2-79.dat). ¿Qué diferencias encuentras entre los datos del día del accidente y este día normal?

17. El director de un establecimiento alimenticio que abre entre la 7 de la mañana y las 9 de la noche está planteándose la posibilidad de reconvertir su negocio en un Abierto 24h. Utilizando la información sobre las ventas de otro establecimiento Abierto 24h, pretende tomar la decisión. Los datos están en el fichero *2-80.dat*. ¿Qué recomendaciones puedes dar al director? Puntualiza también en las limitaciones al usar esos datos.

18. La empresa El Mejor Mueble tiene un crédito con el Banco Mobiliar. A final de mes durante el pasado año, el balance fue el que se presenta en el fichero *sc3-2.dat*. El Banco ofrece reducciones de interés a las empresas que tienen un balance medio mensual por encima de 65.000 euros. ¿El Mejor Mueble podría beneficiarse de dicha oferta? ¿Qué puedes decir sobre el comportamiento anual de su ahorro?

19. El Ayuntamiento pretende continuar con la obra social de Guarderías para Todos, proporcionando una subvención a la Guardería Popular siempre que el promedio de ingresos familiares anuales de los niños que asisten sea inferior a 12500 euros. Los ingresos familiares de los niños que asistieron a la Guardería Popular durante este año están en el fichero *3-7.dat*.

    a) ¿Tendrá derecho la Guardería a recibir la subvención este año?

    b) Construye la distribución de frecuencias. ¿Qué puedes decir sobre el nivel económico de las familias que llevan sus niños a la Guardería Popular?

20. Un profesor ha decidido utilizar un promedio ponderado para evaluar a sus estudiantes. Los ejercicios a resolver por el estudiante contarán un 20 % en la calificación final. Hará un examen a mitad de curso (que puntuará un 25 %) y otro al final, que puntuará un 35 %. Un trabajo puntúa un 10 % y varios cuestionarios otro 10 %. Para las puntuaciones de cinco estudiantes, en el fichero *3-16.dat* obtén la calificación final.

21. Enatcar cree que una velocidad excesiva de sus autobuses incrementa los costes de mantenimiento. Cree que una tiempo mediano razonable para ir de Elche centro al aeropuerto del Altet está en 30 minutos. A partir de los datos en el fichero *3-34.dat*, ¿puedes determinar si los autobuses han ido demasiado rápidos?

    a) Consruye la distribución de frecuencias y contesta la pregunta anterior.

    b) ¿Qué porcentaje de autobuses muestreados tardaron entre 28 y 32 minutos en hacer la ruta?

    c) ¿Cuál es el tiempo más habitual en hacer la ruta?

    d) Calcula los cuartiles y el rango intercuartílico. Dales una explicación en el contexto de las velocidades.

22. Tenemos datos sobre reclamaciones por accidente de coche en el fichero *3-36.dat*. Construye la distribución de frecuencias y la descriptiva básica. Extrae conclusiones.

23. La Universidad organizó un curso sobre Técnicas de Estudio al que atendieron un total de 30 personas. Sus edades están en el fichero *sc3-10.dat*.

    a) Construye y representa la distribución de frecuencias.

    b) Calcula las diversas medidas de tendencia central y concluye sobre cuál consideras más informativa y por qué.

    c) Calcula varias medidas de dispersión y comenta cuál te parece más informativa y por qué.

24. Las edades de los ancianos que viven en la residencia Nuevo Amanecer aparecen en el fichero *3-39.dat*.

    a) Construye y representa la distribución de frecuencias.

    b) Calcula la edad más frecuente.

    c) Calcula las edades media y mediana y compáralas con la moda.

    d) Da alguna medida de la heterogeneidad (en edades) de las personas que viven allí.

25. En el fichero *3-55.dat* tenemos el total de euros recogidos por 20 taxis en la ciudad de Elche durante un día. Da una medida adecuada de dispersión y justifícala.

26. El número de cheques canjeados cada día en cinco oficinas del Banco Amarillo durante el mes pasado está disponible en el fichero *3-64.dat*.El director de operaciones del banco sabe que una desviación estándar en caja de más de 200 cheques por día crea problemas de reparto de trabajo entre las cinco oficinas. ¿Surgieron problemas de este tipo el mes pasado?

27. El administrador del Hospital Central encargó una encuesta durante 200 días en los que se eligieron pacientes al azar y se les preguntó por el tiempo de permanencia en el hospital después de una operación. Los datos están en el fichero *3-66.dat*.

    a) Construye y representa la distribución.

    b) Calcula la desviación estándar y la media.

    c) De acuerdo al teorema de Chebyshev, ¿cuántas estancias debería haber entre 0 y 17 días? ¿Cuántas hay realmente en ese intervalo?

    > *Chebyshev (1821-1894).- Sea cual sea la forma de la distribución, al menos el 75 % de los valores caerán a* ± 2 *desviaciones estándar de la media y al menos el 89 % a* ± 3 *desviaciones estándar de la media.*

    d) Teniendo en cuenta la forma de la distribución, ¿cuántas estancias se esperarían entre 0 y 17 días?

28. La Universidad organizó un curso de especialización que se impartió en dos turnos: uno de mañana y uno de tardes. Disponemos de las edades de los matriculados en cada uno de ellos. Los datos están en el fichero *3-76.dat*.

    a) Construye la distribución de edades en cada turno y compáralas gráficamente.

    b) Describe numéricamente cada turno y compáralos.

    c) Si la homogeneidad de la clase se entiende como un factor positivo en el aprendizaje, utiliza una medida de variabilidad relativa para contestar cuál de los grupos será más fácil de enseñar.

29. La empresa La Semilla Viva vende tres tipos de semillas de maíz (a precios distintos) que se distinguen por la consistencia de la germinación de las semillas. La OCU, dispuesta a descubrir si realmente los precios se justifican por las calidades de las semillas encargó un análisis a un laboratorio. Dicho laboratorio tomó una muestra de 5 sacos de semillas de cada tipo y las calificó en función del número de semillas que germinaban (en un total de 100 semillas en el saco). Los datos se encuentran en el fichero *3-81.dat*.

a) Representa los datos para poder compararlos.

b) ¿Tiene sentido la clasificación en los tres tipos de semillas?

30. Un psicólogo escribió un programa de ordenador para simular el modo en que una persona responde a un test estándar de inteligencia. Para testar el programa simuló 15 respuestas a un cuestionario de inteligencia y calculó con ellas el coeficiente intelectual. Los datos están en el fichero *3-97.dat*.

    a) Construye y representa la distribución de frecuencias.

    b) Superpón una curva de densidad de alguna distribución que pueda describir bien dicha distribución de frecuencias.

    c) Calcula los descriptivos numéricos.

    d) De acuerdo al teorema de Chebyshev, entre qué dos CI deberán estar el 75 % de los resultados? ¿Entre qué valores están?

31. Una empresa de calzado de Elche tiene anotados los días de trabajo anual de sus 10 trabajadores (fichero *3-100.dat*).

    a) Sin calcular ningún descriptivo, ¿qué medida de dispersión piensas que te va a dar más información: el rango o la desviación estándar? ¿Por qué?

    b) Calcula los descriptivos y concluye sobre el comportamiento laboral de los empleados de la empresa.

32. Tenemos los datos sobre cambios de precios el 14 de febrero de todas las floristerías ubicadas en el centro de Elche y en las afueras. Dichos datos están en el fichero *3-101.dat*.

    a) Construye y representa las distribuciones de frecuencias para cada uno de los grupos de floristerías. Compáralas.

    b) Superpón densidades de distribuciones que puedan aproximar bien dicha distribución.

    c) Calcula los descriptivos (localización y dispersión) para cada grupo. Compáralos.

    d) Compara los dos grupos respecto a los coeficientes de variación para determinar qué distribución tiene menor variabilidad relativa.

33. Una empresa que alquila maquinaria funciona a través de contratos de mantenimiento con sus clientes. Para planificar el número de máquinas que ha de tener disponibles ha de tener en cuenta el tiempo que tiene alguna

máquina parada debido a averías. Disponemos de los datos de averías del año pasado y el número de días de reparación de cada una de ellas (fichero 3-102.dat).

a) Construye y representa la distribución de frecuencias.

b) Superpón una densidad de distribución que pueda aproximar bien dicha distribución.

c) ¿Cuál fue el tiempo medio de reparación? ¿Y la mediana? ¿Cuál consideras más útil?

d) ¿Qué garantías tendrán de que una reparación no va a llevar más de 10 días?

e) ¿Qué puedes concluir sobre las averías de las máquinas el año pasado?

34. Un mecánico de Fórmula 1 quería testar ruedas de tres marcas diferentes. Las probó y anotó el número de vueltas que aguantaron en buenas condiciones en un circuito. Los datos están en el fichero *3-109.dat*.

a) Construye y representa la distribución de frecuencias para cada tipo de rueda. Compáralas.

b) Superpón una densidad de distribución que pueda aproximar bien cada distribución.

c) Calcula media y mediana en cada grupo. Compáralas.

d) Calcula las medidas de dispersión estándar y relativas para poder compararlas.

e) ¿Qué tipo de rueda resultó mejor? Justifica la respuesta.

TEMA 3

Estimación y Contraste de Hipótesis Univariantes

Vamos a ver en este tema los procedimientos de estimación puntual por intervalos, y contrate de hipótesis.

3.1. Estimación puntual

En primer lugar vamos a ver como obtener los estimadores máximo verosímiles.

3.1.1. Estimación máximo verosímil

La estimación máximo verosímil consiste en obtener el valor del parámetro para el cual se maximiza la log-verosimilitud.

La función *optimize()* permite el cálculo de máximos sobre un rango determinado en problemas con un sólo parámetro. Necesitamos definir la log-verosimilitud y el rango de valores posibles.

Ejemplo 1: *Obtención del EMV en muestras Bernouilli de tamaño n y parámetro p. Una empresa que fabrica tuercas ha comprado una máquina y desea estimar la proporción de tuercas defectuosas que fabrica dicha máquina. En la primera mañana de uso ha fabricado 81 tuercas. Si la muestra se considera representativa, estima dicha proporción. La clasificación de las tuercas fabricadas es: correctas* (0) *o defectuosas* (1).

La función de log-verosimilitud viene dada por

$$lv = \sum_{i=1}^{n} x_i \, ln(p) + (1 - x_i) ln(1 - p).$$

Hay que definir la función teniendo en cuenta que el primer parámetro es el que deseamos maximizar:

```
LV=function(p,datos)
{
    n=length(datos)
    valor=sum(datos*log(p)+(1-datos)*log(1-p))
    return(valor)
}
```

Representamos la función y calculamos el máximo

```
res=sapply(seq(0.001,0.999,0.001),LV,datos=tuercas)
plot(seq(0.001,0.999,0.001),res,type="l",xlab="p"
    ,ylab="log-verosimilitud")
optimize(LV,interval=c(0,1),datos=tuercas,maximum=T)
```

Ejemplo 2: *Obtención del EMV en muestras Normales de tamaño n con media desconocida y varianza conocida. Tenemos 25 datos de una población $N(\mu, 1)$. Representar la función de log-verosimilitud y obtener el EMV de μ.*

Función de log verosimilitud para μ:

```
LV=function(mu,s2,datos)
{
    n=length(datos)
    valor=0.5*n*log(s2)-0.5*log(2*pi)-0.5*sum((datos-mu)*(datos-mu))/s2
    return(valor)
}
```

Gráfico:

```
res=sapply(seq(-1,5,0.001),LV,s2=1,datos=normales)
plot(seq(-1,5,0.001),res,type="l",xlab=expression(mu)
    ,ylab="log-verosimilitud")
```

Máximo y comprobación:

```
optimize(LV,interval=c(-1000,1000),s2=1,datos=normales,maximum=T)
mean(normales)
```

3.2. Intervalos de confianza

En este caso pretendemos obtener un intervalo en el que se encuentre el verdadero valor del parámetro con un grado de confianza. Al intervalo obtenido lo denominaremos intervalo de confianza al $100(1-\alpha)\,\%$ de θ.

El concepto de confianza de be interpretarse de la siguiente manera: *si se repitiera el experimento muestral X un número suficiente de veces, en $100(1-\alpha)$ de cada 100 casos se confiaría en que el intervalo $[L(X), U(X)]$ contenga al parámetro θ.*

El método habitual para la construcción de intervalos de confianza es la utilización de cantidades pivotales. Una variable aleatoria $Q(X, \theta)$ es una cantidad pivotal o pivote si la distribución de Q es independiente del parámetro θ.

Si denotamos por F a la distribución del pivote, podemos obtener un intervalo de confianza al nivel $1-\alpha$ al despejar el parámetro de interés de la expresión:

$$P(f_{\alpha/2} \leq Q(X, \theta) \leq f_{1-\alpha/2}) \quad = 1-\alpha,$$

con $f_{\alpha/2}$ y $f_{1-\alpha/2}$ los percentiles $\alpha/2$ y $1-\alpha/2$ de la distribución F.

R tiene implementadas algunas funciones que resuelven contrastes y a la vez proporcionan los intervalos de confianza. Sin embargo, en la mayoría de situaciones es preciso implementar nosotros la fórmula correspondiente, tanto para el contraste como para el intervalo de confianza.

Nosotros presentamos las fórmulas de estadísticos pivotes e intervalos de confianza para cada una de las situaciones básicas planteables en un problema inferencial.

3.2.1. Media y varianza de una población normal

Suponemos datos procedentes de una población normal $N(\mu, \sigma^2)$.

IC de la media con varianza conocida

$$Q(X, \mu) = \frac{\bar{x} - \mu}{\sigma/n} \sim N(0, 1) \tag{3.1}$$

$$IC_{1-\alpha}(\mu) = \left[\bar{x} + z_{\alpha/2}\frac{\sigma}{\sqrt{n}}, \bar{x} + z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}}\right], \tag{3.2}$$

donde $z_{\alpha/2}$ y $z_{1-\alpha/2}$ son los correspondientes percentiles de la $N(0,1)$, con $z_{\alpha/2} = -z_{1-\alpha/2}$.

```
# La siguiente función proporciona el IC en \eqref{eq3.2}:
IC.mu.sigma2C=function(datos,sigma2,conf) {
    media=mean(datos)
    n=length(datos)
    alfa=1-(conf/100)
    c1=qnorm(alfa/2)
    c2=qnorm(1-alfa/2)
    return(round(c(media+c1*sqrt(sigma2/n),media+c2*sqrt(sigma2/n)),2))
}
```

Estudiamos a continuación el comportamiento de los intervalos de confianza.

Ejemplo 3: *Generar 1000 muestras normales estándar de tamaños 10, 50, 100, y 250. Comprobar que la distribución en el muestreo de $Q(X,\mu)$ en (3.1) es $N(0,1)$ y calcular los correspondientes intervalos de confianza. ¿Cuántos de esos intervalos no contienen a la media poblacional?*

```
n=10
muestras=1000
simulaciones=matrix(rnorm(n*muestras),ncol=n)
# Estudiamos la distribución en el muestreo
pivote=apply(simulaciones,1,mean)*sqrt(n)
hist(pivote,prob=T,nclass=10,xlim=c(-4,4),ylim=c(0,0.5))
par(new=T)
lines(seq(-4,4,0.001),dnorm(seq(-4,4,0.001)))
# Calculamos intervalos
intervalos=matrix(0,ncol=2,nrow=muestras)
for(i in 1:muestras)
 intervalos[i,]=IC.mu.sigma2C(simulaciones[i,],1,95)
# Porcentaje de intervalos que no contienen al verdadero valor
sel=(intervalos[,1]>=0 | intervalos[,2]<=0)
sum(sel)/muestras
```

Ejemplo 4: *Se quiere estimar la precipitación media durante el mes de enero en los diferentes observatorios de la Comunidad Valenciana. Los datos de los diferentes observatorios aparecen a continuación. Si se sabe que la variabilidad es de 200 l/m^2, calcular los intervalos de confianza al 90 %, 95 %, y 99 %.*

```
# Calculamos los correspondientes intervalos de confianza
IC.mu.sigma2C(precipitacion,200,90)
IC.mu.sigma2C(precipitacion,200,95)
IC.mu.sigma2C(precipitacion,200,99)
```

IC de la media con varianza desconocida

$$Q(X;\mu) = \frac{\sqrt{n}(\bar{x}-\mu)}{s} \sim t_{n-1} \tag{3.3}$$

$$IC_{1-\alpha}(\mu) = \left[\bar{x} - t_{n-1;1-\alpha/2}\frac{s}{\sqrt{n}}, \bar{x} + t_{n-1;1-\alpha/2}\frac{s}{\sqrt{n}},\right] \tag{3.4}$$

donde $s^2 = \sum(x_i - \bar{x})^2/(n-1)$.

Ejemplo 5: *D*urante 60 dias se recoge el número de refrescos vendidos por una máquina en la facultad de ciencias experimentales de la universidad Miguel Hernández. Los resultados de las ventas durante los 60 dias se recogen seguidamente. Se desea estimar la media de las ventas realizadas por la máquina para poder aprovisionarla correctamente.

```
# Representamos gráficamente los datos
par(mfrow=c(1,2))
hist(ventas,freq=F)
qqnorm(ventas)
# Obtenemos el intervalo de confianza  usando la función t.test()
t.test(ventas,conf.level = 0.95)$conf
```

IC de la varianza

$$Q(X;\sigma^2) = \frac{(n-1)s^2}{\sigma^2} \sim \chi^2_{n-1} \tag{3.5}$$

$$IC_{1-\alpha}(\sigma^2) = \left[\frac{(n-1)s^2}{\chi^2_{n-1;1-\alpha/2}}, \frac{(n-1)s^2}{\chi^2_{n-1;\alpha/2}}\right] \tag{3.6}$$

Ejemplo 6: *Los datos que aparecen a continuación representan el consumo de energía primaria por habitante obtenidos de 14 naciones europeas. los datos vienen dados en teps por habitante, donde 1 tep=*10^7 *Kcal es la tonelada equivalente de petróleo. Se desea estimar la variabilidad entre los diferentes países asumiendo que se distribuyen normalmente*

```
# Representamos gráficamente los datos
par(mfrow=c(1,2))
hist(teps,freq=F)
qqnorm(teps)
# En primer lugar obtenemos el intervalo de confianza
# de la media usando la función t.test()
t.test(teps,conf.level = 0.95)$conf
# Ahora el intervalo de confianza de la varianza
n=length(teps)
alfa=0.05
round(c((n-1)*var(teps)/qchisq(1-alfa/2,n-1)
       ,(n-1)*var(teps)/qchisq(alfa/2,n-1)),3)
```

3.2.2. Medias y varianzas en dos poblaciones normales

De forma general suponemos datos procedentes de dos poblaciones normales $N(\mu_x, \sigma_x^2)$ y $N(\mu_y, \sigma_y^2)$.

IC de la diferencia de medias en poblaciones normales independientes con varianzas conocidas e iguales

Si $\sigma_x^2 = \sigma_y^2 = \sigma^2$ conocida, entonces:

$$Q(X, Y; \mu_x, \mu_y) = \frac{(\bar{x} - \bar{y}) - (\mu_x - \mu_y)}{s_{\bar{x}-\bar{y}}} \sim N(0, 1) \tag{3.7}$$

con $s_{\bar{x}-\bar{y}} = \sqrt{\sigma^2 \left(\frac{1}{n_x} + \frac{1}{n_y}\right)}$

$$IC_{1-\alpha}(\mu_x - \mu_y) = \left[(\bar{x} - \bar{y}) + z_{\alpha/2} s_{\bar{x}-\bar{y}}, (\bar{x} - \bar{y}) + z_{1-\alpha/2} s_{\bar{x}-\bar{y}}\right] \tag{3.8}$$

Ejemplo 7: *La cantidad de lluvia anual en centímetros cúbicos en dos ciudades A y B en un un período de 25 años aparecen a continuación. Si suponemos la desviación típica es conocida e igual a 20, calcular el intervalo de confianza al 95 % de la diferencia de medias.*

```
# Representaciones gráficas
par(mfrow=c(3,2))
hist(ciudad.A,freq=F)
qqnorm(ciudad.A)
```

```
hist(ciudad.B,freq=F)
qqnorm(ciudad.B)
hist(ciudad.A-ciudad.B,freq=F)
qqnorm(ciudad.A-ciudad.B)
# Calculemos el intervalo de confianza
dif.medias=mean(ciudad.A)-mean(ciudad.B)
tam=(1/length(ciudad.A)+1/length(ciudad.B))
dtip=20
alfa=0.05
round(c(dif.medias+qnorm(alfa/2)*dtip*sqrt(tam)
       ,dif.medias+qnorm(1-alfa/2)*dtip*sqrt(tam)),2)
```

IC de la diferencia de medias en poblaciones normales independientes con varianzas conocidas y diferentes

Suponemos ahora σ_x^2 y σ_y^2 conocidas y distintas. Entonces:

$$Q(X,Y;\mu_x,\mu_y) = \frac{(\bar{x}-\bar{y})-(\mu_x-\mu_y)}{s_{\bar{x}-\bar{y}}} \sim N(0,1) \tag{3.9}$$

con $s_{\bar{x}-\bar{y}} = \sqrt{\left(\frac{\sigma_x^2}{n_x}+\frac{\sigma_y^2}{n_y}\right)}$

$$IC_{1-\alpha}(\mu_x-\mu_y) = \left[(\bar{x}-\bar{y})+z_{\alpha/2}s_{\bar{x}-\bar{y}}, (\bar{x}-\bar{y})+z_{1-\alpha/2}s_{\bar{x}-\bar{y}}\right] \tag{3.10}$$

Ejemplo 8: *Queremos comparar los datos de la ciudad A (del ejemplo anterior) con los recogidos en la ciudad C durante 18 años, donde se sabe que la desviación típica es 50. Calcular el intervalo de confianza al 95 % de la diferencia de medias.*

```
# Representaciones gráficas
par(mfrow=c(2,2))
hist(ciudad.A,freq=F)
qqnorm(ciudad.A)
hist(ciudad.C,freq=F)
qqnorm(ciudad.C)
# No realizamos el gráfico para las diferencias puesto
# que el número de datos es distinto.

# Calculemos el intervalo de confianza
dif.medias=mean(ciudad.A)-mean(ciudad.C)
```

```
dtip.A<-20
dtip.B<-50
tam=(dtip.A^2/length(ciudad.A)+dtip.B^2/length(ciudad.C))
alfa=0.05
round(c(dif.medias+qnorm(alfa/2)*sqrt(tam)
       ,dif.medias+qnorm(1-alfa/2)*sqrt(tam)),2)
```

IC del cociente de varianzas en poblaciones normales independientes

Si las varianzas de las poblaciones son desconocidas necesitamos saber en primer lugar si podemos considerarlas iguales. Calculamos pues un intervalo de confianza para el cociente de varianzas.

$$Q(X,Y;\sigma_x^2,\sigma_y^2)=\frac{s_y^2/\sigma_y^2}{s_x^2/\sigma_x^2}\sim F_{n_y-1,n_x-1} \tag{3.11}$$

$$IC_{1-\alpha}\left(\frac{\sigma_x^2}{\sigma_y^2}\right)=\left[F_{n_y-1,n_x-1;\alpha/2}\frac{s_x^2}{s_y^2},F_{n_y-1,n_x-1;1-\alpha/2}\frac{s_x^2}{s_y^2}\right] \tag{3.12}$$

Por convenio, cuando calculamos intervalos de confianza del cociente de varianzas, en el numerador colocamos la varianza más grande. En ese caso recordemos que

$$F_{n_y-1,n_x-1;\alpha/2}=\frac{1}{F_{n_x-1,n_y-1;1-\alpha/2}}$$

En este caso sí disponemos de una función implementada en R, *var.test()*, que nos proporciona dicho intervalo de confianza.

Ejemplo 9: *Con los datos de los ejemplos 8 y 9. Calcular los correspondientes intervalos de confianza al 95 % para el cociente de proporciones.*

```
# En primer lugar calculamos las varianzas muestrales
s2.A<-var(ciudad.A)
s2.B<-var(ciudad.B)
s2.C<-var(ciudad.C)
c(s2.A,s2.B)
c(s2.A,s2.C)
# Calculemos el intervalo de confianza
var.test(ciudad.B,ciudad.A,conf.level = 0.95)$conf
var.test(ciudad.C,ciudad.A,conf.level = 0.95)$conf
```

IC de la diferencia de medias en poblaciones normales independientes con varianzas desconocidas e iguales

Dos poblaciones normales independientes $N(\mu_x, \sigma^2)$ y $N(\mu_y, \sigma^2)$ con σ^2 desconocida.

$$Q(X, Y; \mu_x, \mu_y) = \frac{(\bar{x} - \bar{y}) - (\mu_x - \mu_y)}{s_{\bar{x}-\bar{y}}} \sim t_{n_x+n_y-2} \tag{3.13}$$

con $s_{\bar{x}-\bar{y}} = \sqrt{s_p^2 \left(\frac{1}{n_x} + \frac{1}{n_y}\right)}$, y $s_p^2 = \frac{(n_x-1)s_x^2+(n_y-1)s_y^2}{n_x+n_y-2}$

$$IC_{1-\alpha}(\mu_x - \mu_y) = \left[(\bar{x} - \bar{y}) + t_{n_x+n_y-2;\alpha/2} s_{\bar{x}-\bar{y}}, (\bar{x} - \bar{y}) + t_{n_x+n_y-2;1-\alpha/2} s_{\bar{x}-\bar{y}}\right] \tag{3.14}$$

Para el cálculo de este intervalo de confianza vamos a usar la función *t.test()*

Ejemplo 10: *Con los datos de los ejemplo 8 suponiendo las varianzas desconocidas. Calcular el correspondiente intervalo de confianza al 95 % para la diferencia de medias.*

```
# Repitiendo lo visto en el ejemplo 9 vemos si las
# varianzas son iguales:
# Calculemos el intervalo de confianza para la varianza
s2.A<-var(ciudad.A)
s2.B<-var(ciudad.B) c(s2.A,s2.B)
var.test(ciudad.B,ciudad.A,conf.level = 0.95)$conf
#Calculemos el intervalo de confianza para la diferencia de medias
t.test(ciudad.A,ciudad.B,conf.level =0.95,var.equal=T)$conf
```

IC de la diferencia de medias en poblaciones normales independientes con varianzas desconocidas y diferentes

Dos poblaciones normales independientes $N(\mu_x, \sigma_x^2)$ y $N(\mu_y, \sigma_y^2)$ con σ_x^2 y σ_y^2 desconocidas.

$$IC_{1-\alpha}(\mu_x - \mu_y) = \left[(\bar{x} - \bar{y}) + t_{\nu;\alpha/2} s_{\bar{x}-\bar{y}}, (\bar{x} - \bar{y}) + t_{\nu;1-\alpha/2} s_{\bar{x}-\bar{y}}\right] \tag{3.15}$$

con

$$s_{\bar{x}-\bar{y}} = \sqrt{\frac{s_x^2}{n_x} + \frac{s_y^2}{n_y}}; \quad \nu = \frac{\left(\frac{s_x^2}{n_x} + \frac{s_y^2}{n_y}\right)^2}{\frac{(s_x^2/n_x)^2}{n_x-1} + \frac{(s_y^2/n_y)}{n_y-1}}$$

Ejemplo 11: *Con los datos de los ejemplo 9 suponiendo las varianzas desconocidas. Calcular el correspondiente intervalo de confianza al 95 % para la diferencia de medias.*

```
# Repitiendo los visto en el ejemplo 9 vemos si las
# varianzas son iguales:
# Calculemos el intervalo de confianza para la varianza
s2.A<-var(ciudad.A)
s2.C<-var(ciudad.C)
c(s2.A,s2.C)
var.test(ciudad.C,ciudad.A,conf.level = 0.95)$conf
# Calculemos el intervalo de confianza para la diferencia de medias
t.test(ciudad.A,ciudad.C,conf.level = 0.95,var.equal=F)$conf
```

IC de la diferencia de medias en poblaciones normales dependientes

Supongamos que disponemos ahora de dos muestras relacionadas de individuos de dos poblaciones normales dependientes. Entendemos por muestras relacionadas aquellas que tienen características intrínsecas comunes, como en el caso de miembros de una misma familia, etc...Tambien se consideran muestras relacionadas las muestras repetidas sobre un mismo individuo.

Consideramos $d = (x_1 - y_1, x_2 - y_2, \ldots)$ la muestra que obtenemos al realizar las diferencias correspondientes. Tenemos entonces $\mu_D = \mu_x - \mu_y$, y $\sigma_D^2 = \sigma_x^2 + \sigma_y^2 - 2\rho\sigma_x\sigma_y$.

$$Q(X, Y; \mu_x, \mu_y) = \frac{\bar{d} - \mu_D}{s_d/\sqrt{n}} \sim t_{n-1} \tag{3.16}$$

$$IC_{1-\alpha}(\mu_x - \mu_y) = \left[\bar{d} + t_{n-1;\alpha/2}\frac{s_d}{\sqrt{n}}, \bar{d} + t_{n-1;1-\alpha/2}\frac{s_d}{\sqrt{n}}\right] \tag{3.17}$$

Ejemplo 12: *Para comparar la velocidad de dos máquinas de diferentes marcas que realizan el mismo trabajo, se mide el tiempo empleado por cada una de ellas durante cinco días. Calcular el correspondiente intervalo de confianza al 95 % para la diferencia de medias.*

```
maq.a<-c(110,125,141,113,182)
maq.b<-c(102,120,135,114,175)
t.test(maq.a,maq.b,conf.level= 0.95,paired=T)$conf
```

3.2.3. IC sobre proporciones

En este apartado calculamos intervalos de confianza para una proporción poblacional y para la diferencia de dos o más proporciones. Si disponemos de una muestra grande, generalmente por encima de 30 podemos usar la aproximación normal para proporciones:

$$p \sim N\left(\hat{p}, \frac{\hat{p}(1-\hat{p})}{n}\right),$$

con $\hat{p}$ la proporción muestral.

IC de una proporción poblacional

$$IC_{1-\alpha}(p) = \left[\hat{p} + z_{\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}, \hat{p} + z_{1-\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}\right] \tag{3.18}$$

En R ya existe la función *prop.test()* que calcula los intervalos de confianza para una proporción y para la diferencia de proporciones.

Ejemplo 13: *Se desea conocer el intervalo de confianza de la proporción de industrias que tienen informatizada su gestión de almacenes. Para ello, se encuesta a 200 empresas, de las que 157 están ya informatizadas.*

```
# Debemos proporcionar el número de éxitos y el
# total de ensayos realizados
prop.test(157,200,conf.level= 0.95)$conf
# Redondeando
round(prop.test(157,200,conf.level= 0.95)$conf,3)
```

IC de la diferencia de proporciones

Utilizamos de nuevo la aproximación por la normal y obtenemos que:

$$p_x - p_y \sim N\left(\hat{p}_x - \hat{p}_y, s^2_{p_x-p_y}\right),$$

con $s^2_{p_x-p_y} = \frac{\hat{p}_x(1-\hat{p}_x)}{n_x} + \frac{\hat{p}_y(1-\hat{p}_y)}{n_y}$. De esta forma:

$$IC_{1-\alpha}(p_x - p_y) = \left[\hat{p}_x - \hat{p}_y + z_{\alpha/2}\sqrt{s^2_{p_x-p_y}}, \hat{p}_x - \hat{p}_y + z_{1-\alpha/2}\sqrt{s^2_{p_x-p_y}}\right] \tag{3.19}$$

Ejemplo 14: *Se desea comprobar si un nuevo fármaco produce mejoría en ciertos individuos enfermos. Para comprobar su eficacia se comparan los resultados con un fármaco anterior. Tomamos dos muestras, de forma que el nuevo fármaco resulta efectivo en 120 de las 225 personas bajo tratamiento, mientras que con el fármaco antiguo mejoran 90 de 185. Vamos a obtener un intervalo de confianza para la diferencia de proporiones.*

```
# Debemos proporcionar el número de éxitos y el
# total de ensayos realizados en cada muestra
prop.test(c(120,90),c(225,185),conf.level=0.95)$conf
# Redondeando
round(prop.test(c(120,90),c(225,185),conf.level=0.95)$conf,3)
```

3.2.4. IC de la media de una Poisson

De nuevo, como en el caso de proporciones, usamos la aproximación de la normal para muestras grandes. Obtenemos que para un variable $Po(\lambda)$:

$$\bar{x} \sim N\left(\lambda, \frac{\lambda}{n}\right).$$

Por tanto,

$$IC_{1-\alpha}(\lambda) = \left[\bar{x} + z_{\alpha/2}\sqrt{\frac{\bar{x}}{n}}, \bar{x} + z_{1-\alpha/2}\sqrt{\frac{\bar{x}}{n}}\right] \tag{3.20}$$

Ejemplo 15: *Calculemos el intervalo de confianza de la media de la tasa de mortalidad infantil (por 1000 nacidos vivos) en los siguientes países:*

```
# Calculemos el intervalo
media=mean(mort)
alpha=0.05
round(c(media+qnorm(alpha/2)*sqrt(media/length(mort)),
media+qnorm(1-alpha/2)*sqrt(media/length(mort))),3)
```

3.3. Contraste de hipótesis paramétricos

Un contraste o test de hipótesis es una regla de decisión que nos permite optar por un valor u otro del parámetro o espacio paramétrico (Θ) considerado.

Antes de realizar el contraste definimos:

$$\begin{aligned} H_0: &\quad \theta \in \Theta_0 \quad \text{(Hipótesis nula)} \\ H_1: &\quad \theta \in \Theta_1 \quad \text{(Hipótesis alternativa)} \end{aligned}$$

con $\Theta = \Theta_0 \cup \Theta_1$.

La solución dada al problema de los contrastes de las dos hipótesis implica la posibilidad de acertar o fracasar en la elección, al no saber con certeza cuál es la verdadera. Se definen entonces:

$$\alpha = Pr(\text{error tipo I}) = Pr(\text{rechazar } H_0 | H_0 \text{ cierta}),$$

$$\beta = Pr(\text{error tipo II}) = Pr(\text{rechazar } H_1 | H_1 \text{ cierta}),$$

$$1 - \beta == \text{potencia} = Pr(\text{rechazar } H_0 | H_1 \text{ cierta}).$$

La forma de resolver el contraste consiste en:

- Una vez planteadas H_0 y H_1 se toma un m.a.s. y se construye un estadístico de contraste ($C(X)$) que mide la distancia entre el valor del parámetro bajo H_0, y el que le podríamos asignar basándonos en la información muestral. Por ejemplo, si planteamos el contraste $H_0 : \theta = \theta_0$ frente a $H_1 : \theta \neq \theta_0$, un estadístico de contraste habitual es:

$$C = \frac{\hat{\theta} - \theta_0}{\sqrt{var(\hat{\theta})}} \sim F,$$

  con $\hat{\theta}$ una estimación de θ proporcionada por la información muestral, y F la función de distribución del estadístico de contraste bajo H_0.

- Se fija un nivel de significación α. Se calcula la correspondiente región crítica o región de rechazo de H_0 (R) o un intervalo de confianza (IC) para θ:

  - si el contraste es bilateral,

$$\begin{aligned} H_0: &\quad \theta = \theta_0 \\ H_1: &\quad \theta \neq \theta_0 \end{aligned}$$

$$R = \{C \leq qF_{\alpha/2}\} \cup \{C \geq qF_{1-\alpha/2}\},$$

$$IC = \left[\hat{\theta} + qF_{\alpha/2}\sqrt{var(\hat{\theta})} \quad , \quad \hat{\theta} + qF_{1-\alpha/2}\sqrt{var(\hat{\theta})}\right],$$

- si el contraste es unilateral izquierdo,

$$\begin{aligned} H_0: &\quad \theta = \theta_0 \text{ o} \quad H_0: \theta \geq \theta_0 \\ H_1: &\quad \theta < \theta_0 \end{aligned}$$

$$R = \{C \leq qF_\alpha\},$$

$$IC = \left[\hat{\theta} + qF_\alpha \sqrt{var(\hat{\theta})} \quad , \quad +\infty\right],$$

- si el contraste es unilateral derecho,

$$\begin{aligned} H_0: &\quad \theta = \theta_0 \text{ o} \quad H_0: \theta \leq \theta_0 \\ H_1: &\quad \theta > \theta_0 \end{aligned}$$

$$R = \{C \geq qF_{1-\alpha}\},$$

$$IC = \left[-\infty \quad , \quad \hat{\theta} + qF_{1-\alpha} \sqrt{var(\hat{\theta})}\right],$$

con qF_ν el percentil 100ν de la distribución. Rechazamos H_0 si el valor del estadístico de contraste para los datos de la muestra $c_{obs} \in R$ o el valor de contraste $\theta_0 \notin IC$.

- Sin embargo, el procedimiento general consiste en calcular la probabilidad de obtener una discrepancia mayor o igual que la observada cuando H_0 es cierta. Esta probabilidad es lo que denominamos p-valor. Cuando el p-valor es inferior a la significatividad fijada se rechaza H_0. En cada situación calculamos el p-valor como:

  - si el contraste es bilateral y F es simétrica,

$$p = Pr(|C| \geq |c_{obs}| \mid H_0) = 2(1 - F(|c_{obs}|))$$

  - si el contraste es bilateral y F no es simétrica,

$$\begin{aligned} p &= 2min\{Pr(C \leq c_{obs} \mid H_0), Pr(C \geq c_{obs} \mid H_0)\} \\ &= 2min\{F(c_{obs}, 1 - F(c_{obs})\} \end{aligned}$$

  - si el contraste es unilateral izquierdo,

$$p = Pr(C \leq c_{obs} \mid H_0) = F(c_{obs})$$

  - si el contraste es unilateral derecho,

$$p = Pr(C \geq c_{obs} \mid H_0) = 1 - F(c_{obs})$$

con c_{obs} el valor del estadístico de contraste para los datos de la muestra.

3.3.1. Contrastes de la media y varianza de una población

Contrastes para μ:

$$(I)\begin{cases} H_0 & : \mu = \mu_0 \\ H_1 & : \mu \neq \mu_0 \end{cases} \qquad (II)\begin{cases} H_0 & : \mu \leq \mu_0 \\ H_1 & : \mu > \mu_0 \end{cases} \qquad (III)\begin{cases} H_0 & : \mu \geq \mu_0 \\ H_1 & : \mu < \mu_0 \end{cases}$$

Contrastes para σ^2:

$$(Ib)\begin{cases} H_0 & : \sigma^2 = \sigma_0^2 \\ H_1 & : \sigma^2 \neq \sigma_0^2 \end{cases} \qquad (IIb)\begin{cases} H_0 & : \sigma^2 \leq \sigma_0^2 \\ H_1 & : \sigma^2 > \sigma_0^2 \end{cases} \qquad (IIIb)\begin{cases} H_0 & : \sigma^2 \geq \sigma_0^2 \\ H_1 & : \sigma^2 < \sigma_0^2 \end{cases}$$

$\Longrightarrow$ De la media de una población normal con varianza conocida

Estadístico de contraste:

$$z_{obs} = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} \sim N(0,1) \tag{3.21}$$

Ejemplo 16: *En un estudio sobre calidad de vida de los pacientes que sufren depresión , se han calculado tres índices para medir esta relación:*

- *Cv.f: Componente somático o físico relacionado con la depresión.*
- *Cv.e: Componente emocional relacionado con la depresión.*
- *Cv=(Cv.f+Cv.e): Puntuación total de la calidad de vida relacionada con la depresión.*

La varianza de Cv es conocida e igual a 1700. Se desea saber si la media de dicha variable puede ser considerada igual a 100 frente a que sea distinta de 100.

```
# Representemos gráficamente los datos
par(mfrow=c(1,2))
hist(Cv);qqnorm(Cv)
# Representemos el contraste
dtip=sqrt(1700)
mu.0=100
Cv.new=(Cv-mu.0)/dtip
zobs=sqrt(length(Cv))*(mean(Cv)-mu.0)/dtip
alpha=0.05
par(mfrow=c(1,1))
plot(seq(-4,4,0.001),dnorm(seq(-4,4,0.001)),type="l",xlab="",ylab="")
```

```
# Región Crítica
s1=seq(-4,q1,0.001)
s2=seq(q1,-4,-0.001)
polygon(x=c(s1,s2),y=c(rep(0,length(s1)),dnorm(s2)),col="red")
s1=seq(q2,4,0.001)
s2=seq(4,q2,-0.001)
polygon(x=c(s1,s2),y=c(rep(0,length(s1)),dnorm(s2)),col="red")

# Estadístico contraste
segments(zobs,0,zobs,dnorm(zobs),col ="blue",lwd=2)

########################################
# Resolvamos el contraste con el p-valor
########################################
p.valor=2*(1-pnorm(abs(zobs)))
p.valor
```

$\Longrightarrow$ De la media de una población normal con varianza desconocida

Estadístico de contraste:

$$t_{obs} = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} \sim t_{n-1} \tag{3.22}$$

Ejemplo 17: *En las condiciones del ejemplo 16 asumiendo que la varianza es desconocida, vamos a resolver los contrastes (I), (II), y (III).*

```
# Representemos el contraste
n=length(Cv)
dtip=sd(Cv)
mu.0=100
Cv.new=(Cv-mu.0)/dtip
tobs=sqrt(length(Cv))*(mean(Cv)-mu.0)/dtip
alpha=0.05

par(mfrow=c(3,1))
plot(seq(-5,5,0.001),dt(seq(-5,5,0.001),n-1),type="l",xlab="",ylab="")
# Región Crítica bilateral
q1=qt(alpha/2,n-1)
q2=qt(1-alpha/2,n-1)
s1=seq(-5,q1,0.001)
s2=seq(q1,-5,-0.001)
```

```
polygon(x=c(s1,s2),y=c(rep(0,length(s1)),dt(s2,n-1)),col="red")
s1=seq(q2,5,0.001)
s2=seq(5,q2,-0.001)
polygon(x=c(s1,s2),y=c(rep(0,length(s1)),dt(s2,n-1)),col="red")
# Estadístico contraste
segments(tobs,0,tobs,dt(tobs,n-1),col ="blue",lwd=2)

plot(seq(-5,5,0.001),dt(seq(-5,5,0.001),n-1),type="l",xlab="",ylab="")
# Región Crítica unilateral derecho
q1=qt(1-alpha,n-1)
s1=seq(q1,5,0.001)
s2=seq(5,q1,-0.001)
polygon(x=c(s1,s2),y=c(rep(0,length(s1)),dt(s2,n-1)),col="yellow")
# Estadístico contraste
segments(tobs,0,tobs,dt(tobs,n-1),col ="blue",lwd=2)

plot(seq(-5,5,0.001),dt(seq(-5,5,0.001),n-1),type="l",xlab="",ylab="")
# Región Crítica unilateral izquierdo
q1=qt(alpha,n-1)
s1=seq(-5,q1,0.001)
s2=seq(q1,-5,-0.001)
polygon(x=c(s1,s2),y=c(rep(0,length(s1)),dt(s2,n-1)),col="green")
# Estadístico contraste
segments(tobs,0,tobs,dt(tobs,n-1),col ="blue",lwd=2)

########################################
# Resolvamos con la función t.test()
########################################
# (I) Bilateral
t.test(Cv,alternative ="two.sided",mu =100,conf.level=1-alpha)
# (II) Unilateral derecho
t.test(Cv,alternative ="greater",mu =100,conf.level=1-alpha)
# (III) Unilateral izquierdo
t.test(Cv,alternative ="less",mu =100,conf.level=1-alpha)
```

$\Longrightarrow$ De la varianza de una población normal

Estadístico de contraste:

$$\aleph_{obs} = \frac{(n-1)s^2}{\sigma_0^2} \sim \chi^2_{n-1} \tag{3.23}$$

Ejemplo 18: *En las condiciones del ejemplo 17, vamos a resolver los contrastes (Ib), (IIb), y (IIIb) con* $\sigma_0^2 = 1800$.

```
########################################
# Calculemos p.valores
########################################
alpha=0.05
sigma2.0=1800
jiobs=(length(Cv)-1)*var(Cv)/sigma2.0
p1=pchisq(jiobs,length(Cv)-1)
# (Ib)
pvalor=2*min(p1,1-p1);pvalor
# (IIb)
pvalor=1-p1;pvalor
# (IIIb)
pvalor=p1;pvalor
```

3.3.2. Diferencia de medias y comparación de varianzas

Contrastes para la diferencia $\mu_x - \mu_y$:

$$(I)\begin{cases} H_0 & : \mu_x - \mu_y = \delta_0 \\ H_1 & : \mu_x - \mu_y \neq \delta_0 \end{cases} \qquad (II)\begin{cases} H_0 & : \mu_x - \mu_y \leq \delta_0 \\ H_1 & : \mu_x - \mu_y > \delta_0 \end{cases} \qquad (III)\begin{cases} H_0 & : \mu_x - \mu_y \geq \delta_0 \\ H_1 & : \mu_x - \mu_y < \delta_0 \end{cases}$$

Contrastes para igualdad de σ_x^2 y σ_y^2:

$$(Ib)\begin{cases} H_0 & : \frac{\sigma_x^2}{\sigma_y^2} = 1 \\ H_1 & : \frac{\sigma_x^2}{\sigma_y^2} \neq 1 \end{cases} \qquad (IIb)\begin{cases} H_0 & : \frac{\sigma_x^2}{\sigma_y^2} \leq 1 \\ H_1 & : \frac{\sigma_x^2}{\sigma_y^2} > 1 \end{cases} \qquad (IIIb)\begin{cases} H_0 & : \frac{\sigma_x^2}{\sigma_y^2} \geq 1 \\ H_1 & : \frac{\sigma_x^2}{\sigma_y^2} < 1 \end{cases}$$

$\Longrightarrow$ Diferencia de medias con varianzas conocidas: muestras independientes

Estadístico de contraste:

$$z_{obs} = \frac{(\bar{x} - \bar{y}) - \delta_0}{\sqrt{\frac{\sigma_x^2}{n_x} + \frac{\sigma_y^2}{n_y}}} \sim N(0,1) \tag{3.24}$$

Ejemplo 19: *En un estudio sobre un nuevo fármaco para el tratamiento de presión diastólica se trabaja con dos grupos de pacientes: tratados (1) y controles(0). Se mide la presión diastólica al inicio y fin de tratamiento. En un primer momento estamos interesados comparar la diferencia (Inicio-Fin) para tratados y controles. Las variables vienen identificadas como sigue:*

- *trat: tratamiento recibido.*
- *inicio: presión diastólica al inicio.*
- *fin=presión diastólica al fin.*

Asumimos que la varianza de la diferencia para tratados es 44 y para controles es de 27.

```
dif=inicio-fin
# Representemos gráficamente los datos
par(mfrow=c(2,2))
hist(dif[trat==1]);qqnorm(dif[trat==1])
hist(dif[trat==0]);qqnorm(dif[trat==0])
############################
# Resolvamos el contraste
############################
lt=length(trat==1)
lc=length(trat==0)
mt=mean(dif[trat==1])
mc=mean(dif[trat==0])
zobs=(mt-mc)/sqrt(44/lt+27/lc)
alpha=0.05
p.valor=2*(1-pnorm(abs(zobs)))
p.valor
```

$\Longrightarrow$ Comparación de varianzas

Estadístico de contraste:

$$F_{obs} = \frac{s_x^2}{s_y^2} \sim F_{n_x-1,n_y-1} \tag{3.25}$$

Ejemplo 20: *En las condiciones del ejemplo 19, queremos comparar las varianzas de la diferencia entre tratados y controles.*

```
########################################
# Resolvamos el contraste con var.test()
########################################
var.test(dif[trat==1],dif[trat==0],ratio = 1,
           alternative ="two.sided",conf.level = 0.95)
```

$\Longrightarrow$ Diferencia de medias con varianzas desconcidas e iguales: muestras independientes

Estadístico de contraste:

$$t_{obs} = \frac{(\bar{x} - \bar{y}) - \delta_0}{s_{\bar{x}-\bar{y}}} \sim t_{n_x+n_y-2}, \tag{3.26}$$

con $s_{\bar{x}-\bar{y}} = \sqrt{\frac{(n_x-1)s_x^2+(n_y-1)s_y^2}{n_x+n_y-2}}\sqrt{\frac{1}{n_x}+\frac{1}{n_y}}$.

Ejemplo 21: *En las condiciones del ejemplo 19, queremos comparar las medias de la diferencia de controles y tratados.*

```
########################################
# Comparemos las varianzas
########################################
var.test(dif[trat==1],dif[trat==0],ratio = 1,
            alternative ="two.sided",conf.level = 0.95)
########################################
# Comparemos las medias
########################################
t.test(dif[trat==1],dif[trat==0], mu= 0,
    alternative ="two.sided",conf.level = 0.95,var.equal=T)
```

$\Longrightarrow$ Diferencia de medias con varianzas desconocidas y distintas: muestras independientes

Estadístico de contraste:

$$t_{obs} = \frac{(\bar{x} - \bar{y}) - \delta_0}{s_{\bar{x}-\bar{y}}} \sim t_{\nu}, \tag{3.27}$$

con $s_{\bar{x}-\bar{y}} = \sqrt{\frac{s_x^2}{n_x}+\frac{s_y^2}{n_y}}$, y $\nu = \frac{\left(\frac{s_x^2}{n_x}+\frac{s_y^2}{n_y}\right)^2}{\frac{(s_x^2/n_x)^2}{n_x-1}+\frac{(s_y^2/n_y)}{n_y-1}}$

Ejemplo 22: *Se están probando dos concentraciones de fármaco para la reducción de trastornos del sueño. En concreto se miden el número de dias durante el último año que los pacientes no tan tenido trastornos del sueño. Se desea comparar el número de días sin trastornos para ambos concentraciones. Los datos obtenidos aparecen a continuación:*

```
########################################
# Comparemos las varianzas
########################################
var.test(conc1,conc2,ratio = 1,
            alternative ="two.sided",conf.level = 0.95)
```

```
#######################################
# Comparemos las medias
#######################################
t.test(conc1,conc2, mu= 0,
    alternative ="two.sided",conf.level = 0.95,var.equal=F)
```

$\Longrightarrow$ Diferencia de medias con varianzas desconocidas y distintas: muestras dependientes

Estadístico de contraste:

$$t_{obs} = \frac{\bar{d} - \delta_0}{s_d/\sqrt{n}} \sim t_{n-1}, \tag{3.28}$$

con $\bar{d} = \sum d_i/n$, $d_i = x_i - y_i$, y $s_d = \sqrt{\frac{\sum(d_i - \bar{d})}{n-1}}$.

Ejemplo 23: *Se estudia a concentración de una nueva droga 5 minutos después de ser administrada y a las 6 horas. Se desea comparar la media de la concentración a los cinco minutos frente a las 6 horas. Los datos aparecen a continuación:*

```
#######################################
# Comparemos las medias
#######################################
t.test(inicio,fin, mu= 0,paired=T,conf.level = 0.95)
```

3.3.3. Comparación de K medias y varianzas

En este apartados presentamos brevemente los tests de comparación de k medias y varianzas. Hay que tener en cuenta que para que el test de medias se pueda realizar es necesario verificar en primer lugar la igualdad de varianzas.

Supongamos k poblaciones normales $N(\mu_1, \sigma_1^2), \ldots, N(\mu_k, \sigma_k^2)$ con tamaños muestrales $n_1, \ldots, n_k$. Tenemos entonces:

$x_{11}, \ldots, x_{1n_1}$ m.a. $N(\mu_1, \sigma_1^2)$	con $\bar{x}_{1\bullet}$ y s_1^2 media y varianza de la muestra 1
$x_{21}, \ldots, x_{2n_2}$ m.a. $N(\mu_2, \sigma_2^2)$	con $\bar{x}_{2\bullet}$ y s_2^2 media y varianza de la muestra 2
$\vdots$	$\vdots$
$x_{k1}, \ldots, x_{kn_k}$ m.a. $N(\mu_k, \sigma_k^2)$	con $\bar{x}_{k\bullet}$ y s_k^2 media y varianza de la muestra k

Denotamos además por $n = n_1 + \ldots + n_k$ y $\bar{x}_{\bullet\bullet} = \bar{x}_{1\bullet} + \ldots + \bar{x}_{k\bullet}/n = \sum_{i=1}^{k} \bar{x}_{i\bullet}/n$.

Estamos interesados en realizar los contrastes:

Contraste de igualdad de medias:

$$\begin{aligned} H_0 &: \mu_i = \mu_j, \qquad \forall i, j \\ H_1 &: \mu_i \neq \mu_j, \qquad \text{para algún i y j} \end{aligned}$$

Contraste de igualdad de varianzas:

$$\begin{aligned} H_0 &: \sigma_i^2 = \sigma_j^2, \qquad \forall i, j \\ H_1 &: \sigma_i^2 \neq \sigma_j^2, \qquad \text{para algún i y j} \end{aligned}$$

▪ Comparación de varianzas

Veamos en primer lugar como realizar el contraste de varianzas. Para resolver este contraste vamos a usar el test de Bartlett que se obtiene de la forma siguiente:

- Se calcula

$$S_D^2 = \frac{\sum_{i=1}^{k} s_i^2}{n-k}$$

- Calculamos el estadístico de contraste:

$$M_{obs} = \frac{1}{C}\left[(n-k)log(S_D^2) - \sum_{i=1}^{k}(n_i - 1)log(s_i^2)\right] \sim \chi_{k-1}^2,$$

con

$$C = 1 + \left[(\sum_{i=1}^{k} \frac{1}{n_i - 1}) - \frac{1}{n-k}\right]$$

El contraste resulta significativo cuando el valor de M_{obs} se mayor que que el percentil α de la distribución χ_{k-1}^2. El p-valor se calcula como

$$Pr(M \geq M_{obs}|H_0) = 1 - \chi_{k-1}^2(M_{obs}).$$

▪ Comparación de medias

Para poder realizar el test de comparación de medias es necesario construir la tabla anova que nos proporciona el estadístico de contraste. La idea básica del análisis de varianza es la siguiente: Consideremos que todas las

observaciones proceden de una misma población de forma que es posible calcular:

$$x_{ij} - \bar{x}_{\bullet\bullet},$$

elevando al cuadrado y sumando para i e j tendríamos:

$$\sum_{i=1}^{k}\sum_{j=1}^{n_k}(x_{ij} - \bar{x}_{\bullet\bullet})^2,$$

que es una estimación de la variabilidad global de todas las n observaciones (en concreto ns^2, con s^2 la varianza muestral de las n observaciones) en los k grupos. A esta parte se le denomina *suma de cuadrados total* y se denota por SS_T.

Por otro lado es posible escribir:

$$x_{ij} - \bar{x}_{\bullet\bullet} = (x_{ij} - \bar{x}_{i\bullet}) + (\bar{x}_{i\bullet} - \bar{x}_{\bullet\bullet}),$$

que elevando al cuadrado y sumando para i e j nos da

$$\sum_{i=1}^{k}\sum_{j=1}^{n_k}(x_{ij} - \bar{x}_{\bullet\bullet})^2 = \sum_{i=1}^{k}\sum_{j=1}^{n_k}(x_{ij} - \bar{x}_{i\bullet})^2 + \sum_{i=1}^{k} n_i(\bar{x}_{i\bullet} - \bar{x}_{\bullet\bullet})^2.$$

De esta forma la variabilidad total de las n observaciones queda dividida en dos trozos, uno debido a la variabilidad entre las muestras (SS_E) y otro debido a la variabilidad dentro de cada muestra (SS_D). Por tanto, si todas las observaciones proceden de una misma población es razonable pensar que SS_E debe ser aproximadamente SS_D. Esta es la base para obtener el estadístico de contraste para la comparación de k medias. Para ello se construye la tabla de análisis de la varianza (ANOVA) como sigue:

Construcción de la tabla anova:

Fuente de variación	gl	Suma de cuadrados	Cuadrados Medios
entre tratamientos	$k-1$	$SS_E = \sum_{i=1}^{k} n_i(\bar{x}_{i\bullet} - \bar{x}_{\bullet\bullet})^2$	$MS_E = SS_E/(k-1)$
dentro de tratamientos	$n-k$	$SS_D = \sum_{i=1}^{k}\sum_{j=1}^{n_i}(x_{ij} - \bar{x}_{i\bullet})^2$	$MS_D = SS_D/(n-k)$
total	$n-1$	$SS_T = SS_E + SS_D$	

El estadístico de contraste viene dado por:

$$f_{obs} = \frac{MS_E}{MS_D} \sim F_{k-1,n-k}$$

El contraste resulta significativo cuando el valor de f_{obs} se mayor que que el percentil α de la distribución $F_{k-1,n-k}$. El p-valor se calcula como

$$Pr(F \geq f_{obs}|H_0) = 1 - F_{k-1,n-k}(f_{obs}).$$

Ejemplo 24: *Se están probando cinco nuevos tratamientos para la reducción de peso. Las variables recogidas son las siguientes:*

- *trat: Tratamiento administrado,*
- *ppp: Pérdida de peso promedio mensual en Kg,*
- *eficacia: Eficacia subjetiva del tratamiento a largo plazo en cinco niveles*

  0: no eficaz
  1: intermedio 0-2
  2: moderadamente eficaz
  3: intermedio 2-4
  4: eficaz

Los datos aparecen a continuación:

```
# Representamos gráficamente los datos
par(mfrow=c(1,1))
boxplot(ppp ~ factor(trat))
# Comparemos las varianzas
bartlett.test(ppp ~ factor(trat), data = datos)
# Comparemos las medias
oneway.test(ppp ~ factor(trat),data=datos,var.equal = T)
# Comparaciones dos a dos ajustados por Bonferroni
pairwise.t.test(ppp, factor(trat), p.adj = "bonf")
```

3.3.4. Comparación de proporciones

Supongamos que la muestra consiste en n pruebas independientes con dos posibles resultados, "éxito´´ o "fracaso´´, con n suficientemente grande ($n\pi > 5$ y $n(1-\pi) > 5$).

Contrastes para π:

$$(I)\begin{cases} H_0 & : \pi = \pi_0 \\ H_1 & : \pi \neq \pi_0 \end{cases} \qquad (II)\begin{cases} H_0 & : \pi \leq \pi_0 \\ H_1 & : \pi > \pi_0 \end{cases} \qquad (III)\begin{cases} H_0 & : \pi \geq \pi_0 \\ H_1 & : \pi < \pi_0 \end{cases}$$

$\Longrightarrow$ De una proporción: n grande.

Estadístico de contraste:

Utilizando corrección por continuidad,

$$(I) \quad z_{obs} = \frac{\hat{\pi} - \pi_0}{\sqrt{\frac{\pi_0(1-\pi_0)}{n}}} \sim N(0,1)$$

$$(II) \quad z_{obs} = \frac{\hat{\pi} - \pi_0 - 0{,}5 * n}{\sqrt{\frac{\pi_0(1-\pi_0)}{n}}} \sim N(0,1)$$

$$(III) \quad z_{obs} = \frac{\hat{\pi} - \pi_0 + 0{,}5 * n}{\sqrt{\frac{\pi_0(1-\pi_0)}{n}}} \sim N(0,1) \tag{3.29}$$

Ejemplo 25: *En un estudio sobre un nuevo fármaco sobre 950 personas, se observa que 524 presentan mejoría mientras que el resto no mejoran. Se desea saber si la proporción de mejora es del 50 % o si por el contrario es superior al 50 %.*

```
# Usamos la función prop.test()
prop.test(524,950,alternative="greater",conf.level = 0.95)
```

$\Longrightarrow$ De una proporción: test exacto.

Cuando n es pequeño podemos a la normal y debemos recurrir a calcular directamente los p-valores con las probabilidades de la distribución Binomial asociada al número de éxitos.

Estadístico de contraste:

$$y_{obs} = \text{número de éxitos.} \tag{3.30}$$

Ejemplo 26: *En un estudio sobre un nuevo fármaco sobre 20 personas, se observa que 13 presentan mejoría mientras que el resto no mejoran. Se desea saber si la proporción de mejora es del 50 % o si por el contrario es distinto al 50 %.*

```
# Usamos la función binom.test()
binom.test(13,20,p=0.5,alternative="two.sided",conf.level=0.95)
```

$\Longrightarrow$ De la diferencia de proporciones: muestras independientes.

Estadístico de contraste:

Utilizando corrección por continuidad,

$$z_{obs} = \frac{\hat{\pi}_x - \hat{\pi}_y - \delta_0}{\sqrt{\frac{\hat{\pi}_x(1-\hat{\pi}_x)}{n_x} + \frac{\hat{\pi}_y(1-\hat{\pi}_y)}{n_y}}} \sim N(0,1) \tag{3.31}$$

Ejemplo 27: *En un estudio sobre un nuevo fármaco tenemos dos grupos de pacientes, 400 tratados y 650 controles. De estos, 250 de los tratados presentan mejoría tras cierto tiempo de tratamiento, mientras que sólo 150 de los controles presentan mejoría. Se desea contrastar si el proporción de mejora en los tratados es igual a la de los controles.*

```
# Usamos la función prop.test()
prop.test(c(250,150),c(400,650),conf.level=0.95)
```

3.3.5. Cálculo del tamaño muestral para resolver un contraste

Un problema muy relacionado con la resolución de un contraste es el calculo del tamaño muestral necesario para resolver dicho contraste con un nivel de significatividad (α) y potencia ($1-\beta$) deseados. En este apartado vamos a calcular los tamaños muestrales para:

- (I) Contraste sobre la media de una población normal con varianza desconocida.
- (II) Contraste sobre la diferencia de medias de poblaciones normales con varianzas desconocidas.
- (III) Contraste sobre la diferencia en muestras emparejadas.
- (V) Contraste sobre la diferencia de proporciones.

• Cálculo de n para resolver (I).

Queremos calcular n para resolver los contrastes sobre μ:

$$(B)\begin{cases} H_0 & : \mu = \mu_0 \\ H_1 & : \mu \neq \mu_0 \end{cases} \qquad (US)\begin{cases} H_0 & : \mu = \mu_0 \\ H_1 & : \mu > \mu_0 \end{cases} \qquad (UI)\begin{cases} H_0 & : \mu = \mu_0 \\ H_1 & : \mu < \mu_0 \end{cases}$$

Para resolver cualquiera de estos contrastes vamos a usar el estadístico de contraste dado en (3.22). Bajo H_0 el estadístico t_{obs} dado en (3.22) se distribuye según una t_{n-1},

- Contraste US:
  Bajo H_1 podemos expresar dicha hipótesis como $\mu = \mu_0 + \delta$ con $\delta > 0$, donde δ es la mínima diferencia que consideramos para declarar el contraste como significativo. En este caso:

$$\frac{(\bar{x} - \mu_0) - \delta}{s/\sqrt{n}} \sim t_{n-1}.$$

  La región critica viene dada por $\{t_{obs} > t_{n-1;\alpha}\}$ y podemos calcular la potencia como

$$\begin{aligned} 1 - \beta &= Pr\left(\frac{(\bar{x} - \mu_0)}{s/\sqrt{n}} > t_{n-1;\alpha} \mid H_1 \text{ cierta } \right) \\ &= Pr\left(\frac{(\bar{x} - \mu_0) - \delta}{s/\sqrt{n}} > t_{n-1;\alpha} - \frac{\delta}{s/\sqrt{n}} \mid H_1 \text{ cierta } \right), \end{aligned}$$

  de donde obtenemos:

$$-t_{n-1;1-\beta} = t_{n-1;\alpha} - \frac{\delta}{s/\sqrt{n}},$$

  y despejando:

$$n = \left[\frac{s[t_{n-1;\alpha} + t_{n-1;1-\beta}]}{\delta}\right]^2$$

  El tamaño para UI se obtiene de la misma forma.
- Contraste B:
  En este caso la región crítica viene dada por $\{t_{obs} > t_{n-1;1-\alpha/2}\} \cup \{t_{obs} < t_{n-1;\alpha/2}\}$, y la potencia la podemos expresar como:

$$\begin{aligned} 1 - \beta &= Pr\left(\frac{(\bar{x} - \mu_0)}{s/\sqrt{n}} > t_{n-1;1-\alpha/2} \mid H_1\right) + Pr\left(\frac{(\bar{x} - \mu_0)}{s/\sqrt{n}} < t_{n-1;\alpha/2} \mid H_1\right) \\ &= Pr\left(\frac{(\bar{x} - \mu_0) - \delta}{s/\sqrt{n}} > -t_{n-1;\alpha/2} - \frac{\delta}{s/\sqrt{n}} \mid H_1\right) + \\ &\quad Pr\left(\frac{(\bar{x} - \mu_0) - \delta}{s/\sqrt{n}} < t_{n-1;\alpha/2} - \frac{\delta}{s/\sqrt{n}} \mid H_1\right) \\ &= T_{n-1}\left(t_{n-1;\alpha/2} + \frac{\delta}{s/\sqrt{n}}\right) + T_{n-1}\left(t_{n-1;\alpha/2} - \frac{\delta}{s/\sqrt{n}}\right) \end{aligned}$$

  donde $T_{n-1}(a)$ es la función de distribución de un t de Student con $n-1$ grados de libertad evaluada en el punto a. En este caso no es posible despejar n y hay que realizar un proceso iterativo para obtener el tamaño muestral.

Ejemplo 28: *Una empresa farmacéutica esta diseñando un ensayo clínico sobre un nuevo tratamiento en el que la variable de interés es de tipo cuantitativo. Se sabe que el nuevo fármaco resulta efectivo si la diferencia entre la media de la variable de interés difiere en 2 unidades respecto de un valor obtenido por otro fármaco del mismo tipo. Por experiencias previas se conoce que la desviación típica de la variable de interés es 15. Se desea calcular el tamaño muestral correspondiente a una significatividad de 0.05 y una potencia del 80 % tanto para los contrastes (B) y (US).*

```
# Usamos la función power.t.test() que sirve
# tanto para calcular tamaños muestrales, significatividades
# y potencias.
power.t.test(n=NULL, delta=2, sd=15, sig.level=0.05, power=0.8,
    type="one.sample",alternative="one.sided")
power.t.test(n=NULL, delta=2, sd=15, sig.level=0.05, power=0.8,
    type="one.sample",alternative="two.sided", strict=FALSE)
```

- **Cálculo de n para resolver (II).**

  Queremos calcular n para resolver los contrastes sobre μ_x y μ_y:

  $$(B)\begin{cases} H_0 & : \mu_x = \mu_y \\ H_1 & : \mu_x \neq \mu_y \end{cases} \qquad (US)\begin{cases} H_0 & : \mu_x = \mu_y \\ H_1 & : \mu_x > \mu_y \end{cases} \qquad (UI)\begin{cases} H_0 & : \mu_x = \mu_y \\ H_1 & : \mu_x < \mu_y \end{cases}$$

  En este caso el R sólo trabaja con varianzas iguales y por tanto el estadístico de contraste viene dado en (3.26) con $\delta_0 = 0$. Sin embargo podríamos calcular también el tamaño muestral en la situación de varianzas distintas, y entonces deberíamos utilizar el estadístico de contraste dado en (3.27) con $\delta_0 = 0$. Además asumimos que ambos grupos tienen tamaños iguales $n = n_1 = n_2$

  Bajo H_0 tenemos que t_{obs} se distribuye según una $t_{2(n-1)}$, y bajo H_1 tenemos que

  $$t_{obs} - \frac{\delta}{s_{\bar{x}-\bar{y}}} \sim t_{2(n-1)},$$

  con $s_{\bar{x}-\bar{y}} = s\sqrt{2}/\sqrt{n}$, donde s es la desviación típica que hemos asumido igual para ambos grupos.

  El cálculo de la potencia para todos los contrastes es similar al caso (I) obteniéndose las siguientes expresiones para n:

  - *US*

    $$n = \left[\frac{s\sqrt{2}[t_{2(n-1);\alpha} + t_{2(n-1);1-\beta}]}{\delta}\right]^2$$

- B

  De nuevo en este caso no hay una expresión explícita y debemos proceder numéricamente con la expresión

$$1-\beta = T_{2(n-1)}\left(t_{2(n-1);\alpha/2} + \frac{\delta}{s\sqrt{2}/\sqrt{n}}\right) + T_{2(n-1)}\left(t_{2(n-1);\alpha/2} - \frac{\delta}{s\sqrt{2}/\sqrt{n}}\right)$$

Ejemplo 29: *En la situación del ejemplo 28 se desea comparar el comportamiento medio de un grupo de individuos a los que se les da tratamiento y otro grupo a los que se les da placebo. La empresa estima que la diferencia debe ser de 10 unidades entre la media de tratados y controles. Si la desviación típica es de 15. Calcular el tamaño muestral correspondiente a una significatividad de 0.05 y una potencia del 80 % tanto para los contrastes (B) y (US).*

```
# Usamos la función power.t.test()
power.t.test(n=NULL, delta=10, sd=15, sig.level=0.05, power=0.8,
    type="two.sample",alternative="one.sided")
power.t.test(n=NULL, delta=10, sd=15, sig.level=0.05, power=0.8,
    type="two.sample",alternative="two.sided", strict=FALSE)
```

- **Cálculo de n para resolver (III).**

  Puesto que las muestra están emparejadas debemos trabajar con las observaciones obtenidas al calcular las diferencias entre ellas. En ese caso nos quedaríamos con una única muestra y los cálculos son los mismo que para el caso (I).

Ejemplo 30: *En la situación del ejemplo 29 supongamos que los tratados y controles están emparejados. Calcular los tamaños muestrales en dichas condiciones.*

```
# Usamos la función power.t.test()
power.t.test(n=NULL, delta=10, sd=15, sig.level=0.05, power=0.8,
    type="paired",alternative="one.sided")
power.t.test(n=NULL, delta=10, sd=15, sig.level=0.05, power=0.8,
    type="paired",alternative="two.sided", strict=FALSE)
```

- **Cálculo de n para resolver (IV).**

  En este caso vamos a usar el estadístico de contraste dado en (3.29). Los tamaños muestrales se obtienen:

- Contraste unilateral

$$n = \left[\frac{z_\alpha \sqrt{2p(1-p)} + z_{1-\beta}\sqrt{p_1(1-p_1)+p_2(1-p_2)}}{|p_1 - p_2|\sqrt{p_1(1-p_1)+p_2(1-p_2)}} \right]^2$$

  con $p = (p_1 + p_2)/2$.

- Contraste bilateral
  Hay que resolver la ecuación:

$$\begin{aligned} 1-\beta \;\; &= \Phi\left(\sqrt{n}|p_1 - p_2| - z_{\alpha/2}\frac{\sqrt{2p(1-p)}}{\sqrt{p_1(1-p_1)+p_2(1-p_2)}} \right) + \\ &\quad \Phi\left(\sqrt{n}|p_1 - p_2| + z_{\alpha/2}\frac{\sqrt{2p(1-p)}}{\sqrt{p_1(1-p_1)+p_2(1-p_2)}} \right). \end{aligned}$$

Ejemplo 31: *De nuevo la empresa farmacéutica esta interesada en calcular el tamaño muestral necesario para detectar diferencias significativas para una variable que mide la proporción de mejora de un grupo de individuos sujetos a un nuevo tratamiento frente a los que se les da placebo. Se desea contrastar los valores de 0.6 para los tratados y 0.15 para los controles con* $\alpha = 0{,}05$, $1 - \beta = 0{,}8$.

```
# Usamos la función power.prop.test()
power.prop.test(n=NULL,p1=0.6,p2=0.15,sig.level=0.05,
     power=0.8,alternative="one.sided")
power.prop.test(n=NULL,p1=0.6,p2=0.15,sig.level=0.05,
     power=0.8,alternative="two.sided", strict=FALSE)
```

3.4. Contraste de hipótesis no paramétricos

Si la distribución es de los datos es tal que no se puede asumir normalidad o no se puede contrastar la normalidad, lo habitual es usar métodos no paramétricos para la comparación de medias y varianzas. Dichos métodos están basados en el cálculo de rangos para las observaciones de la muestra.

3.4.1. Contrastes sobre medias y varianzas

De la mediana de una población.

Este contraste requiere simetría en torno a la mediana. Supongamos que M es la mediana de una población continua y simétrica. Nos interesa realizar los contrastes:

$$H_0 : M = M_0$$

frente a:

$$H_1 : M \neq M_0; \quad H_1 : M > M_0; \quad H_1 : M < M_0.$$

Si H_0 es cierta, las observaciones se encontrarán simétricamente distribuidas en torno a la mediana, y las n diferencias $x_i - M_0$ estarán simétricamente distribuidas en torno a 0.

El procedimiento para obtener el estadístico de contraste consiste en ordenar de forma creciente los valores absolutos de las diferencias, y asignamos a cada una de ellas el rango (posición) que ocupan. En caso de empates calculamos el rango promedio entre todos los empates.

El estadístico de contraste T^+ de Wilcoxon consiste en la suma de rangos que corresponden a las diferencias que son positivas antes de tomar valor absoluto. Cuando $n > 20$ podemos aproximar la distribución del estadístico mediante una normal como sigue:

$$z_{obs} = \frac{T^+ - E(T^+) - 0{,}5}{\sqrt{var(T^+)}} \sim N(0,1),$$

con $E(T^+) = n(n+1)/4$ y $var(T^+) = n(n+1)(2n+1)/24$.

Ejemplo 32: *En la situación del ejemplo 24 se desea contrastar si la mediana de la eficacia es igual a 3 frente a que sea inferior a 3, lo que daría una indicación de dicha variable no es simétrica.*

```
# En primer lugar dibujemos los datos
boxplot(eficacia)
# Usamos la función wilcox.test()
# Como tenemos 176 datos usamos la aproximación de la normal
# con la corrección de continuidad (correct) y no calculamos
# el p-valor exacto (exact).
wilcox.test(eficacia,alternative="less",mu=3,exact=NULL
     ,correct=TRUE,conf.int=T,conf.level=0.95)
```

De las medianas para 2 muestras independientes.

Este test se denomina también test de la suma de rangos de Wilcoxon. Se utiliza para contrastar si 2 muestras extraídas al azar pertenecen a una misma población. Planteamos los contrastes:

$$H_0 : M_1 = M_2$$

frente a:

$$H_1 : M_1 \neq M_2; \quad H_1 : M_1 > M_2; \quad H_1 : M_1 < M_2,$$

con M_1 y M_2 las medianas de las correspondientes muestras. Si n_1 y n_2 son los tamaños muestrales respectivos, se calcula:

$$U_1 = n_1 n_2 + \frac{n_1(n_1+1)}{2} - R_1,$$

$$U_2 = n_1 n_2 + \frac{n_2(n_2+1)}{2} - R_2,$$

donde R_i es igual a la suma de los rangos de las muestras respectivas donde estos se han asignado de forma conjunta. Se define el estadístico U de Mann-Whitney como:

$$U_m = min(U_1, U_2).$$

Si n_1 o n_2 son mayores que 10 podemos utilizar una aproximación por la normal con:

$$E(U_m) = \frac{n_1 n_2}{4}, \quad var(U_m) = \frac{n_1 n_2 (n_1 + n_2 + 1)}{12}.$$

Se define entonces el estadístico de contraste (usando corrección por continuidad):

- Si $U_m > E(U_m)$

$$z_{obs} = \frac{U_m - E(U_m) - 0{,}5}{\sqrt{var(U_m)}} \sim N(0,1).$$

- Si $U_m < E(U_m)$

$$z_{obs} = \frac{U_m - E(U_m) + 0{,}5}{\sqrt{var(U_m)}} \sim N(0,1).$$

Ejemplo 33: *Se pretende contrastar la eficiencia de dos tratamientos cuyos resultados se han medido en una escala ordinal de 1 a 10, donde 1 indica que no hay mejora y 10 indica mejora completa.*

```
# En primer lugar dibujemos los datos
boxplot(trat1,trat2)
# Usamos la función wilcox.test()
# Usamos la aproximación de la normal con la corrección
# de continuidad (correct) y no calculamos
# el p-valor exacto (exact).
wilcox.test(trat1,trat2,alternative="two.sided",paired=F
     ,correct=TRUE)
```

De la mediana de la diferencia para 2 muestras relacionadas.

Supongamos que disponemos de dos muestras relacionadas, Denotamos por M_D a la mediana de la diferencia y nos planteamos el contraste:

$$H_0 : M_D = M_0 (= 0)$$

frente a:

$$H_1 : M_D \neq M_0; \quad H_1 : M_D > M_0; \quad H_1 : M_D < M_0.$$

Para calcular el estadístico de contraste calculamos en primer lugar las diferencias $d_i = x_i - y - i$. Se ordenan los valores absolutos $|d_i - M_0|$ y se calcula el estadístico T^+ como en el caso de una muestra.

Ejemplo 34: *Se pretende contrastar la eficiencia de dos tratamientos cuyos resultados se han medido en una escala ordinal de 1 a 10, donde 1 indica que no hay mejora y 10 indica mejora completa.*

```
# En primer lugar dibujemos las diferencias
boxplot(trat1-trat2)
# Usamos la función wilcox.test()
# Usamos la aproximación de la normal con la corrección
# de continuidad (correct) y no calculamos
# el p-valor exacto (exact).
wilcox.test(trat1,trat2,alternative="two.sided",paired=T
     ,correct=TRUE)
```

De la medianas de k poblaciones independientes.

Permite verificar si c muestra independientes de tamaños $n1, \ldots, n_c$ proceden de una misma población. La hipótesis nula puede expresar de la siguiente forma:

$$H_0 : F_1(x) = \ldots = F_c(x), \quad \forall x.$$

Para calcular el estadístico de contraste se combinan todas las observaciones de las c muestras ordenándolas de menor a mayor, asignando el rango correspondiente a cada observación. Si R_i es la suma de los rangos de las n_i observaciones de la muestra i, entonces el estadístico de contraste viene dado por:

$$H = \frac{12}{n(n+1)} \sum_{i=1}^{c} \frac{R_i^2}{n_i} - 3(n+1).$$

Si $n_i > 5, \forall i$ entonces $H \sim \chi^2_{c-1}$.

Ejemplo 35: *En la situación del ejemplo 24 se desea contrastar si la eficacia subjetiva del tratamiento varía según el tratamiento administrado.*

```
# En primer lugar dibujemos
boxplot(eficacia~trat)
# Usamos la función kruskal.test()
kruskal.test(eficacia ~ trat)
```

De la medianas de k muestras relacionadas.

Está diseñado para comprobar si existen diferencias significativas entre c tratamientos distintos $T_i, i = 1, \ldots, c$ aplicados a n elementos muestrales. Se platea el contraste:

$$H_0 : T_1 = \ldots = T_c$$

frente a

$$H_1 : \exists i, j \text{ tales que } T_i \neq T_j.$$

El estadístico de contraste es:

$$S == \frac{12}{nc(c+1)} \sum_{i=1}^{c} \frac{R_i^2}{n_i} - 3n(c+1).$$

En este caso los rangos se asignan a las observaciones dentro de cada elemento muestral y después se suman todos los rangos correspondientes a un mismo tratamiento.

Si $n \geq 10$, y $c \geq 4$ tenemos que $S \sim \chi^2_{c-1}$. En otro caso hay que aplicar una corrección al estadístico anterior.

Ejemplo 36: *Se realiza un experimento con un nuevo fármaco para ver si este es capaz de reducir el dolor de cierta enfermedad. En concreto se prueban cuatro concentraciones de fármaco en los mismos individuos dejando un período de descanso entre la administración de cada tratamiento. Para cada concentración se recoge una valoración del enfermo, al final de cada tratamiento, sobre su estado de salud en una escala de 1 a 10, donde 1 indica enfermo y 10 sano. Estamos interesados en valorar si las cuatro concentraciones de fármaco producen resultados similares.*

```
# reorganizamos los datos para poder realizar el contraste
resul=c(conc1,conc2,conc3,conc4)
n=length(conc1)
trata=c(rep(1,n),rep(2,n),rep(3,n),rep(4,n))
ind=rep(1:n,4)
# Usamos la función friedman.test()
friedman.test(resul~trata | id)
```

Homogeneidad de varianzas.

En este caso vamos a utilizar el test de Fligner (más detalles en el manual del R).

Ejemplo 37: *En la situación del ejemplo 35 deseamos contrastar la homogeneidad de varianzas de la eficacia según el tratamiento.*

```
# usamos la funcion fligner.test()
fligner.test(eficacia ~ trat)
```

3.5. Contrastes de bondad de ajuste

Los contrastes de bondad de ajuste pretenden comprobar si la muestra aleatoria simple obtenida tras realizar un experimento se distribuye de una u otra forma. Aunque existen diferentes criterios para valorar la bondad del ajuste, sobre todo en el caso de contrastar normalidad, nosotros nos vamos en el que consideramos más general y menos arbitrario como es el contraste de Kolmogorov-Smirnov.

Bondad de ajuste mediante K-S.

Este test es adecuado para contrastar si una muestra aleatoria simple procede de una determinada distribución de probabilidad. Dicho test sólo es válido cuando la distribución de probabilidad está totalmente especificada. Planteamos el contraste:

$$H_0 : F_n(x) = F(x)$$

frente a

$$H_1 : F_n(x) \text{ no se distribuye según } F(x),$$

donde $F_n(x)$ es la función de distribución empírica y $F(x)$ es la función de distribución que deseamos contrastar. Recordemos que la función de distribución empírica para una muestra $x_1, \ldots, x_n$ viene dada por:

$$F_n(x_{(i)}) = \frac{N_i}{n},$$

donde $x_{(i)}$ es la observación que ocupa la posición i una vez ordenamos la muestra de menor a mayor, y N_i es la frecuencia acumulada hasta x_i.

En el caso de que F sea discreta el estadístico de contraste viene dado por:

$$D_n = \sup_{-\infty<x<\infty} |F_n(x) - F(x)|.$$

Si F es continua definimos:

$$D^+[i] = |\frac{N_i}{n} - F(x_i)|, \quad D^-[i] = |F(x_i) - \frac{N_i}{n}|, \quad 1 \leq i \leq n,$$

de forma que el estadístico de contraste viene dado por:

$$D_n = \sup_{1 \leq i \leq n} \left[sup(D^+[i], D^-[i]) \right].$$

En el caso de desconocer los parámetros de la distribución que se desea contrastar podríamos intentar estimarlos a partir de la muestra obtenida con el método de los momentos.

Ejemplo 38: *Se desea contrastar si los bancos de datos que aparecen a continuación proviene respectivamente de una normal estándar, una distribución uniforme en* $(0, 20)$*, una distribución exponencial de media 5, una distribución de poisson de media 10.*

```
ks.test(normal,"pnorm",alternative="two.sided")
ks.test(normal,"pnorm",alternative="greater")
ks.test(normal,"pnorm",alternative="less")
ks.test(uniforme,"punif",min=0, max=20,alternative="two.sided")
ks.test(uniforme,"punif",min=0, max=20,alternative="greater")
ks.test(uniforme,"punif",min=0, max=20,alternative="less")
ks.test(exponencial,"pexp",rate=1/5,alternative="two.sided")
ks.test(exponencial,"pexp",rate=1/5,alternative="greater")
ks.test(exponencial,"pexp",rate=1/5,alternative="less")
ks.test(poisson,"ppois",lambda=10,alternative="two.sided")
ks.test(poisson,"ppois",lambda=10,alternative="greater")
ks.test(poisson,"ppois",lambda=10,alternative="less")
```

3.6. Ejercicios Tema 3

1. Según la Encuesta de Presupuestos Familiares elaborada por el INE, tenemos datos de 30 familias sobre sus gastos en alimentación, bebidas y tabaco (en cientos de euros, dados en el fichero `mu-ejer5.3.dat`).

   a) Suponiendo que la distribución del gasto es normal con varianza 2600, calcula el intervalo de confianza del gasto medio en alimentación, bebidas y tabaco, al nivel de confianza del 97 %.

   b) Repite el apartado anterior asumiendo varianza desconocida.

   c) Asumiendo normalidad y varianza conocida (igual a 2600), contrasta si podemos afirmar que el gasto medio mensual de una familia en alimentación, bebidas y tabaco es superior a 950 euros.

   d) Repite el apartado anterior asumiendo varianza desconocida.

   e) Asumiendo normalidad y varianza desconocida, contrasta si podemos afirmar que el gasto medio mensual de una familia en alimentación, bebidas y tabaco es inferior a 1250 euros.

2. En una empresa dedicada a la fabricación de envases de vidrio, la probabilidad de fabricar un envase defectuoso es $\pi = 0{,}03$. Calcula el número de envases que se han de fabricar para obtener al menos 100 envases defectuosos con probabilidad 0.95.

3. Se quiere estimar el precio medio del metro cuadrado construido de las viviendas colectivas de Pamplona. Para ello se han tomado los datos dados en el fichero `mu-ejer5.8.dat`, referentes a los precios de mercado por m^2 construido (en cientos de euros) de diferentes barrios de Pamplona.

   a) Calcula el IC de la media al nivel del 95 % asumiendo normalidad.

   b) Contrasta si podemos afirmar que el precio medio por metro cuadrado construido es inferior a 18600 euros.

   c) ¿Y superior a 15000?

   d) Contrasta normalidad y resuelve los dos contrastes anteriores en coherencia con el resultado de normalidad.

4. La dureza de una pieza de fruta es un buen indicador de su grado de madurez. En un experimento se midió, por un lado, la dureza de una muestra de 17 naranjas recién recogidas y por otro, la dureza de otra muestra de 17 naranjas que llevaban una semana en el almacén. Los datos están en el fichero `mu-ejer5.10.dat`. Calcula in IC para la diferencia de medias a un nivel de confianza del 95 %. Asume normalidad e independencia y:

a) varianzas conocidas e iguales a 2.25.

b) varianzas conocidas y distintas $\sigma_x^2 = 1{,}5$ y $\sigma_y^2 = 2{,}25$.

c) varianzas desconocidas e iguales.

d) varianzas desconocidas y distintas.

5. Dados los datos de población activa en España en el año 1993 (en cientos de miles de personas). Los datos están en el fichero `mu-ejer5.12.dat`.

   a) Asumiendo normalidad e independencia, calcula el IC de la diferencia de medias entre las cifras de hombres y mujeres al nivel del 95 %.

      1) que las varianzas son iguales a 20
      2) las varianzas son, respectivamente, 25 y 10.
      3) las varianzas son desconocidas e iguales
      4) las varianzas son desconocidas y distintas.

   b) Contrasta si el número de hombres en activo es significativamente mayor al de mujeres en activo.

   c) Contrasta si la diferencia entre hombres y mujeres activas es superior a 100.000.

6. Para comparar la velocidad de dos estaciones de trabajo de distintas marcas, una SUN y otra DIGITAL, se mide el tiempo que ambas invierten en la realización de un tipo determinado de simulaciones complejas. Se toma una muestra de cinco simulaciones de ese tipo y cada una de ellas se realiza con ambas estaciones. Los resultados (en minutos) aparecen en el fichero `mu-ejer5.17.dat`. Asumiendo normalidad,

   a) ¿Qué puedes decir sobre la magnitud de la diferencia media entre tiempos de ejecución? Calcula un IC al 95 %.

   b) ¿Hay diferencias significativas entre las dos máquinas, considerando

      1) que los datos se han obtenido realizando las mismas cinco simulaciones en las dos estaciones de trabajo?
      2) que los datos se han obtenido realizando distintas simulaciones en cada estación de trabajo?

7. En el fichero `mu-ejer5.19.dat` tenemos los datos de consumo medio de energía por habitante en 14 naciones europeas (en teps/hab, donde 1 tep=10^7Kcal es la tonelada equivalente de petróleo). Asumiendo normalidad, da una estimación puntual y por intervalo para el consumo medio y la variabilidad del consumo de energía entre naciones.

8. En el fichero `mu-ejer5.20.dat` tenemos los datos de consumo de energía en España en función de los diferentes tipos de energía (en Kteps, donde 1 tep=10^7Kcal es la tonelada equivalente de petróleo). Asumiendo normalidad, da una estimación puntual y por intervalo para el consumo medio y la variabilidad del consumo según la fuente de energía.

9. Se desea obtener una estimación (puntual y en intervalo) de la proporción de industrias alimentarias que tienen informatizada su gestión de almacenes. Para ello, se encuesta a 200 empresas, de las que 157 resultan estar ya informatizadas.

10. Se desea conocer la proporción de propietarios de fincas rústicas que son menores de 40 años. Para ello se toma una m.a.s. de 2000 fincas, en las que 400 propietarios resultan ser menores de 40 años.

    a) Da una estimación puntual y por intervalo a un nivel de confianza del 95 %.

    b) Si a priori no se sabe nada de la proporción objeto de estudio, calcula el tamaño de la muestra necesario para que el intervalo de confianza de la proporción, al nivel de confianza del 95 %, tenga una amplitud inferior a 0.03. Determina el error de estimación que estamos tolerando.

11. Se desea comprobar si un cambio en determinado proceso industrial es beneficioso. Para ello se toman dos muestras: la primera cuando todavía no se había implementado el cambio y la segunda una vez implementado. Se observa que 70 de los 1400 elementos de la primera muestra son defectuosos, mientras que en la segunda muestra son defectuosos 90 de 2000. ¿Qué puedes decir sobre la efectividad de ambos procesos? ¿Cuál resulta mejor?

12. Disponemos de los datos de mortalidad infantil (por 1000 nacidos vivos) en varios países (fichero `mu-ejer5.27.dat`). Da una estimación de la tasa media de mortalidad.

13. Queremos estimar la proporción de piezas defectuosas que se fabrican en una empresa. Para ello se extrae una muestra piloto de 300 piezas, de las cuales 6 son defectuosas. Calcula el tamaño necesario para estimar la proporción poblacional si se quiere tener una confianza del 95 % de que el error de estimación sea, como máximo, de 0.01.

14. Se desea contrastar si una determinada variedad de trigo produce un rendimiento medio de tres unidades por parcela. Para ello se siembran quince parcelas

iguales y se observan sus rendimientos. Resuelve el contraste al nivel de significación $\alpha = 0{,}05$, asumiendo normalidad para la variable rendimiento. Los datos están en el fichero `mu-ejer6.10.dat`.

15. Tenemos datos sobre los gastos corrientes anuales por comunidades autónomas en enseñanza no universitaria (fichero `mu-ejer6.11.dat`, unidades en miles de millones). Contrasta si el gasto medio anual es superior a 20 miles de millones, asumiendo normalidad.

16. Dados los tiempos en minutos empleados por dos secretarias en la realización de ciertas tareas, comprobar si existen diferencias significativas entre ellas respecto a la rapidez de ejecución. Los datos están en el fichero `mu-ejer6.13.dat`. Asume normalidad para resolverlos.

    a) Considera varianzas iguales.

    b) Considera varianzas distintas.

    c) Contrasta igualdad de varianzas y decide entre los dos apartados anteriores para dar la conclusión definitiva sobre la secretaria más rápida.

17. Se dispone de la ganancia media por trabajador y mes de los años 1981 a 1998 en el primer y tercer trimestre del año. Asumiendo normalidad, contrasta si ha habido un incremento en ganancias medias en los dos trimestres. Los datos están en el fichero `mu-ejer6.17.dat`.

18. Se quiere contrastar si el precio de cierta marca de pantalones se ha hecho más volátil en el último mes que en el mes anterior, en el que su varianza fue de 64.25. Para ello, tomamos los precios de los últimos 20 días y obtenemos una media de 81.42 y una cuasivarianza muestral de $s^2 = 87{,}47$. Realiza el contraste correspondiente asumiendo normalidad en el precio y calcula el intervalo de confianza al nivel del 95 %.

19. Se quiere contrastar la igualdad en el precio de la gasolina sin plomo entre comunidades autónomas geográficamente situadas en el norte y las situadas en el sur del país. Para ello tenemos los datos en el fichero `mu-ejer6.20.dat`. ¿Cuál es tu conclusión?

    a) Considera varianzas iguales.

    b) Considera varianzas distintas.

    c) Contrasta igualdad de varianzas y decide entre los dos apartados anteriores para dar la conclusión definitiva.

20. En una encuesta realizada a 950 personas, 524 contestaron a favor del cambio de hora en primavera (y el resto, en contra). ¿Se podría concluir estadísticamente que la gente, mayoritariamente, está a favor del cambio de hora?

21. En una encuesta sobre el consumo familiar se descubrió que 4 de cada 5 encuestados tenía dificultades para llegar a fin de mes. ¿Podemos asegurar que el 80 % de las familias tienen dificultades para llegar a fin de mes?

22. En un estudio de eventualidad se realizaron dos muestreos: uno dirigido a empresas nacionales y otro a multinacionales. De la primera muestra de 400 empresas nacionales, 190 tenían más empleados fijos que eventuales. En la muestra de 800 multinacionales, resultó que 300 tenían más empleados fijos que contratados.

    a) ¿Se puede decir que la proporción de empresas nacionales con mayoría de personal fijo es inferior al 40 %?

    b) ¿Y para las multinacionales, se puede hacer tal aseveración?

    c) ¿Se puede decir que básicamente la proporción de empresas nacionales con mayoría de personal fijo es similar a la de multinacionales con mayoría de personal fijo?

23. En un test sobre la creencia en la vida futura sobre una población de 520.000 hombres y 625.000 mujeres, se han encuestado a 582 mujeres y 509 hombres. De las mujeres, 435 han manifestado su creencia en la vida futura, y de los hombres 375.

    a) Contrasta que el 50 % de las mujeres son creyentes.

    b) Contrasta que el 50 % de los hombres son creyentes.

    c) ¿Existen diferencias significativas entre los sexos respecto a la creencia en la vida futura?

24. Un fabricante de fertilizantes está preocupado por la concentración de impurezas en los fosfatos y desea que esta concentración no exceda el 2 %. Se sabe que para un lote en particular, la concentración de impurezas sigue una distribución normal con una desviación típica $\sigma = 0{,}3\,\%$. Se examina una muestra aleatoria de 80 sacos de abono de un lote y se encuentra que la media muestral de la concentración de impurezas es el 2.07 %.

    a) ¿Se puede concluir estadísticamente que le concentración media de impurezas es del 2 %?

b) Contesta a la misma pregunta proponiendo como alternativa una hipótesis unilateral (concentración media superior al 2 %).

25. En el fichero `mu-ejer6.29.dat` disponemos de los datos de producción de hortalizas y frutales en España. En términos medios, son similares la producción de hortalizas y la de frutales?

26. Para estudiar la eficiencia de empresas públicas y privadas disponemos de los resultados de una evaluación de tipo ordinal realizada mediante encuestas. Los datos están en el fichero mu-ejer7.3.

    a) Contrasta, asumiendo normalidad, que el valor medio de eficiencia en la empresa privada es de 81.4.

    b) Contrasta si los resultados de eficiencia en las empresas privadas se pueden considerar provinientes de una distribución simétrica con mediana 81.4.

    c) Contrasta, asumiendo normalidad, que el valor medio de eficiencia en la empresa pública es inferior al de la empresa pública.

    d) Contrasta, sin asumir normalidad, que el valor medio de eficiencia en la empresa pública es inferior al de la empresa pública.

    e) Contrasta la normalidad de los datos y concluye sobre cuál de las conclusiones anteriores es la que te merece mayor credibilidad.

27. Se toman 15 muestras antes y después de un nuevo proceso de fabricación de embutidos, con objeto de comprobar si hay diferencias significativas entre los resultados. Los datos están en el fichero `mu-ejer7.5.dat`. Verifica dicha hipótesis asumiendo normalidad y sin asumirla. ¿Cuál es tu conclusión definitiva en función del test de normalidad sobre los datos?

28. En tres países europeos se investigan las subvenciones recibidas por la Unión Europea en ayudas a la pequeña empresa, para lo que se obtienen los resultados en el fichero `mu-ejer7.6.dat`. ¿Existen diferencias significativas entre las ayudas recibidas?

29. Se han evaluado las calidades de tres tipos de caldos: tinto, rosado y blanco, de la campaña del año pasado, en 5 bodegas. Los resultados están en el fichero `mu-ejer7.7.dat`. ¿Podríamos afirmar que la calidad de los tres caldos es la misma en todas las bodegas?

30. Se han recogido datos sobre el número de accidentes en una región, durante 100 días. Los datos están en el fichero `mu-ejer7.9.dat`. ¿Se podría dar como válida una distribución de Poisson $Po(\lambda = 1)$ para modelizar dichos datos?

31. (**ESPECIAL**) En el fichero `ex0773.dat` tenemos los datos financieros que proporcionó *The Wall Street Journal* (14/05/1993) sobre los fondos mutuales de una m.a. de 35 empresas (sobre un total de 3000). Las variables observadas son:

    NAV (net asset value) el precio (en dólares) al cual un inversor puede redimir participaciones del fondo

    OP (offering price) el precio (en dólares) que un inversor paga para comprar participaciones en el fondo

    inc.nav, el cambio en NAV respecto del día anterior

    ytd.perc (year-to-date percentage change) cambio (en porcentaje) desde el inicio del año hasta la fecha, en el valor de una inversión en el fondo, asumiendo que todos los dividendos son reinvertidos.

    a) Estima el cambio promedio en el nav.inc para todos los fondos de inversión listados en *The Wall Street Journal*. Estima su error estándar y construye un intervalo de confianza. ¿Qué puedes decir sobre cómo se modifica el NAV de un día para otro?

    b) Repite el apartado anterior para estimar la media de la variable ytd.perc. ¿Que puedes concluir sobre cómo se ha modificado el valor de las inversiones desde principio de año hasta la fecha del 14 de mayo?

    c) Asumiendo que la desviación estándar que estimaste en el apartado anterior está cerca a la desviación estándar real de la población, ¿cuántas empresas necesitaríamos para estimar el porcentaje promedio year-to-date con un error de estimación inferior al 0.5 % y a un nivel de confianza del 99 %?

    d) Los fondos para los cuales el precio de oferta (OP) es igual al NAV se llaman fondos sin ahorro. Usa la muestra disponible para estimar qué fracción de todos los fondos listados en el periódico son fondos sin ahorro. Construye un intervalo de confianza al 98 %.

    e) Utilizando sólo los datos correspondientes a los fondos sin ahorro, construye un intervalo de confianza para el porcentaje medio de cambio recogido en la variable ytd.perc. ¿Es preciso asumir normalidad para construir tal intervalo? Justifica tu respuesta.

    f) ¿Tenemos evidencias a favor de la diferencia de tratamiento, respecto del ytd.perc promedio, entre las empresas con fondos sin ahorro y las restantes? Utilizando los datos de las 35 empresas proporcionados, calcula el tamaño de muestra necesario para resolver detectar diferencias al menos de 0.9 entre ambos grupos de empresas, a un nivel

de significatividad del 0.05 y una potencia de 0.8. Repite este último cálculo cuando sólo se pretenden detectar diferencias de 0.6 entre los promedios de ytd.perc.

g) Un analista está interesado en contrastar si la variable ytd.perc, en promedio, toma un valor inferior al 3 %. Plantea y resuelve el contraste de hipótesis a un nivel de confianza del 95 %.

h) Contrasta si hubo variación en el NAV promedio de las empresas listadas en el periódico entre el día 13 y el 14 en que se publicaron los datos. Plantea y resuelve el contraste. ¿Se puede hablar de estabilidad en el valor del NAV?

TEMA 4

Asociación entre variables

Vamos a tratar en este tema los procedimientos estadísticos para valorar la relación en dos variables de tipo categórico y dos variables de tipo continuo.

4.1. Asociación entre variables categóricas

Tratemos en primer lugar la asociación entre dos variables categóricas.

4.1.1. Tablas de contingencia

Denotemos por X e Y dos variables categóricas. Supongamos que la variable tiene I niveles y la variable Y tiene J niveles. Una tabla de contingencia es una tabla donde se recogen los resultados de las posibles coincidencias de las IxJ combinaciones que podemos construir.

	1	2	...	J
1	n_{11}	n_{12}	...	n_{1J}
2	n_{21}	n_{22}	...	n_{2J}
⋮	⋮	⋮	⋮	⋮
I	n_{I1}	n_{I2}	...	n_{IJ}

La función *expand.grid()* crea una tabla de contingencia con todas las combinaciones de vectores o factores proporcionados como argumentos:

```
personal <- expand.grid(zona=c("norte,","Interior","Sur")
, numero=c("<5 personas","5-10 personas",">10 personas"))
fr =c(20,10,20,30,10,10,25,10,15)
attach(personal)
personal.tabla <- table(zona,numero)*fr; personal.tabla
```

Denotamos n al número total de individuos de la tabla, $n_{i\cdot}$ al número de individuos en la categoría i de la variable X, y $n_{\cdot j}$ al número de individuos en la categoría j de la variable Y.

Para estudiar la asociación entre las dos variables teóricas hay que estudiar en primer lugar las distribuciones teóricas que podemos obtener a partir de la tabla de contingencia anterior. Veamos las probabilidades teóricas (que denotamos por π) y sus estimadores muestrales (que denotamos por p).

Probabilidad conjunta

$$\pi_{ij} = P(X = i, Y = j), \qquad p_{ij} = \frac{n_{ij}}{n}$$

Probabilidades marginales

$$\pi_{i\cdot} = P(X = i), \qquad p_{i\cdot} = \frac{n_{i\cdot}}{n}$$

$$\pi_{\cdot j} = P(Y = j), \qquad p_{\cdot j} = \frac{n_{\cdot j}}{n}$$

Probabilidades condicionadas

$$\pi_{i|j} = P(X = i \mid Y = j), \qquad p_{i|j} = \frac{n_{ij} n_{i\cdot}}{n_{\cdot j}}$$

$$\pi_{j|i} = P(Y = j \mid X = i), \qquad p_{j|i} = \frac{n_{ij} n_{\cdot j}}{n_{i\cdot}}$$

4.1.2. Contraste de asociación/independencia

Uno de los objetivos más importantes en el estudio de tablas de contingencia es analizar la posible asociación entre las dos variables categóricas que forman la tabla. En este apartado vamos a estudiar el test χ^2 de independencia.

Diremos que dos variables categóricas son independientes si:

$$\pi_{ij} = \pi_{i\cdot}\pi_{\cdot j}, \quad i = 1, \ldots, I \text{ y } j = 1, \ldots, J.$$

La idea subyacente en la construcción del test χ^2 es comparar las frecuencias observadas n_{ij} con las frecuencias esperadas que vienen dadas por $\varepsilon_{ij} = n\pi_{ij}$.

El contraste se plantea como:

$$\begin{cases} H_0 & : \pi_{ij} = \pi_{i\cdot}\pi_{\cdot j} \qquad \text{(las variables son independientes)} \\ H_1 & : \pi_{ij} \neq \pi_{i\cdot}\pi_{\cdot j} \qquad \text{(las variables no son independientes)} \end{cases}$$

El estadístico de contraste viene dado por:

$$\chi^2_{obs} = \sum_{i=1}^{I}\sum_{j=1}^{J}\frac{(n_{ij} - e_{ij})^2}{e_{ij}}$$

donde e_{ij} es un estimador de las frecuencias esperadas ε_{ij} bajo H_0, que viene dado por:

$$e_{ij} = np_{ij} = np_{i\cdot}p_{\cdot j} = \frac{n_{i\cdot}n_{\cdot j}}{n}.$$

La distribución del estadístico de contraste cuando $e_{ij} > 5$ para todas las celdas es:

$$\chi^2_{obs} \sim \chi^2_{(I-1)(J-1)}.$$

Rechazamos H_0 cuando nos encontramos en la región crítica

$$\chi^2_{obs} > \chi^2_{(I-1)(J-1);1-\alpha}.$$

4.2. Asociación entre variables continuas

En este apartado vamos a tratar la asociación entre dos variables de tipo continuo.

4.2.1. Correlación lineal

Un análisis de correlación tiene sentido para detectar y cuantificar una relación lineal entre un para de variables cuantitativas o continuas. Se define el coeficiente de correlación (ρ) de Pearson como:

$$\rho = \frac{Cov(X,Y)}{\sqrt{Var(X)Var(Y)}}.$$

Dada una muestra $(x_1, y_1), \ldots, (x_n, y_n)$ de dos variables X e Y, se define el coeficiente de correlación muestral simple (r) de Pearson como:

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \sum_{i=1}^{n}(y_i - \bar{y})^2}},$$

de forma que valores de r cercanos a 1 o -1 indican asociación lineal entre las variables X e Y, mientras que valores próximos a cero indican no asociación lineal entre X e Y.

Contraste de Hipótesis

En este caso estamos interesados en realizar el contraste:

$$\begin{cases} H_0 & : \rho = 0 \\ H_1 & : \rho \neq 0 \end{cases}$$

El estadístico de contraste es:

$$r_t = r\sqrt{\frac{n-2}{1-r^2}} \sim t_{n-2}.$$

Rechazamos H_0 cuando nos encontramos en la región crítica:

$$|r_t| > t_{n-2;1-\alpha/2}.$$

Podríamos realizar también los contrastes:

$$\begin{cases} H_0 & : \rho = 0 \\ H_1 & : \rho > 0 \end{cases} \qquad \begin{cases} H_0 & : \rho = 0 \\ H_1 & : \rho < 0 \end{cases}$$

cuyas regiones críticas vienen dadas respectivamente por:

$$r_t > t_{n-2;1-\alpha} \text{ cuando } r > 0 \ ,$$

$$r_t < t_{n-2;\alpha} = 1 - t_{n-2;1-\alpha} \text{ cuando } r < 0 \ .$$

4.3. Ejercicios Tema 4

1. El Ministerio de Agricultura, Pesca y Alimentación quiere averiguar si el consumo de pollos por persona al año está relacionado con las zonas geográficas del país. Para ello analiza 50 familias en tres zonas distintas: la zona costera del norte, la zona del interior y la zona costera del sur. Los resultados son los siguientes:

	menos de 5 pollos	de 5 a 10 pollos	más de 10 pollos
N	20	10	20
I	30	10	10
S	25	10	15

   Decide si existe relación entre el consumo y la zona geográfica.

2. Simula y representa apropiadamente las siguientes propuestas de datos. Concluye sobre el tipo de tendencia/relación apreciada.

   a) $\mathrm{x} \sim Bi(40, 0{,}6)$ e $\mathrm{y} \sim N(1 + 2\mathrm{x}, 2)$

   b) $\mathrm{x} \sim Ber(0{,}6)$ e $\mathrm{y} \sim N(1 + 2\mathrm{x}, 2)$

   c) $\mathrm{x} \sim Bi(40, 0{,}6)$ e $\mathrm{y} \sim N(1 + 2log(\mathrm{x}), 3)$

   d) $\mathrm{x} \sim Un(0, 1)$ e $\mathrm{y} \sim N(1 + 2exp(\mathrm{x}), 2)$

   e) $\mathrm{x} \sim Ber(0{,}6)$, $\mathrm{z} \sim Un(0, 4)$ e $\mathrm{y} \sim N(1 + 2\mathrm{zx}, 2)$

   f) $\mathrm{x} \sim Ber(0{,}6)$, $\mathrm{z} \sim Un(0, 4)$ e $\mathrm{y} \sim N(1 + 2\mathrm{x}\sqrt{\mathrm{z}}, 2)$

3. Para las situaciones presentadas en la Figura 4.1, sabemos que los coeficientes de correlación muestrales son $-0{,}85; -0{,}38; -1; 0{,}06; 0{,}97; 0{,}62$. Identifica cada coeficiente con el gráfico que corresponde.

4. Para las situaciones ilustradas en la Figura 4.2 sobre la relación entre un par de variables x e y, expresada en términos de la relación analítica correspondiente, formula transformaciones apropiadas para conseguir linealidad (de Montgomery y Peck, 1992, pag.90).

5. Para las situaciones ilustradas en la Figura 4.3 sobre la relación entre un par de variables x e y (datos en el fichero `transf.dat`), contrasta linealidad y plantea transformaciones apropiadas para conseguirla.

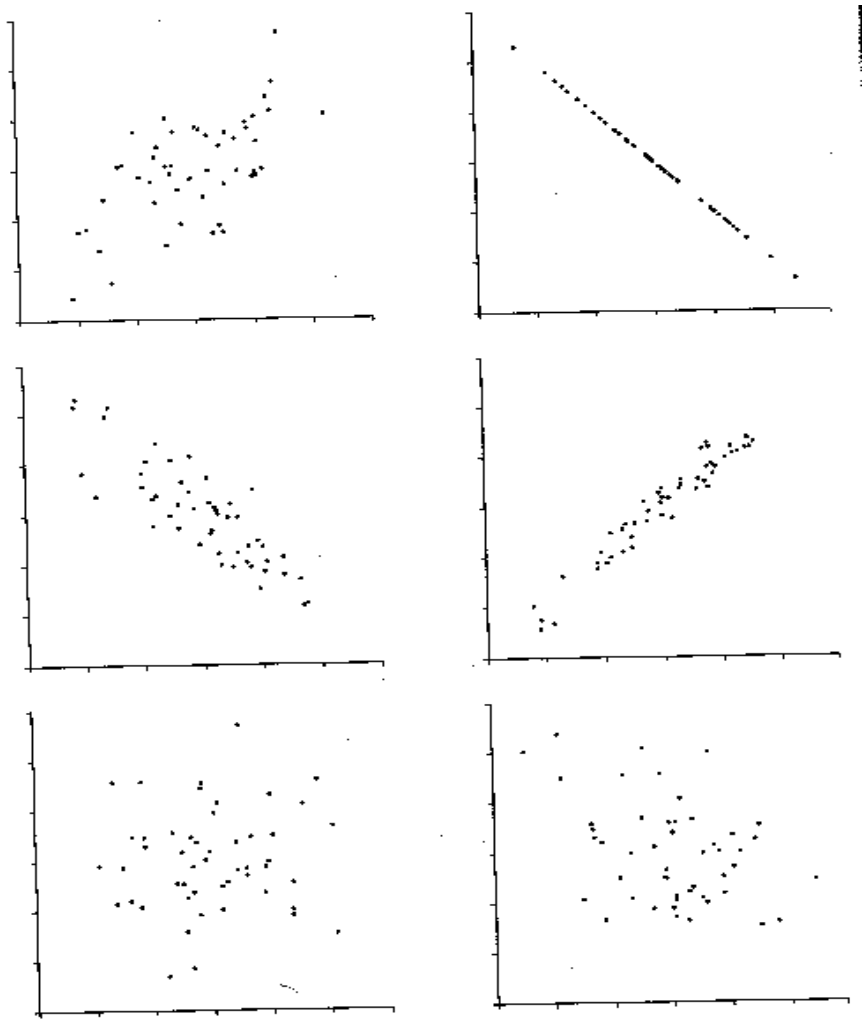


Figura 4.1: Correlación lineal.

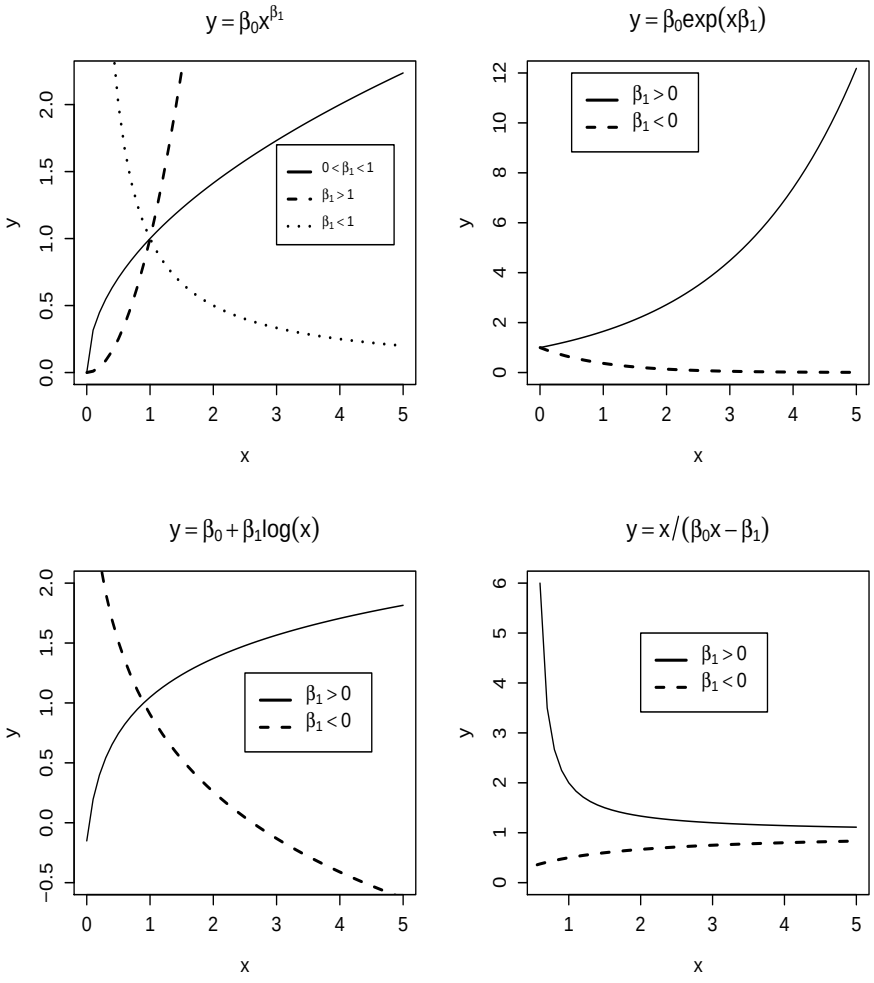


Figura 4.2: Relaciones linealizables.

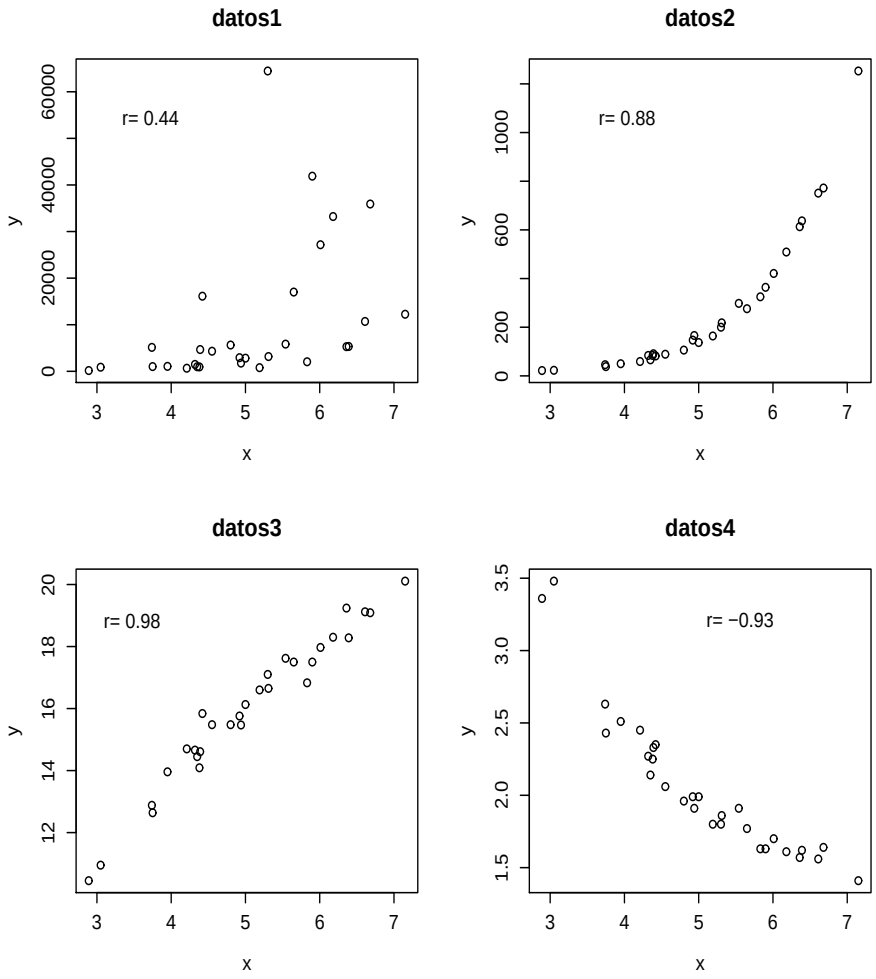


Figura 4.3: Transformaciones para conseguir linealidad.