Modelos Estadísticos para Pérdidas y Reclamaciones



UNIVERSITAS Miguel Hernández

ASUNCIÓN M. MAYORAL
JAVIER MORALES
XAVIER BARBER
JUAN APARICIO

ASUNCIóN M. MAYORAL · JAVIER MORALES · XAVIER BARBER · JUAN APARICIO

Modelos Estadísticos para Pérdidas y Reclamaciones



ISBN: 978-84-96297-78-4

9 788496 297784

Dep. Legal: A-839-2007

Dpto. Estadística, Matemáticas e Informática
Universidad Miguel Hernández de Elche

Modelos Estadísticos para Pérdidas y Reclamaciones

Asunción M. Mayoral
Javier Morales
Xavier Barber
Juan Aparicio

Dpto. Estadística, Matemáticas e Informática
Universidad Miguel Hernández de Elche

Modelos Estadísticos para Pérdidas y Reclamaciones

El contenido de este libro no podrá ser reproducido, ni total ni parcialmente, sin el previo permiso del emisor. Reservados todos los derechos.

Editor: **Universidad Miguel Hernández**

Autores: Mª Asunción Martínez Mayoral
Javier Morales Socuéllamos
Josep Xavier Barber i Vallés
Juan Aparicio Baeza

ISBN: **978-84-96297-78-4**
Depósito Legal: **A-839-2007**

Impreso en España / Printed in Spain
Fotocomposición, Impresión y Encuadernación
CEE Limencop, S.L.
http://www.limencop.com
correo: publicaciones@limencop.com
correo: reprografia.elche@umh.es
Telf.: 966658487 / 966658791 / 965903400 Extension 2784

Este libro ha sido confeccionado por personal discapacitado perteneciente al Centro Especial de Empleo Limencop.

Limencop

Prólogo

Este manual es fruto de la labor docente realizada en la Licenciatura de Ciencias Actuariales y Financieras de la Universidad Miguel Hernández desde el curso 2003-2004. La visión del curso es eminentemente práctica, encaminada a lograr del estudiante una visión clara de la utilidad de la modelización estadística para el análisis, previsión y planificación de coberturas en carteras de seguros, fundamentalmente de tipo no-vida.

El estudiante adquiere durante el curso una buena percepción de cuál es la dinámica a seguir para obtener una buena modelización que dé lugar a análisis y previsiones fiables. Ya sea primero con modelos (continuos) para las cuantías de las pérdidas, o después con modelos (discretos) para el número de reclamaciones (o siniestros), se reitera una y otra vez, durante el curso, todo el proceso de modelización, consistente en la descripción de datos para la propuesta de modelos, ajuste de las propuestas, validación y comparación de modelos, selección del mejor modelo y previsión de costes con variaciones en las coberturas/condiciones que rodean al seguro.

El software utilizado para resolver cada uno de los pasos mencionados en la modelización es el Excel, por su accesibilidad y sencillez. Al final del curso, el estudiante es capaz de resolver con Excel el análisis completo de una cartera de seguros.

Índice general

1. Modelos Estadísticos de Riesgo para la planificación de carteras **1**

1.1. Introducción 1

2. Modelización de pérdidas **5**

2.1. Introducción 5

2.2. Distribución empírica de las pérdidas 6

2.3. Modelización paramétrica de las pérdidas 10

2.3.1. Estimadores y propiedades 11

2.3.2. Ajuste de un modelo 12

2.3.3. Métodos básicos de estimación 12

2.4. Modelos probabilísticos para las pérdidas 15

2.5. Predicción con modelos: provisión de seguros 16

2.6. Transformación de variables 21

2.6.1. Cambios inflacionarios y familias de escala 21

2.6.2. Otras transformaciones, límites y relaciones entre distribuciones . 22

2.7. Modelos para datos incompletos 23

2.7.1. Tipos de datos incompletos 23

2.7.2. Estimación por máxima-verosimilitud 24
2.8. Bondad de Ajuste y Selección de modelos 28
2.8.1. Bondad del Ajuste 28
Tests informales 28
Tests formales 29
2.8.2. Selección de Modelos 30

3. Modelos y distribuciones de frecuencia para el Número de Pagos 33

3.1. Introducción 33
3.2. Presentación de los datos 34
3.3. Descripción empírica 34
3.4. Modelización de variables discretas 35
3.4.1. Estimación de modelos discretos 35
3.4.2. Modelos habituales: la familia $(a, b, 0)$ 36
Distribución de Poisson 37
Distribución Binomial Negativa 39
La distribución binomial 40
3.4.3. Modificaciones en el cero: la clase $(a, b, 1)$ de distribuciones . . . 41

4. Modelos de pérdida agregados 45

4.1. Introducción 45
4.2. Modelo de riesgo individual 46
4.3. Modelo de riesgo colectivo 48
4.3.1. Características 50
4.3.2. Ventajas 51

4.3.3. Aproximación de la distribución de S 55

A. Prácticas **57**

A.1. Práctica 1:
Descripción de Muestras 58

A.2. Práctica 2:
Modelización de pérdidas 59

A.3. Práctica 3:
Predicción y provisión de seguros 60

A.4. Práctica 4:
Ajuste de Modelos con Datos Incompletos 61

A.5. Práctica 5:
Contraste y Selección de Modelos 63

A.6. Práctica 6: Distribuciones habituales para el número de reclamaciones . 64

A.7. Práctica 7: Distribuciones en la clase $(a, b, 1)$ para el número de reclamaciones 67

A.8. Práctica 8: Cálculo de la pérdida agregada 69

B. Ejercicios Variados **73**

B.1. Ejercicios del Tema 2 73

B.2. Ejercicios del Tema 3 76

B.3. Ejercicios del Tema 4 77

C. Distribuciones de probabilidad **81**

C.1. Distribuciones Continuas 81

C.1.1. Distribuciones de un parámetro 82

C.1.2. Distribuciones de dos parámetros 83

C.2. Distribuciones discretas 86

C.2.1. Familia $(a, b, 0)$ 86
C.2.2. Familia $(a, b, 1)$ 87
Distribuciones $(a, b, 1)$ truncadas en el cero 88

D. Casos Prácticos **91**

D.1. Introducción 91
D.2. Caso Práctico 1 91
D.3. Caso Práctico 2 94
D.4. Caso Práctico 3 96
D.5. Caso Práctico 4 99
D.6. Caso Práctico 5 101
D.7. Caso Práctico 6 104

Bibliografía 109

Capítulo 1

Modelos Estadísticos de Riesgo para la planificación de carteras

1.1. Introducción

El objetivo de un sistema de seguros es indemnizar a los tenedores de seguros cuando le acontecen sucesos adversos contemplados en sus contratos. En cualquier sistema de seguros hay una serie de características comunes:

1. Hay riesgo, esto es, la posibilidad de que acontezca algo distinto a lo que se esperaba. El riesgo actuarial es un fenómeno que tiene consecuencias económicas y que está sujeto a incertidumbre con respecto a las siguientes variables:

   ocurrencia: probabilidades de una reclamación, y que atañe directamente al número de pagos que se hayan de realizar;

   tiempo: en el que la reclamación se produce, si lo hace;

   severidad: costes de la reclamación para la empresa.

   Cualquiera o todas las variables de riesgo pueden ser aleatorias.

   Ejemplo 1.1.1. *Consideramos un par de ejemplos en el que todas o algunas de las variables de riesgo son aleatorias.*

   - *En una póliza de seguro de coche, las tres variables son aleatorias: el hecho de que ocurra un siniestro, el instante en que se produce y los gastos que ocasiona.*
   - *Un seguro de vida lleva implícito una ocurrencia segura (de la muerte); sin embargo, es aleatorio el instante en el que se produce y, en función del tipo*

de seguro, puede ser aleatoria o no la cantidad que haya de desembolsar la empresa aseguradora tras dicha muerte.

2. La pérdida ha de ser financiera, es decir supone una pérdida en dinero.

   Una distribución de pérdidas es una distribución de probabilidad (asignación de probabilidades) para la pérdida o la cuantía del pago en una reclamación. Puede incluir pagos de cero y otros gastos de gestión asociados a la reclamación.

3. Parte o la totalidad del riesgo se transfiere del asegurado al asegurador, que asume el riesgo al asegurar a su cliente.

4. El asegurador espera no perder dinero con una cartera de seguros. Dicha esperanza la basa en promedios de riesgos *(pérdida total esperada).*

Dado que existe azar involucrado en todo sistema de seguros, según el *Comité para Principios Actuariales* de la *Sociedad de Actuarios*, "*los riesgos actuariales pueden ser modelizados estocásticamente en función de hipótesis asumidas sobre: a) las probabilidades que se aplican a las variables de riesgo actuarial en el futuro, y b) las condiciones que regularán el futuro*".

Un modelo estocástico (o estadístico) es una descripción matemática simplificada construida utilizando el conocimiento y la experiencia del actuario, combinadas con datos del pasado. Los datos guiarán al actuario para seleccionar la forma del modelo así como para estimar cantidades desconocidas de interés llamadas parámetros. La selección del mejor modelo se hará en función de la simplicidad del mismo (pocos parámetros a estimar) y la conformidad con los datos (bondad del ajuste).

La consideración de un modelo nos permitirá estimar cantidades de interés actual y evaluar también la fiabilidad de las estimaciones obtenidas (errores, nivel de confianza, ...). Asimismo, permitirá la incorporación de evoluciones para adaptar las estimaciones y predecir así lo que puede suceder cuando concurran las nuevas condiciones impuestas.

El proceso de modelización estadística podemos esquematizarlo de la siguiente forma:

P1.- Recolección de datos y de información y experiencia previa.

P2.- Descripción numérica y gráfica de los datos, que oriente a la modelización.

P3.- Propuesta y ajuste de modelos estadísticos.

P4.- Estudio de la adecuación y validación de los modelos propuestos.

P5.- Comparación de los modelos alternativos que superen con éxito el Paso 4.

P6.- Consideración de variaciones, adaptación y predicción para el futuro.

La evaluación de un sistema de seguros depende básicamente del número de reclamaciones con derecho a pago que recibe la empresa aseguradora y de la cuantía de los pagos que ha de efectuar. Puesto que el azar y la variabilidad son características intrínsecas, tanto sobre el hecho de que se produzca una reclamación como del pago asociado, la Teoría de la Probabilidad y la Inferencia Estadística serán las herramientas básicas para explicar y predecir las pérdidas sufridas por una empresa aseguradora. La base de cualquier proceso de inferencia es la disponibilidad de una muestra aleatoria, esto es, de un conjunto de observaciones independientes y representativas de una característica (variable) de interés observable en la población objetivo.

Si X denota a la variable de interés, entonces $X_1, X_2, \ldots, X_n$ identificarán a las variables observables en distintas unidades muestrales (correspondientes al cliente 1, 2, ... ,n). Una vez observadas, decimos que tenemos una muestra $X_1 = x_1, X_2 = x_2, \ldots, X_n = x_n$, y con ella extraeremos conclusiones a través de la Inferencia Estadística, consiguiendo extrapolar resultados al global de la población de interés.

Nuestro objetivo básico en este curso será estudiar modelos y procedimientos estadísticos útiles para la evaluación y planificación de un sistema de seguros eficiente que garantice ganancias a la empresa aseguradora, tanto ajustando la cobertura de los seguros que ofrezcamos, como considerando posibles cambios económicos en el futuro. En concreto, trataremos:

- Distribuciones de pérdidas y modelos para la cuantía de un pago único, en el Tema 2.
- Distribuciones de frecuencias y modelos para el número de pagos, en el Tema 3.
- En el Tema 4 estudiaremos modelos de pérdida agregados para las cantidades totales pagadas para todas las reclamaciones que se han producido en un período dado de tiempo sobre una cartera concreta. Básicamente éstos se clasifican en modelos de riesgos colectivos (se consideran sólo los seguros de la cartera que han ocasionado gastos; el número de estos seguros es aleatorio) y modelos de riesgos individuales (se consideran todos los seguros de la cartera, algunos de ellos con pagos de cero).

Por último, repasemos conceptos habituales en la dinámica de los seguros, y que emplearemos a lo largo del curso.

Definición 1.1.1. *Una reclamación es un incidente que acontece a un asegurado que sufre daños potencialmente cubiertos por su seguro.*

Definición 1.1.2. *La pérdida es la cantidad monetaria en que se valora el daño sufrido por un asegurado que ha presentado una reclamación. La pérdida puede ser cero.*

Definición 1.1.3. *Una reclamación con derecho a pago es un incidente en el que el asegurado recibe un pago como compensación a los daños sufridos y cubiertos por su seguro.*

Definición 1.1.4. *Un* pago *es la cantidad monetaria que percibe un asegurado que presenta una reclamación con derecho a pago. Puede incluir o no, los gastos de gestión añadidos a los daños pagados, especificados generalmente en las provisiones del seguro.*

Definición 1.1.5. *La* severidad *es, bien la pérdida o la cantidad pagada asociada a una reclamación. En general hablaremos de modelos de severidades; en ocasiones nos estaremos refiriendo a pérdidas y otras veces a pagos.*

Las modificaciones de cobertura de un seguro más comunes son:

Definición 1.1.6. *Una* franquicia *es una provisión que especifica que cuando la pérdida es menor o igual a dicha cantidad, no habrá pagos, y cuando la exceda, la cantidad pagada será la pérdida menos la franquicia.*

Definición 1.1.7. *Un* límite *es una provisión que especifica que cuando la pérdida exceda dicha cantidad, se percibirá dicho límite sin excederse.*

Definición 1.1.8. *Un* factor de coaseguranza *es la proporción de pérdida que será pagada por el asegurador después de que se hayan aplicado todas las modificaciones restantes (franquicias, límites). Una coaseguranza es una provisión que especifica cierto factor de coaseguranza.*

Definición 1.1.9. *La* tasa de inflación *es el porcentaje en que se incrementará la cuantía de una pérdida respecto de su valor actual.*

Ejemplo 1.1.2. *Un plan de hospitalización tiene una franquicia de 100, un límite de 5000 y un factor de coaseguranza del 90 %. Si los gastos ocasionados son de 4000, la póliza paga* $0{,}9(4000 - 100) = 3510$. *Si los gastos son de 5500, el seguro paga* $(0{,}9)(5000 - 100)$.

Capítulo 2

Modelización de pérdidas

2.1. Introducción

Puesto que nuestro punto de partida será una muestra de datos, una primera aproximación a su modelización provendrá de la información que extraigamos de una inspección gráfica y numérica. Hablamos de extraer "pistas"para la propuesta de modelos (paramétricos) examinando la *distribución empírica* de los datos. Después abordaremos la aproximación paramétrica, que ya nos resultará útil para sacar y extrapolar conclusiones, hablar de la fiabilidad de las mismas y predecir el futuro.

En este tema vamos a tratar de estudiar modelos útiles para predecir la cuantía del pago (o pérdida) asociado a una reclamación por daños realizada por un cliente que tiene contratado un seguro. En general hablaremos de la modelización de pérdidas o severidades, si bien en ocasiones lo que modelizaremos serán los pagos asociados a una reclamación.

Los datos de pérdidas (gastos) asociados a una cartera nos pueden venir dados de dos formas básicas:

1. bien con todos los valores individualizados $x_1, \ldots, x_n$, esto es, toda la información completa;
2. bien con el resumen de una muestra agrupada por intervalos, esto es, contabilizados el número de pagos n_j cuya cuantía está entre los extremos del intervalo $I_j = (c_{j-1}, c_j)$, siendo $j = 1, \ldots, r$, el subíndice que caracteriza a los r intervalos disponibles de agrupación.

En función de cómo nos vengan dados los datos sobre pérdidas, los cálculos que hagamos con ellos, encaminados a una descripción empírica o al ajuste de un modelo, se

harán de uno u otro modo.

2.2. Distribución empírica de las pérdidas

Describir la distribución empírica de los datos consiste en describir numéricamente los datos, es decir, extraer toda la información posible sobre su localización, dispersión, forma de distribuirse alrededor de su valor medio, etc.

Definición 2.2.1. *La **distribución empírica** describe cómo se distribuyen los datos en torno a la media. En particular, la distribución empírica reparte la probabilidad entre todas las observaciones disponibles, esto es, da 1/n de probabilidad a cada observación.*

Función de distribución: *nos da información sobre el porcentaje de reclamaciones con pérdidas menores o iguales a cualquier cantidad. Se calcula según:*
– En datos individualizados:

$$F_n(x) = \frac{\#\{x_j \leq x\}}{n} \tag{2.1}$$

donde $\#\{..\}$ denota el cardinal del conjunto de valores de la muestra que satisfacen la condición entre llaves. – En datos agrupados:

$$F_n(x) = \begin{cases} 0, & x \leq c_0 \\ \frac{(c_j - x)F_n(c_{j-1}) + (x - c_{j-1})F_n(c_j)}{c_j - c_{j-1}}, & c_{j-1} < x \leq c_j \\ 1, & x > c_r. \end{cases} \tag{2.2}$$

La proporción de pérdidas mayores que cierta cantidad x se calculará con $1 - F_n(x)$.

Función de densidad: *es la derivada de la función de distribución y nos da información sobre qué zonas tienen más densidad de probabilidad y cuáles menos. Es la representación numérica de un histograma. Se calcula de la siguiente manera:*

Cuando la variable es de tipo continuo, como las pérdidas, para calcular la densidad es preciso previamente agrupar los datos en intervalos y entonces aplicar la fórmula siguiente:

$$f_n(x) = \begin{cases} 0, & x \leq c_0 \\ \frac{F_n(c_j) - F_n(c_{j-1})}{c_j - c_{j-1}} = \frac{n_j}{n(c_j - c_{j-1})}, & c_{j-1} < x \leq c_j \\ 0, & x > c_r, \end{cases} \tag{2.3}$$

con $n = \sum_{j=1}^{r} n_j$ el total de datos disponibles en la muestra.
Si los datos vienen ya agrupados, basta con aplicar (2.3). Si vienen individualizados, hay que elegir una partición adecuada y agrupar. Una buena elección de

la partición nos permitirá visualizar con más claridad la forma de la distribución empírica.

Definición 2.2.2. *Los **momentos centrados y no centrados** en el origen nos dan información sobre la localización y dispersión de los datos. Son descriptores numéricos de los datos.*

Momento no centrado $\mu'_k = E(X^k)$. *Dan idea, básicamente, sobre la localización de los datos.*

El estimador empírico del momento no centrado de orden k es:

- *Para datos individualizados:*

$$\hat{\mu}'_k = \frac{1}{n}\sum_{j=1}^{n} x_j^k. \tag{2.4}$$

En concreto, el la versión empírica del momento no centrado de orden 1 es el promedio muestral, $\hat{\mu}'_1 = \bar{x}$.

- *Para datos agrupados:*

$$\hat{\mu}'_k = \frac{1}{n}\sum_{j=1}^{r} \frac{n_j(c_j^{k+1} - c_{j-1}^{k+1})}{(k+1)(c_j - c_{j-1})}. \tag{2.5}$$

En particular, para calcular la media en datos agrupados basta sustituir $k = 1$ *en* (2.5)*, lo que simplifica la fórmula a:*

$$\hat{\mu}'_1 = E(\hat{X}) = \sum_{j=1}^{r} \frac{n_j(c_j + c_{j-1})}{2n}. \tag{2.6}$$

Momento centrado $\mu_k = E[(X - \mu'_1)^k]$. *Nos dan información, básicamente, sobre la dispersión de los datos en torno a la media. El que nos suele interesar es el momento centrado de orden dos, esto es, la varianza, que se puede calcular a partir de los momentos centrados.*

Cuando los datos vienen individualizados, el momento centrado de orden k se aproxima con:

$$\hat{\mu}_k = \frac{1}{n}\sum_{j=1}^{n}(x_j - \bar{x})^k, \tag{2.7}$$

con $\bar{x}$ *la media muestral de los datos,* $\bar{x} = \hat{\mu}'_1$.

Definición 2.2.3. *Otros descriptivos (estimadores empíricos) interesantes, la mayoría de los cuales se pueden calcular a partir de los momentos, son los siguientes:*

- *La varianza $\mu_2 = \sigma^2$ se puede obtener a partir de los momentos no centrados de orden 1 y 2:*

$$Var(X) = E(X^2) - E(X)^2 \quad \rightsquigarrow \quad \sigma^2 = \mu_2 = \mu_2' - (\mu_1')^2. \tag{2.8}$$

- *La desviación estándar es $\sigma = \sqrt{\sigma^2}$.*

- *El coeficiente de variación es σ/μ_1'.*

- *El coeficiente de asimetría es $\gamma_1 = \mu_3/\sigma^3$, y sirve para caracterizar el grado de asimetría de una distribución con respecto a su media. Un estimador empírico del coeficiente de asimetría es:*

$$\hat{\gamma_1} = \frac{n}{(n-1)(n-2)} \sum_{i=1}^{n} \left(\frac{x_i - \bar{x}}{s} \right)^3, \tag{2.9}$$

donde $\bar{x}$ es la media muestral de los datos y s desviación típica insesgada:

$$s = \sqrt{\sum_{i=1}^{n} \frac{x_i - \bar{x}}{n-1}}.$$

Un valor positivo de $\hat{\gamma_1}$ identifica una distribución asimétrica que se extiende hacia valores más positivos (asimetría a la derecha). Un valor negativo caracteriza distribuciones asimétricas hacia la izquierda, esto es, la cola se prolonga hacia valores más negativos.

- *La curtosis es $\gamma_2 = \mu_4/\sigma^4$ y caracteriza el apuntamiento o achatamiento de una distribución, comparada con la distribución normal. Un estimador empírico viene dado por:*

$$\hat{\gamma_2} = \frac{n(n+1)}{(n-1)(n-2)(n-3)} \sum_{i=1}^{n} \left(\frac{x_i - \bar{x}}{s} \right)^4 - \frac{3(n-1)^2}{(n-2)(n-3)}. \tag{2.10}$$

Este estimador da valores positivos para indicar que la distribución es más apuntada que la normal; una curtosis negativa indica que la distribución es más achatada.

- *La moda se define en una distribución continua como el punto en el que la densidad de probabilidad es máxima. Una vez hemos identificado el intervalo modal como aquel con la máxima frecuencia absoluta de entre todos los intervalos de agrupación, , $I_j = (c_{j-1}, c_j)$, aplicamos la siguiente fórmula:*

$$Moda = c_{j-1} + (c_j - c_{j-1}) \, \frac{n_j - n_{j-1}}{2n_j - n_{j-1} - n_{j+1}} \tag{2.11}$$

Definición 2.2.4. *El **momento limitado por** u **de orden** k tiene especial relevancia en seguros y se define como:*

$$E[(X \wedge u)^k] = E[\text{mín}(X, u)^k]. \tag{2.12}$$

El momento limitado de primer orden se denomina LEV= $E(X \wedge u)$. Tiene utilidad cuando pretendemos conocer cuál es el valor esperado de los gastos ocasionados por una reclamación cuyo seguro tiene un límite por encima del cual no recibe compensación adicional.

En general, se define para variables aleatorias discretas y continuas como:

V.A.discretas.

$$E[(X \wedge u)^k] = \sum_{x_j<u} x_j^k f(x_j) + u^k \sum_{x_j \geq u} f(x_j),$$

con $f(x)$ la función puntual de probabilidad evaluada en x.

V.A.continuas. *Si la variable X no toma valores negativos:*

$$E[(X \wedge u)^k] = \int_0^u x^k f(x)dx + u^k \int_u^{+\infty} f(x)dx,$$

con $f(x)$ la función de densidad de probabilidad evaluada en x.

Sus aproximaciones empíricas para variables continuas como las pérdidas son:

- *Para datos individualizados:*

$$E_n[(X \wedge u)^k] = \frac{1}{n} \left(\sum_{x_j<u} x_j^k + u^k \cdot (\#\{x_j \geq u\}) \right) \tag{2.13}$$

- *Para datos agrupados: una vez identificado el intervalo de agrupación al que pertenece u, $u \in (c_{j-1}, c_j)$,*

$$E_n[(X \wedge u)^k] = \sum_{i=1}^{j-1} a_i(c_i) + a_j(u) + \frac{n_j u^k (c_j - u)}{n(c_j - c_{j-1})} + \sum_{i=j+1}^{r} \frac{n_i u^k}{n}, \tag{2.14}$$

con

$$a_j(x) = \frac{n_j(x^{k+1} - c_{j-1}^{k+1})}{n(k+1)(c_j - c_{j-1})}.$$

En particular, para $k = 1$:

$$E_n[X \wedge u] = \sum_{i=1}^{j-1} \frac{n_i(c_i + c_{i-1})}{2n} + \frac{n_j(2uc_j - c_{j-1}^2 - u^2)}{2n(c_j - c_{j-1})} + \sum_{i=j+1}^{r} \frac{n_i u}{n}. \tag{2.15}$$

Definición 2.2.5. *El **percentil** p100 de una distribución $F(x)$ es aquel número π_p tal que*

$$p = F(\pi_p).$$

Los percentiles empíricos se pueden aproximar de la siguiente forma:

- *Para datos individualizados: Supongamos la muestra ordenada $x_{(1)}, \ldots, x_{(n)}$, para los que disponemos de las probabilidades acumuladas $\tilde{F}_n(x_{(i)})$. En función de dichas probabilidades podemos determinar entre qué valores $x_{(g)}$ y $x_{(g+1)}$ está el percentil π_p en cuestión. Se determina entonces según:*

$$\hat{\pi}_p = (1-h)x_{(g)} + hx_{(g+1)}, \tag{2.16}$$

  con $g = [np]$, donde [] denota parte entera, y $h = np - g$.

- *Para datos agrupados: En función de las probabilidades acumuladas en los extremos de los intervalos, $F_n(c_j)$ determinamos en qué intervalo (c_{j-1}, c_j) está el percentil π_p en cuestión. De ahí no tenemos más que despejar en la fórmula (2.2) la igualdad $p = F_n(\pi_p)$, de donde:*

$$\hat{\pi}_p = \frac{p(c_j - c_{j-1}) - c_j F_n(c_{j-1}) + c_{j-1}F_n(c_j)}{F_n(c_j) - F_n(c_{j-1})}. \tag{2.17}$$

Un caso particular de percentil es la mediana, que constituye el percentil 50. Una fórmula alternativa para obtener una aproximación es la siguiente. Una vez hemos identificado el intervalo en el que se halla la mediana, $I_j = (c_{j-1}, c_j)$, aplicamos la fórmula:

$$Mediana = c_{j-1} + \frac{(n-1)/2 - \sum_{i=j+1}^{r} n_i}{n_j}\ (c_j - c_{j-1}) \tag{2.18}$$

Práctica A.1: Descripción de Muestras

2.3. Modelización paramétrica de las pérdidas

La aproximación paramétrica para la descripción de un proceso consiste en la consideración y ajuste de un modelo de probabilidad que imite razonablemente bien el comportamiento del fenómeno (variable) observado, en nuestro caso la variable de pérdidas (o pagos). Esta aproximación nos proporciona una serie de beneficios que podemos resumir en los siguientes puntos:

1. Supone la consideración del azar implícito en todo proceso de selección aleatoria de muestras que intentan representar a una población de interés (error muestral).

2. Permite simplificar un problema inicial de n datos disponibles a otro en que sólo utilizamos unos pocos parámetros (do o tres a lo sumo, generalmente) de los que depende el modelo que finalmente ajustemos.

3. El hecho de que utilice una distribución de probabilidad para reproducir el comportamiento de una variable, facilitará las conclusiones en términos de probabilidad, de modo que podremos cuantificar la fiabilidad que nos merece cualquier estimación que consigamos. Nos dará una medida de lo que denominamos error de estimación, proporcionándonos también el modo de construir intervalos de confianza.

4. La última ventaja que reseñamos es la versatilidad que ofrece de cara a facilitarnos predicciones aun cuando cambien las condiciones que rodean al seguro (límites, franquicias, inflación,...). Es más, modelizando las pérdidas podremos calcular y predecir los pagos a realizar bajo diversas coberturas y condiciones.

2.3.1. Estimadores y propiedades

En estimación hablamos de estimadores como aquellas funciones que nos sirven para aproximar parámetros de interés. Cuando evaluamos un estimador con los datos que proporciona una muestra, obtenemos una "estimación"del parámetro en cuestión. El concepto que surge a continuación es el de la distribución en el muestreo, que nos ofrece una visión global de cómo se comporta dicho estimador, de modo que podemos evaluarlo y compararlo con otros estimadores. Las medidas básicas de calidad de un estimador son:

Sesgo: que depende del parámetro a estimar θ, y se define como la diferencia entre el valor esperado del estimador y el valor real del parámetro:

$$b_\theta(\hat{\theta}) = E(\hat{\theta}) - \theta.$$

El sesgo asintótico es el que conlleva el estimador para muestras grandes:

$$lim_{n\to\infty} b_\theta(\hat{\theta}).$$

Consistencia: Es una medida de lo probable que es obtener muestras que proporcionen estimaciones cercanas al verdadero valor del parámetro θ. Decimos que un estimador es consistente si $\forall\delta > 0$, $\forall\theta$

$$lim_{n\to\infty}\ Pr(|\hat{\theta}_n - \theta| < \delta) = 1.$$

Error cuadrático medio: Es una medida (cuadrática) de la distancia esperada entre el estimador y el valor del parámetro:

$$MSE_\theta(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = Var(\hat{\theta}) + [b_\theta(\hat{\theta})]^2.$$

Un estimador insesgado de mínima varianza es uno que es insesgado y que para cualquier valor de θ no existe ningún otro insesgado y con varianza más pequeña.

Siempre buscaremos estimadores con las mejores propiedades. En este sentido, los más eficientes serán los estimadores máximo-verosímiles.

2.3.2. Ajuste de un modelo

Una familia paramétrica de distribuciones es una colección de funciones de distribución, todas con el mismo funcional dependiente de un parámetro (o conjunto de parámetros) θ:

$$\{F(x;\theta) : \ \theta \in \Theta\},$$

donde Θ es el conjunto de todos los posibles valores del parámetro en cuestión.

El ajuste de un modelo consistirá en:

1. Determinar qué familia paramétrica describe a la población de interés.

   Ej: Proponer un modelo exponencial para un conjunto de pérdidas.

2. Estimar el valor del parámetro que la representa.

   Ej: Estimar el parámetro θ de la exponencial.

3. Estimar las cantidades (características) de interés en la población.

   Ej: Estimar el valor medio de la pérdida, o la probabilidad de que se produzca una pérdida superior a 5000 euros.

4. Calcular la precisión de las estimaciones obtenidas.

   Ej: Dar una medida de la fiabilidad del valor medio de la pérdida (intervalo de confianza).

2.3.3. Métodos básicos de estimación

Los métodos de estimación más habituales son:

Emparejado de descriptivos muestrales y poblacionales

El **método de los momentos** consiste en igualar momentos teóricos (paramétricos) con momentos empíricos. Si una familia paramétrica tiene r parámetros, y $\mu'_j = E(X^j|\theta)$, entonces el estimador de momentos se obtiene de resolver las ecuaciones:

$$\mu'_k = E(X^k|\theta), \quad k = 1, \ldots, r, \tag{2.19}$$

donde μ'_k representa la fórmula correspondiente al momento empírico de orden k calculado con los datos, (2.4) o (2.5), y $E(X^k|\theta)$ es la expresión que tiene el momento de orden k para la distribución paramétrica que proponemos como modelo, y que es una función de los parámetros de dicho modelo.

En el **emparejado de percentiles**, los percentiles empíricos y paramétricos son igualados. Si hay que estimar r parámetros, tendremos que utilizar r percentiles y resolver las ecuaciones:

$$\pi_{p_j} = \pi^F_{p_j} \quad \Leftrightarrow \quad F(\pi_{p_j};\theta) = p_j \;\; j = 1, \ldots, r, \tag{2.20}$$

donde π_{p_j} representa el percentil empírico $p_j 100$, en (2.16) o (2.17), y $\pi^F_{p_j}$ el percentil teórico calculado según el modelo propuesto $F(;\theta)$. La igualdad entre ambos percentiles equivale a la expresión de la derecha en (2.20), en términos de la función de distribución del modelo a ajustar, $F(x;\theta)$, mucho más fácil de calcular en función de θ.

MÁXIMA-VEROSIMILITUD. La verosimilitud que proporcionan observaciones independientes sobre los posibles valores (más y menos verosímiles) de un parámetro θ, $L(\theta)$, viene dada por el producto de las verosimilitudes independientes $L_j(\theta)$:

$$L(\theta) = \prod_{j=1}^{n} L_j(\theta) = \begin{cases} \prod_{j=1}^{n} f(x_j;\theta), & \text{n datos individuales} \\ \prod_{j=1}^{r} [F(c_j;\theta) - F(c_{j-1};\theta)]^{n_j}, & \text{agrup. en r intervalos,} \end{cases} \tag{2.21}$$

donde $f(x_j;\theta)$ es la función de densidad evaluada en la observación x_j, interpretable entonces como una función de verosimilitud para θ, $F(c_j;\theta)$ es la función de distribución (acumulada) evaluada en los extremos de los intervalos de agrupación y n_j son las frecuencias (absolutas) observadas en cada intervalo de agrupación $(c_{j-1}, c_j]$.

Maximizar la verosimilitud consiste en buscar el valor de θ más verosímil a la vista de los datos observados. En lugar de maximizar la verosimilitud, es preferible maximizar la log-verosimilitud $l(\theta) = log(L(\theta))$, que suele tener una expresión más sencilla, libre de potencias y exponenciales. En particular la log-verosimilitud derivada de (2.21) se calcula según:

$$l(\theta) = log(L(\theta)) = \begin{cases} \sum_{j=1}^{n} log(f(x_j;\theta)), & \text{n datos individuales} \\ \sum_{j=1}^{r} n_j log[F(c_j;\theta) - F(c_{j-1};\theta)], & \text{agrup. en r intervalos.} \end{cases} \tag{2.22}$$

No está garantizado que siempre exista el estimador máximo-verosímil. Si existe, entonces tiene una serie de 'buenas' propiedades, que son:

- Es asintóticamente insesgado: cuando se evalúa con muchos datos, su valor esperado es el valor del parámetro que estima.
- De entre los estimadores insesgados es el de menor varianza. Con muchos datos es el que menor error proporciona al estimar el parámetro.

- Es invariante a transformaciones paramétricas: cualquier función $g(\theta)$ se estimaría con $g(\hat{\theta})$.

- Se puede obtener una fórmula explícita para su varianza asintótica (válida para muestras grandes), que es la inversa de la matriz de información de Fisher:

$$I(\theta) = -E\left[\frac{\partial^2}{\partial\theta^2} l(\theta)\right] = E\left[\left(\frac{\partial}{\partial\theta} l(\theta)\right)^2\right], \tag{2.23}$$

  con $l(\theta) = log(L(\theta))$ y $L(\theta)$ la verosimilitud conjunta dada en (2.21)

  De hecho, una estimación de la varianza se obtiene simplemente sustituyendo el EMV en su expresión:

$$\hat{Var}(\hat{\theta}) = I^{-1}(\hat{\theta}) \tag{2.24}$$

- Asintóticamente tiene una distribución normal con la que es posible calcular intervalos de confianza al nivel $(1-\alpha)100\,\%$:

$$\left(\hat{\theta} - z_{1-\alpha/2}\sqrt{\hat{var}(\hat{\theta})}, \hat{\theta} + z_{1-\alpha/2}\sqrt{\hat{var}(\hat{\theta})}\right)., \tag{2.25}$$

  con $z_{1-\alpha/2}$ el cuantil $1-\alpha/2$ de una distribución normal estándar.

- Otra de las ventajas de disponer de la verosimilitud es el hecho de poder llevar a cabo **contrastes de hipótesis** y concluir sobre si los datos proporcionan evidencias a favor de la hipótesis que queremos corroborar (H_1, y en contra de H_0).

  Resultado 2.3.1. *Si proponemos el contraste $H_0 : \theta \in R_j(\theta), j = 1, \ldots, k$, que denotan un conjunto de k restricciones sobre θ, lo resolvemos a través del estadístico del cociente de verosimilitudes dado por:*

$$2[l(\hat{\theta}; x) - l(\hat{\theta}^*; x)] \sim \chi^2_k, \tag{2.26}$$

  donde $\hat{\theta}$ es el EMV sin restricciones y $\hat{\theta}^*$ el correspondiente obtenido añadiendo las restricciones de H_0. Si el p-valor asociado a dicho estadístico es inferior a $1-\alpha$, donde $\alpha 100\,\%$ es el nivel de confianza al que queremos concluir, decimos que los datos proporcionan evidencias en contra de H_0 (y a favor de la no validez de las restricciones contrastadas).

  Ejemplo 2.3.1. *Supongamos que, una vez ajustado un modelo Exponencial para unos datos, queremos concluir sobre si los datos nos dan suficientes indicios para asegurar que el valor del parámetro es inferior a un cierto valor θ_0. Es decir, queremos resolver el contraste $H_0 : \theta \geq \theta_0$ versus $H_1 : \theta < \theta_0$. Resolveríamos en función del estadístico del cociente de verosimilitudes:*

$$2[l(\hat{\theta}; x) - l(\theta_0; x)] \sim \chi^2_1, \tag{2.27}$$

Hay otros métodos de estimación basados en diversos criterios de optimización en los que no entraremos, y cuyo transfondo es siempre el de minimizar la distancia entre el estimador paramétrico y los datos.

Práctica A.2: Modelización de pérdidas

2.4. Modelos probabilísticos para las pérdidas

A la hora de proponer modelos válidos para ajustar datos procedentes de pérdidas (o pagos) asociados a un seguro, hemos de tener en cuenta una serie de características deseables para las distribuciones, útiles en la predicción de pérdidas:

1. Den probabilidad a todos los números reales no-negativos.

   En la mayoría de los procesos de pérdidas no hay un máximo para la pérdida posible. Cuando el máximo viene fijado por el valor conocido del objeto asegurado o por un límite, la distribución de la pérdida estará definida entre 0 y dicho máximo. Las distribuciones beta y beta generalizada son familias "acotadas" de ese tipo.

   Tiene cierto sentido utilizar distribuciones definidas por encima del cero (no dan probabilidad al cero) cuando por ejemplo las pérdidas por debajo de una cierta cantidad no son importantes (como cuando se aplica una franquicia). La Pareto de un único parámetro es de este tipo.

2. Sean suaves.

   La probabilidad de la pérdida ha de evolucionar de un modo continuo y suave cuando ésta lo haga. Sin embargo hay que considerar las situaciones de redondeo, que no son especialmente claras de modelizar, aunque hay varias aproximaciones. En todo caso, el proceso real de pérdidas no será tan suave como el modelo (teórico) que consideremos.

3. Algunas tengan una moda en cero y otras no.

   Si bien generalmente la distribución exacta de las pérdidas desde cero hasta algún número pequeño suele ser de poco interés.

4. Algunas tengan colas moderadas y otras colas pesadas (que tarden en caer).

   Las colas de la derecha en las distribuciones de pérdidas son cruciales en el ámbito actuarial. Hay que considerar y evaluar la posibilidad de pérdidas muy grandes, con el fin de ajustar las prestaciones de los seguros. En seguros, una cola larga significa generalmente que tarda mucho tiempo en ocurrir, durante la vigencia de una política aseguradora, una reclamación con un pago asociado alto.

El comportamiento de la cola se puede evaluar en términos de la función de supervivencia o de la función hazard. Para más detalles, ver Klugman, Panjer y Wilmot (1998, pags. 96-92).

2.5. Predicción con modelos: provisión de seguros

Una de las ventajas básicas de la modelización paramétrica es la posibilidad de predecir los resultados que se obtienen al modificar las provisiones de un seguro.

En lo que sigue denotaremos por X a la variable de pérdida y por Y a la variable de pagos. Asumiremos que hemos sido capaces de modelizar las pérdidas, esto es, de ajustar una distribución paramétrica F_X sobre la variable X a partir de observaciones $x_1, x_2, \ldots, x_n$. Nuestro objetivo será el de predecir el valor medio de un pago, $E(Y)$, a una reclamación con una pérdida X, cuando modificamos las condiciones actuales del seguro respecto a inflación (con un incremento de precios del $100r\,\%$), imposición de una franquicia d, de un límite a pagar u y/o considerando la posibilidad de una coaseguranza que establece el pago de una proporción α del total a pagar.

Definición 2.5.1. *Si X es una v.a. que representa la pérdida, la cantidad pagada por el seguro Y tras añadir una tasa de inflación de r, una franquicia d, un límite de u y un factor de coaseguranza de α, es:*

$$Y = \begin{cases} 0, & si\ X \leq d/(1+r) \\ \alpha[(1+r)X - d], & si\ d/(1+r) < X \leq u/(1+r) \\ \alpha(u-d), & si\ X \geq u/(1+r). \end{cases} \tag{2.28}$$

Una vez tengamos un modelo F_X para X, si somos capaces de escribir cómo realizamos los pagos Y en términos de cómo son los costes X, podremos obtener el modelo según el que se rigen los pagos, F_Y.

Supongamos que la variable Y está relacionada con la variable X según (2.28)*. Entonces, la distribución para Y se obtiene a partir de la de X, F_X según:*

$$Pr(Y=0) = Pr(X \leq d/(1+r)) = F_X(d/(1+r)) \quad (2.29)$$

$$\begin{aligned} Pr(Y \leq y) &= Pr(\alpha[(1+r)X - d] \leq y) \\ &= Pr\left(X \leq \frac{y+\alpha d}{\alpha(1+r)}\right) \\ &= F_X\left(\frac{y+\alpha d}{\alpha(1+r)}\right) \qquad 0 < y < \alpha(u-d) \\ f_Y(y) &= f_X\left(\frac{y+\alpha d}{\alpha(1+r)}\right) \cdot \frac{1}{\alpha(1+r)} \end{aligned}$$

$$\begin{aligned} Pr(Y = \alpha(u-d)) &= Pr(X \geq u/(1+r)) \\ &= 1 - F_X(\geq u/(1+r)) \end{aligned}$$

Cuando optamos por una determinada cobertura, hemos de tener en cuenta que nuestro objetivo es siempre el de minimizar el pago que realizamos al cliente, siempre y cuando la política establecida no repercuta en reducir la cuota de mercado y hacer variar las características básicas de la cartera de clientes. En ese sentido, una medida interesante a calcular será el pago esperado, con el fin de compararlo para diferentes coberturas aplicables.

Consideramos primeramente un resultado que nos será útil para calcular el valor esperado del pago a realizar:

Resultado 2.5.1. *Para variables aleatorias positivas, esto es, cuando $Pr(X \leq 0) = 0$, tenemos que el valor esperado del mínimo entre la variable X y el valor a, $X \wedge a$, se calcula según:*

$$\begin{aligned} E_X(X \wedge a) &= \int_0^a x f_X(x)dx + \int_u^{+\infty} u f_X(x)dx \\ &= \int_0^a x f_X(x)dx + \int_u^{+\infty} u f_X(x)dx \\ &= \int_0^a [1 - F_X(x)]dx. \end{aligned}$$

En consecuencia:

$$E_X(X \wedge u) - E_X(X \wedge d) = \int_d^u [1 - F_X(t)]dt$$
$$= (u-d) - \int_d^u F(t)dt.$$

Resultado 2.5.2. *Así, el pago esperado por pérdida X cuando tenemos una franquicia d, un límite u, un factor de coaseguranza α y una tasa de inflación r se calcula en términos de los valores esperados limitados según la distribución de X:*

$$E(Y) = \alpha(1+r)\{E_X[X \wedge u/(1+r)] - E_X[X \wedge d/(1+r)]\}, \tag{2.30}$$

donde E_X representa el valor esperado respecto de la distribución de probabilidad ajustada sobre las pérdidas X, F_X.

El pago esperado por pago o pago esperado efectivo, esto es, el pago medio para las reclamaciones que van a tener derecho a pago (que son las que provocan pérdidas en la empresa de seguros), es decir, para los incidentes en que el coste supera a la franquicia, $(1+r)X > d$), está basado en la distribución condicional $Y|X > d/(1+r)$, y se calcula según:

$$E[Y|X > d/(1+r)] = \frac{E(Y)}{1 - F_X(d/(1+r))}. \tag{2.31}$$

***Demostración**: El valor esperado del pago Y lo calculamos a partir de la distribución $f_x(x)$ para la variable de pérdidas X:*

$$E(Y) = 0Pr(Y=0) + \int_0^{\alpha(u-d)} y f_Y(y)dy + \alpha(u-d)\ Pr(Y = \alpha(u-d))$$
$$= \int_0^{\frac{d}{1+r}} 0 f_X(x)dx + \int_{\frac{d}{1+r}}^{\frac{u}{1+r}} \alpha[(1+r)x - d] f_X(x)dx + \alpha(u-d)\int_{\frac{u}{1+r}}^{\infty} f_X(x)dx$$
$$= \alpha(1+r)\int_{\frac{d}{1+r})}^{\frac{u}{1+r}} x f_X(x)dx - \alpha d \underbrace{\int_{\frac{d}{1+r}}^{\frac{u}{1+r}} f_X(x)dx}_{F(\frac{u}{1+r}) - F(\frac{d}{1+r})} + \alpha(u-d)\left(1 - F\left(\frac{u}{1+r}\right)\right),$$

de mode que integrando por partes el primer sumando:

$$\int_{\frac{d}{1+r})}^{\frac{u}{1+r}} x f_X(x)dx = x F_X(x)|_{\frac{d}{1+r})}^{\frac{u}{1+r}} - \int_{\frac{d}{1+r})}^{\frac{u}{1+r}} F_X(x)dx$$
$$= \frac{u}{1+r}F_X\left(\frac{u}{1+r}\right) - \frac{d}{1+r}F_X\left(\frac{d}{1+r}\right) - \int_{\frac{d}{1+r})}^{\frac{u}{1+r}} F_X(x)dx$$

despejamos, simplificamos y aplicando el Resultado (2.5.1)*, obtenemos finalmente:*

$$\begin{aligned} E(Y) &= \alpha(u-d) - \alpha(1+r)\int_{\frac{d}{1+r})}^{\frac{u}{1+r}} F_X(x)dx \\ &= \alpha(1+r)\left[\left(\frac{u}{1+r} - \frac{d}{1+r}\right) - \int_{\frac{d}{1+r})}^{\frac{u}{1+r}} F_X(x)dx\right] \\ &= \alpha(1+r)\left(E_X\left[X \wedge \frac{u}{1+r}\right] - E_X\left[X \wedge \frac{d}{1+r}\right]\right)) \end{aligned}$$

Definición 2.5.2. *El* ratio de pérdida eliminada *(LER en inglés) tras la imposición de una franquicia d es la reducción relativa en el pago esperado tras dicha imposición, esto es:*

$$LER_X(d) = E_X(X \wedge d)/E_X(X), \tag{2.32}$$

si ambos valores esperados existen.

Definición 2.5.3. *El* exceso de pérdida medio *tras la imposición de una franquicia de d es la cantidad que excede la pérdida esperada a dicha franquicia cuando efectivamente hay un exceso, es decir:*

$$e_X(d) = e(d) = E(X-d|X>d) = \frac{E_X(X) - E_X(X \wedge d)}{1 - F_X(d)}. \tag{2.33}$$

Resultado 2.5.3. *Cuando la tasa de inflación es $r = 0$, la varianza del pago efectuado por pérdida es:*

$$\begin{aligned} Var(Y) = \alpha^2\{E_X[(X \wedge u)^2] - E_X[(X \wedge d)^2] - 2d[E_X(X \wedge u) - E_X(X \wedge d)] \\ - [E_X(X \wedge u) - E_X(X \wedge d)]^2\}. \end{aligned} \tag{2.34}$$

Ejemplo 2.5.1. *Ejemplo 2.29 KPW. Consideremos los datos del Ejemplo 1 en la Práctica 1, provenientes de pagos Y realizados en un seguro con una franquicia de 50 euros.*

1. *Estimar empíricamente el valor medio de un pago.*

   Basta con calcular el promedio de los pagos observados, $\bar{y} = 335{,}5$.

2. *Si se presume una inflación del 10 % para el año próximo, comentar las dificultades en la utilización de una aproximación empírica.*

   Disponemos de todos los pagos a reclamaciones con pérdidas asociadas X superiores a 50 euros, que es la franquicia actual. Si suben los precios el año próximo, los datos con que deberíamos contar para realizar correctamente la estimación empírica son todos aquellos cuya pérdida actual ha sido superior a 45.45 euros, puesto que tras la inflación, tendrán derecho a pago aquellas reclamaciones tales

que $1{,}1X > 50 \Leftrightarrow X > 45{,}45$. *Sin embargo, tales datos no nos han sido proporcionados, con lo que no podemos dar una aproximación empírica razonable. La inflación afecta aquí a la frecuencia de pagos: si los precios suben, habrá mas pagos porque será más fácil rebasar la franquicia.*

3. *Asumiendo que las pérdidas X son modelizables con una distribución exponencial, predecir el valor esperado de un pago actual y de un pago del año próximo (con la consecuente inflación aplicada). ¿Qué beneficios proporciona la aproximación paramétrica?*

   • *Si los datos corresponden a pagos Y_i, recuperamos las pérdidas asociadas a dichos pagos mediante $x_i = y_i + d$, con $d = 50$, y sobre los valores $x_1, x_2, \ldots, x_{10}$ ajustamos un modelo exponencial para las pérdidas, que resulta ser*

$$X \sim Exp(\hat{\theta} = 385{,}5).$$

   Si escribimos los pagos (actuales) Y en función de las pérdidas asociadas X, tenemos:

$$Y = \begin{cases} 0 & si\ X < 50 \\ X - 50 & si\ X \geq 50. \end{cases}$$

   De modo que predecimos el pago esperado según

$$E(Y) = E_X(X) - E_X(X \wedge 50) = 338{,}6$$

   , y el pago medio para las reclamaciones con derecho a pago con:

$$E(Y|X > 50) = E(Y)/Pr_X(X > 50) = 385{,}5.$$

   • *Si asumimos una inflación del 10 % para el año próximo, los precios, y en consecuencia las pérdidas asociadas a accidentes, X^*, subirán y estarán relacionadas con las pérdidas (precios) del año anterior según $X^* = (1 + r)X$, con $r = 0{,}1$. Los pagos asociados a las reclamaciones con pérdidas X^* se calcularán según:*

$$Y^* = \begin{cases} 0 & si\ X^* < d \ \Leftrightarrow\ X < d/(1+r) \\ X^* - d = (1+r)X - d & si\ X^* \geq d \ \Leftrightarrow\ X \geq d/(1+r). \end{cases}$$

   En consecuencia, el pago medio será

$$E(Y^*) = E(X^*) - E(X^* \wedge 50) = (1+r)[E(X) - E(X \wedge d/(1+r))] = 376{,}88,$$

   y el pago medio en una reclamación con derecho a pago resultará:

$$E(Y^*|X^* > 50) = \frac{E(Y^*)}{Pr(X^* \geq 50)} = \frac{E(Y^*)}{Pr(X \geq 50/1{,}1)} = 424{,}05.$$

   La aproximación paramétrica evita este problema, pues una vez ajustado un modelo tenemos controlada la frecuencia de todo tipo de reclamaciones, al tener controlada la frecuencia de las pérdidas que se producen entre 0 y $+\infty$. En consecuencia, podemos dar la predicción sobre cualquier posibilidad que se considere sobre la forma de realizar los pagos.

Práctica A.3: Predicción y provisión de seguros

2.6. Transformación de variables

Nuestro objetivo, generalmente, es el de predecir pagos Y a través de algún modelo ajustado sobre las pérdidas X. Al fin y al cabo lo que estaremos haciendo es determinar la distribución para los pagos en función de la de las pérdidas, esto es, estaremos abordando un cambio de variable. Para ciertos cambios y ciertas distribuciones de probabilidad, este proceso es directo y sencillo. Transformaciones de variables bastante comunes en el ámbito actuarial son: la multiplicación por una constante, la potenciación, la exponenciación, la mixtura, y los límites respecto de alguno de los parámetros. Veamos que existen familias de distribuciones que se comportan bien (es fácil calcular la distribución de la transformada) para determinados cambios de variable.

2.6.1. Cambios inflacionarios y familias de escala

Cuando estamos considerando un factor de inflación r que va a afectar a los precios (y en consecuencia a las pérdidas ocasionadas a consecuencia de siniestros), la nueva variable de pérdidas X^* no es más que el producto de la subida $1+r$ por la variable de pérdida actual X: $X^* = (1+r)X$. La distribución de la nueva pérdida inflacionada X^* se calcula a través de un cambio de variable que consiste en la *multiplicación por una constante*. Los **parámetros y familias de escala** facilitan los cambios inflacionarios.

Definición 2.6.1. *Una familia paramétrica de distribuciones es una familia de escala si para una v.a. X de dicha familia, una transformada de la forma $Y = cX$ también es miembro de la familia.*

Definición 2.6.2. *Una familia paramétrica de distribuciones posee un parámetro de escala es una familia de escala y además los parámetros de la distribución de $Y = cX$ son idénticos a los de X, excepto el de escala, que viene multiplicado por la constante c.*

Todas las distribuciones del Apéndice A de KPW son familias de escala. Todas, excepto la log-normal y la inversa Gausiana, tienen un parámetro de escala.

Ejemplo 2.6.1. .

- *La distribución log-normal es una familia de escala pero no tiene parámetro de*

escala. Si $X \sim Log - Normal(\mu, \sigma)$*, sea* $Y = cX$*:*

$$F_Y(y) = Pr(Y \leq y) = Pr(cX \leq y) = Pr(X \leq y/c) = \\ = \Phi\left(\frac{log(y/c) - \mu}{\sigma}\right) = \Phi\left(\frac{log(y) - log(c) - \mu}{\sigma}\right),$$

y por tanto, $Y \sim Log - Normal(\mu + log(c), \sigma)$*.*

• *La distribución de Pareto tiene un parámetro de escala. Sea* $X \sim Pa(\alpha, \theta)$*, e* $Y = cX$*:*

$$F_Y(y) = Pr(X \leq y/c) = 1 - \left(\frac{\theta}{\theta + y/c}\right)^{\alpha} \\ = 1 - \left(\frac{c\theta}{c\theta + y}\right)^{\alpha},$$

y en consecuencia $Y \sim Pa(\alpha, c\theta)$ *y* θ *es un parámetro de escala.*

Ejemplo 2.6.2. *Supongamos que las pérdidas* X *asociadas a los siniestros de cierta cartera de seguros las podemos modelizar con una distribución exponencial* $Exp(353{,}34)$*. Si pensamos que el año próximo tendremos una inflación del 12 %, ¿cuál será la distribución de las pérdidas para dicho año? ¿Y la variabilidad de las pérdidas? ¿Qué porcentaje de siniestros tendrán pérdidas superiores a 400 euros?*

Si $X \sim Exp(\hat{\theta})$*, con* $\hat{\theta} = 353{,}34 \Rightarrow X^* = (1 + 0{,}12)X \sim Exp(\theta^*)$*, con* $\theta^* = 1{,}12\hat{\theta} = 395{,}74$*, y por lo tanto:*

$$Var(X^*) = (1{,}12\hat{\theta})^2 = 124849{,}2, \quad y \quad Pr(X^* \geq 400) = 1 - F_{X^*}(400) = 0{,}3224.$$

2.6.2. Otras transformaciones, límites y relaciones entre distribuciones

Inversión. Sabemos que si $X \sim Ga(\alpha, \theta)$ tiene una distribución Gamma, entonces su inversa, $1/X = X^{-1} \sim GaI(\alpha, \theta)$ tiene una distribución Gamma Inversa.

Exponenciación. Si tenemos una v.a. normal, su exponencial es log-Normal

$$X \sim N(\mu, \sigma^2) \dashrightarrow e^X \sim LogNormal(\mu, \sigma).$$

Mixturas. (Ejemplo 2.48 KPW)

Supongamos que las pérdidas individuales por daños físicos en el automóvil tienen una distribución $Exp(\theta_X)$. Tenemos dudas sobre cuál será el factor de inflación $c = 1+r$ para el año próximo y modelizamos la incertidumbre sobre él a través de una distribución exponencial inversa de parámetro θ_c. Entonces, la distribución

de las pérdidas del año próximo se obtiene integrando toda la incertidumbre, y resulta una distribución de Pareto con parámetros θ_c y θ_X:

$$\begin{aligned} X &= \text{ pérdidas actuales } \sim Exp(\theta_X) \\ r &= \text{ tasa inflación año próximo: desconocida} \\ Y &= (1+r)X = cX = \text{ pérdidas año próximo} \\ & \quad Y|c \sim Exp(c \cdot \theta_X) \\ & \quad c \sim Exp - Inv(\theta_c) \end{aligned}$$

$$f(y) = \int_0^\infty f(y|c)f(c)dc = \frac{\theta_c\theta_X}{(y+\theta_c\theta_X)^2} = Pa(y|1, \theta_c\theta_X).$$

Límites. Otras distribuciones se obtienen como casos límite de otras cuando hacemos converger sus parámetros a ciertos valores, como es el caso de la distribución $N(0,1)$, que es el límite de una distribución t de Student con ν grados de libertad, cuando $\nu \to \infty$.

2.7. Modelos para datos incompletos

2.7.1. Tipos de datos incompletos

Tener datos incompletos significa que ciertas observaciones se han perdido o no se han anotado correctamente. Hay dos causas básicas de datos incompletos:

Truncamiento.- las observaciones que caen en un determinado rango dado son excluidas. El **truncamiento por abajo** (respectivamente, **por arriba**) significa que se perdieron todas las observaciones por debajo (resp. por encima) de cierto valor.

Ejemplo 2.7.1. *Una franquicia impone que los pagos observados correspondan a pérdidas con un truncamiento por debajo: no se observan las que tienen un valor inferior a la franquicia.*

Censura.- se habla de datos censurados cuando se conoce el número de observaciones que caen en un determinado rango, pero se desconocen los valores concretos de las observaciones. Igualmente al caso de truncamiento, se habla de **censura por abajo** y **censura por arriba**.

Ejemplo 2.7.2. *Un límite provoca una censura por arriba en la variable de pérdidas.*

Nos preocuparemos aquí de cómo estimar un modelo adecuadamente cuando hay datos incompletos, incorporando la información que tenemos sobre de qué modo son incompletos. Una vez ajustado un modelo, se usará, como siempre, para obtener todas las inferencias de interés.

Ejemplo 2.7.3. *(Ejemplo 2.70 KPW) Se tienen datos de los gastos que han ocasionado al seguro una serie de reclamaciones. Las condiciones del mismo eran franquicia de 100 y límite de 1000:*

$$17, 307, 346, 376, 567, 900, 900, 900, 900, 900.$$

Tenemos pues, un problema de truncamiento por abajo debido a la franquicia impuesta, y de censura por arriba, debido al límite.

Nuestro propósito es ajustar un modelo Weibull para las pérdidas, considerando el hecho de que no disponemos de las pérdidas inferiores a 100 y carecemos del valor exacto de las que resultaron superiores a 1000.

2.7.2. Estimación por máxima-verosimilitud

Si tenemos datos incompletos de pérdidas y pretendemos ajustar un modelo F_X sobre las pérdidas X, hemos de obtener la relación existente entre la variable observada (generalmente pagos) y la de pérdidas. Una vez expresada la distribución de la variable observada en función de la de X, F_X, utilizamos su función de densidad para expresar la verosimilitud que otorgan los datos disponibles sobre los parámetros del modelo F_X. Al maximizar la verosimilitud conjunta obtenemos el ajuste del modelo y conseguimos nuestra herramienta de predicción.

Tratemos individualmente cada una de las situaciones que se nos pueden presentar:

1. TRUNCAMIENTO: Nos dan los datos correspondientes a los pagos que ha realizado el seguro, teniendo en cuenta que existía una franquicia d. Queremos estimar el modelo para las pérdidas X.

   Los datos que tenemos provienen de la distribución de la variable $X^* = ((X - d)|(X > d))$. Así pues, las distribuciones de X^*, la variable observada, y X, la variable a ajustar, vienen relacionadas de la siguiente forma:

   $$F_{X^*}(x) = Pr(X^* \leq x) = Pr(X - d \leq x | X > d) = Pr(X \leq x + d | X > d)$$
   $$= \frac{Pr(d < X < x + d)}{Pr(X > d)} = \frac{F_X(x + d) - F_X(d)}{1 - F_X(d)}$$

   de modo que las funciones de densidad, que van a contener información sobre la verosimilitud que proporcionan los datos sobre los parámetros de la distribución

de X, están relacionadas según:

$$f_{X^*}(x) = \frac{f_X(x+d)}{1-F_X(d)}.$$

En realidad la verosimilitud de los datos originarios se corrige por la probabilidad del rango en el que se han podido observar los datos, esto es, $X > d$.

• Otra forma de considerar el truncamiento es trabajar directamente con modelos trasladados. Si sólo observamos datos por encima de una franquicia, en lugar de empeñarnos en ajustar un modelo sobre las pérdidas originales X, podemos proponer ajustar un modelo sobre la variable observada, X^*. Al proceder de este modo, sólo podremos extraer conclusiones sobre lo observable; esto es, podremos predecir las pérdidas originales X, pero exclusivamente en el rango $X > d$.

Esto implica que si disponemos de datos $x_1, \ldots, x_n$ observados de X^*, variable sobre la que proponemos el modelo F_{X^*}, la verosimilitud vendrá dada directamente por la densidad $f_{X^*}()$, esto es, $f_{X^*}(x_1), \ldots, f_{X^*}(x_n)$.

Ajustado un modelo F_{X^*} para $X^* = (X-d)|(X > d)$, podemos predecir X en el rango $X > d$. Así, para $x > d$:

$$F_X(x|x > d) = Pr(X \leq x|x > d) = Pr(X - d \leq x - d|x > d) = F_{X^*}(x-d)$$

2. CENSURA: Nos dan los datos correspondientes a los pagos que ha realizado el seguro, teniendo en cuenta que existía un límite u. Queremos estimar el modelo para las pérdidas X.

   Los datos que tenemos provienen de la distribución de la variable

$$X^{\#} = X \wedge u = \begin{cases} X & \text{si } X < u \\ u & \text{si } X \geq u. \end{cases}$$

   Así pues, las distribuciones de X^*, la variable observada, y X, la variable a ajustar, vienen relacionadas de la siguiente forma:

$$F_{X^{\#}}(x) = \begin{cases} F_X(x) & \text{si } x < u \\ 1 & \text{si } x = u \end{cases} \qquad f_{X^{\#}}(x) = \begin{cases} f_X(x) & \text{si } x < u \\ 1 - F_X(u) & \text{si } x = u. \end{cases}$$

   Así las observaciones $x < u$ contribuyen con verosimilitud $f_X(x)$ y las observaciones en el límite u con la probabilidad del rango de costes a los que se paga con el límite u, esto es, $Pr(X > u) = 1 - F_X(u)$.

3. TRUNCAMIENTO Y CENSURA: Nos dan los datos correspondientes a los pagos que ha realizado el seguro, teniendo en cuenta que existía un límite u y una franquicia d. Queremos estimar el modelo para las pérdidas X.

Los datos que tenemos provienen de la distribución de la variable $Y = (X^{\#}|(X > d))$:

$$Y = \begin{cases} X - d & \text{si } d < X < u \\ u - d & \text{si } X \geq u. \end{cases}$$

Así pues, las distribuciones de $Y = (X^*|(X > d))$, la variable observada, y X, la variable a ajustar, vienen relacionadas de la siguiente forma:

$$f_Y(x) = \begin{cases} \frac{f_X(x+d)}{1-F_X(d)} & \text{si } 0 < x < u - d \\ \\ \frac{1-F_X(u)}{1-F_X(d)} & \text{si } x = u - d, \end{cases}$$

que representa el modo de expresar la verosimilitud de los datos disponibles en términos de los parámetros del modelo de X, F_X, a ajustar.

Respecto a la función de distribución de probabilidad, tenemos:

$$F_Y(x) = \begin{cases} \frac{F_X(x+d)-F_X(d)}{1-F_X(d)} & \text{si } 0 < x < u - d \\ \\ 1 & \text{si } x = u - d, \end{cases}$$

• La forma de tratar la censura por arriba con un modelo trasladado consiste en ajustar un modelo para la variable $X^* = (X - d)|(X > d)$, sabiendo que disponemos además de información censurada por arriba debido a un límite u. La variable que observamos, escrita en términos de X^* es:

$$Y = \begin{cases} X^* & \text{si } X^* < u - d \\ u - d & \text{si } X^* \geq u - d. \end{cases}$$

Así, la verosimilitud para los datos observados $y_1, \ldots, y_n$ vendrá dada por la función de densidad f_Y descrita en términos de la distribución para X^*, F_{X^*}:

$$f_Y(y) = \begin{cases} f_{X^*}(y) & \text{si } y < u - d \\ 1 - F_{X^*}(u - d) & \text{si } y = u - d. \end{cases}$$

Ejemplo 2.7.4. *(Ejemplo 2.70 KPW) La contribución a la verosimilitud de las observaciones disponibles es:*
Para los puntos $0 < y_i < 900$*:*

$$L(\theta; \tau; y_i) = \frac{\tau(y_i + 100)^{\tau-1}}{\theta^\tau} \; exp\left\{ -\left(\frac{y_i + 100}{\theta}\right)^\tau + \left(\frac{100}{\theta}\right)^\tau \right\}$$

Para los puntos $y_i = 900$*:*

$$L(\theta; \tau; y_i) = exp\left\{ \left(\frac{100}{\theta}\right)^\tau - \left(\frac{1000}{\theta}\right)^\tau \right\}.$$

La EMV da como estimaciones $\hat{\theta} = 1199{,}0869$ *y* $\hat{\tau} = 0{,}70074$.

Con este modelo predecimos las probabilidades de que la pérdida sea inferior a la franquicia y superior al límite con:

$$Pr((100 < X) \cap (X > 1000)) = 0{,}575431.$$

Ejemplo 2.7.5. *(Ejemplo 2.70 KPW) En el Ejemplo en que disponemos de datos observados con franquicia* $d = 100$ *y límite* $u = 1000$*, asumimos un modelo Weibull para la variable que representa la pérdida real menos la franquicia,* $X^* = X - 100 \sim Weibull(\theta, \tau)$*. Los pagos realizados* Y*, expresados en función de* X^* *vienen dados por:*

$$Y = \begin{cases} X^* & si\ X^* < 900 \\ 900 & si\ X^* \geq 900. \end{cases}$$

Así, los pagos y_i *inferiores a* $u - d = 900$ *constituyen realizaciones de la v.a.* X^**, y por lo tanto su contribución a la verosimilitud proviene directamente de la función de densidad de dicha Weibull evaluada en los puntos observados:*

$$L(\theta; \tau; y_i) = \tau(y_i/\theta)^{\tau-1} exp\{-(y_i/\theta)^{\tau}\}$$

Las observaciones en el límite, $y_i = u - d = 900$*, contribuyen a través de la probabilidad de que la v.a. Weibull supere dicho límite:*

$$L(\theta; \tau; y_i) = Pr(X^* \geq 900) = exp\{-(900/\theta)^{\tau}\}.$$

A continuación se determina la verosimilitud conjunta y se obtiene la estimación máximo-verosímil de θ *y* τ*.*

La estimación con modelos trasladados da como estimaciones $\hat{\theta} = 1373{,}878$ *y* $\hat{\tau} = 0{,}8220$.

Con este modelo podemos predecir la probabilidad de que la pérdida sea superior al límite con $Pr(X > 1000) = Pr(X^* > 900)$*, sin embargo no podemos predecir el efecto de reducir la franquicia, dado que hemos prescindido de dar probabilidad al rango de pérdidas inferiores a la franquicia original (*$Pr(X < 100) = Pr(X^* < 0) = 0$*). Los modelos trasladados, adolecen pues, de esta limitación, con la que no nos encontramos para el caso del ajuste máximo-verosímil descrito anteriormente.*

Práctica A.4: Ajuste de Modelos con Datos Incompletos

2.8. Bondad de Ajuste y Selección de modelos

Ante un conjunto de datos (de pérdidas), plantearemos diversas posibilidades sobre modelos viables para predecir cómo se producen o pueden variar los costes de los siniestros. De cara a obtener el mejor modelo posible, procederemos de la siguiente forma:

1. Para cada uno de los modelos propuestos y ajustados, conviene revisar lo que se denomina la 'bondad del ajuste', esto es, lo bueno que resulta el modelo para captar la variabilidad de los datos.
2. De entre los modelos que superan la bondad del ajuste, elegiremos el mejor modelo utilizando algún criterio de selección de modelos.

2.8.1. Bondad del Ajuste

Planteamos la aceptabilidad de algún modelo propuesto para ajustar ciertos datos observados $x_1, \ldots, x_n$ de una variable X, a través del contraste:

$$\begin{aligned} H_0 &: \quad \text{la distribución de los datos es } F(x;\theta) \text{ para algún } \theta \in \Theta \\ H_1 &: \quad \text{no es } F(x;\theta). \end{aligned}$$

Generalmente, proponemos un modelo $F(x;\theta)$ y estimamos θ por máxima-verosimilitud, con lo que el contraste que realmente resolvemos es $H_0 : F_X = F(x;\hat{\theta})$ versus $H_1 : F_X \neq F(x;\hat{\theta})$, con $\hat{\theta}$ la estimación obtenida.

Dicho contraste lo podemos resolver a través de:

Tests informales

- Superposición (o comparación) de la densidad propuesta sobre el **histograma** de los datos.
- **Gráficos qq-plot**, es decir, cuantiles empíricos versus cuantiles teóricos del modelo propuesto y estimado.
  - Si disponemos de las observaciones $x_1, \ldots, x_n$ individualizadas, consiste en representar los puntos

$$\left\{ \frac{j}{n+1}, F(x_j;\hat{\theta}) \right\}_{j=1}^{n}.$$

- Si vienen agrupados, se representan

$$\left\{\sum_{i=1}^{j}\frac{n_i}{n+1}, F(c_j;\hat{\theta})\right\}_{j=1}^{r}.$$

Si la distribución propuesta es buena, los puntos han de definir una recta de pendiente 1.

- **Computar medidas relevantes** con la muestra y compararlas con las descripciones correspondientes obtenidas con el modelo propuesto (medias, desviaciones típicas, probabilidades, cuantiles, ...).

Tests formales

- Test **Chi-cuadrado de bondad de ajuste**, basado en datos agrupados por intervalos $I_j = (c_{j-1}, c_j], j = 1, \ldots, k$, definido por:

$$\chi^2 = \sum_{j=1}^{k}\frac{(n_j - E_j)^2}{E_j}, \tag{2.35}$$

donde n_j es el número de datos observados en dicho intervalo y

$$E_j = n \cdot Pr_F(X \in I_j;\hat{\theta})$$

Se utiliza que $\chi^2 \sim \chi^2_{k-r-1}$, donde r es el número de parámetros del modelo propuesto y k el número de intervalos considerados. Conviene que $E_j > 5$ en todos los intervalos, por lo que deberíamos reagrupar de no ser así. Se concluye rechazando el modelo propuesto $F(x;\hat{\theta})$ si el p-valor asociado al valor del estadístico χ^2 es inferior a un nivel de significatividad dado ($p < \alpha$, con $1-\alpha$ el nivel de confianza exigido). Habitualmente, rechazamos si $p - valor < 0{,}05$, donde el p-valor se calcula según:

$$p - valor = Pr(\chi^2_{k-r-1} > \chi^2) = 1 - F_{\chi^2_{k-r-1}}(\chi^2).$$

- **Kolmogorov-Smirnov**: Es específico para datos individuales, pero también es viable para datos agrupados. Se define como la máxima diferencia entre la función de distribución empírica y la función de distribución del modelo propuesto en los puntos observados, es decir,

$$D = sup_x|F_n(x) - F(x;\hat{\theta})|. \tag{2.36}$$

Se concluye rechazando que el modelo propuesto $F(x;\hat{\theta})$ es válido cuando $D > D_\alpha$, donde D_α es el valor crítico asociado y que se calcula según la Tabla siguiente, válida para bases de datos con tamaños superiores a 15 ($n > 15$).

significatividad	valor crítico
0.20	$1{,}07/\sqrt{n}$
0.10	$1{,}22/\sqrt{n}$
0.05	$1{,}36/\sqrt{n}$
0.01	$1{,}63/\sqrt{n}$

Cuando los datos vienen agrupados, basta con calcular, para cada intervalo $I_j = (c_{j-1}, c_j]$, el máximo de las diferencias $|F_n(c_{j-1}) - F(c_{j-1}; \hat{\theta})|$ y $|F_n(c_j) - F(c_j; \hat{\theta})|$. El valor del estadístico D será el máximo de estas k cantidades. En ese caso, el valor crítico se consigue considerando como n el número de intervalos de agrupación ($n = k$).

2.8.2. Selección de Modelos

Presentamos dos procedimientos básicos de comparación de modelos, basados ambos en la verosimilitud de los modelos ajustados. Estos criterios son susceptibles de ser utilizados para discriminar entre mejores y peores ajustes, de entre aquellos que han superado la prueba de la bondad del ajuste.

- **Test del cociente de verosimilitudes**. Es válido para contrastar dos modelos alternativos.

  Cuando los modelos comparados son anidados, es decir, el modelo más simple, propuesto en H_0 es un caso particular del modelo más complejo propuesto en H_1, es posible concluir sobre el contraste a cierto nivel de significatividad. El estadístico de contraste es menos dos veces la diferencia del logaritmo de las verosimilitudes respectivas (de H_0 y H_1) evaluadas en los EMV, que tiene una distribución χ^2 con tantos grados de libertad como es la diferencia entre el número de parámetros estimados en los dos modelos

  $$\chi^2 = -2[log(L(\hat{\theta}_0)) - log(L(\hat{\theta}_1))] \sim \chi^2_{r_1 - r_0}, \tag{2.37}$$

  donde $L()$ denota la verosimilitud. Se concluye rechazando H_0 si el p-valor asociado es inferior al nivel de significatividad fijado (generalmente 0.05).

  Cuando no trabajamos con modelos anidados, simplemente podemos comparar modelos en función de sus log-verosimilitudes evaluadas en el estimador máximo-verosímil. Se preferirán los modelos con un valor mayor para la log-verosimilitud, o lo que es lo mismo, un valor mínimo para la log-verosimilitud cambiada de signo.

  Ejemplo 2.8.1. *Consideremos un banco de datos de pérdidas sobre el que hemos ajustado tres modelos distintos: Weibull, Gamma y Exponencial. Una vez ajustados los tres, obtenemos que sus log-verosimilitudes en las estimaciones máximo-verosímiles son:*

	Weibull	*Gamma*	*Exponencial*
log-verosim	*-336,4787115*	*-337,5858151*	*-383,7562731*

Los modelos Gamma y Exponencial, como son anidados (el segundo es un caso particular del primero), los podemos comparar mediante el test del cociente de verosimilitudes, de modo que

$$\chi^2 = -2 * [l(Exp) - l(Gamma)] = 92{,}341,$$

donde $l()$ denota la log-verosimilitud evaluada en el EMV, y el p-valor asociado se calcula con una distribución χ^2 con un grado de libertad, pues el modelo Gamma tiene dos parámetros y el Exponencial sólo uno:

$$p.valor = Pr(\chi^2_1 > 92{,}341) = 1 - F_{\chi^2_1}(92{,}341) = 0,$$

de donde, como $p.valor < 0{,}05$, se rechaza el modelo Exponencial a favor del Gamma.

La comparación entre los modelos Weibull y Gamma ha de hacerse exclusivamente con los valores de las verosimilitudes (o log-verosimilitudes). Preferimos el modelo con mayor verosimilitud (el más verosímil), o lo que es lo mismo, con menor log-verosimilitud cambiada de signo, y por lo tanto, en este caso, el modelo Weibull:

$$-l(Weibull) = 336{,}479 < 337{,}586 = -l(Gamma).$$

- **Criterio de información bayesiano (BIC)**, o criterio de Schwartz. Supone una corrección del criterio de verosimilitud considerando el número de parámetros estimados y el número de datos. Se define como:

$$BIC = -log[L(\hat{\theta}; y)] + rlog(n/2\pi), \tag{2.38}$$

donde r es el número de parámetros estimados en el modelo propuesto y n es el número de datos disponibles. Se prefiere el modelo con el mínimo valor del BIC.

Práctica A.5: Contraste y Selección de Modelos

Capítulo 3

Modelos y distribuciones de frecuencia para el Número de Pagos

3.1. Introducción

Cuando queremos predecir las primas puras y disponemos de información, por un lado de cada uno de los siniestros acontecidos entre nuestros asegurados y por otro del número de siniestros de cada uno, necesitamos: primero, ajustar un modelo a las pérdidas asociadas a los siniestros, y es de lo que nos ocupamos en el tema anterior; segundo, ajustar un modelo al número de siniestros asociados a una póliza, y es de lo que tratamos en este tema. Con sendos modelos seremos capaces de predecir el coste medio de cada siniestro, así como el número esperado de siniestros por póliza. El producto de ambas cantidades será el predictor del coste asociado a cada póliza y podrá pues, establecerse como prima pura.

En este tema proponemos modelos paramétricos útiles para modelizar el número de siniestros (o reclamaciones) asociados a una póliza (o cartera). La dinámica de trabajo es exactamente igual a la que planteamos en el tema anterior:

1. Visualizar los datos.
2. Proponer modelos de ajuste.
3. Ajustar los modelos propuestos.
4. Contrastar la bondad del ajuste de los modelos considerados, con el fin de descartar los no válidos.

5. Seleccionar el mejor modelo de entre los que hemos dado por "aceptables".

6. Utilizar el modelo seleccionado para realizar las predicciones de interés.

3.2. Presentación de los datos

Consideremos en primer lugar, un ejemplo tipo.

Ejemplo 3.2.1 (Ej 3.8 KPW)**.** *Una cartera de 10.000 pólizas proporcionó los siguientes datos sobre las reclamaciones presentadas, consistentes en el número de pólizas para las que se presentaron ninguna, una, dos, tres o cuatro o más reclamaciones.*

Nº reclamaciones	*Nº pólizas*
0	*9.048*
1	*905*
2	*45*
3	*2*
4+	*0*

La variable aleatoria es el número de reclamaciones por póliza y año. Los posibles valores observados para esta variable han sido 0,1,2,3 y 4 o más reclamaciones (en la primera columna). Los datos observados consisten en el número de pólizas que ocasionaron (en un año) cada una de las posibilidades en cuanto a número de reclamaciones. Así, un total de 9.048 pólizas no presentaron ninguna reclamación; 905 asegurados presentaron tan sólo una reclamación; 45 clientes presentaron dos reclamaciones a lo largo del año; sólo 2 clientes presentaron tres reclamaciones y no hubo ningún cliente que presentara más de tres reclamaciones. La segunda columna contiene pues información sobre la frecuencia *con que han sido observados cada uno de los posibles valores de la variable 'número de reclamaciones por póliza y año'.*

3.3. Descripción empírica

Para una variable aleatoria discreta de frecuencias N, con valores en los enteros positivos, los datos se observan como el número de ocurrencias (frecuencias) n_k en cada uno de los posibles estados $\{k = 0, 1, 2, 3, \ldots\}$. Cuando consideramos la modelización del número de siniestros por póliza (variable N), n_k representará el número de clientes asegurados que han presentado $N = k$ reclamaciones, para $\{k = 0, 1, 2, 3, \ldots\}$.

La función de probabilidad empírica se define para cada uno de los sucesos posibles, $N = k$, como la proporción de casos en los que se han dado exactamente k ocurrencias

(reclamaciones generalmente en nuestros problemas), y se calcula según:

$$\tilde{p_k} = Pr(N = k) = \frac{n_k}{n}, \qquad k = 0, 1, 2, 3, \ldots, m \tag{3.1}$$

con $n = \sum_{i=0}^{m} n_i$ y m el número máximo de ocurrencias observadas en los datos.

La función de distribución empírica se calcula aplicando (2.1):

$$F_N(k) = Pr(N \leq k) = \frac{\sum_{i=0}^{k} n_i}{n}.$$

La media empírica para una variable discreta N se calcula según:

$$\hat{\mu}'_1 = \frac{\sum_{i=0}^{m} i \; n_i}{n}, \tag{3.2}$$

y en general, el momento de orden k empírico, se calcula con:

$$\hat{\mu}'_k = \frac{\sum_{i=0}^{m} i^k n_i}{n}. \tag{3.3}$$

Nuestro objetivo en este tema es proponer modelos útiles para el número de reclamaciones correspondientes a una cartera. Haremos un repaso de varias distribuciones discretas de interés.

3.4. Modelización de variables discretas

3.4.1. Estimación de modelos discretos

La forma de ajustar modelos discretos partirá, como habitualmente, de la maximización de la función de verosimilitud conjunta, o equivalentemente de la función de logverosimilitud conjunta, definida en términos de las probabilidades p_k del modelo propuesto (dependientes de los parámetros del modelo en cuestión) y de las frecuencias observadas n_k. Dado que la verosimilitud conjunta para un modelo con valores posibles $k = 0, 1, 2, \ldots$, probabilidades asociadas $p_0, p_1, p_2, \ldots$ y frecuencias observadas $n_0, n_1, n_2, \ldots, m$, tiene la forma:

$$L(\theta; n_1, \ldots, n_m) = \prod_{i=0}^{m} p_i^{n_i}, \tag{3.4}$$

la logverosimilitud conjunta se calcula según:

$$l(\theta; n_1, \ldots, n_m) = \sum_{k=0}^{m} n_k log(p_k). \tag{3.5}$$

Para obtener la estimación máximo verosímil de los parámetros del modelo propuesto, θ, basta maximizar (3.5) respecto de θ, considerando las restricciones propias de los parámetros θ involucrados.

3.4.2. Modelos habituales: la familia $(a, b, 0)$

Comenzamos presentando las distribuciones de probabilidad habituales para la modelización de datos de naturaleza discreta, como son los modelos de Poisson, binomial negativo, geométrico y binomial. Todos ellos comparten una característica común que es la de pertenecer a la clase denominada $(a, b, 0)$ de distribuciones. Las distribuciones de esta familia tienen cierta peculiaridad, y es que existen unas constantes a y b tales que las probabilidades puntuales pueden calcularse recursivamente según:

$$p_k = p_{k-1}\left(a + \frac{b}{k}\right), \qquad k = 1, 2, 3, \ldots. \tag{3.6}$$

La probabilidad en el cero, p_0, puede calcularse a partir de la fórmula recursiva anterior, dado que las probabilidades deben sumar 1.

Este hecho nos permite una identificación gráfica rápida derivada de representar los valores $k(n_k/n_{k-1})$ observados versus k. Si alguno de los tres modelos es adecuado, los puntos representados deben manifestar cierta tendencia lineal, dado que la fórmula (3.6) puede reescribirse como:

$$k\frac{p_k}{p_{k-1}} = ak + b, \qquad k = 1, 2, 3, \ldots.$$

Si efectivamente se aprecia una tendencia lineal, basta con fijarse en el signo de la pendiente de la recta que definen para decidir la adecuación de alguno de los modelos anteriores:

- Pendiente cero $\rightsquigarrow$ Modelo Poisson:

$$Po(\lambda),\ a = 0, b = \lambda$$

- Pendiente positiva $\rightsquigarrow$ Modelo Binomial Negativo:

$$BinNeg(r, \beta),\ a = \beta/(1+\beta),\ b = (r-1)a).$$

- Pendiente negativa $\rightsquigarrow$ Modelo Binomial:

$$Bin(m, p),\ a = -p/(1-p),\ b = -a(m+1).$$

Describimos a continuación, con algo más de detalle, las características y propiedades de estos modelos.

Distribución de Poisson

La función de probabilidad de una v.a. Poisson de parámetro λ, $N \sim Po(\lambda)$, viene dada por:

$$p_k = Pr(N = k) = \frac{e^{-\lambda}\lambda^k}{k!}, \qquad k = 0, 1, 2, \ldots. \tag{3.7}$$

El parámetro λ representará, en seguros, la tasa de riesgo asociada a la ocurrencia de reclamaciones, esto es, el número esperado de reclamaciones por unidad poblacional.

La forma más cómoda para calcular probabilidades es a través de la fórmula recursiva siguiente:

$$\begin{aligned} p_0 &= e^{-\lambda} \\ p_k &= \frac{\lambda}{k}\, p_{k-1}. \end{aligned} \tag{3.8}$$

Para una v.a.Poisson, la media y la varianza coinciden con el parámetro del modelo:

$$E(N) = \lambda = Var(N).$$

La distribución de Poisson goza de una serie de buenas propiedades, útiles en particular para la modelización de riesgos en seguros.

Resultado 3.4.1. *La suma de n v.a. independientes Poisson, $N_i \sim Po(\lambda_i)$ $i = 1, \ldots, n$, es Poisson,*

$$N = N_1 + \ldots + N_n \sim Po(\lambda = \lambda_1 + \ldots + \lambda_n).$$

El resultado anterior es útil cuando, por ejemplo, distinguimos dos (o más) grupos de riesgo en nuestro colectivo de asegurados (para un determinado tipo de seguro). Si el número de reclamaciones en cada grupo es modelizable con distribuciones de Poisson (diferentes en función de las diferentes tasas de riesgo), entonces el total de reclamaciones realizadas para el mencionado seguro será también Poisson.

Ejemplo 3.4.1. *Se sabe que a lo largo de un año, en una cartera de 1000 pólizas se presentaron un total de 140 reclamaciones. Asumiendo un modelo de Poisson para el número de reclamaciones por póliza en un mes, estimar la probabilidad de que un tenedor de seguros concreto no haga ninguna reclamación durante 9 meses consecutivos.*

`Respuesta`*: Sea N =número de reclamaciones presentadas por un individuo asegurado durante un mes, y asumamos que $N \sim Po(\lambda)$. Entonces, $1000N$ corresponderá al número de reclamaciones realizadas en un mes por 1000 individuos (independientes), y tendrá una distribución $Po(1000\lambda)$. Es más, $12000N$ representará el número de*

reclamaciones realizadas a lo largo de un año por 1000 asegurados (12 meses independientes), y tendrá una distribución $Po(12000\lambda)$. *Puesto que se observaron un total de 140 reclamaciones durante un año en el total de la cartera de 1000 asegurados, por el método de los momentos podemos estimar* λ*:*

$$E(12000N) = 12000\lambda = 140 \;\rightsquigarrow\; \hat{\lambda} = 140/12000 = 0{,}01166667.$$

Así, puesto que $9N$ *representa el número de reclamaciones presentadas por un asegurado durante 9 meses consecutivos, dicha variable tendrá una distribución* $Po(9\lambda) = Po(0{,}105)$). *La probabilidad de que un asegurado no presente ninguna reclamación en 9 meses se calcula pues según* (3.8)*:*

$$p_0 = e^{-0{,}105} = 0{,}9003245.$$

Resultado 3.4.2. *Sea el número total de sucesos* N *una v.a. Poisson* $Po(\lambda)$. *Supongamos que dichos sucesos se pueden clasificar en* m *tipos diferentes e independientes, con probabilidades asociadas* $p_1, \ldots, p_m$. *Entonces las v.a.* $N_1, \ldots, N_m$ *que se corresponden con el número de sucesos de cada tipo, son también Poisson, con parámetros* $\lambda p_1, \ldots, \lambda p_m$.

Esto puede ayudar a modificar un seguro para diferenciar entre las prestaciones que se conceden a unos y otros clientes en función de diferentes tasas de riesgo o costes. En particular, si es Poisson la distribución para el número de reclamaciones asociadas a una cartera de seguros que contiene diversas prestaciones, también será Poisson la distribución para el número de reclamaciones asociadas a cada una de dichas prestaciones.

Ejemplo 3.4.2. *En un seguro médico el número medio de reclamaciones por individuo/año es de 2.3 y el número de reclamaciones seguro/año se distribuye como Poisson. Se está considerando excluir de la cobertura del seguro cierto servicio médico. Basado en estudios históricos, este servicio se ha prestado en un 10 % de las reclamaciones. ¿Cuál sería la nueva distribución de frecuencias para el nuevo seguro con tal servicio excluido? ¿Cuántas reclamaciones se esperan recibir por individuo/año tras la eliminación de dicha prestación?*

`Respuesta`*: Sea* N *el número de reclamaciones por individuo/año con el seguro actual, que se asume* $Po(2{,}3)$. *Si el 10 % de tales reclamaciones correspondieron al servicio médico en cuestionamiento,* $N_r = 0{,}9N$ *representará el número de reclamaciones asociadas a otros servicios médicos, y por lo tanto las que corresponderían al nuevo seguro que excluye el servicio médico en cuestión. Así,* N_r *tendrá una distribución* $Po(\lambda_r = 0{,}9 \cdot 2{,}3 = 2{,}07)$, *y por tanto el número esperado de reclamaciones individuo/año cuando se excluya dicha prestación será de 2.07.*

Distribución Binomial Negativa

Es una alternativa a la distribución de Poisson, especialmente cuando la variabilidad que manifiestan los datos es superior al valor medio observado. Es decir, es recomendable para modelizar datos Poisson sobredispersos (con más variabilidad de la esperada para un modelo Poisson).

La función de probabilidad de la distribución binomial negativa $N \sim BinNeg(\beta, r)$, con parámetros $\beta > 0$ y $r > 0$, viene dada por:

$$Pr(N = k) = p_k = \begin{pmatrix} k+r-1 \\ k \end{pmatrix} \frac{\beta^k}{(1+\beta)^{k+r}}, \quad k = 0, 1, 2, \ldots \tag{3.9}$$

donde el número combinatorio anterior se puede evaluar de modo generalizado a través de la función gamma:

$$\begin{pmatrix} k+r-1 \\ k \end{pmatrix} = \frac{\Gamma(k+r)}{\Gamma(r)\Gamma(k+1)}.$$

En todo caso, la forma más cómoda para calcular probabilidades es a través de la fórmula recursiva siguiente:

$$\begin{aligned} p_0 &= (1+\beta)^{-r} \\ p_k &= \left(\frac{k+r-1}{k}\right)\left(\frac{\beta}{1+\beta}\right) p_{k-1}. \end{aligned} \tag{3.10}$$

La esperanza y varianza son, respectivamente:

$$E(N) = r\beta, \qquad Var(N) = r\beta(1+\beta).$$

El parámetro β da una medida de la variación extra sobre una variable Poisson. Un valor de $\beta = 0$ significa que no hay variación extra-Poisson; un valor de $\beta = 0{,}25$ significa que esta nueva variable tiene un incremento de varianza del 25 % comparada con una distribución de Poisson con la misma media $\mu = r\beta$.

Para una distribución de Poisson se asume que las reclamaciones van llegando a lo largo del tiempo a un ritmo constante. Para una distribución binomial negativa, este ritmo aumenta linealmente con el número de reclamaciones que ya han llegado.

La **distribución geométrica** es un caso especial de la binomial negativa cuando $r = 1$. Esta distribución es, en cierto sentido, al análogo discreto de la distribución exponencial continua. Tanto la distribución geométrica como la exponencial tienen una función de probabilidad que decae exponencialmente y de ahí les viene la propiedad de la *falta de memoria.* Esta propiedad se puede interpretar de diversas formas. Si la distribución geométrica modeliza el número de reclamaciones, la propiedad de la

falta de memoria diría que, dado que al menos se han producido m reclamaciones, la distribución de probabilidad del número de reclamaciones en exceso de m no depende de m, $Pr(N \leq n|N > m) = Pr(N \leq n)$.

La distribución binomial negativa tiene una cola más pesada que la geométrica cuando $r < 1$, y más ligera (cae más rápidamente) cuando $r > 1$.

La distribución binomial

Es otra distribución útil para modelizar el número de reclamaciones. Tiene una serie de características que la hacen diferir de las otras distribuciones ya presentadas:

1. Su varianza es menor que su media. Esto la hace útil para ajustar datos en que la varianza muestral es menor que la media (muestral).

2. Si p denota la probabilidad de que se presente una reclamación, la probabilidad de que se produzcan exactamente k reclamaciones cuando hay opción a presentar un máximo de m reclamaciones es:

$$p_k = Pr(N = k) = \left(\begin{array}{c} m \\ k \end{array} \right) p^k (1-p)^{m-k}, \qquad k = 0, 1, 2, \ldots, m. \tag{3.11}$$

   Para evaluar estas probabilidades podemos utilizar la siguiente fórmula recursiva:

$$\begin{aligned} p_0 &= (1-p)^m \\ p_k &= \frac{m-k+1}{k} \frac{p}{1-p} \, p_{k-1}, \qquad k = 1, 2, \ldots, m. \end{aligned}$$

3. La distribución binomial sólo da probabilidad a un conjunto finito de valores. Es útil para describir situaciones en que existe un máximo valor observable m para la variable. Así pues, puede ser útil, por ejemplo, para modelizar el número de damnificados en un accidente automovilístico (dado el número de plazas limitado en un coche), o el número de accidentes por automóvil durante un año (puesto que sería prácticamente impensable tener más de, por ejemplo, 12 reclamaciones, teniendo en cuenta los períodos de reparación entre accidentes). En cualquier caso, será útil para modelizar frecuencias acotadas superiormente.

4. La media y varianza de una distribución binomial son, respectivamente:

$$E(N) = mp, \qquad Var(N) = mp(1-p). \tag{3.12}$$

Ejemplo 3.4.3. *Supongamos un seguro de vida, y en concreto los clientes dentro del mismo grupo de riesgo: fumadores de 35 años con 5 años de contrato. Si denotamos por p la probabilidad de que una persona con esos atributos muera el próximo año,*

entonces el número de reclamaciones (muerte) de un único cliente tendrá una distribución Bernoulli $Ber(p)$, con probabilidad $1-p$ de no morir.

El número total de reclamaciones (muertes) sobre los m individuos en dicho grupo de riesgo tendrá una distribución Binomial $Bi(m,p)$.

Práctica A.6: Distribuciones habituales para el número de reclamaciones.

3.4.3. Modificaciones en el cero: la clase $(a,b,1)$ de distribuciones

A veces las distribuciones anteriores no describen adecuadamente las características de algunos conjuntos de datos. Esto puede ser debido al comportamiento de las colas o a que dichas distribuciones no capturan la forma de la distribución de los datos en otras zonas.

Cuando el problema de tener una ajuste inadecuado es debido a la cola de la izquierda de la distribución, en concreto a la probabilidad asignada al cero (mayor o menor de la esperada bajo una de las distribuciones anteriores), tenemos la opción de utilizar las distribuciones de la clase $(a,b,1)$, que no son más que un ajuste de las distribuciones de la clase $(a,b,0)$, alterando la probabilidad del cero.

Ejemplo 3.4.4. *Por ejemplo, consideremos los seguros contratados habitualmente con las tarjetas de crédito. Dado que estos seguros suelen ser olvidados a la hora de sufrir algún percance, es de esperar en ese seguro un número bastante grande de asegurados que no habrán hecho ninguna reclamación, incrementando pues la probabilidad del cero, p_0, respecto de la probabilidad esperada bajo cualquiera de las distribuciones habituales.*

Una distribución es miembro de la clase $(a,b,1)$ si existen constantes a y b tales que:

$$\frac{p_k}{p_{k-1}} = a + \frac{b}{k}, \qquad k = 2,3,4,\ldots$$

La única diferencia con la clase $(a,b,0)$ es que la recursividad empieza en p_1 en lugar de p_0. Así, una distribución concreta en la clase $(a,b,1)$ tendrá la misma forma que su análoga en la clase $(a,b,0)$, y diferirá exclusivamente en el reparto de probabilidades. La probabilidad no asignada a los puntos $k = 1,2,\ldots$, le será dada al cero, $p_0 = 1 - \sum_{k=1}^{\infty} p_k$.

El hecho de poder modificar las probabilidades en el cero con esta clase de distribuciones permite modelizar situaciones de:

Truncamiento en el cero. Con $p_0 = 0$, de modo que toda la probabilidad se reparte

entre los puntos (sucesos) restantes. La probabilidad puntual la denotaremos como $p_k^T = Pr(N = k)$.

Modificación en el cero. Con $p_0 > 0$, pero modificado respecto de su análogo en la clase $(a, b, 0)$. La probabilidad puntual la denotaremos por p_k^M.

La relación entre una distribución de la clase $(a, b, 0)$ y su correspondiente modificada en la clase $(a, b, 1)$ viene dada por:

$$p_k^M = c \cdot p_k, \qquad k = 1, 2, \ldots \tag{3.13}$$

con $c = \frac{1-p_0^M}{1-p_0}$ dado que $P^M(1) = P(1) = 1$.

La relación entre una distribución de la clase $(a, b, 0)$ y su correspondiente truncada en la clase $(a, b, 1)$ viene dada por:

$$p_k^T = \frac{p_k}{1 - p_0}, \qquad k = 1, 2, \ldots \tag{3.14}$$

Y la relación entre una distribución modificada y la truncada en la clase $(a, b, 1)$, viene dada por:

$$p_k^M = (1 - p_0^M)p_k^T, \qquad k = 1, 2, \ldots, \tag{3.15}$$

expresión con la que se observa que la distribución modificada en el cero resulta como un promedio ponderado de una distribución degenerada en el cero y el miembro truncado en el cero de la distribución de la clase $(a, b, 0)$.

La clase $(a, b, 1)$ admite otras distribuciones distintas a las modificadas y truncadas en el cero. De hecho, es posible ampliar la distribución binomial negativa para incluir casos en que $-1 < r \leq 0$ (como la distribución binomial negativa truncada extendida (ETNB), con $r > -1,\ \beta > 0$).

Estimación en la clase $(a, b, 1)$

A la hora de obtener las estimaciones máximo-verosímiles de alguno de estos modelos, basta considerar lo siguiente:

- en los modelos truncados en el cero, el valor $N = 0$ tiene probabilidad cero, $\hat{p}_0 = 0$;
- en los modelos modificados en el cero, el EMV de p_0 viene dado por la frecuencia relativa observada para el valor $N = 0$:

$$\hat{p}_0 = \frac{n_0}{n},$$

donde $n = \sum_{i=0}^{m} n_i$, y $n_0, n_1, \ldots, n_m$ son las frecuencias observadas para $N = 0, 1, 2, \ldots, m$.

Respecto a las restantes probabilidades para $N = 1, 2, 3, \ldots$, basta calcular la logverosimilitud conjunta de la forma habitual, y maximizar respecto de los parámetros del modelo propuesto.

Práctica A.7: Distribuciones Modificadas en el cero para el número de reclamaciones.

Capítulo 4

Modelos de pérdida agregados

4.1. Introducción

El objetivo de este tema es desarrollar modelos de pérdidas agregados para predecir la cantidad total pagada por una aseguradora en todas las reclamaciones que se han producido durante un período de tiempo fijo sobre un conjunto de contratos de seguros.

Precisando definiciones:

N es la v.a. del número de reclamaciones. Su distribución es la distribución de frecuencias o del número de reclamaciones.

X es la v.a. de pérdida individual. Estrictamente hablando, X representará generalmente en este tema, un pago efectivo, aunque hablemos de ella como "pérdida". Otra denominación para X es la de **severidad**. En cualquier caso, trataremos de distinguir específicamente la pérdida real del pago.

S es la v.a. de pérdida agregada o pérdida total.

Básicamente, hay dos formas de proceder para conseguir la predicción de la pérdida agregada:

Modelo de riesgo individual .- La pérdida agregada se obtiene como la suma de los pagos realizados a los n contratos de que se compone la cartera en cuestión,

$$S = X_1 + X_2 + \ldots + X_n.$$

Generalmente se asume la independencia de dichos pagos, aunque no tienen porqué distribuirse idénticamente. Las variables X_j's se suelen modelizar con

masa de probabilidad en el cero, correspondiente a la probabilidad de que un contrato no haya acarreado pérdidas a la empresa. Los datos disponibles se corresponden con las pérdidas agregadas asociadas a los siniestros sufridos para cada una de las pólizas, $X^* = (X|X > 0)$. Así, la distribución de X, la pérdida (agregada) asociada a una póliza tendrá como distribución de probabilidad:

$$\begin{aligned} Pr(X = 0) &\leftarrow \text{ proporción de pólizas con coste cero} \\ X^* \equiv (X|X > 0) \sim F_{X^*}() &\leftarrow \text{ costes agreg. en las pólizas que ocasionaron pagos} \\ &\rightsquigarrow Pr(X \leq x) = [1 - Pr(X = 0)] \cdot F_{X^*}(x), \quad \text{si } x > 0. \end{aligned}$$

Modelo de riesgo colectivo .- El total de pérdidas para la aseguradora se representa como una suma del total de pagos efectivos. Tanto el número de pagos, N, como las cuantías pagadas, X_j's, son variables aleatorias:

$$S = X_1 + X_2 + \ldots + X_N. \tag{4.1}$$

Generalmente se asume independencia y una distribución de probabilidad idéntica para todas las X_j's.

4.2. Modelo de riesgo individual

Este modelo representa la pérdida agregada como una suma fija de variables aleatorias independientes pero no necesariamente idénticamente distribuidas,

$$S = X_1 + X_2 + \ldots + X_n,$$

donde n es el tamaño total de la cartera en cuestión. Es decir, la pérdida agregada se calcula como la suma de las pérdidas asociadas a cada uno de los n contratos de la cartera.

El modelo de riesgo individual se desarrolló inicialmente para seguros de vida. Sean:

$X_j =$ variable de pérdida ocasionada por el contratante j a la empresa

$q_j =$ probabilidad de morir este año el contratante j

$b_j =$ beneficio o desembolso de dinero que hace la compañía al morir el individuo j,

entonces

$$f_{X_j}(x) = Pr(X_j = x) = \begin{cases} 1 - q_j, & \text{si } x = 0 \\ q_j, & \text{si } x = b_j. \end{cases} \tag{4.2}$$

En ese caso, la media y la varianza de las pérdidas agregadas se calcula fácilmente al asumir independencia entre las $X_j's$ y son:

$$\begin{aligned} E(S) &= \sum_{j=1}^{n} E(X_j) = \sum_{j=1}^{n} b_j q_j \\ Var(S) &= \sum_{j=1}^{n} Var(X_j) = \sum_{j=1}^{n} E(X_j^2) - E(X_j)^2 \\ &= \sum_{j=1}^{n} b_j^2 q_j - (b_j q_j)^2 = \sum_{j=1}^{n} b_j^2 q_j (1 - q_j). \end{aligned}$$

Si todos los riesgos son idénticos ($q_j = q$) y además $b_j = 1$, entonces $S \sim Bi(n, q)$.

Generalizando, podemos considerar que las pérdidas X_j asociadas al seguro j se pueden calcular como

$$X_j = I_j B_j,$$

donde

$$I_j = \begin{cases} 1 \equiv \text{se produce pérdida} \\ 0 \equiv \text{no se produce pérdida} \end{cases}, \qquad I_j \sim Br(q_j), \tag{4.3}$$

y B_j es la magnitud de la pérdida asociada a la póliza j, dado que conlleva pérdida efectiva. La distribución de los B_j's puede ser cualesquiera. Si asumimos

$$\mu_j = E(B_j), \quad \sigma_j^2 = Var(B_j),$$

entonces:

$$\begin{aligned} E(S) &= \sum_{j=1}^{n} E(X_j) = \sum_{j=1}^{n} q_j \mu_j \\ Var(S) &= \sum_{j=1}^{n} Var(X_j) = \sum_{j=1}^{n} Var[E(B_j I_j | I_j)] + E[Var(B_j I_j | I_j)] \\ &= \sum_{j=1}^{n} Var(I_j \mu_j) + E(I_j^2 \sigma_j^2) = \sum_{j=1}^{n} \mu_j^2 q_j (1 - q_j) + \sigma_j^2 q_j. \end{aligned}$$

Ejemplo 4.2.1. *(Ejemplo 4.24 KPW). Se considera una cartera de seguros de vida sobre 75 trabajadores de una empresa. Se asume que el riesgo de mortalidad durante el año actual es similar para todos los empleados y que $Pr(muerte) = 0{,}01$. En general, el 30 % de las muertes que se producen al año son accidentales. Las condiciones de los seguros son las siguientes:*

- *50 empleados tienen unos beneficios por muerte normal de 50.000 €, y por muerte accidental de 100.000€.*
- *25 empleados tienen unos beneficios por muerte normal de 75.000 €, y por muerte accidental de 150.000€.*

1. *Determinar la media y la varianza para un modelo de riesgo individual. Para todos,* $q_j = 0{,}01$*,* $I_j = 1$ *si muere, y 0 en otro caso,* $I_j \sim Br(q_j)$*.*

   - *50 empleados* $\rightsquigarrow$

   $$Pr(B_j = x) = \begin{cases} 0{,}3, & x = 100{,}000 \\ 0{,}7, & x = 50{,}000 \end{cases}$$
   $$\mu_j = 65{,}000,\ \sigma_j^2 = 525{,}000$$

   - *25 empleados* $\rightsquigarrow$

   $$Pr(B_j = x) = \begin{cases} 0{,}3, & x = 150{,}000 \\ 0{,}7, & x = 75{,}000 \end{cases}$$
   $$\mu_j = 97{,}500,\ \sigma_j^2 = 1{,}181{,}250{,}000$$

   Luego

   $$E(S) = 56{,}875,\ Var(S) = 5{,}001{,}984{,}375$$

2. *Aproximar la distribución de la pérdida agregada mediante:*

   a*) un modelo normal*

   b*) un modelo gamma*

   c*) un modelo log-normal,*

   y comparar las aproximaciones.

3. *Con cada una de las aproximaciones, calcular la probabilidad de que la pérdida agregada supere 100.000€.*

4.3. Modelo de riesgo colectivo

En el modelo de riesgo colectivo, la distribución de la pérdida agregada S, se obtiene tras especificar separadamente la distribución de frecuencias N y la de severidades X. Así, el valor esperado y varianza de la pérdida agregada se calculan según:

$$\begin{aligned} E(S) &= E(N)E(X) \\ Var(S) &= E(N)Var(X) + Var(N)E(X)^2. \end{aligned} \tag{4.4}$$

Ejemplo 4.3.1 (Ejemplo 4.1 KPW)**.** *Un asegurador estima que el coste por siniestro* X *de cierto tipo de cliente, tiene una distribución* $f_X(x) \equiv Ga(\alpha = 7; \theta = 0{,}01)$*. En cada siniestro, el asegurador paga el 80 % de lo que excede la pérdida a una franquicia de 1.000€, y el pago máximo es de 100.000€. Por último, se considera que hay un reaseguro por el cual el reaseguro paga el exceso de 50.000€. Especifica los modelos*

para la pérdida agregada por póliza, S, en las siguientes situaciones y calcula además, $E(S)$ y $Var(S)$ sabiendo que la distribución del número de siniestros por póliza, N, es Poisson de parámetro $\lambda = 0{,}2$.

1. *la pérdida total sin reaseguro,*
2. *la pérdida agregada para el asegurador, antes del reaseguro,*
3. *la pérdida agregada para el reasegurador,*
4. *la pérdida agregada para el asegurador después del pago del reaseguro.*
5. *la pérdida agregada del asegurado (lo que no cobra del seguro).*

`Respuesta:`
Inicialmente, calculamos ciertas características de las distribuciones involucradas en costes y número de siniestros:

$$X \sim Ga(7; 0{,}01) \rightarrow E(X) = 700, Var(X) = 70000$$
$$N \sim Po(0{,}2) \rightarrow E(N) = 0{,}2 = Var(X)$$

y tendremos en cuenta la relación (4.4) *para estimar la media y varianza de la pérdida agregada.*

1. *La pérdida total del tomador del seguro.-*

$$S = X_1 + X_2 + \ldots + X_N,$$

con $X_i \sim f_X(x)$, y N es el número de siniestros que sufre el cliente. Entonces,

$$E(S) = 140, \quad Var(S) = 33600.$$

2. *La pérdida agregada para el asegurador (sin reaseguro).-*

$$S = Y_1 + Y_2 + \ldots + Y_N, \qquad con$$

$$Y_i = \begin{cases} 0, & X_i \leq 1{,}000 \\ 0{,}8(X_i - 1{,}000), & 1{,}000 < X_i \leq 126{,}000 \\ 100{,}000, & X_i > 126{,}000, \end{cases}$$

y N es el número de siniestros que sufre el cliente. Entonces, utilizando (2.30) *calcularemos $E(Y)$ y a partir de ahí:*

$$E(S) = E(Y)E(N), \quad Var(S) = E(N)Var(Y) + Var(N)E(Y)^2.$$

3. *La pérdida agregada para el reasegurador.-*

$$S = Y_1^\sharp + Y_2^\sharp + \ldots + Y_N^\sharp, \qquad con$$

$$Y_i^\sharp = \begin{cases} 0, & X_i \leq 63{,}500 \\ 0{,}8X_i - 50{,}800 & 63{,}500 < X_i \leq 126{,}000 \\ 50{,}000, & X_i > 126{,}000. \end{cases}$$

y N es el número de siniestros que sufre el cliente.

4. *La pérdida agregada para el asegurador tras cobrar el reaseguro.-*

$$S = Y_1^\flat + Y_2^\flat + \ldots + Y_N^\flat, \qquad con$$

$$Y_i^\flat = \begin{cases} 0, & X_i \leq 1{,}000 \\ 0{,}8(X_i - 1{,}000) & 1{,}000 < X_i \leq 63{,}500 \\ 50{,}000, & X_i > 63{,}500, \end{cases}$$

pues si $X_i > 63{,}500 \Rightarrow 0{,}8(X_i - 1000) > 50{,}000 \Rightarrow Y_i^\flat = Y_i - Y_i^\sharp$. Como antes, N es el número de siniestros que sufre el cliente.

5. *La pérdida agregada del asegurado (no cubierta por el seguro).-*

$$S = Y_1^* + Y_2^* + \ldots + Y_N^*, \qquad con$$

$$Y_i^* = \begin{cases} X_i, & X_i \leq 1{,}000 \\ 0{,}2X_i + 800, & 1{,}000 < X_i \leq 126{,}000 \\ X_i - 100{,}000, & X_i > 126{,}000. \end{cases}$$

y N es el número de siniestros que sufre el cliente.

4.3.1. Características

El modelo de riesgo colectivo tiene una serie de características:

1. $S = 0$ cuando $N = 0$.
2. Condicionadas a que $N = n$, las v.a. $X_1, X_2, \ldots, X_n$ son iid.
3. Condicionadas a que $N = n$, la distribución común de las v.a. $X_1, X_2, \ldots, X_n$ no depende de n.
4. La distribución de N no depende de los valores de $X_1, X_2, \ldots$.

Estas características reportan una serie de bondades de cara a modelizar de un modo flexible y más ajustado a la realidad, las pérdidas agregadas a una póliza o a una cartera.

4.3.2. Ventajas

Las ventajas de modelizar frecuencia y severidad separadamente son varias:

1. Control de la exposición sobre el número de reclamaciones N.

   • Cuando aumenta (o disminuye) el volumen de negocio de una empresa aseguradora, es de esperar que lo haga también el número de reclamaciones.

   • Asimismo, idealmente el modelo elegido para las frecuencias no debe depender de la amplitud del período de tiempo del estudio, y la frecuencia esperada debe resultar proporcional a la amplitud de dicho periodo.

   Si hemos modelizado las frecuencias de reclamación con algún modelo de la clase $(a, b, 0)$, alguno de sus parámetros se modificará proporcionalmente al incremento (decremento) experimentado en la exposición.

   Sea N el número de reclamaciones asociadas a una póliza en un año, y pretendemos predecir N^*, el número de reclamaciones asociadas:

   - a una cartera de n pólizas, a lo largo de un año,
   - o equivalentemente, a una única póliza a lo largo de n años.

   Entonces la distribución de N^* se obtendrá a partir de la de N según:

$$\begin{array}{lcl} N \sim Po(\lambda) & \rightarrow & N^* \sim Po(\lambda n) \\ N \sim BinNeg(\beta, r) & \rightarrow & N^* \sim BinNeg(\beta, nr) \\ N \sim Bin(m, p) & \rightarrow & N^* \sim Bin(mn, p). \end{array} \tag{4.5}$$

Ejemplo 4.3.2. *(Ejemplo 3.33 KPW) De estudios previos se determinó que el número de compensaciones a un grupo de 300 empleados de cierta clase tiene una distribución binomial negativa con $\beta = 0{,}3$ y $r = 10$. Entonces la distribución de frecuencias para un grupo de 500 empleados de ese tipo será también binomial negativa, pero con $\beta = 0{,}3$ y $r = 10 \cdot 500/300 = 16{,}67$.*

Ejemplo 4.3.3. *(Ejemplo 3.34 KPW) Determinar la verosimilitud de los datos de la Tabla 4.1 asumiendo un modelo de Poisson para el número de reclamaciones asociadas a cada seguro. Asumir además, que la tasa de reclamaciones no ha variado de un año para otro entre 1986 y 1991. Determinar el estimador máximo-verosímil.*

`Respuesta`*: Estamos asumiendo que todos los años tenemos la misma distribución $Po(\lambda)$ para el número de reclamaciones M_i asociadas a cada seguro, $M_i \sim Po(\lambda)$. Si n_k^e es el número de exposiciones (seguros en la cartera) en el año k, entonces el número de reclamaciones en dicho año, $N_k^* = \sum_{i=1}^{n_k^e} M_i$ tendrá una distribución $Po(\lambda \cdot n_k^e)$. La verosimilitud conjunta que proporcionan*

Año	Exposición	Reclamaciones
1986	2145	207
1987	2452	227
1988	3112	341
1989	3458	335
1990	3698	362
1991	3872	359

Tabla 4.1: Reclamaciones automovilísticas por año.

todos los años considerados, con frecuencias observadas n_k, será igual al producto de las verosimilitudes de cada uno de los años:

$$L(\lambda) = \prod_{k=1}^{6} \frac{e^{-\lambda n_k^e}(\lambda n_k^e)^{n_k}}{n_k!},$$

y el EMV($\hat{\lambda}$) resultará:

$$\hat{\lambda} = \frac{\sum_{k=1}^{6} n_k}{\sum_{k=1}^{6} n_k^e} = 0{,}09772.$$

2. Control del efecto de la inflación sobre las severidades o pagos. Los efectos de la inflación se reflejan en las pérdidas incurridas por las partidas aseguradas y en las reclamaciones pagadas por las compañías de seguros. En general, es útil que la distribución de severidad pertenezca a una familia de escala, ya que así el tipo de moneda en que se valora no afecta a los resultados. Además, estas familias permiten ajustar fácilmente los efectos de la inflación a lo largo del tiempo.

3. Control del efecto de las modificaciones en la cobertura del seguro, bien a través de la modificación de la distribución de severidades para obtener la de los pagos, bien variando la distribución del número de reclamaciones.

   Supongamos que X, la severidad, representa la pérdida sufrida en un accidente, sin tener en cuenta modificaciones de cobertura del seguro. Sea N el número de pérdidas.

   Ahora consideremos una modificación de cobertura tal que v representa la probabilidad de que una pérdida resulte en pago, por ejemplo cuando hay franquicia d, $v = Pr(X > d)$. Sea Y la cantidad pagada dado que se realiza pago; en nuestro ejemplo, $Y = (X^*|X > d)$, con $X^* = X - d$ el pago que se realiza. Asumimos además, que la imposición de modificaciones de cobertura no afecta al proceso de producción de pérdidas, o al tipo de individuo que contratará el seguro.

   Hay dos formas de proceder para determinar el número de pagos N^* asociados a las modificaciones de cobertura consideradas:

   a) no modificar la distribución de frecuencias y hacerlo con la distribución de la severidad (pagos);

b) modificar la distribución de frecuencias simplemente.

Mantenimiento de Frecuencias. Consiste en no modificar la distribución de frecuencias de las pérdidas y considerar pagos de cero con cierta probabilidad (la asociada a las pérdidas que no acaban en pagos).

Básicamente, para calcular la pérdida agregada, se utilizará la distribución de frecuencias de N y la distribución de pagos Y, obtenida a partir de las severidades originales X.

La distribución de severidad modificada o pago realizado, Y, se convierte en una mixtura de dos puntos:

$$\begin{aligned} Pr(Y = 0) &= (1 - v) \\ Pr(Y = X^*) &= v \end{aligned}$$

donde X^* es el pago a efectuar cuando hay derecho a pago, y v es la probabilidad de que se una pérdida resulte en pago.

Ejemplo 4.3.4. *(Ejemplo 3.36 KPW). Supongamos que* $N \sim BinNeg(\beta = 0{,}3; r = 10)$*, y que sólo hay seis posibles valores para las pérdidas,* $X \in \{25, 50, 75, 100, 200, 500\}$*, con probabilidades asociadas* $\{0{,}2; 0{,}3; 0{,}2; 0{,}12; 0{,}1; 0{,}05\}$*. Proporciona un modelo para esta cartera cuando se impone una franquicia de 50.*

`Respuesta`*: Si queremos mantener la distribución de frecuencias de* N *para* N^**, hemos de reajustar la distribución de pagos* Y*:*

$$Y = \begin{cases} 0, & si\ X = 25, 50 \\ X - 50, & si\ X = 75, 100, 200, 500, \end{cases}$$

con

$$Pr(Y = 0) = Pr(X \leq 50) = 0{,}5 = 1 - v,$$

y para los valores $y \in \{25, 50, 150, 450\}$*,*

$$Pr(Y = y) = Pr(X = y + 50).$$

Modificación de Frecuencias. Con esta segunda solución, para calcular la pérdida agregada se utilizará la distribución de severidades originales X, y la distribución del número de reclamaciones con derecho a pago, N^*, obtenida a partir de la de N.

Sea N es el número de pérdidas y v la probabilidad de que una pérdida resulte en pago. Sea N^* el número de pagos (distintos de cero), cuya distribución resultará:

$$
\begin{aligned}
N \sim Po(\lambda) &\rightsquigarrow N^* \sim Po(v\lambda) \\
N \sim Po(\lambda)^M &\rightsquigarrow \lambda^* = v\lambda, p_0^{M*} = \frac{p_0^M - e^{-\lambda} + e^{-\lambda^*}(1-p_0^M)}{1-e^{-\lambda}} \\
N \sim Bin(m,p) &\rightsquigarrow N^* \sim Bin(m, vp) \\
N \sim Bin(m,p)^M &\rightsquigarrow p^* = vp \\
& \qquad p_0^{M*} = \frac{p_0^M - (1-p)^m + (1-p^*)^m(1-p_0^M)}{1-(1-p)^m} \\
N \sim BinNeg(\beta, r) &\rightsquigarrow N^* \sim BinNeg(\beta v, r) \\
N \sim BinNeg(\beta, r)^M &\rightsquigarrow \beta^* = \beta v \\
& \qquad p_0^{M*} = \frac{p_0^M - (1+\beta)^{-r} + (1+\beta^*)^{-r}(1-p_0^M)}{1+(1+\beta)^{-r}}
\end{aligned}
$$

Ejemplo 4.3.5. *(Ejemplo 3.37 KPW). Un modelo alternativo para el Ejemplo 4.3.4 propuesto anteriormente, consiste en recalcular la distribución de las reclamaciones con derecho a pago. Si* $N \sim BinNeg(\beta = 0{,}3; r = 10)$*, entonces* $N^* \sim BinNeg(0.15; 10)$*, dado que* $v = 0{,}5$*.*

Todos los resultados anteriores se aplican igualmente para un incremento de la franquicia. Si N es la distribución de frecuencias para los pagos con una franquicia de d y N^* lo es para una franquicia $d^* > d$, entonces $v = \frac{1-F_X(d^*)}{1-F_X(d)}$, que es la proporción de reclamaciones que seguirán produciendo una reclamación tras la subida de la franquicia. En el caso de que se decidiera bajar la franquicia, los resultados son los mismos, pero entonces $v > 1$, lo que implica que es posible que los parámetros de la distribución de N^* queden fuera del rango aceptable, en cuyo caso no podremos generalizar el modelo con respecto a las reclamaciones adicionales que surgirán al haber rebajado la franquicia.

4. Los datos que son heterogéneos en términos de franquicias y límites pueden combinarse para obtener la distribución hipotética del tamaño de la pérdida. Esto es útil cuando se combinan datos de diferentes años en que las provisiones de los seguros han ido cambiando.

5. Los modelos desarrollados para pérdidas no cubiertas a asegurados, los costes de reclamación para los aseguradores, y los costes de reclamación a los reaseguradores pueden ser mutuamente consistentes. Esto es útil para un asegurador directo que está estudiando las consecuencias de trasladar las pérdidas a un reasegurador.

6. La forma de la distribución de S depende de la forma de las distribuciones de N y de X. Por ejemplo, si la cola de la distribución de severidad es mucho más pesada que la de la distribución de frecuencias, la distribución de las pérdidas agregadas dependerá básicamente de la primera y será insensible a la elección de la distribución de frecuencias.

En resumen, especificando separadamente la distribución de frecuencias y severidad, será posible construir un modelo más preciso y flexible para las pérdidas agregadas.

4.3.3. Aproximación de la distribución de S

El cálculo de las distribuciones (funciones de densidad/distribución) para la pérdida agregada es tedioso. Podemos sin embargo, utilizar ciertas aproximaciones sencillas, que consisten en utilizar bien distribuciones aproximantes, bien simulación Monte Carlo.

Distribución aproximante calculada mediante el método de los momentos a partir de los valores $E(S)$ y $Var(S)$. Se trata de una aproximación simple y sencilla, pero con serios inconvenientes porque no hay forma de saber lo buena que es aproximando la verdadera distribuciónde S; de hecho, puede fallar al acomodar características específicas de dicha distribución, y dar lugar a resultados críticamente diferentes, en especial en la cola derecha de la distribución.

La distribución normal da una buena aproximación cuando $E(N)$ es grande. En particular, si N tiene una distribución Poisson, binomial o binomial negativa, una versión del TCL justifica que cuando λ, m o r son grandes, la distribución de S es prácticamente normal.

Ejemplo 4.3.6 (Ejemplos 4.2-4.3 KPW)**.** *Se sabe que la media observada (y desviación estándar) del número de reclamaciones y de las pérdidas individuales durante los 10 meses pasados fue de 6.7(2.3) y 179.247 (52.141) respectivamente.*

1. *Calcular la media y desviación estándar de las pérdidas agregadas:*

$$E(S) = 1.200.955, \qquad Var(S) = 1,88180 \cdot 10^{11}.$$

2. *Utilizando la aproximación por la normal de la distribución de pérdidas agregadas, calcular la probabilidad de que dicha pérdida global exceda el 140 % de los costes esperados.*
   Asumiendo $S \sim N(\mu = E(S), \sigma^2 = Var(S))$,

$$Pr[S > (1{,}40)E(S)] = 1 - \Phi(1{,}107) = 0{,}134.$$

3. *Repetir el apartado anterior asumiendo como válida una aproximación a través de la distribución log-normal.*
   Igualando por el método de los momentos tendremos

$$S \sim Log - Normal(\mu = 13{,}93731, \sigma^2 = 0{,}1226361),$$

   de donde

$$Pr(S > (1{,}40)E(S)) = 1 - \Phi(1{,}135913) = 0{,}128.$$

En este ejemplo, puesto que $E(N)$ no es muy grande, no tenemos modo de descubrir qué distribución aproximante es mejor.

Simulación Una vez especificados y ajustados los modelos para las frecuencias y severidad, basta con simular de dichas distribuciones y aproximar la distribución de S a través de la distribución empírica basada en la muestra simulada. Básicamente, el procedimiento consiste en lo siguiente:

1. Simular $n^{(j)} \sim F_N(n), \qquad j = 1, \ldots, nsim$
2. Para cada $n^{(j)}$, simular independientemente $x_i^{(j)} \sim F_X(x)$, $i = 1, \ldots, n^{(j)}$.
3. Para cada $n^{(j)}$, calcular $s^{(j)} = \sum_{i=1}^{n^{(j)}} x_i^{(j)}, \quad j = 1, \ldots, nsim.$

La muestra obtenida $s^{(1)}, s^{(2)}, \ldots, s^{(nsim)}$ constituye una muestra aleatoria de la distribución ajustada para S, y dicha distribución puede ser aproximada por la función de distribución empírica $\tilde{F}_S(s)$,

$$\tilde{F}_S(s) = \frac{\#\{s^{(j)} \leq s\}}{nsim} \tag{4.6}$$

Práctica 8:Cálculo de la pérdida agregada

Apéndice A

Prácticas

A.1. Práctica 1: Descripción de Muestras

Ejemplo 1. Los datos que se presentan a continuación son las cantidades (en euros) pagadas por el seguro a 10 clientes que hubieron de recibir asistencia médica dental.

$$141, 16, 46, 40, 351, 259, 317, 1511, 107, 567.$$

Ejemplo 2. Se presentan aquí más datos sobre gastos dentales cubiertos por el seguro, resumidos de la siguiente forma (Tabla A.1):

Cantidad pagada	número de pagos
0-25	30
25-50	31
50-100	57
100-150	42
150-250	65
250-500	84
500-1000	45
1000-1500	10
1500-2500	11
2500-4000	3

Tabla A.1: Gastos dentales cubiertos por la aseguradora.

1. Describe la variable aleatoria observada y comenta de qué tipo (continua o discreta) y cómo se presentan los datos (individualizados o agrupados).
2. Proporciona varios parámetros poblacionales asociados a dicha población.
3. Describe gráfica y numéricamente la muestra disponible, aproximando la distribución empírica.

A.2. Práctica 2: Modelización de pérdidas

Utilizando los datos del Ejemplo 1 en la Práctica 1 considera los modelos exponencial, gamma y Pareto, y para cada uno de ellos resuelve las siguientes cuestiones:

1. Obtén las estimaciones que se derivan de aplicar:
   - el método de los momentos,
   - el método de los percentiles (con los percentiles 40 o 40/70 si se trata de distribuciones con dos parámetros)
   - el método de máxima-verosimilitud.
2. Formula el modelo ajustado por máxima-verosimilitud y con él estima:
   a) el pago esperado para una reclamación por gastos dentales;
   b) la probabilidad de que se dé una reclamación con gastos asociados superiores a 500 euros; la proporción de reclamaciones que se espera que tengan gastos superiores a los 500 euros;
   c) la cuantía por debajo de la cual tenemos ciertas garantías de que estarán la mayoría (en concreto el 95 %) de las facturas reclamadas al seguro.
3. Determina la matriz de información de Fisher y calcula con ella la matriz de varianzas-covarianzas. Da una medida del error de la estimación máximo-verosímil y construye un intervalo de confianza al nivel (de confianza) del 95 %.
4. Repite los ejercicios anteriores para el Ejemplo 2 en la Práctica 1, con datos agrupados.

A.3. Práctica 3: Predicción y provisión de seguros

Vas a trabajar con los datos del Ejemplo 2 de la Práctica 1, suponiendo que las cantidades descritas (X) se refieren a los gastos dentales que tuvieron diversos asegurados el año pasado.

1. Calcula empíricamente la media y la varianza. Por el método de los momentos, estima los parámetros de una distribución log-normal útil para modelizar dichas pérdidas (gastos).
2. Asumiendo la adecuación del modelo log-normal para describir los gastos dentales ocasionados, considera las siguientes situaciones de cara a planificar (o modificar) seguros dentales de cara al año próximo:

   S1. se impone una franquicia de 25

   S2. se impone un límite de 2500

   S3. se imponen franquicia (25) y límite (2500)

   S4. se producirá una tasa de inflación del 10 %

   S5. se asume una inflación del 10 % y se impone una franquicia de 25

   S6. se asume una inflación del 10 % y se imponen franquicia (25) y límite (2500).

   Calcular:

   a) El pago esperado que sufragará el seguro por gasto dental (individual).

   b) El ratio de eliminación de pérdida esperado ($E(Y)/E(X)$) con las nuevas políticas y/o previsiones sobre el seguro. ¿Qué interpretación le das?

   c) Para la situación con franquicia, límite y asumiendo inflación 0 (S3), calcula:

      1) La diferencia entre el pago esperado a efectuar con y sin restricciones cuando una reclamación tiene derecho a pago, $E(Y|X > d)/E(X)$. ¿Qué interpretación le das?
      2) La variabilidad de los pagos efectuados por el seguro en gastos dentales para la situación.

   d) ¿Qué política parece más ventajosa cuando se presume inflación 0? ¿Y cuando se prevé una inflación del 10 %?

A.4. Práctica 4: Ajuste de Modelos con Datos Incompletos

1. (Example 2.74 KPW): **Truncamiento por arriba**.

   Se dispone de los datos (agrupados) de los tiempos transcurridos hasta que se presentó reclamación al seguro por 'práctica médica irregular' para una serie de clientes que fueron reclamando desde la ocurrencia del suceso hasta 14 años más tarde. Queremos estimar un modelo Weibull para el tiempo transcurrido hasta que se presenta reclamación (variable X)

   a) Comentar si existe algún problema de datos incompletos en los datos disponibles. Identificar de qué tipo es (truncamiento o censura por arriba/abajo).

   b) Estimar el modelo Weibull para X, a partir de los datos disponibles, utilizando máxima-verosimilitud.

   c) Sabiendo que la matriz de covarianzas para los EMV es:

   $$Cov(\hat{\theta}, \hat{\tau}) = \begin{pmatrix} 4{,}18651 & 0{,}0143151 \\ 0{,}0143151 & 0{,}00503498 \end{pmatrix},$$

   obtener un intervalo de confianza al 95 % para las estimaciones.

   d) Se pretende estimar el número de reclamaciones que no llegaron a presentarse durante los 14 años de recogida de datos. Obtener la estimación máximo verosímil y un intervalo de confianza al 95 %.

2. (Ejercicio 2.115 KPW) Se nos dice que las pérdidas asociadas a accidentes que tienen un grupo de asegurados sigue una distribución Weibull con parámetros $\tau = 1$ y $\theta = 20$. Se recoge una muestra de pérdidas, pero los datos están truncados por abajo debido a una franquicia de 10.

   a) Determinar la probabilidad de que una pérdida observada sea por lo menos de 25.

   b) Dado que se realiza un pago, ¿cuál es la probabilidad de que dicho pago sea al menos de 25?

3. (Ejercicio 2.116 KPW) Se conoce la distribución de X ='pérdida durante 2002' para un conjunto de asegurados, cuya función de densidad es $f(x) = 0{,}1e^{-0{,}1x}$, $x > 0$. Se prevé una inflación del 10 % (uniforme) sobre todas las pérdidas del 2002 al 2003. En el 2003 se está pensando en aplicar una franquicia de d a todas las pérdidas. Determinar la probabilidad de que se dé un pago por pago inferior a 5 en el 2003.

4. (Ejercicio 2.118 KPW) Se supone que las pérdidas X de un conjunto de pólizas sigue una distribución de Pareto con parámetros $\alpha = 2$ y $\theta = 1000$. Se esperan

10 accidentes con pérdidas cada año. Para cada pérdida, el pago que realiza el asegurador es igual a la pérdida si ésta es mayor de 100. El asegurador no paga si la pérdida es menor o igual a dicha cantidad.

a) Determinar el pago anual esperado a realizar por la aseguradora.

b) Determinar el pago anual esperado que realizará el asegurador si las pérdidas se cree que la cuantía de las pérdidas se incrementará en un 10 %.

A.5. Práctica 5: Contraste y Selección de Modelos

1. Considera los datos del Ejemplo 2 en la Práctica 1.

   a) Valora informalmente la bondad del ajuste máximo-verosímil del modelo log-normal.

   b) Realiza el test chi-cuadrado de bondad de ajuste para comprobar si el modelo log-normal es apropiado. Realiza también el test de Kolmogorov-Smirnov.

   c) Repite los apartados anteriores con el modelo Gamma y compara los resultados con los del log-normal. ¿Con qué modelo concluyes finalmente y en base a qué?

2. Para otro conjunto de datos (Tabla 2.18 de KPW[1]), se ajustaron por máximo-verosimilitud diversos modelos con distintos número de parámetros. Los resultados de '-log-verosimilitud(EMV))', el número de parámetros en cada modelo y los resultados del test chi-cuadrado de bondad de ajuste, aparecen en la Tabla A.2. Juzga la idoneidad de cada uno de los modelos y concluye sobre cuál de ellos es preferible (para un mismo número de parámetros y en general), dando el nivel de significatividad asociado cuando sea posible.

Modelo	Nºpars.	-Logver(EMV)	χ^2	g.l.	p-valor
exponencial	1	548.72	81.02	8	$<$ 0,0001
exponencial inversa	1	520.27	490.6	8	$<$ 0,0001
lognormal	2	498.29	4.51	9	0.8744
gausiana inversa	2	502.26	12.95	9	0.1648
Pareto	2	499.31	6.37	9	0.7028
Pareto inversa	2	500.09	7.52	9	0.5831
Loglogística	2	499.93	7.51	9	0.5847
Gamma	2	507.84	16.38	8	0.0372
Gamma inversa	2	509.80	26.77	8	0.0008
Weibull	2	501.63	8.16	8	0.4183
Weibull inversa	2	506.72	20.27	9	0.0163
Paralogística	2	499.79	7.30	9	0.6055
Paralogística inversa	2	500.01	7.58	9	0.5767
Burr	3	498.41	4.79	8	0.7793
Burr inversa	3	499.01	5.33	8	0.7220
Pareto generalizada	3	498.62	5.00	8	0.7580

Tabla A.2: Ajustes por máxima-verosimilitud.

[1]Klugman, Panjer y Willmot, 1998

A.6. Práctica 6: Distribuciones habituales para el número de reclamaciones

1. (Ejercicio 3.5 KPW) Una política de seguros de coches cubre accidentes causados tanto por motoristas asegurados a mínimos como no asegurados. A partir de datos de 1000 accidentes causados por motos, se obtuvo la información de la Tabla A.3.

   a) Determinar el EMV de λ para un modelo de Poisson en cada una de las variables de frecuencias de reclamación (N_1 =nº reclamaciones con cobertura mínima, y N_2 =nº reclamaciones en accidentes con motorista no asegurado).

   b) Realizar el test chi cuadrado de bondad de ajuste al nivel de significatividad de $\alpha = 0{,}05$ para cada modelo ajustado en el apartado anterior. ¿Qué conclusiones obtienes?

   c) ¿Qué significaría que N_1 y N_2 fueran independientes? Asume independencia y determina un modelo útil para predecir el número total de reclamaciones por accidentes provocados por motoristas asegurados a mínimos o no asegurados ($N = N_1 + N_2$). Calcula un intervalo de confianza al 95 % para la tasa de reclamaciones asociadas a accidentes provocados por alguno de los dos tipos de motoristas considerados.

Nº reclamaciones	seguros mínimos	no asegurados
0	901	947
1	92	50
2	5	2
3	1	1
4	1	0
5+	0	0

Tabla A.3: Reclamaciones por accidentes de coches.

2. (Ejercicio 3.7 KPW) Los datos de la Tabla A.4 representan el número de prescripciones rellenadas por un grupo de miembros mayores de un plan de seguros.

   Se pide ajustar un modelo Poisson para dichos datos, calcular un intervalo de confianza para el número esperado de prescripciones y llevar a cabo el test de bondad de ajuste para dicho modelo.

Nº prescripciones	frecuencia	Nº prescripciones	frecuencia
0	82	16-20	40
1-3	49	21-25	38
4-6	47	26-35	52
7-10	47	36+	91
11-15	57		

Tabla A.4: Reclamaciones por accidentes de coches.

3. (Ejemplo 3.4 KPW) En la Tabla A.5 hay datos sobre el número de accidentes por día a lo largo de un año, que resultaron en reclamación a la compañía de seguros para una cobertura concreta.

nº reclamaciones/día	nº días
0	47
1	97
2	109
3	62
4	25
5	16
6	4
7	3
8	2
9+	0

Tabla A.5: Número de accidentes (reclamaciones) por día en un año.

   a) Determinar si el modelo Poisson es apropiado (obtener el ajuste y realizar el test de bondad de ajuste).

   b) Inferir sobre el número esperado de reclamaciones por día a un nivel de confianza del 95 %.

   c) Suponer que nos hubieran dado los datos completos hasta 5 reclam/día, y sólo nos dijeran que con 6 o más de 6 reclamaciones han habido 9 días (censura por arriba). Determinar la verosimilitud bajo este supuesto de censura y obtener el EMV. Juzgar la adecuación del modelo con el test chi-cuadrado de bondad de ajuste y derivar las inferencias correspondientes.

   d) Estimar el modelo binomial negativo para los datos completos de la Tabla A.5. A la vista de una primera inspección empírica de los datos, ¿tiene sentido este modelo? ¿en qué te basas? Utilizar el método de los momentos y la estimación máximo-verosímil.

   e) Comparar los modelos Poisson y Binomial-negativo (con los EMV) y concluir sobre cuál parece más adecuado para el ajuste de los datos dados. Utilizar el test del cociente de verosimilitudes.

4. (Ejemplo 3.10 KPW) El número de reclamaciones por póliza durante un año para un conjunto de 15.160 pólizas viene dado en la Tabla A.6. Ajustar un modelo binomial.

nº reclamaciones/póliza	nº pólizas
0	5367
1	5893
2	2870
3	842
4	163
5	23
6	1
7	1
8+	0

Tabla A.6: Número de reclamaciones por póliza.

A.7. Práctica 7: Distribuciones en la clase $(a, b, 1)$ para el número de reclamaciones

1. Considera una v.a. Binomial Negativa con parámetros $\beta = 0{,}3$, $r = 2{,}5$. Determinar las cinco primeras probabilidades y representarlas. Determinar también dichas probabilidades y representarlas para las correspondientes distribuciones truncada y modificada en el cero con $p_0^M = 0{,}4$.

2. Para los datos de la Tabla A.7, de Beard et al. (1984), determinar un modelo que describa adecuadamente los datos. Probar con las distribuciones Poisson, Geométrica, y sus correspondientes modificados en el cero. Realizar los test de bondad de ajuste y del cociente de verosimilitudes.

No.Accidentes	No.Reclamaciones
0	370412
1	46545
2	3935
3	317
4	28
5	3
6+	0

Tabla A.7: Datos de Beard et al.(1984). Table 3.13 KPW.

3. Para los bancos de datos en las Tablas A.8-A.11:

   a) Representa los datos para elegir la distribución apropiada (kn_k/n_{k-1} versus k), y justifica tu respuesta.

   b) Determina los emv en cada uno de los modelos de la clase $(a, b, 0)$.

   c) Ajusta también los modelos modificados en el cero Poisson, Geométrico, Binomial Negativo y el modelo Logarítmico.

   d) Utilizando el test chi-cuadrado de bondad de ajuste y el test del cociente de verosimilitudes, ¿qué modelo proporciona el mejor ajuste?

No.recl.médicas	No.accidentes
0	529
1	146
2	169
3	137
4	99
5	87
6	41
7	25
8+	0

Tabla A.8: Número de reclamaciones médicas en accidentes de automóvil declarados.

No.reclamaciones	No.Pólizas
0	9048
1	905
2	45
3	2
4+	0

Tabla A.9: Número de reclamaciones de una cartera de 10.000 pólizas.

No.prescripciones	frecuencia	N0.prescripciones	frecuencia
0	82	16-20	40
1-3	49	21-25	38
4-6	47	26-35	52
7-10	47	36+	91
11-15	57		

Tabla A.10: Número de prescripciones rellenadas en un año por un grupo de individuos de un plan de pensiones.

No.recl.médicas	No.accidentes
0	861
1	121
2	13
3	3
4	1
5	0
6	1
7+	0

Tabla A.11: Número de reclamaciones de una cartera de 1.000 pólizas.

A.8. Práctica 8: Cálculo de la pérdida agregada

1. (Ejercicio 3.48 KPW) Una poliza de seguros de vida tiene una cláusula por muerte accidental. Para muertes ordinarias, el beneficio es de 10.000, y para una muerte accidental es de 20.000. Los asegurados tienen aproximadamente la misma edad, de modo que es razonable asumir que todos ellos tendrán las mismas probabilidades de reclamación. Supongamos que estas probabilidades sean: 0.97 de no reclamar, 0.01 por muerte ordinaria y 0.02 por muerte accidental. Un reasegurador ha sido preguntado para proporcionar los 10.000 de exceso para muertes accidentales.

   a) El proceso de reclamaciones se puede modelizar con un modelo de frecuencias compuesto que tiene una distribución Bernoulli para las frecuencias (reclamar/no reclamar) y una componente de severidad de dos puntos (con probabilidades asociadas a los dos niveles de reclamación cuando se da tal reclamación). Especificar las distribuciones de probabilidad para las variables de frecuencia y severidad.

   b) Supón que el reasegurador quiere retener la misma distribución de frecuencias. Determina la distribución de severidad modificada que reflejará los pagos del reasegurador.

   c) Determina las distribuciones de frecuencias y severidad del reasegurador cuando la distribución de severidad viene condicionada en que se realiza un pago por el reaseguro.

2. (Ejercicio 3.49 KPW) Las pérdidas individuales tienen una distribución de Pareto con $\alpha = 2$ y $\theta = 1000$. Con una franquicia de 500, la distribución de frecuencias para el número de pagos es Poisson con $\lambda = 3$. Si la franquicia se eleva a 1.000, determina la distribución para el número de pagos. También determina la función de densidad para la severidad (por pago) cuando se aplique la nueva franquicia.

3. (Ejercicio 3.50 KPW) Las pérdidas tienen una distribución de Pareto con $\alpha = 2$ y $\theta = 1000$. La distribución de frecuencias para una franquicia de 500 es logarítmica truncada en el cero, con $\beta = 4$. Determina un modelo para el número de pagos cuando la franquicia se reduce a cero.

4. (Ejemplo 4.4 KPW.) Un plan de seguros dentales cubre a los empleados de una fábrica y a sus familias. El premium para cada empleado casado es el mismo sea cual sea el número de miembros en la familia. La compañía de seguros tiene datos sobre los costes anuales que le han permitido ajustar un modelo para la pérdida anual por individuo y una distribución para el número de beneficiarios por contrato; dichas distribuciones aparecen en la Tabla A.12.

   El objetivo es estimar el coste agregado anual S de cada contrato:

Costes en 25$		Número beneficiarios	
x	$f_X(x)$	n	p_n
1	0.150	0	0.05
2	0.2	1	0.1
3	0.25	2	0.15
4	0.125	3	0.2
5	0.075	4	0.25
6	0.05	5	0.15
7	0.05	6	0.06
8	0.05	7	0.03
9	0.025	8	0.01
10	0.025		

Tabla A.12: Gastos en seguros dentales para un grupo de empleados.

a) La media y desviación típica del total de pagos por empleado (considera la unidad de medida y expresa el resultado en dólares).

$$E(S) = E(N)E(X)$$
$$Var(S) = E(N)Var(X) + Var(N)E(X)^2.$$

b) La distribución de pagos agregados por empleado, asumiendo que la distribución normal con media y varianza anteriores la aproxima bien.

$$S \sim N(E(S), Var(S))$$

c) La distribución exacta de pagos agregados por empleado hasta 525$ (probabilidades asociadas).

$$f_S(x) = \sum_{n=0}^{8} p_n f_X^{*n}(x),$$

con

$$f_X^{*k}(x) = \sum_{y=0}^{x} f_X^{*k-1}(x-y) f_X(y), \qquad x = 1, 2, \ldots,$$

y $f_X^{*0}(x) = 0$, por tratarse de una distribución de severidades "discreta".

d) Compara las dos distribuciones anteriores y concluye sobre la efectividad de la aproximación normal.

e) Prueba ahora a aproximar con una distribución log-normal con media $E(S)$ y varianza $Var(S)$, y extrae conclusiones sobre su efectividad.

$$E(S) = exp\{\mu + \sigma^2/2\}; \qquad E(S^2) = exp\{2\mu + 2\sigma^2\}$$

5. (Ejemplo 4.21 KPW). Supongamos que en una cartera el número de pérdidas que se producen se puede modelizar a través de una distribución de Poisson $Po(10)$, y que las cantidades de pérdida en cada una por una distribución de Pareto $Pa(\alpha = 3, \theta = 100)$.

   a) Determinar el modelo que resulta para la pérdida agregada y aproximar su distribución mediante simulación. Calcular la media y varianza de dicha distribución.

$$S = X_1 + X_2 + \ldots + X_N$$

$$\begin{aligned} &E(N) = 10 = Var(N) \\ &E(X_j) = 50,\ Var(X_j) = 100^2 - 50^2 = 7500. \\ \Rightarrow &\begin{cases} E(S) = 10 \cdot 50 = 500 \\ Var(S) = 10 \cdot 7500 + 10 \cdot 50^2 = 100{,}000 \end{cases} \end{aligned}$$

   b) Si se establece como condición en el seguro una franquicia de 50, determinar el modelo para el pago agregado. Calcular la media y varianza de dicha distribución. Aproximar su distribución con simulación y con una aproximación con la distribución normal. Comparar ambas aproximaciones.

$$S^* = Y_1 + Y_2 + \ldots + Y_{N^*},$$

   con N^* = número de pagos (efectivos), $N^* \sim Po(10v)$, con $v = Pr(pago) = Pr(X > 50) = (100/150)^3 = 0{,}296296$, de donde

$$E(N^*) = 2{,}96296 = Var(N^*),$$

$$\begin{aligned} Pr(Y \leq y) =& Pr(X \leq y + 50 | X > 50) = \frac{F_X(y+50) - F_X(50)}{1 - F_X(50)} \\ =& 1 - \left(\frac{150}{150 + y}\right)^3 \\ \Rightarrow Y \sim Pa(3, 150)\ &\begin{cases} E(Y) = 75 \\ Var(Y) = 16{,}875. \end{cases} \end{aligned}$$

Apéndice B

Ejercicios Variados

Los ejercicios que se citan a continuación están extraídos del libro de Klugman, Panjer y Willmot, 1998. Son ejercicios tipo que involucran los conceptos fundamentales tratados a lo largo del curso, útiles por tanto, para afianzar la asignatura.

B.1. Ejercicios del Tema 2

Ej 2.2, 2.102, 2.120 KPW Los datos del fichero Tabla 2.24 (KPW) son del libro Practical Risk Theory for Actuaries (27,pag 76). Representa las pérdidas por incendios en el Reino Unido (medidas en libras). Había un total de 16.536 pérdidas en el conjunto de datos, y la pérdida media fue de 7.009. Como es común en datos agrupados, para cada intervalo se presenta la media muestral.

1. Estima la media, desviación estándar, coeficiente de variación y asimetría para la población de pérdidas por incendios.
2. Estima los percentiles 50, 75, 90 y 95. ¿Cuál es la pérdida por encima de la cual tan sólo quedaron el 5 % de las pérdidas por incendios?
3. Estima el primer momento limitado por 350.000.
4. Ajusta un modelo apropiado para los datos. Considera varios modelos y utiliza tests de bondad de ajuste para compararlos y elegir uno definitivo. (Ayuda: Lognormal, loglogística, Paralogística Inversa, Burr, Burr Inversa y Beta Transformada)
   a) Estima la media y desviación estándar.
   b) ¿Cuál es la probabilidad de que se dé una pérdida por incendios inferior a 3.200?
   c) ¿Cuál es la pérdida por encima de la cual se esperan tan sólo el 5 % de las pérdidas por incendios?

d) Compara estos resultados con los que obtuviste utilizando las estimaciones empíricas con todos los datos disponibles.

5. Supón que no te dan las once primeras filas de la tabla. Esto significaría que los datos habían venido truncados por abajo en 3.200, de modo que representaran pérdidas superiores a una franquicia de 3.200. Ajusta (por verosimilitud) un modelo Weibull para estos datos reducidos. Con dicho modelo ajustado:
   a) Estima la media y desviación estándar.
   b) ¿Cuál es el porcentaje de incendios que se espera con pérdidas asociadas inferiores a 3.200?
   c) ¿Cuál es la pérdida por encima de la cual tan sólo quedaron el 5 % de las pérdidas por incendios?
   d) Compara estos resultados con los que obtuviste con el modelo que ajustaste con todos los datos disponibles.
   e) Se está pensando en cambiar las prestaciones del seguro una franquicia de 5.000 y un límite de 1.000.000. Escribe la variable de pagos Y en función de la de pérdidas X (teniendo en cuenta el truncamiento). Determina el pago esperado por pago. ¿Cuál es la el porcentaje de pagos efectivos (por pago) que se harán por una valía superior a 500.000?
   f) Asumiendo una inflación del 2 % para el año próximo, considera tú otra cobertura diferente del seguro, tratando de obtener mayores beneficios (como empresa). Especifica claramente cómo se realizan los pagos Y^* con tu política (en función de X). Justifica la bondad de la cobertura que propones.

Ej 2.38,2.66,2.106,2.123 KPW Se recogieron las siguientes 20 observaciones. Se desea estimar $Pr(X > 200)$. Cuando se requiera un modelo, utiliza la distribución de Pareto con un solo parámetro ($F(x) = 1 - (100/x)^{\alpha}, x > 100, \alpha > 0$).

132	149	476	147	135	110	176	107	147	165
135	117	110	111	226	108	102	108	227	102

1. Determina la estimación empírica de $Pr(X > 200)$.
2. Ajusta el modelo Pareto por el método de los momentos y estima con él dicha probabilidad.
3. Ajusta por máxima verosimilitud el modelo Pareto y estima $Pr(X > 200)$. Calcula el test de Kolmogorov-Smirnov para valora la adecuación del modelo Pareto.
4. Obtén la varianza del estimador empírico como una función de α.
5. Obtén la varianza asintótica del EMV y un intervalo de confianza al 95 %.
6. Compara los dos estimadores.
7. Estima el pago esperado para una sola pérdida.

8. Estima el cociente de eliminación de pérdida si se impone una franquicia de 200.
9. Un reasegurador está considerando dar una cobertura que pagará el 80 % del exceso sobre 500. Compara el pago esperado (por pérdida) de la reaseguranza según el modelo de Pareto con la estimación empírica. Haz lo mismo para el pago esperado por pago.
10. El pago esperado por pérdida si se aplica uniformemente a todas las pérdidas una inflación del 5 %.
11. El cociente de eliminación de pérdida si se impone una franquicia de 200 sobre las pérdidas inflacionadas.
12. Supón que los datos hubieran sido truncados por abajo en 125 y censurados por arriba en 200. Ajusta el modelo Pareto con estas restricciones (conservando $\theta = 100$). Calcula $Pr(X > 200)$ y compara los resultados.

Ej 2.68 KPW En el libro *Loss Distributions* (66, p.161) aparecen los datos del fichero Tabla 2.29 (KPW). Dicha tabla contiene las indemnizaciones pagadas por accidentes de automóvil. El objetivo es comparar el pago esperado por pérdida con un límite de 25.000 y el correspondiente a un límite de 10.000 a través del cociente de ambos, al que denominamos *factor de incremento de límite*. Utiliza siempre una distribución Weibull y estimación máximo verosímil.

1. Ajusta el modelo Weibull con los datos de límite 25.000 y llámalo M1. Repite la operación con los datos de límite 10.000 y llámalo M2. Estima los pagos esperados por pérdida con límites de 25.000 y 10.000 con los modelos respectivos y calcula el factor de incremento de límite.
2. Ajusta el modelo Weibull con todos los datos (de los 5 límites). Estima después el factor de incremento de límite.
3. Asume que los modelos Weibull aplicables a cada límite tienen el mismo valor para el parámetro τ, pero diferentes valores para el θ. Estima el único valor de τ y los diferentes de θ. Luego estima factor utilizando el modelo que corresponda.
4. Utiliza el test del cociente de verosimilitudes para determinar cuál de las tres aproximaciones es más apropiada para este problema.

Ej 2.115 KPW Se nos dice que las pérdidas en una determinada cartera siguen una distribución Weibull con parámetros $\tau = 1$ y $\theta = 20$. Se recoge una muestra aleatoria de pérdidas, pero los datos de la misma aparecen truncados por abajo debido a la existencia de una franquicia e 10.

1. Determina la proporción esperada de pérdidas *observadas* por encima de 25.
2. Dado que se realiza un pago, ¿cuál es la probabilidad de que dicho pago sea por lo menos de 25?

B.2. Ejercicios del Tema 3

Ej 3.8 KPW Una cartera de 10.000 pólizas proporcionó los siguientes números de reclamaciones:

Nº reclamaciones	Nº pólizas
0	9.048
1	905
2	45
3	2
4+	0

1. Ajustar un modelo de Poisson por máxima-verosimilitud, contrastar la bondad del ajuste y construir un intervalo de confianza para λ al 95 %.
2. Ajustar un modelo Binomial Negativo, realizar el test de bondad de ajuste.
3. Ajustar un modelo geométrico, contrastar la bondad del ajuste y construir un intervalo de confianza para β al 95 %.
4. Ajustar un modelo binomial asumiendo desconocidos los dos parámetros (p, m). Contrastar la bondad del ajuste y construir un intervalo de confianza para p al 95 %, basado en una aproximación normal.
5. Comparar los modelos ajustados y concluir sobre cuál es el mejor.
6. Construye un gráfico de los valores kn_k/n_{k-1} versus k y juzga con él qué modelo de la clase (a,b,0) es el más apropiado. Justifica tu respuesta y compara los resultados con los que obtuviste en el apartado anterior.

Ej 3.19 KPW La siguiente tabla da el número de reclamaciones médicas por accidente de automóvil declarado.

1. Construye un gráfico de los valores kn_k/n_{k-1} versus k y juzga si parece apropiado algún modelo de la clase (a,b,0) para ajustar los datos. Si es así, ¿cuál?
2. Ajusta los modelos de la clase (a,b,0) por máxima-verosimilitud.
3. Basado en los tests de bondad de ajuste y los criterios de comparación de modelos, ¿cuál proporciona el mejor ajuste?

Nº reclamaciones	0	1	2	3	4	5	6	7	8+
Nº accidentes	529	146	169	137	99	87	41	25	0

Ej 3.58 KPW Roberts (1959) llevó a cabo un estudio sobre reclamaciones automovilísticas con datos recogidos en 1957. El interés era la frecuencia de reclamaciones que producen excesivas pérdidas. Los datos eran el número de reclamaciones en exceso de 10.000 para un accidente del que se sabe que al menos tuvo

asociada una de dichas reclamaciones excesivas (en la tabla siguiente). Supón que se ha determinado que la probabilidad de que una pérdida supere los 20.000 sabiendo que está por encima de 10.000, es 0.75. También, se ha determinado que la probabilidad de que un accidente no produzca ninguna reclamación por más de 10.000 es 0.85. Determina un modelo de frecuencia para el número de pérdidas por accidente que exceden los 10.000. Determina también modelos para el número de pérdidas por encima de 20.000.

Nº reclamaciones	1	2	3	4	5	6	7	8	9	10	24	28	39
Nº accidentes	2072	301	165	120	69	50	15	8	6	4	1	1	1

B.3. Ejercicios del Tema 4

(Ejemplo 4.21 KPW). Supongamos que en una cartera el número de pérdidas que se producen se puede modelizar a través de una distribución de Poisson $Po(10)$, y que las cantidades de pérdida en cada una por una distribución de Pareto $Pa(\alpha = 3; \theta = 100)$.

1. Determinar el modelo que resulta para la pérdida agregada y aproximar su distribución mediante simulación. Calcular la media y varianza de dicha distribución.
$$S = X_1 + X_2 + \ldots + X_N$$
2. Si se establece como condición en el seguro una franquicia de 50, determinar el modelo para el pago agregado. Calcular la media y varianza de dicha distribución. Aproximar su distribución con simulación y con una aproximación con la distribución normal. Comparar ambas aproximaciones.
$$S^* = Y_1 + Y_2 + \ldots + Y_{N^*},$$
con N^* = número de pagos (efectivos), $N^* \sim Po(10v)$, con $v = Pr(pago) = Pr(X > 50)$, e Y la variable de pagos.

Ej 3.48 KPW Una compañía de seguros de vida tiene una cláusula por muerte accidental. Para muertes ordinarias, el seguro paga 10.000; sin embargo, para una muerte por accidente, el seguro paga 20.000. Los asegurados son aproximadamente de la misma edad, de modo que es razonable asumir que todos tienen la misma probabilidad de reclamación. Asumamos que es de 0.97 la probabilidad de no reclamar, 0.01 la de una muerte ordinaria y 0.02 la de una muerte accidental. Se ha conseguido un reasegurador que pagará 10.000 por cada muerte accidental.

1. El proceso de reclamaciones puede ser modelizado con una componente de frecuencia con la distribución Bernoulli (reclamación/no reclamación) y una componente de severidad de dos puntos (las probabilidades vienen asociadas con los dos niveles de reclamación, dado que se da una reclamación).

Especifica las distribuciones de probabilidad para las v.a. de frecuencia y severidad.

2. Supón que el reasegurador quiere mantener la misma distribución de frecuencias. Determina la distribución de severidad modificada que reflejará los pagos del reasegurador.
3. Determina las distribuciones de frecuencia y severidad para el reasegurador cuando la distribución de severidad está condicionada en que se realiza un pago del reaseguro.

Ej 4.10 KPW Considera la siguiente información sobre pacientes de SIDA.

1. La distribución condicional de los costes médicos de un individuo, dado que dicho individuo no tiene SIDA, tiene media 1.000 y varianza 250.000.
2. Cuando el individuo tiene SIDA, dicha distribución condiciona tiene media 70.000 y varianza 1.600.000.
3. El número de individuos con SIDA en un grupo de m adultos seleccionados al azar tiene una distribución binomial con parámetros m y $q = 0{,}01$.

Una compañía de seguros determina los premiums para un grupo como la media más el 10 % de la desviación estándar de la distribución de reclamaciones agregadas para el grupo. P es el premium para un grupo de 10 individuos que no tiene SIDA. Q es el premium para un grupo de 10 adultos seleccionados aleatoriamente. Determinar P/Q.

Ej 4.22 KPW La distribución de pérdidas individuales es normal con $\mu = 100$ y $\sigma^2 = 9$. La distribución para el número de reclamaciones, N, viene dada en la Tabla siguiente. Determinar la probabilidad de que la pérdida agregada exceda las 100 unidades.

n	Pr(N=n)
0	0.5
1	0.2
2	0.2
3	0.1

Ej 4.31 KPW El número de accidentes en que incurre un conductor asegurado durante un año tiene una distribución de Poisson de parámetro $\lambda = 2$. Si ocurre un accidente, la probabilidad de que el coste de la reparación exceda la franquicia es de 0.25. El número de reclamaciones y las pérdidas sufridas son independientes. ¿Cuál es la probabilidad de que en un año no haya accidentes cuyas reparaciones excedan la franquicia?

Ej 4.44 KPW Un día cualquiera, un médico proporciona cuidados a N_a adultos y N_n niños. N_a y N_n tienen distribuciones de Poisson con parámetros 3 y 2 respectivamente. Las distribuciones sobre la duración de la atención médica por paciente es como sigue:

	Adulto	Niño
1 hora	0.4	0.9
2 horas	0.6	0.1

N_a, N_n y las duraciones de la atención médica para todos los pacientes son independientes. La tarifa del médico son de 200 por hora. Determinar la probabilidad de que el ingreso total al cabo del día sea menor o igual a 800.

Nota: *Utiliza el siguiente resultado.*
Sea $S = M_1 + M_2 + \ldots + M_N$, *con* $N \sim P_1(z)$. *Si la distribución primaria* $P_1(z)$ *es un miembro de la clase* $(a, b, 0)$, *entonces:*

$$p_k = Pr(N = k) = \left(a + \frac{b}{k}\right) p_{k-1}, \qquad k = 1, 2, \ldots,$$

$$g_k = Pr(S = k) = \frac{1}{1 - a\ f_0} \sum_{j=1}^{k} \left(a + \frac{bj}{k}\right) f_j g_{k-j}, \qquad k = 1, 2, \ldots$$

donde $f_0 = Pr(M_i = 0)$.

Ej 4.62 KPW Una compañía de seguros asume que las probabilidades de reclamación de las personas cubiertas por sus seguros de vida son la siguientes:

Tipo	Prob.Reclamación
Fumador	0.02
No fumador	0.01

Dicha empresa tiene una cartera en la que todos los seguros de vida (independientes) tienen una cobertura individual de 1000. En base a que la empresa asume que el 20 % de los contratos corresponde a fumadores, establece el premium como el 110 % de la pérdida (individual) esperada.

Si resulta que el porcentaje de fumadores es del 30 %, y el tamaño de la cartera es de 226 contratos, ¿cuál es la probabilidad de que la pérdida total supere el premium global? Calcúlalo utilizando la aproximación normal.

Apéndice C

Distribuciones de probabilidad

Para todas y cada una de las distribuciones que presentamos a continuación, se presentan las funciones de densidad o probabilidad, distribución, momentos de orden k, momentos limitados de orden k, y alguna otra característica distribucional. Por último, se dan las estimaciones de los parámetros del modelo, basadas en el método de los momentos o del emparejado de percentiles.

C.1. Distribuciones Continuas

Denotamos por m y t respectivamente a las estimaciones de los momentos empíricos de orden 1 y 2 de una variable continua X, observada en una muestra de individuos.

- Si tenemos disponibles los datos individualizados $x_1, x_2, \ldots, x_n$ de la variable de interés X:

$$m = \frac{1}{n}\sum_{i=1}^{n} x_i, \qquad t = \frac{1}{n}\sum_{i=1}^{n} x_i^2 \tag{C.1}$$

- Si tenemos disponibles los datos agrupados en intervalos $I_j = (c_{j-1}, c_j)$, $j = 1, \ldots, r$, con n_j el número de datos observados en cada intervalo I_j, y siendo n el total de datos, $n = \sum_{j=1}^{r} n_j$:

$$m = \sum_{j=1}^{r} \frac{n_j(c_j + c_{j-1})}{2n}, \qquad t = \frac{1}{n}\sum_{j=1}^{r} \frac{n_j(c_j^3 - c_{j-1}^3)}{3(c_j - c_{j-1})}. \tag{C.2}$$

Denotamos por p y q respectivamente, a los percentiles empíricos 25 y 75:

$$p = \pi_{0,25}, \qquad q = \pi_{0,75}.$$

Como funciones accesorias útiles, tenemos la función Gamma, definida para valores positivos $a > 0$ por:

$$\Gamma(a) = \int_0^\infty t^{a-1} e^{-t} dt. \tag{C.3}$$

Cuando $a \in \mathbb{Z}$ es un número entero, entonces $\Gamma(a) = (a-1)!$, con $\Gamma(1) = 1$.

La función Gamma incompleta viene definida para valores $\alpha > 0$, $x > 0$ por:

$$\Gamma(\alpha; x) = \frac{1}{\Gamma(\alpha)} \int_0^x t^{\alpha-1} e^{-t} dt, \tag{C.4}$$

y es igual a la función de distribución de una variable Gamma $Ga(a, 1)$ evaluada en el punto x,

$$\Gamma(\alpha; x) = F_{Ga(\alpha,1)}(x).$$

En particular:

$$F_{Ga(\alpha,\theta)}(x) = \Gamma(\alpha; x/\theta).$$

Utilizaremos también la función:

$$G(\alpha; x) = \frac{1 - F_{Ga(\alpha,1)}(x)}{\Gamma(\alpha)}.$$

C.1.1. Distribuciones de un parámetro

Exponencial $Exp(\lambda)$, con $\lambda > 0$

$$\begin{aligned}
f(x) &= \lambda e^{-\lambda x} \\
F(x) &= 1 - e^{-\lambda x} \\
E(X) &= 1/\lambda \\
E(X^k) &= k!/\lambda^k \\
E(X \wedge x) &= (1 - e^{-\lambda x})/\lambda \\
E[(X \wedge x)^k] &= k! F_{Ga(k+1,1/\lambda)}(x)/\lambda^k + x^k e^{-x\lambda} \\
moda &= 0
\end{aligned}$$

$$\hat{\lambda} = 1/m.$$

Exponencial Inversa $IExp(\lambda)$, con $\lambda > 0$

$$\begin{aligned} f(x) &= e^{-1/(\lambda x)}/(\lambda x^2) \\ F(x) &= e^{-1/(\lambda x)} \\ E(X^k) &= \Gamma(1-k)/\lambda^k \\ E[(X \wedge x)^k] &= E(X^k)G(1-k;1/(\lambda x)) + x^k(1-e^{-1/(\lambda x)}) \\ moda &= 1/(2\lambda) \end{aligned}$$

$$\hat{\lambda} = -1/(qlog(m)).$$

Pareto de un parámetro $Pa(\alpha, \theta)$, con θ conocido, $\alpha > 0$.

$$\begin{aligned} f(x) &= \alpha\theta^\alpha/x^{\alpha+1} \\ F(x) &= 1-(\theta/x)^\alpha \\ E(X^k) &= \alpha\theta^k/(\alpha-k), \quad k<\alpha \\ E(X \wedge x) &= \alpha\theta/(\alpha-1) - \theta^\alpha/((\alpha-1)x^{\alpha-1}), \qquad \alpha > 1 \\ E[(X \wedge x)^k] &= \alpha\theta^k/(\alpha-k) - k\theta^\alpha/((\alpha-k)x^{\alpha-k}), \qquad k<\alpha \\ moda &= \theta \end{aligned}$$

$$\hat{\alpha} = m/(m-\theta).$$

C.1.2. Distribuciones de dos parámetros

Lognormal $LogN(\mu, \sigma)$, con $\mu \in R$

$$\begin{aligned} f(x) &= \phi(z/(\sigma x)), \qquad \text{con } z = (log(x)-\mu)/\sigma \\ F(x) &= \Phi(z) \\ E(X^k) &= exp(k\mu + k^2\sigma^2/2) \\ E[(X \wedge x)^k] &= E(X^k)\Phi(z-k\sigma) + x^k[1-F(x)] \\ moda &= exp(\mu-\sigma^2) \end{aligned}$$

$$\hat{\sigma} = \sqrt{log(t) - 2log(m)}, \quad \hat{\mu} = log(m) - \sigma^2/2.$$

Pareto $Pa(\alpha,\theta)$, con α el parámetro de forma y θ el de localización

$$\begin{aligned} f(x) &= \frac{\alpha\theta^\alpha}{(x)^{\alpha+1}} \\ F(x) &= 1-\left(\frac{\theta}{x}\right)^\alpha \\ E(X^k) &= \frac{\alpha\theta^k}{\alpha-k}, \qquad k<\alpha \\ E(X) &= \frac{\alpha\theta}{\alpha-1}, \qquad 1<\alpha \\ E[(X\wedge x)^k] &= \frac{\alpha\theta^k}{\alpha-k}-\frac{k\theta^\alpha}{(\alpha-k)x^{\alpha-k}} \\ E(X\wedge x) &= E(X)-\frac{\theta^\alpha}{(\alpha-1)x^{\alpha-1}} \\ moda &= \theta \end{aligned}$$

$$\hat{\alpha}=1+\sqrt{1+m/(t-m^2)}, \quad \hat{\theta}=m(1-1/\hat{\alpha}).$$

Loglogística $Loglog(\gamma,\theta)$

$$\begin{aligned} f(x) &= \frac{\gamma(x/\theta)^\gamma}{x[1+(x/\theta)^\gamma]^2} \\ F(x) &= \frac{(x/\theta)^\gamma}{1+(x/\theta)^\gamma}=u \\ E(X^k) &= \theta^k\Gamma(1+k/\gamma)\Gamma(1-k/\gamma), \quad -\gamma<k<\gamma \\ E[(X\wedge x)^k] &= E(X^k)\beta[1+k/\gamma,1-k/\gamma;u]+x^k(1-u), \quad k>-\gamma \\ moda &= \theta\left(\frac{\gamma-1}{\gamma+1}\right)^{1/\gamma} \end{aligned}$$

$$\hat{\gamma}=\frac{2log(3)}{log(q)-log(p)}, \quad \hat{\theta}=exp\left(\frac{log(q)+log(p)}{2}\right)$$

Paralogística $Parlog(\alpha,\theta)=Burr(\alpha,\theta,\alpha)$

$$\begin{aligned} f(x) &= \frac{\alpha^2(x/\theta)^\alpha}{x[1+(x/\theta)^\alpha]^{\alpha+1}} \\ F(x) &= 1-u^\alpha, \qquad u=(1+(x/\theta)^\alpha)^{-1} \\ E(X^k) &= \theta^k\Gamma(1+k/\alpha)\Gamma(\alpha-k/\alpha)/\Gamma(\alpha), \quad -\alpha<k<\alpha^2 \\ E[(X\wedge x)^k] &= E(X^k)\beta[1+k/\alpha,\alpha-k/\alpha;1-u]+x^ku^\alpha, \quad k>-\alpha \\ moda &= \theta\left(\frac{\alpha-1}{\alpha^2+1}\right)^{1/\alpha} \end{aligned}$$

$$\tilde{\alpha}=\frac{2log(3)}{log(q)-log(p)}, \quad \tilde{\theta}=exp\left(\frac{log(q)+log(p)}{2}\right)$$

Gamma $Ga(\alpha,\theta)$, con α parámetro de forma y θ de escala

$$\begin{aligned}
f(x) &= \frac{x^{\alpha-1}}{\theta^{\alpha}\Gamma(\alpha)}e^{-x/\theta} \\
F(x) &= \Gamma[\alpha; x/\theta] \\
E(X^k) &= \theta^k(\alpha+k-1)\ldots\alpha \\
E(X) &= \alpha\theta \\
Var(X) &= \alpha\theta^2 \\
E[(X\wedge x)^k] &= E(X^k)F_{Ga(\alpha+k,\theta)}(x) + x^k[1-F_{Ga(\alpha,\theta)}(x)], \qquad k>-\alpha \\
moda &= \theta(\alpha-1), \qquad \alpha>1, \text{ si no0}
\end{aligned}$$

$$\hat{\alpha} = m^2/(t-m^2), \quad \hat{\theta} = (t-m^2)/m.$$

Weibull $Weib(\alpha,\beta)$, con α parámetro de forma y β de escala

$$\begin{aligned}
f(x) &= \left(\frac{\alpha}{\beta}\right)\left(\frac{x}{\beta}\right)^{\alpha-1} e^{-(x/\beta)^{\alpha}} \\
F(x) &= 1-e^{-(x/\beta)^{\alpha}} \\
E(X^k) &= \beta^k\Gamma(1+k/\alpha), \qquad k>-\alpha \\
E(X) &= \beta\Gamma(1+1/\alpha) \\
E[(X\wedge x)^k] &= E(X^k)F_{Ga(1+k/\alpha,\beta^{\alpha})}(x^{\alpha}) + x^k e^{-(x/\beta)^{\alpha}}, \qquad k>-\alpha \\
moda &= \beta\,(1-1/\alpha)^{1/\alpha} \quad \text{si } \alpha>1, \text{ si no, } 0
\end{aligned}$$

$$\hat{\beta} = exp\left(\frac{glog(p)-log(q)}{g-1}\right), \quad \hat{\alpha} = \frac{log(log(4))}{log(q)-log(\hat{\beta})}$$

con $g = \dfrac{log(log(4))}{log(log(4/3))}$,

y p, q los cuantiles 25 y 75 respectivamente.

Gausiana inversa $Gaus-I(\mu,\theta)$, con $\mu>0, \theta>0$

$$\begin{aligned}
f(x) &= \left(\frac{\theta}{2\pi x^3}\right)^{1/2}\exp\left\{-\frac{\theta z^2}{2x}\right\}, \quad z=\frac{x-\mu}{\mu} \\
F(x) &= \Phi\left(z\sqrt{\theta/x}\right) + \exp(2\theta/\mu)\Phi\left(-y\sqrt{\theta/x}\right), \quad y=\frac{x+\mu}{\mu} \\
E(X) &= \mu \qquad Var(X)=\mu^3/\theta \\
E[X\wedge x] &= x-\mu\Phi\left(z\sqrt{\theta/x}\right) - \mu y\exp(2\theta/\mu)\Phi\left(-y\sqrt{\theta/x}\right)
\end{aligned}$$

$$\hat{\mu} = m, \qquad \hat{\theta} = \frac{m^3}{t-m^2}.$$

Beta $Be(a,b)$, con $a>0, b>0$ y $0<x<1$

$$\begin{aligned} f(x) &= \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)}\, x^{a-1}(1-x)^{b-1} \\ F(x) &= \beta(a,b;x) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \int_0^x t^{a-1}(1-t)^{b-1}dt \\ E(X^k) &= \frac{\Gamma(a+b)\Gamma(a+k)}{\Gamma(a)\Gamma(a+b+k)} \\ E(X) &= \frac{a}{a+b} \\ E[(X\wedge x)^k] &= \frac{a(a+1)...(a+k-1)\beta(a+k,b;x)}{(a+b)(a+b+1)...(a+b+k-1)} + x^k[1-\beta(a,b;x)] \end{aligned}$$

$$\hat{a} = \frac{\theta m^2 - mt}{\theta(t-m^2)}, \quad \hat{b} = \frac{(\theta m - t)(\theta - m)}{\theta(t-m^2)}.$$

C.2. Distribuciones discretas

Denotamos por $\hat{\mu}$ y $\hat{\sigma}^2$ respectivamente, la media y varianza empírica, obtenidas a partir de las frecuencias $\{n_k\}$, observadas para los sucesos $N=k,\ k=0,1,2,3,\ldots$:

$$\hat{\mu} = \frac{1}{n}\sum_{k=0}^{\infty} k n_k, \qquad \hat{\sigma}^2 = \frac{1}{n}\sum_{k=0}^{\infty} k^2 n_k - \hat{\mu}^2. \tag{C.5}$$

Estas estimaciones empíricas serán utilizadas resolver ajustes por el método de los momentos.

C.2.1. Familia $(a,b,0)$

Todas las distribuciones de esta familia responden a la fórmula recursiva:

$$k\frac{p_k}{p_{k-1}} = ak + b, \qquad k = 1,2,3,\ldots.$$

Poisson $Po(\lambda)$, con $\lambda>0$.

$$\begin{aligned} & a=0,\ b=\lambda \\ p_0 &= e^{\lambda} \\ p_k &= \frac{e^{\lambda}\lambda^k}{k!} = \frac{\lambda}{k}\, p_{k-1}, \qquad k=1,2,\ldots \end{aligned}$$

$$\begin{aligned} E(N) &= \lambda, \qquad Var(N)=\lambda \\ & \hat{\lambda} = \hat{\mu}. \end{aligned}$$

Geométrica $Geom(\beta)$, con $\beta > 0$.

$$\begin{aligned} & a = \beta/(1+\beta),\ b = 0 \\ p_0 &= 1/(1+\beta) \\ p_k &= \frac{\beta^k}{(1+\beta)^{k+1}} = \frac{\beta}{\beta+1}\, p_{k-1}, \qquad k = 1, 2, \ldots \end{aligned}$$

$$\begin{aligned} E(N) &= \beta, \qquad Var(N) = \beta(1+\beta) \\ & \hat{\beta} = \hat{\mu}. \end{aligned}$$

Binomial Negativa $BinNeg(\beta, r)$, con $\beta, r > 0$.

$$\begin{aligned} & a = \beta/(1+\beta),\ b = (r-1)\beta/(1+\beta) \\ p_0 &= 1/(1+\beta)^r \\ p_k &= \frac{r(r+1)...(r+k-1))\beta^k}{k!(1+\beta)^{k+r}} = \frac{\beta}{\beta+1}\frac{k+r-1}{k}\, p_{k-1}, \qquad k = 1, 2, \ldots \end{aligned}$$

$$\begin{aligned} E(N) &= r\beta, \qquad Var(N) = r\beta(1+\beta) \\ & \hat{\beta} = \hat{\sigma}^2/\hat{\mu} - 1, \qquad \hat{r} = \hat{\mu}^2/(\hat{\sigma}^2 - \hat{\mu}). \end{aligned}$$

Binomial $Bin(m, p)$, con $0 < p < 1, m \in Z$.

$$\begin{aligned} & a = -p/(1-p),\ b = (m+1)p/(1-p) \\ p_0 &= (1-p)^m \\ p_k &= \binom{m}{k} p^k (1-p)^{m-k} = \frac{m-k+1}{k}\frac{p}{1-p}\, p_{k-1}, \qquad k = 1, 2, \ldots \\ E(N) &= mp, \qquad Var(N) = mp(1-p) \\ & \hat{p} = \hat{\mu}/m. \end{aligned}$$

C.2.2. Familia $(a, b, 1)$

Si p_k denota la probabilidad de $N = k$ para una distribución D de la familia $(a, b, 0)$, entonces p_k^T denotará la probabilidad de su versión truncada en el cero, D^T, y p_k^M la correspondiente a la versión modificada en el cero, D^M. La relación entre ellas viene dada por:

Truncada $\quad p_k^T = \dfrac{p_k}{1-p_0}, \qquad k = 1, 2, \ldots$

Modificada $\quad p_k^M = c \cdot p_k, \qquad k = 1, 2, \ldots, \quad \text{con } c = \dfrac{1-p_0^M}{1-p_0}$

$$E(D^M) = (1-p_0^M)E(D^T)$$
$$Var(D^M) = (1-p_0^M)Var(D^T) + p_0^M(1-p_0^M)E(D^T)^2.$$

Distribuciones $(a, b, 1)$ truncadas en el cero

Poisson Truncada $Po^T(\lambda)$, con $\lambda > 0$.

$$\begin{aligned} & a = 0,\ b = \lambda \\ p_1^T &= \lambda/(e^\lambda - 1) \\ p_k^T &= \frac{\lambda^k}{k!(e^\lambda - 1)} = \frac{\lambda}{k}\, p_{k-1}^T, \qquad k = 2, \ldots \end{aligned}$$

$$\begin{aligned} E(N^T) &= \lambda/(1 - e^{-\lambda}), \qquad Var(N^T) = \lambda[1 - (\lambda + 1)e^\lambda]/(1 - e^{-\lambda})^2 \\ & \hat{\lambda} = log(n\hat{\mu}/n_1). \end{aligned}$$

Geométrica Truncada $Geom^T(\beta)$, con $\beta > 0$.

$$\begin{aligned} & a = \beta/(1 + \beta),\ b = 0 \\ p_1^T &= 1/(1 + \beta) \\ p_k^T &= \frac{\beta^{k-1}}{(1 + \beta)^k} \\ &= \frac{\beta}{\beta + 1}\, p_{k-1}^T, \qquad k = 2, \ldots \end{aligned}$$

$$\begin{aligned} E(N^T) &= 1 + \beta, \qquad Var(N^T) = \beta(1 + \beta) \\ & \hat{\beta} = \hat{\mu} - 1. \end{aligned}$$

Binomial Negativa Truncada $BinNeg^T(\beta, r)$, con $\beta > 0$, $r > -1$.

$$\begin{aligned} & a = \beta/(1 + \beta),\ b = (r - 1)\beta/(1 + \beta) \\ p_1^T &= \frac{r\beta}{(1 + \beta)^{r+1} - (1 + \beta)} \\ p_k^T &= \frac{r(r + 1)...(r + k - 1)}{k![(1 + \beta)^r - 1]} \left(\frac{\beta}{1 + \beta}\right)^k \\ &= \frac{\beta}{\beta + 1} \frac{k + r - 1}{k}\, p_{k-1}^T, \qquad k = 2, \ldots \end{aligned}$$

$$\begin{aligned} E(N^T) &= \frac{r\beta}{1 - (1 + \beta)^{-r}} \\ Var(N^T) &= \frac{r\beta[(1 + \beta) - (1 + \beta + r\beta)(1 + \beta)^{-r}]}{[1 - (1 + \beta)^{-r}]^2} \end{aligned}$$

$$\hat{\beta} = \hat{\sigma}^2/\hat{\mu} - 1, \qquad \hat{r} = \hat{\mu}^2/(\hat{\sigma}^2 - \hat{\mu}).$$

Binomial Truncada $Bin^T(m,p)$, con $0 < p < 1, m \in Z$.

$$
\begin{aligned}
& a = -p/(1-p),\ b = (m+1)p/(1-p) \\
p_1^T &= \frac{mp(1-p)^{m-1}}{1-(1-p)^m} \\
p_k^T &= \frac{\binom{m}{k} p^k (1-p)^{m-k}}{1-(1-p)^m} = \frac{m-k+1}{k}\frac{p}{1-p}\, p_{k-1}, \qquad k = 2, \ldots \\
E(N) &= mp/[1-(1-p)^m] \\
Var(N) &= \frac{mp[(1-p)-(1-p+mp)(1-p)^m]}{[1-(1-p)^m]^2} \\
& \hat{p} = \hat{\mu}/m.
\end{aligned}
$$

Logarítmica $Logaritmica(\beta)$, con $\beta > 0$.

$$
\begin{aligned}
& a = \beta/(1+\beta),\ b = -\beta/(1+\beta) \\
p_1^T &= \beta/[(1+\beta)log(1+\beta)] \\
p_k^T &= \frac{\beta^k}{k(1+\beta)^k log(1+\beta)} = \frac{\beta}{\beta+1}\frac{k-1}{k}\, p_{k-1}^T, \qquad k = 2, \ldots \\
E(N^T) &= \beta/log(1+\beta), \qquad Var(N^T) = \frac{\beta[1+\beta-\beta/log(1+\beta)]}{log(1+\beta)} \\
& \hat{\beta} = n\hat{\mu}/n_1 - 1 \ o\ 2(\hat{\mu}-1)/\hat{\mu}.
\end{aligned}
$$

Apéndice D

Casos Prácticos

D.1. Introducción

El objeto de esta Apéndice es el de plantear diversos casos prácticos cuya resolución es factible utilizando todas las herramientas mostradas a lo largo del curso: modelos para pérdidas, modelos para reclamaciones y modelos agregados. Los ficheros de datos están disponibles en la página web `http://statelx.umh.es`.

D.2. Caso Práctico 1

Dispones de un fichero Excel (datos-caso1.xls) con los datos correspondientes a una cartera de seguros. Sobre él, y utilizando Excel, has de trabajar, resolviendo las cuestiones que se te plantean a continuación.

EJERCICIO 1. Describe gráfica y numéricamente la distribución de las pérdidas. Utiliza las correspondientes aproximaciones empíricas para:

1. Construir un histograma agrupando los datos en los intervalos $< 8, (8, 10], (10, 12], (12, 13], (13, 15], (15, 16], (16, 19]$ y > 19 (con rango de clases 8,10,12,13,15,16 y 19). Especifica aquí la probabilidad asociada a cada clase y la probabilidad acumulada.
2. Calcular la media, varianza, mínimo, máximo, cuartiles y momento (no centrado) de orden 2.
3. ¿Qué puedes decir sobre la simetría de dicha distribución? ¿Y sobre su localización y dispersión?

EJERCICIO 2. Ajusta un modelo Gamma para las pérdidas X en dicha cartera entre 1990 y 1993. Utiliza el método de los momentos y obtén también la estimación máximo-verosímil.

Con el modelo ajustado:

1. Calcula $E(X)$ y $Var(X)$. ¿Se parecen a sus análogos empíricos?
2. Si $x_{(1)}$ y $x_{(42)}$ representan, respectivamente, la mínima y máxima pérdida observada, calcula la probabilidad estimada para las colas, $Pr(X < x_{(1)})$ y $Pr(X > x_{(42)})$. ¿Qué conclusiones extraes sobre el modo en que la distribución Gamma acomoda cada una de las colas para los datos dados?
3. Calcula el test χ^2 de bondad de ajuste del modelo Gamma, utilizando el rango de clases 10,12,13,15 y 19. ¿Cuál es la significatividad (p-valor) asociada a dicho modelo? ¿Qué conclusión extraes?

EJERCICIO 3. Ajusta sobre las pérdidas X un modelo Weibull.

Nota: En Excel, la distribución Weibull está parametrizada al revés de como la tenéis en el Apéndice de KPW. Así, la $Weibull(\theta, \tau)$ del Apéndice se corresponde con la $Weibull(\alpha = \tau, \beta = \theta)$ en Excel.

1. ¿Podemos rechazar el modelo Weibull con el test χ^2 de bondad de ajuste? Justifícalo.
2. Compara los modelos Gamma y Weibull con el criterio del cociente de verosimilitudes. Justifica tus conclusiones.
3. Compara los modelos Gamma y Weibull con el criterio BIC. Justifica tus conclusiones.

EJERCICIO 4. Asumimos como adecuado para describir las pérdidas el modelo Gamma. De cara a una posible modificación de las condiciones de los seguros, consideramos las siguientes políticas, homogéneas para todos los seguros de la cartera:

P1: $d = 3$ (franquicia)
P2: $u = 12$ (límite)
P3: $d = 3,\ u = 12$.

Prevemos que de cara al año próximo (que es cuando se implantaría alguna de estas políticas), la tasa de inflación será del $\alpha = 3\,\%$. Si denotamos por Y el pago por pérdida, para cada una de las políticas consideradas:

1. Describe Y en función de X.
2. Calcula el pago esperado por pérdida, $E(Y)$, y el pago esperado por pago, $E(Y|X > d)$.
3. Concluye en función de $E(Y)$ y de $E(Y|X > d)$, sobre qué política resulta más positiva para la aseguradora. Justifícalo.

EJERCICIO 5. En la Hoja "reclamaciones" tienes los datos anuales (entre 1990 y 1993) sobre el tamaño de la cartera, el número de pérdidas y el número de pagos que se realizaron.

1. Especifica y ajusta un modelo binomial para el número de pérdidas N_i, asumiendo que la proporción de pérdidas en la cartera, π, no ha variado con el paso de los años.
2. Empíricamente, determina la proporción de pérdidas que conllevaron un pago (indemnización) por parte de la aseguradora. Con dicha probabilidad, determina la distribución del número de indemnizaciones N_i^* y obtén la predicción en cada uno de los años considerados. ¿Hay mucha discordancia entre las predicciones y el número de indemnizaciones observadas esos años? Júzgalo con el test chi-cuadrado.
3. Con el modelo ajustado, estima el número de pérdidas esperadas para el año próximo si las previsiones sobre el tamaño de la cartera son de 1350 contratos.

EJERCICIO 6. Con el modelo Gamma ajustado para las pérdidas y el binomial para el número de pérdidas, y asumiendo que el año próximo el tamaño de la cartera será de 1350 contratos:

1. Propón la fórmula para obtener la pérdida agregada S, en función del número de pérdidas N y de la cuantía X_i de las mismas. Calcula el valor esperado de dicha pérdida agregada y su varianza.
2. Asumiendo que el modelo normal es apropiado para aproximar la distribución de la pérdida agregada para el año próximo, estima la probabilidad de que dicha pérdida global supere la cantidad de 300.

D.3. Caso Práctico 2

Dispones de un fichero Excel (datos-caso2.xls) con los datos correspondientes a las pérdidas de una cartera de seguros. Sobre él, y utilizando Excel, has de trabajar, resolviendo las cuestiones que se te plantean a continuación. **EJERCICIO 1.** Describe gráfica y numéricamente la distribución de las pérdidas. Utiliza las correspondientes aproximaciones empíricas para:

1. construir un histograma agrupando los datos en los intervalos $(0, 5], (5, 10], (10, 20], (20, 35]$. Especifica aquí la probabilidad asociada a cada clase y la probabilidad acumulada.

2. calcular la media, varianza, mínimo, máximo, cuartiles y el momento (no centrado) de orden dos.

3. ¿Qué puedes decir sobre la simetría de dicha distribución? ¿Y sobre su localización y dispersión?

EJERCICIO 2. Ajusta un modelo Gamma para las pérdidas X en dicha cartera. Utiliza el método de los momentos y obtén también la estimación máximo-verosímil.

Con el modelo ajustado:

1. Estima $E(X)$ y $Var(X)$. ¿Se parecen a sus análogos empíricos?

2. Si $x_{(1)}$ y $x_{(50)}$ representan, respectivamente, la mínima y máxima pérdida observada, calcula la probabilidad estimada para las colas, $Pr(X < x_{(1)})$ y $Pr(X > x_{(50)})$. ¿Qué conclusiones extraes sobre el modo en que la distribución Gamma acomoda cada una de las colas para los datos dados?

3. Calcula el test χ^2 de bondad de ajuste del modelo Gamma, utilizando el rango de clases $(0, 5], (5, 10], (10, 20], (20, +\infty]$. ¿Cuál es la significatividad (p-valor) asociada a dicho modelo? ¿Qué conclusión extraes?

4. Ajustando el modelo Exponencial obtuvimos que el valor de la log-verosimilitud conjunta evaluada en el estimador máximo-verosímil era de $-173{,}156$. Compara este modelo con el Gamma a través del cociente de verosimilitudes y del BIC. ¿Cuál es preferible? Justifica tus conclusiones.

EJERCICIO 3. Asumimos como adecuado para describir las pérdidas el modelo Gamma. De cara a una posible modificación de las condiciones de los seguros, consideramos las siguientes políticas, homogéneas para todos los seguros de la cartera:

P1: $d = 10$ (franquicia)
P2: $u = 30$ (límite)
P3: $d = 10,\ u = 30$.

Preveemos que de cara al año próximo (que es cuando se implantaría alguna de estas políticas), la tasa de inflación será del $r = 3\,\%$. Si denotamos por Y el pago por pérdida, para cada una de las políticas consideradas:

1. Describe Y en función de X.
2. Calcula el pago esperado por pérdida, $E(Y)$, y el pago esperado por pago, $E(Y|X > d/(1+r))$.
3. Concluye en función de dichos pagos esperados sobre qué política resulta más positiva para la aseguradora. Comenta los resultados obtenidos (la ordenación de políticas de mejor a peor).

EJERCICIO 4. Con el modelo Gamma ajustado para las pérdidas, suponiendo que el número de pérdidas tiene una distribución $Bi(n, 0{,}00096)$, y asumiendo que el año próximo el tamaño de la cartera será de 2000 contratos:

1. Propón la fórmula para obtener la pérdida agregada S, en función del número de pérdidas N y de la cuantía X_i de las mismas. Calcula el valor esperado de dicha pérdida agregada y su varianza.
2. Asumiendo que el modelo normal es apropiado para aproximar la distribución de la pérdida agregada para el año próximo, estima la probabilidad de que dicha pérdida global supere la cantidad de 300.

D.4. Caso Práctico 3

En el fichero `'datos-caso3.xls'` tenemos datos sobre los daños producidos por 35 huracanes entre los años 1949 y 1980. Las pérdidas han sido ajustadas por la inflación para quedar expresadas en términos de dólares de 1981. Todas las entradas representan huracanes *críticos*, esto es, huracanes para los cuales las pérdidas superaron los 5 millones de dólares. El gobierno federal está considerando crear un programa para cubrir el 100 % de los pagos para todos los daños ocasionados por huracanes críticos.

EJERCICIO 1. Proporciona una descripción empírica de las pérdidas ocasionadas por huracanes críticos y comenta los resultados sobre localización y dispersión. ¿Cuál es la pérdida por debajo de la cual quedaron el 95 % de los daños ocasionados por los huracanes críticos durante estos años?

> ***Nota:*** *Para la estimación del percentil empírico π_p utiliza la siguiente fórmula:*
>
> $$\hat{\pi}_p = (1-h)x_{(g)} + hx_{(g+1)}, \tag{D.1}$$
>
> *con $g = [np]$, donde [] denota parte entera, y $h = np - g$.*

EJERCICIO 2. Considerando el truncamiento por abajo en 5:

1. Ajusta por máxima verosimilitud un modelo Weibull para las pérdidas base X. Juzga su idoneidad con el test de Kolmogorov-Smirnov.

2. El modelo Gamma ajustado daba una log-verosimilitud de -218.25; ¿cuál de los dos sería preferible según el criterio del cociente de verosimilitudes?

3. ¿Cuál es la probabilidad de que un huracán ocasione pérdidas por más de 500 millones de dólares?

> ***Nota:*** *Recuerda que en un modelo truncado a partir de f_X, la verosimilitud viene dada por $f_X(x)/Pr(\text{observar el dato})$.*

EJERCICIO 3. Respecto al número de huracanes por año tenemos 7 años sin huracanes, 18 con uno, 5 con dos, 1 con tres y 1 con cuatro. Los resultados de ajustar una serie de distribuciones sobre estos datos aparecen en la siguiente tabla:

Modelo	–Verosimilitud	chi-cuadrado	g.l.	p-valor
Poisson	40.2991	5.33	1	0.02009
Geométrica	46.3737	17.40	1	0.0000
Poisson modif.cero	38.0683	0.15	0	
Geométrica modif.cero	37.7497	0.00	0	
Binomial Negativa	37.8285	0.05	0	

1. Juzga en función de los criterios proporcionados en la tabla anterior, la bondad de los modelos ajustados y concluye sobre cuál consideras más apropiado.

2. Supongamos apropiado el modelo Geométrico modificado en el cero. Para él, las estimaciones de los parámetros son $\hat{p}_0 = 0{,}21875$ y $\beta = 0{,}4$. Según este modelo, ¿cuál es la probabilidad de que en un año se produzcan 3 o más de 3 huracanes?

3. Actualmente, el gobierno proporciona cobertura total para los huracanes que ocasionan daños superiores a 500 millones de dólares. ¿Cuál es la probabilidad de que en un año se produzca al menos un huracán con cobertura? ¿Qué puedes decir sobre la política actual de cobertura del gobierno? Utiliza para contestar esta pregunta también el EJER 2.

Nota: *Se trata de determinar la distribución de frecuencias modificada por efecto de modificaciones de severidad. Sabemos que la distribución binomial negativa modificada en el cero, tiene buenas propiedades respecto a modificaciones de severidad. Así, si v representa la probabilidad* ***esperada*** *de que un huracán provoque pérdidas con derecho a cobertura estatal, entonces la distribución de frecuencias modificada seguirá siendo binomial negativa, con parámetros:*

$$p_o^{M*} = \frac{p_0^M - (1+\beta)^{-r} + (1+v\beta)^{-r} - p_0^M(1+v\beta)^{-r}}{1-(1+\beta)^{-r}}$$

$$\beta^* = v\beta, \qquad r^* = r$$

EJERCICIO 4. Si S representa la pérdida agregada anual ocasionada por huracanes, calcula utilizando los apartados anteriores, la pérdida agregada esperada y su varianza. Mediante una aproximación por la distribución gamma, estima la probabilidad de que en un año los huracanes produzcan daños totales superiores a 500 millones de dólares.

Nota: Los momentos de las distribuciones modificadas en el cero se pueden obtener fácilmente a partir de los momentos de las correspondientes distribuciones truncadas en el cero. Así, la media de la distribución modificada es $1-p_0^M$ *veces la media de la distribución truncada. La varianza es* $1-p_0^M$ *veces la varianza de la truncada más* $p_0^M(1-p_0^M)$ *veces la raíz cuadrada de la media de la truncada.*

D.5. Caso Práctico 4

En el fichero `'datos-caso4.xls'` tenemos datos sobre los pagos Y realizados a asegurados en una compañía durante los años 90 y 91. Acompañando a los pagos, disponemos de información sobre la franquicia (d) y el límite (u) de cada uno de ellos. Hemos calculado las pérdidas X asociadas a dichas reclamaciones y ninguna de ellas supera el límite contratado.

EJERCICIO 1. Proporciona una descripción empírica de las pérdidas asociadas a reclamaciones con derecho a pago y comenta los resultados sobre localización y dispersión. ¿Cuál es la pérdida por debajo de la cual quedaron el 75 % de los asegurados con derecho a pago estos años? ¿Y el 25 %?

> ***Nota:*** *Para la estimación del percentil empírico utiliza la función PERCENTIL de Excel*

EJERCICIO 2. A partir de los datos de pérdidas **tal cual se presentan** (sin tener en cuenta el truncamiento por abajo producido por las franquicias):

1. Ajusta por máxima verosimilitud un modelo Weibull para las pérdidas X. Juzga su idoneidad con el test de Kolmogorov-Smirnov.
2. El modelo Gamma ajustado daba una log-verosimilitud de -337.586. ¿Cuál de los dos sería preferible según el criterio del cociente de verosimilitudes?
3. Con el modelo elegido, ¿cuál es la probabilidad de que en la cartera en cuestión un cliente presente una reclamación con una pérdida asociada superior a 2000 euros?
4. ¿Qué cifra H garantiza que el porcentaje de reclamaciones que conllevan una pérdida inferior a H sea del 30 %?

EJERCICIO 3. Respecto al número de reclamaciones presentadas por año por cada cliente tenemos datos históricos referentes a varios años (datos del Ejer3).

1. Ajusta un modelo de Poisson y juzga su bondad con un test chi-cuadrado.
2. Para el modelo Poisson ajustado, ¿cuál es la probabilidad de que en un año un mismo cliente ocasione 2 o más reclamaciones?
3. Si la compañía de seguros decidiera marcar una franquicia común a todos los seguros, lo haría intentando eliminar algunas pérdidas asumibles por el cliente.

Imagina que estipula como franquicia común la cantidad H que calculaste en el ejercicio anterior (si no la calculaste, asume que dicha cantidad vale H=100). Con esta nueva política, ¿cuál es la proporción de clientes que no van a presentar ninguna reclamación "con derecho a pago"? Compárala con la proporción de clientes que no presentan ninguna reclamación (con o sin derecho a pago).

Considerando que, en media, una reclamación va asociada a un gasto (pérdida) $E(X)$, ¿cuánto se ahorraría en promedio la empresa con esta nueva política?

EJERCICIO 4. Si S representa la pérdida agregada anual ocasionada por los clientes de su cartera, calcula utilizando los apartados anteriores, la pérdida agregada esperada y su varianza. Mediante una aproximación por la distribución gamma para la pérdida agregada, estima la probabilidad de en un año se den unas pérdidas totales superiores a 2 veces la media que obtienes.

D.6. Caso Práctico 5

EJERCICIO 1. Se recogieron las siguientes observaciones sobre los gastos ocasionados por reparaciones en el hogar en un conjunto de 20 viviendas (Tabla D.1). A la empresa aseguradora le interesa especialmente conocer algo sobre las siguientes dos cantidades:

- el gasto medio
- la probabilidad de las reparaciones caras, esto es, por un valor superior a 200.

132	149	476	147	135	110	176	107	147	165
135	117	110	111	226	108	102	108	227	102

Tabla D.1: Gastos por reparaciones en el hogar para 20 viviendas.

1. Da una descripción de la distribución empírica de X: gráfica y numérica, comentando los resultados. Determina la estimación empírica de las dos cantidades de interés.
2. Dada la forma de la distribución, se pensó que un modelo Pareto con un solo parámetro y $\theta = 100$, $Pa(\alpha, 100)$, podría resultar adecuado. Ajústalo por máxima verosimilitud a partir de la estimación que da el método de los momentos.
3. Calcula el test de Kolmogorov-Smirnov para el modelo Pareto. Estima con el modelo ajustado las cantidades de interés y compáralas con las que da la distribución empírica. Concluye con todo ello sobre la bondad del ajuste.
4. Si la matriz de información de Fisher es n/α^2, con n el número de datos utilizados para ajustar la distribución, obtén una estimación de la varianza asintótica del $EMV(\alpha)$ y un intervalo de confianza al 95 %.
5. Se ajustaron también otros dos modelos "aceptables", con los siguientes resultados (Nota: $L(\hat{\theta})$ representa la log-verosimilitud en la EMV):
   - Exponencial Inverso $Exp{-}Inv(\hat{\theta} = 44{,}015)$, $L(\hat{\theta}) = -120{,}20$, $E(X) = 134{,}6$ y $Pr(X > 200) = 0{,}4898$.
   - Gamma Inverso $Ga - Inv(\hat{\alpha} = 5{,}53, \hat{\theta} = 700{,}60)$, $L(\hat{\theta}) = -105{,}42$, $E(X) = 150{,}57$ y $Pr(X > 200) = 0{,}1518$.

   Compáralos con el modelo Pareto en base a los siguientes criterios y concluye qué modelo te parece el más adecuado. ¿Cuál de estos criterios es el más determinante?

a) el cociente de verosimilitudes;

b) la semejanza entre el gasto medio según el modelo y el gasto medio empírico;

c) la probabilidad $Pr(X > 200)$.

6. Se consideran las siguientes condiciones de cobertura. Plantea cómo se realizarán los pagos Y por la empresa aseguradora en función de los gastos X para cada situación y compara las políticas concluyendo sobre la más ventajosa.

   a) Se asume una cobertura del 100 %.

   b) Se impone una franquicia de 60.

   c) Se reasegura el $\alpha = 80\,\%$ del exceso del gasto sobre $b = 500$. Expresa, en este caso, cómo calcularías $E(Y)$ a partir de su relación con X.

   $$\boxed{\textit{En este caso, } E(Y) = \alpha E(X \wedge b) + (1-\alpha)E(X) - bPr(X > b)}$$

   d) Se impone un límite de 200.

7. Supón que los datos hubieran sido truncados por abajo en 125 y censurados por arriba en 200. Considera sólo los datos que cumplen dicha restricción y ajusta un nuevo modelo Pareto para las pérdidas originales (conservando $\theta = 100$). Calcula $E(X)$ y $Pr(X > 200)$ con el nuevo modelo ajustado, y compáralos con las estimaciones obtenidas a partir del ajuste con todos los datos. ¿Hay mucha variación? ¿Se ha perdido mucha información con el truncamiento y la censura?

EJERCICIO 2. Un daño causado en un accidente de tráfico lo consideramos "grave"si su coste es superior a 10.000. Un accidente de tráfico lo consideramos "grave"si ha ocasionado al menos un daño "grave". Los datos disponibles en la Tabla D.2 consisten en el número de daños graves ocasionados en accidentes *de los que se sabe* que resultaron graves,

$$N = (\text{número de daños graves en un accidente}|\text{el accidente es grave}).$$

1. Ajusta un modelo geométrico truncado en el cero para N con los datos de la tabla y contrasta la bondad del ajuste con un test chi-cuadrado. ¿Cuántos daños graves se esperan en un accidente del que se sabe que es grave?

2. La probabilidad de que un accidente no sea "grave" es de 0.85. Sea $N^* =$(número de daños graves en un accidente), cuando no se sabe si el accidente fue grave o no.

   - Sabiendo que $N = (N^*|$ el accidente es grave $)$, ¿cómo están ligadas sus probabilidades $p_k = Pr(N = k)$ y $p_k^* = Pr(N^* = k)$?

- A partir del modelo truncado, justifica la utilización del modelo geométrico modificado en el cero que sirve para predecir N^*. Obtenlo. ¿Cuántos daños graves se esperan en un accidente cuando no se sabe si éste es grave o no? (**Nota**: la media de una distribución modificada en el cero es $1 - p_0^M$ veces la media de la correspondiente distribución truncada).

N° reclamaciones	1	2	3	4	5	6	7	8	9	10	24	28	39
N° accidentes	2072	301	165	120	69	50	15	8	6	4	1	1	1

Tabla D.2: Número de daños graves ocasionados en accidentes con costes superiores a 10.000 u.m.

EJERCICIO 3. El número de accidentes N en que incurre un conductor asegurado durante un año tiene una distribución de Poisson de parámetro $\lambda = 2$. La cuantía de los gastos asociados a un accidente tiene una distribución $Gamma(\alpha = 3, \theta = 60)$. El número de reclamaciones y las pérdidas sufridas son independientes.

1. Calcula $E(S)$ y $Var(S)$ a partir de la información proporcionada.
2. Utiliza un modelo normal para aproximar la distribución de la pérdida agregada asociada a un conductor a lo largo del año. Con ella, calcula la probabilidad de que el total de reparaciones supere los 700€.

   ¿Te parece que la aproximación Normal está bien justificada en este caso por el Teorema Central del Límite? ¿Por qué?
3. Utiliza un modelo gamma para aproximar la distribución de la pérdida agregada asociada a un conductor a lo largo del año. Con ella, calcula la probabilidad de que el total de reparaciones supere los 700€. Compara el resultado con el apartado anterior y explica el porqué de las diferencias.

D.7. Caso Práctico 6

EJERCICIO 1. En el fichero `datos-caso6.xls$>$pagos` tenemos los datos de los pagos Y que realizó la compañía aseguradora en una cartera de clientes, sobre cierta garantía de Defensa Jurídica del vehículo. En dicha cartera teníamos dos tipos de clientes, diferenciados por la cobertura que tenían contratada (columna 2=franquicia): los que contratan el seguro sin franquicia y los que lo hacen asumiendo una franquicia de 180 €.

Nos consta, por experiencia previa, que la distribución Weibull suele proporcionar buenos ajustes para la modelización de las pérdidas X asociadas a los siniestros.

1. Calcula, para todas las reclamaciones disponibles, las pérdidas X asociadas y da una descripción empírica (gráfica y numérica) de las mismas, comentando los resultados.

2. Ajusta por máxima verosimilitud un modelo Weibull para las pérdidas X (utilizando los datos de las mismas), a partir de la estimación que da el método de los momentos, considerando las 'peculiaridades' de los datos disponibles. ¿Tenemos algún problema de datos incompletos (truncamiento y/o censura)? Justifícalo y trata el problema de forma pertinente.

NOTA: Ten en cuenta que dispones de dos tipos de datos: con y sin franquicia, de modo que la verosimilitud, así como la función de distribución de ambos, no se va a escribir igual.

$Weib(\alpha, \beta)$, con α parámetro de forma y β de escala

$$\begin{aligned} f(x) &= \frac{\alpha}{\beta}\left(\frac{x}{\beta}\right)^{\alpha-1} e^{-(x/\beta)^\alpha} \\ F(x) &= 1 - e^{-(x/\beta)^\alpha} \\ E(X^k) &= \beta^k \Gamma(1 + k/\alpha), \\ E(X) &= \beta\Gamma(1 + 1/\alpha) \\ E[(X \wedge x)^k] &= E(X^k) F_{Ga(1+k/\alpha,\beta^\alpha)}(x^\alpha) + x^k e^{-(x/\beta)^\alpha} \end{aligned}$$

$$\hat{\beta} = exp\left(\frac{glog(p) - log(q)}{g-1}\right), \qquad \hat{\alpha} = \frac{log(log(4))}{log(q) - log(\hat{\beta})}$$

con $g = \dfrac{log(log(4))}{log(log(4/3))}$, *y* p, q *los cuantiles 25 y 75 respectivamente.*

3. Calcula el test de Kolmogorov-Smirnov para el modelo Weibull sobre las pérdidas X. Calcula también el valor medio y la varianza y compáralos con las correspondientes estimaciones empíricas. Concluye con todo ello sobre la bondad del ajuste.

> *NOTA: Recuerda que si hay algún problema de datos incompletos e información al respecto, es preciso tenerlo en cuenta al calcular la función de distribución teórica. Los datos incompletos, como ya sabes, no afectan sin embargo a la función de distribución empírica.*

4. Se ajustaron también otros modelos, con los siguientes resultados sobre la logverosimilitud en el EMV, Logver(EMV), y el valor del estadístico de Kolmogorov-Smirnov, KS:

Modelo	Logver(EMV)	KS
A	-700.01	0.154
B	-703.52	0.081
C	-699.85	0.094

   Compáralos con el modelo Weibull, si procede, en base a la información proporcionada en la tabla, y concluye qué modelo te parece el más adecuado, justificando tu respuesta.

5. Se consideran los siguientes cambios en las coberturas ofertadas por la empresa. Plantea cómo se realizarán los pagos Y^* por la empresa aseguradora en función de los gastos X para cada situación. Utilizando el modelo Weibull que ajustaste anteriormente, calcula el 'pago medio por pérdida' y el 'pago medio por pago', y utiliza estas cantidades para comparar las políticas y concluir sobre la más ventajosa.

   a) Se asume una franquicia homogénea para todos los clientes de 100 €, con una previsión del 3 % de inflación.

   b) Se impone una franquicia homogénea para todos los clientes de 130 €, con una previsión del 6 % de inflación.

NOTA: Para un modelo Weibull, el momento limitado y la función de distribución dependen de la expresión

$$e^{-(x/\beta)^\alpha}$$

Para evitar indeterminaciones y calcularla interesa escribir

$$-(x/\beta)^\alpha = -\exp\{\alpha[ln(x) - ln(\beta)]\},$$

de modo que

$$e^{-(x/\beta)^\alpha} = \exp\{-\exp\{\alpha[ln(x) - ln(\beta)]\}\}$$

6. Continúa asumiendo el modelo Weibull para los gastos X. Supón ahora que el cliente sólo está dispuesto a aceptar una franquicia tal que le garantice, 'en términos medios', que la aseguradora va a cubrir la mitad de los gastos asociados a los siniestros. Asume una inflación del 4.5 %. Calcula el valor de dicha franquicia, susceptible de ser aceptada por el cliente. ¿Cómo resulta en comparación con las otras dos posibilidades de contratación propuestas en el apartado anterior?

EJERCICIO 2. Pretendemos obtener un modelo útil para predecir el número de accidentes provocado por un asegurado al cabo del año. Tenemos datos del número de siniestros provocados por un conjunto de individuos de cierta cartera de vehículos (fichero `datos-caso6.xls>nºsiniestros`).

1. Obtén una representación gráfica útil para proponer un modelo de la familia $(a, b, 0)$. Justifica tu elección final.

2. Ajusta el modelo Geométrico y contrasta la bondad del ajuste con el test chi-cuadrado. Se ajustó también el modelo Binomial Negativo, que superó la bondad del ajuste y dió una logverosimilitud en el EMV de -1562.7723. Compara ambos modelos con el test del cociente de verosimilitudes (pues son anidados), concluyendo sobre cuál es el mejor.

3. Con el modelo seleccionado: ¿cuántos siniestros provoca, por término medio, cada asegurado? ¿Se aprecia mucha heterogeneidad entre los asegurados respecto al número de siniestros que provocan? Justifica tu respuesta.

EJERCICIO 3. El número de accidentes N en que incurre un conductor asegurado durante un año tiene una distribución Geométrica de parámetro $\beta = 1{,}28$. La cuantía de los gastos asociados a un accidente tiene una distribución $Weib(\alpha = 15, \theta = 200)$. El número de reclamaciones y las pérdidas sufridas son independientes.

1. Si S representa la pérdida agregada asociada a un asegurado a lo largo de un año, ¿cuál es su relación con X y con N? Calcula $E(S)$ y $Var(S)$.

2. Supongamos que la empresa va a ofertar la garantía en cuestión, asumiendo todo el gasto con un límite de 200€. Si S^* representa el coste agregado que supone un cliente a la empresa aseguradora, expresa S^* en función de N, del coste Y asumido por la empresa y finalmente del gasto completo X. Calcula $E(S)$ y $Var(S)$.

NOTA: Para resolver el último apartado, formula $Y = (X \wedge u)$ en términos de X. Ten en cuenta además que sus momentos se calculan según:

$$E(Y) = E[X \wedge u] \text{ y } Var(Y) = E[(X \wedge u)^2] - E[X \wedge u]^2$$

Bibliografía

Boj, E., Claramunt, M.M. y Fortiana, J. (1998). *Análisis multivariante aplicado a la selección de factores de riesgo en la tarificación*. Cuaderno nº 88 Fundación MAPFRE estudios.

Boland, P.J. (2007). *Statistical and Probabilistic Methods in Actuarial Science*. Taylor & Francis, CRC Press. Series: Interdisciplinary Statistics, Vol.16.

Booth, P.(1999). *Modern actuarial theory and practice*. Chapman & Hall/CRC, Boca Ratón.

Borowiak, D.S.(2003). *Financial and actuarial statistics: an introduction*. Marcel Dekker, Inc.

Bühlmann, H.(2005). *A course in credibility theory and its applications*. Springer, New York.

Daykin, C. D., (Chris D.) (1994). *Practical risk theory for actuaries*. Chapman & Hall.

Hoog, R.V. and Klugman, S.A.(1984). *Loss distributions*. John Wiley & Sons, N.Y.

Hossack, I. B.(1999). *Introductory statistics with applications in general insurance*. Cambridge Cambridge University Press.

Hossack, I.B.(2001). *Introducción a la estadística con aplicaciones a los seguros generales*. MAPFRE D.L., Madrid.

Kaas, R., Goovaerts, M., Dhaene, J., Denuit, M. (2001). *Modern actuarial risk theory*. Kluwer Academic cop., Boston.

Klugman, S.A. (1992). *Bayesian statistics in actuarial science with emphasis on credibility*. Kluwer Academic, Boston.

Klugman, S.A., Panjer, H.H. & Willmot, G.E.(2004). *Loss models: from data to decisions*, 2nd ed. John Wiley & Sons, N.Y.

Klugman, S.A., Panjer, H.H. & Willmot, G.E.(2004). *Loss models: from data to decisions. Solutions manual*. John Wiley & Sons, N.Y.

Latorre Llorens, L. (1992). *Teoría del riesgo y sus aplicaciones a la empresa aseguradora*. MAPFRE D.L., Madrid.

Lopez Cachero, M.(1996). *Estadística para actuarios*. Mapfre D.L., Madrid.

McNeill, I.B. and Umphrey, G., Eds. (2001). *Advances in the Statistical Sciences: Actuarial Science*. Springer.

Singpurwalla, N.(2006). *Reliability & Risk: a bayesian perspective*. Wiley Series in Probability and Statistics.

Vegas Pérez, A.(1981). *Estadística-aplicaciones econométricas y actuariales*. Pirámide, Madrid.