Modelos Lineales en Econometría

Juan Aparicio, Mª Asunción Martínez Mayoral y Javier Morales

Índice general

1. Introducción **1**

1.1. Introducción 1

1.1.1. Qué es la Econometría 1

1.1.2. El modelo económico y el modelo econométrico: un ejemplo 3

1.1.3. Historia de la Econometría 4

2. El proyecto R **9**

2.1. ¿Qué es R? 9

2.1.1. Motivos para usar R 9

2.1.2. Cómo descargarnos R desde internet 10

2.2. Principios Básicos de Uso 12

2.3. Creación y manipulación de objetos 12

2.3.1. Clases de objetos 13

2.3.2. Operadores Lógicos 14

2.3.3. Vectores, Secuencias y Factores 14

2.3.4. Matrices y Arrays 16

2.3.5. Listas 16

2.3.6. Operaciones con vectores, matrices y listas 17

2.3.7. Data Frames 18

2.4. Ejercicios 20

3. Ejemplos y Modelización Estadística **21**

3.1. Ejemplos 21

3.2. Modelización Estadística 27

3.3. Notación 29

4. Análisis de Correlación **31**

4.1. Introducción 31

4.2. Análisis gráfico de asociación 31

4.3. Análisis de Correlación 34

4.4. Correlación Lineal Simple 34

Contraste de Hipótesis 36

4.5. Transformaciones para conseguir linealidad 38

4.6. Correlación Múltiple y Parcial 41

4.7. Resumen 45

4.8. Ejercicios 46

5. El Modelo de Regresión Lineal Simple (RLS) **49**

5.1. Introducción 49

5.2. ¿Por qué el nombre de Regresión? 50

5.3. Formulación del modelo RLS 51

5.4. Hipótesis Básicas del modelo RLS 51

5.5. Estimación de la recta de regresión 52

5.6. Propiedades del ajuste de la recta de regresión. 57

5.7. Estimación de σ^2. 58

5.8. Inferencia sobre $\hat{\beta}_0$ y $\hat{\beta}_1$. 59

5.8.1. Estimación de la respuesta esperada 62
5.8.2. Predicción de nuevas observaciones 63
5.9. Ajuste del modelo. Descomposición de la varianza: Anova 64
5.9.1. El coeficiente de determinación 66
5.10. Diagnóstico Gráfico del Modelo. Análisis de los Residuos 68

Capítulo 1

Introducción

1.1. Introducción

Las siguientes secciones están basadas fundamentalmente en los textos de Trívez(2004), Álvarez(1999), Peña(1995) y Stanton(2001).

1.1.1. Qué es la Econometría

Desde un punto de vista etimológico, *Econometría* procede de la unión de la palabras griegas *oikonomia* (economía) y *metron* (medida). Es decir, Econometría significaría algo así como la medición de la economía. Cuando revisamos bibliografía, encontramos diversas acepciones que han dado los estudiosos sobre el concepto de Econometría, en las que han señalado los diversos objetivos que persigue esta materia. Destacamos las siguientes definiciones de Econometría:

Spanos : La Econometría está dedicada al estudio sistemático de los fenómenos económicos usando los datos observados.

Cowles Commission : La Econometría tiene por objeto la explicación de la economía y el pronóstico económico mediante el conocimiento de las estructuras o relaciones que describen conductas humanas.

Malinvaud : La Econometría tiene por objeto la determinación empírica de

leyes económicas.

Intriligator : La Econometría tiene por objeto la estimación empírica de las relaciones económicas.

Maddala : La Econometría tiene por objeto la aplicación de los métodos estadísticos a datos económicos.

Otero : la Econometría se ocupa de la cuantificación de los fenómenos y de la verificación de las teorías económicas, haciendo uso para ello de las estadísticas económicas y aplicando a tal fin, métodos especiales de inferencia estadística.

Tinbergen : Econometría es un nombre para un campo de la ciencia, en el que la investigación económico-matemática y estadístico-matemática se aplican en combinación.

Tintner : La Econometría es la aplicación de un método específico en el campo general de la ciencia económica, en un esfuerzo de buscar resultados numéricos y de verificar teoremas económicos. Consiste en la aplicación de la teoría económica matemática y los procedimientos estadísticos a los datos económicos en orden a establecer resultados numéricos en el campo de la economía y verificar teoremas económicos.

Gollnick : El análisis econométrico combina la Teoría Económica, las Matemáticas y la Estadística para cuantificar y verificar las relaciones entre las variables económicas.

Judge, Hill, Griffiths, Lütkepohl y Lee : la Econometría, haciendo uso de la Teoría Económica, las Matemáticas y la Inferencia Estadística como fundamentos analíticos, y de los datos económicos como base informativa, proporciona una base para: 1) modificar, refinar o posiblemente refutar las conclusiones contenidas en el cuerpo de conocimientos conocidos como Teoría Económica, y 2) conseguir signos, magnitudes y afirmaciones de calidad para los coeficientes de las variables en las relaciones económicas, de modo que esta información puede usarse como base para la elección y toma de decisiones.

Las teorías o leyes económicas, entendiendo por éstas a las hipótesis aceptadas con validez general, suelen ser formuladas como proposiciones cualitativas de carácter necesario. La inmensa mayoría de estas leyes se expresan de forma sencilla a través de un lenguaje matemático dependiente de una serie de constantes (parámetros). Es entonces cuando la Econometría, a través de un conjunto de datos observados procedentes del fenómeno económico de interés, puede proporcionar las herramientas necesarias para la cuantificación empírica de los valores de los parámetros. Por ejemplo, la ley de la demanda siempre dice que ésta presenta pendiente negativa en su relación con el precio. Las técnicas estadísticas pertinentes permitirán al econometra obtener el valor concreto de tal pendiente (estimación).

Sobre las anteriores mediciones se fundamentan las predicciones y análisis de los efectos de la aplicación de distintas políticas económicas. Además, han sido ampliamente usadas como base para la toma de decisiones por parte de entidades tanto públicas como privadas.

1.1.2. El modelo económico y el modelo econométrico: un ejemplo

Para llegar a comprender la diferencia entre un modelo "matemático económico" y uno "econométrico", describiremos a continuación un ejemplo que puede ser hallado en Trívez(2004).

Se entiende por modelo teórico a una representación simplificada y en símbolos matemáticos de cierto conjunto de relaciones. Así, por ejemplo, un modelo teórico sobre el consumo puede enunciarse, siguiendo a Keynes, estableciendo que el consumo para un individuo C, viene dado en función de su renta disponible R, esto es,

$$C = f(R).$$

Para pasar de este modelo teórico al econométrico, será necesario especificar una forma funcional concreta para f, e introducir un término de perturbación aleatoria que nos permita razonar en términos probabilísticos y no exactos. Esta perturbación aleatoria servirá para aceptar cierta variabilidad en la relación entre

renta y consumo para individuos distintos.

Así, si se intuye una relación lineal entre renta y consumo, un modelo econométrico podría ser:

$$C = \alpha + \beta R + u,$$

donde u contendría toda la información sobre la variabilidad en la relación entre la renta y el consumo, esto es, básicamente, información sobre la heterogeneidad de los individuos respecto a la relación renta-consumo y la influencia de otros posibles factores (variables) relacionados también con el consumo, útiles para predecirlo, pero no considerados en el modelo. Asimismo, el término aleatorio contiene el efecto de los posibles errores de medida en que se incurre a la hora de la toma de los datos para las distintas variables involucradas en el modelo.

1.1.3. Historia de la Econometría

Hacer notar en principio, que estudiosos distintos de la Historia de la Econometría citan como precursores de la misma a científicos diferentes, eso sí, economistas en su mayoría.

Schumpeter, por ejemplo, marca a los economistas de los siglos XVII y XVIII, como Petty, King, Cantillon y Quesnay como los principales precursores de esta disciplina. Otros incluso incluyen en esta lista a Davenant.

Cowles sostiene sin embargo, que "la Econometría estrictamente hablando, tuvo sus orígenes en la Europa del siglo XIX, principalmente con los trabajos de Von Thünen, Cournot, Walras, Jevons, Edgeworth, Pareto y Wicksell". En este sentido, cabe destacar que hacia el año 1870 se registran antecedentes de importancia en los primeros pasos de la Econometría. Sobresalen algunos trabajos que hacen uso de datos atemporales, que habrían de servir más tarde para enunciar las leyes de Engel.

Arrow, junto a Trívez, defiende que la Econometría, como disciplina autónoma, es mucho más reciente, y sitúa su punto de arranque en la segunda década del siglo XX. La investigación econométrica, iniciada en esas fechas, tenía como objetivo principal el análisis de la demanda. Este hecho parece ser debido a la existencia de una teoría de la demanda bien estructurada, la posibilidad de

obtener series estadísticas sobre cantidades y precios y, finalmente, como consecuencia de la teoría estadística introducida por Pearson a través del estudio de las correlaciones entre variables.

Se le achaca a Moore ser el máximo fundador del análisis econométrico de la demanda. Moore recurrió en sus investigaciones al empleo de transformaciones de variables, inclusión de variables con retardo, correlaciones múltiples y análisis armónico. Junto a Moore destacan otros científicos: Working, Ezequiel y Shultz. Sobresale el trabajo de Shultz sobre el análisis de la demanda de azúcar.

El empuje de éstos y otros economistas llevó a Fisher en 1912 a intentar crear, apoyado en la Asociación Americana Para El Avance de la Ciencia, una organización compuesta por economistas, estadísticos y matemáticos. Su idea no tuvo éxito.

En 1926 Frisch, con las mismas pretensiones que Fisher, promueve una organización de objetivos similares entre los economistas europeos. Es en una carta de Frisch a Divisa en septiembre de 1926, donde se sugiere, además de la creación de la susodicha asociación, la edición de una revista científica a la que denomina "*Econometrica*" en analogía con la revista ya existente "*Biometrika*". Parece ser que ésta representa la primera referencia histórica que se posee sobre el término "Econometría".

En cuanto a *Econometrica*, es una revista de carácter científico que publica artículos originales en todas las ramas de la economía, teórica y empírica, abstracta y aplicada. A su vez, promueve los estudios que tienen como objetivo la unificación de lo teórico-cuantitativo y el acercamiento empírico-cuantitativo a los problemas económicos. Para hacernos una idea de la relevancia actual de la revista dentro del panorama internacional, bastará indicar que en el ISI *Journal Citation Reports*®Ranking de 2003, *Econometrica* aparece en primera posición dentro del área de Ciencias Sociales y Métodos Matemáticos, y la cuarta en el área de Estadística y Probabilidad.

Por otro lado, cierta polémica suscitada a raíz de un artículo de Roos en Estados Unidos, generó en 1928 que se discutiera en una reunión de la Asociación Americana para el Avance de la Ciencia, sobre la creación de una nueva sección dedicada plenamente al desarrollo de la Economía Política y la Sociología como ciencias.

Frisch y Roos, de intereses comunes, con el fin de dar origen a una institución completamente independiente, solicitan ayuda a Fisher en el año 1928. Del fruto de ésta y otras reuniones, se funda la *Sociedad de Econometría* (Econometric Society) el 29 de diciembre de 1930, al auspicio de la *Asociación Americana para el Avance de la Ciencia*. El propio Fisher fue nombrado presidente de la sociedad.

Una vez establecida la Sociedad de Econometría, era importante la existencia de una institución donde se localizaran y centraran las investigaciones econométricas. Nacerá así la *Cowles Commission*, financiada íntegramente por el multimillonario Alfred Cowles, quien ofrecerá los fondos necesarios para sacar a la luz el primer número de *Econometrica*, en enero de 1933.

La *Cowles Commission for Research in Economics* se creó en el año 1932 en Colorado Springs, con el objetivo fundamental de "fomentar la investigación científica en Economía, Finanzas, Comercio e Industria".

Dentro de las famosas monografías de la *Cowles Commission* destacan los trabajos de Haavelmo, Hood, Koopmans, Marschak, Rubin, Chernoff, Divinsk y Hurwicz, entre otros. En éstos aparecen cuestiones relacionadas con la inferencia estadística en modelos econométricos multiecuacionales, teoría económica, números índice, etc.

Nos es posible citar, además, las monografías número 10, *Statistical Inference in Dynamic Economic Models*, y la 14, *Studies in Econometric Methods*, como piezas clave de la obra clásica de la Econometría. No obstante, la mayoría de los anteriores trabajos forman parte de un periodo inicial de lo que se entiende hoy en día por estudio econométrico. Más recientemente destacan los siguientes trabajos:

- Chow(1960): test sobre permanencia estructural.

- Zellner(1962, 1963): sistemas de ecuaciones aparentemente no relacionadas.

- Shapiro y Wilk(1963): test de normalidad.

- Box y Cox(1964): transformación de variables.

- Goldfeld y Quandt(1965): contrastes sobre heterocedasticidad.

- Durbin y Watson(1971): autocorrelación.

Todo lo anterior hace referencia a los inicios y desarrollo posterior de la

Econometría, no obstante, en cuanto a las pretensiones científicas de relacionar linealmente una variable Y con otra X, cabe señalar que fueron Laplace y Gauss los primeros en aplicar modelos matemáticos lineales en disciplinas como la Astronomía y la Física. Sin embargo, el nombre por el que son conocidos estos modelos matemáticos, *Modelos de Regresión*, proviene de los trabajos de Galton a finales del siglo XIX. Galton, primo de Darwin, encaminó sus investigaciones hacia el estudio de la herencia biológica, concibiendo las nociones modernas de correlación y regresión.

Es habitual encontrar en los libros de texto la definición de coeficiente de correlación lineal de Pearson antes de la definición de recta de regresión. Sin embargo, en Stanton (2001) hallamos la verdadera secuencia temporal en la introducción de estas herramientas en la literatura científica. La primera recta de regresión fue presentada en 1877 en un estudio desarrollado por Galton, mientras que Pearson presentó formalmente su coeficiente de correlación en el año 1896, en el *Philosophical Transactions of the Royal Society of London*.

El nombre de *Modelo de Regresión*, por otro lado, procede de la naturaleza de algunos de los resultados obtenidos por el propio Galton. Éste estudió la dependencia de la estatura de los hijos (variable que hacía las veces de variable respuesta Y) respecto a la de sus padres (variable explicativa X). Halló así lo que denominó una "regresión" a la media de los datos. Los padres altos tienen, en términos generales, hijos altos, pero, en promedio, no tan altos como sus padres. Por otro lado, los padres bajos tienen hijos bajos, pero, en media, más altos que sus padres. Desde entonces viene utilizándose dicha denominación en el mundo estadístico y econométrico.

Capítulo 2

El proyecto R

2.1. ¿Qué es R?

Los ejemplos numéricos que aparecen en el libro han sido desarrollados enteramente con R. R, un proyecto GNU (software libre), es una aplicación libremente disponible para ser usada con propósitos de índole estadística. Tiene implementadas una amplia variedad de gráficos y técnicas estadísticas: el modelo de regresión lineal y no lineal, pruebas estadísticas de todo tipo, análisis de series temporales, herramientas de clasificación, etc.

Por otro lado, para acceder a este software debemos conectarnos a CRAN. CRAN es una red ftp de servidores de internet alrededor del mundo que almacenan versiones del código y documentación de R idénticas y actualizadas. En las siguientes secciones veremos cómo podemos descargarnos dicho programa desde la red CRAN a través de dos vías distintas.

2.1.1. Motivos para usar R

R es un paquete estadístico tan potente o más que otros actualmente de moda en el panorama mundial dentro del contexto del uso de la Estadística. La ventaja fundamental que presenta frente a otros, y que lo hace del todo atractivo, es su gratuidad total de uso. Esto implica que desde un punto de vista empresarial de minimización de costes resulte más adecuada su adquisición que otro tipo

de software existente en el mercado actual. Al mismo tiempo cabe destacar la continua actualización y mejora que se viene produciendo de R, y de las cuales, nos podemos beneficiar descargando las actualizaciones de manera sencilla a través de internet. Sin embargo, el interface de R difiere del típico usado en otras muchas aplicaciones para Windows (como con el SPSS, por ejemplo). En contrapartida, para comunicarnos con R lo tendremos que hacer a través de la utilización de una línea de comandos.

2.1.2. Cómo descargarnos R desde internet

Aunque las formas de descargarse R y sus múltiples librerías son variadas, hemos optado por mostrar dos de ellas. Mediante la primera haremos uso de la web oficial del proyecto R: www.r-project.org. La segunda opción necesita la conexión a la redIRIS (Interconexión de los Recursos InformáticoS) patrocinada por el Plan Nacional de I+D. Evidentemente, en ambos casos necesitamos estar conectados a internet.

1. Abrimos el navegador. La dirección URL a la que debemos dirigirnos es http://www.r-project.org. En el menú de la izquierda seleccionamos *Download CRAN*. Elegimos como servidor el español (Spain). Para descargarnos R, pinchamos sobre *Windows (95 and later)* → *Base* → *rw1091.exe*. Éste es el fichero que debéis descargaros a vuestro disco duro. Una vez completado el proceso de descarga, bastará con pinchar dos veces sobre el archivo y aceptar todas las opciones por defecto. Se instalará el programa y aparecerá un icono de acceso en el escritorio de vuestro ordenador. Asimismo, las librerías son accesibles desde este mismo entorno en *Windows (95 and later)/Contributed extension packages*.

2. Vía ftp. Haremos uso de cualquier cliente ftp (CuteFTP, WSFTP,...). El nombre del servidor ftp es: *ftp.rediris.es*. En usuario y contraseña debemos introducir, en ambos casos, *anonymous*. Dentro de la carpeta *mirror* buscaremos *CRAN*. Una vez hayamos entrado en *CRAN* pincharemos dos veces sobre la carpeta denominada *bin*. Dentro de bin seleccionamos *windows*. Y dentro de la subcarpeta *base* encontraremos el fichero rw1091.exe, el cual descargaremos a nuestro disco duro. Como con el método anterior,

una vez completado el proceso de descarga, bastará con pinchar dos veces sobre el archivo y aceptar todas las opciones por defecto. Indicar que se os instalará en el sistema la versión 1.9.1, apareciendo un icono identificativo en el escritorio de vuestro ordenador.

Las librerías de R se encuentran en *bin*, dentro de *1.9* en la carpeta *contrib*.

Existe la posibilidad de actualizar todas las librerías de R automáticamente por Internet. Para ello bastará con ejecutar el icono de R de vuestro escritorio y, posteriormente, ir al menú *Packages*. Bajo este menú se encuentra la opción *Update packages from CRAN*. Al seleccionar ésta comenzará la descarga de librerías. En la siguiente sección estudiaremos cómo cargar una librería en concreto para poder ser utilizada por R.

Ha llegado el momento de comenzar a dar nuestros primeros pasos con R.

2.2. Principios Básicos de Uso

Inicio de sesión	Rgui.exe
Consulta de ayuda sobre una función concreta	?funcion help("funcion") Help/R functions (text)
Consulta de ayuda sobre funciones que contienen una "cadena" de caracteres	apropos("cadena") Help/Apropos
Consulta de ayuda sobre funciones relacionadas con una "cadena" de caracteres	help.search("cadena") Help/Search help
Consulta de ayuda html	Help/Html help/Search Engine...
Especificar directorio de trabajo	File/Change dir
Guardar sintaxis y resultados sesión	File/Save to File
Inspección de objetos creados Salvar objetos creados en un fichero.RData Cargar objetos guardados en un fichero.RData	objects(), ls() File/Save Workspace File/Load Workspace
Salvar sintaxis ejecutada en un fichero.RHistory Cargar sintaxis guardada en un fichero.RHistory Cargar sintaxis guardada en un fichero.R	File/Save History File/Load History File/Source R code source("fichero.R")
Volcado de resultados a un fichero	sink("fichero.out") ... sink() cat(...,file="fichero")
Visualizar ficheros de texto	File/Display file(s)
Inspección bases de datos disponibles Cargar base de datos disponibles	data() data(nombre base de datos)
Borrar objetos Borrar todos los objetos	rm(nombre objeto) rm(list = ls())
Inspección de librerías cargadas Instalar librerías Cargar librerías instaladas Consulta de ayuda sobre librerías	search() Packages/Install package(s) ... Packages/Load package library(librería) Help/Html help/Packages

2.3. Creación y manipulación de objetos

Para crear un objeto es preciso utilizar el operador de asignación `<-`, subrayado, o directamente el comando *assign()*. En las últimas versiones de R también funciona "=", pero conviene usarlo con cautela, pues siempre no funciona.

```
x<-5
x=5
assign("x",5)
```

2.3.1. Clases de objetos

Los tipos de objetos en R son:

Vectores	vector()
Factores (*cualitativos*)	factor(),gl()
Listas	list()
(admite elementos de distinto tipo)	
Matrices	matrix(ncol,nrow), array(dim)
Bases de datos	data.frame()
(matriz con columnas de distinto tipo)	

En general, salvo los factores, todos los objetos admiten elementos de tipo numérico, carácter, complejo o lógico. Los factores sólo aceptan elementos numéricos o caracteres.

Para inspeccionar y/o modificar los atributos de un objeto se utilizan los comandos:

```
attr(objeto)
attributes(objeto)
```

Todo objeto tiene dos atributos intrínsecos: tipo y longitud. Los tipos básicos de los objetos son: 'logical', 'integer', 'numeric', 'complex', 'character' y 'list'. Para inspeccionar el tipo de un objeto se utilizan los comandos:

```
typeof(objeto)
mode(objeto)
```

2.3.2. Operadores Lógicos

El símbolo # identifica como comentario todo lo que sigue en la misma línea.

$<$	menor que
$>$	mayor que
$<=$	menor o igual que
$>=$	mayor o igual que
$==$	igual que
$!=$	distinto de
$\|$	uno u otro
$\&$	uno y otro

2.3.3. Vectores, Secuencias y Factores

Un vector es una colección ordenada de números, símbolos lógicos, caracteres, complejos.

```
x <-1:30
c(1, 1.5, 2, 2.5, 3, 3.5, 4, 4.5, 5)
seq(1, 5, by=0.5)
seq(1, 5, length=20)
seq(length=9, from=1, to=5)
z <- scan() # e introducimos los números que queremos
# pulsando al final dos veces la tecla Intro
rep(1, 30)
sequence(c(10,5))
```

Es posible leer datos sin formato de ficheros externos con el comando `scan()`

```
cat("Probamos a leer cosas", "2 3 5 7", "11 13 17",
file="prueba.data", sep="\n")
pp <- scan("prueba.data")
scan("prueba.data", skip = 1)
scan("prueba.data", skip = 1, nlines=1)
str(scan("prueba.data", what = list("","","")))
str(scan("prueba.data", what = list("","",""), flush = TRUE))
unlink("prueba.data") # Borra el fichero.
```

La función `gl()` genera factores, esto es, vectores cuyos elementos son de tipo cualitativo y que sirven para identificar grupos o categorías de clasificación. Los dos comandos más comunes para generar factores son `factor(vector)` y `gl()`:

```
gl(3, 5)
gl(3, 5, length=30)
gl(2, 6, label=c("Macho", "Hembra"))
gl(2, 10)
gl(2, 1, length=20)
gl(2, 2, length=20)

factor(as.character(rep(1:2,5)),levels=c(1,2),
labels=c("Blanco","Negro"))
```

También podemos categorizar variables de tipo numérico con el comando `cut()`:

```
edad<- c(7,15,84,45,21,11,35,57,71,55,62,12,35,36,25,44,45,80,18)
edad.f <- cut(edad,breaks=c(0,15,30,50,75,100))
```

Selección de elementos de un vector/factor:

```
x[2]
x[(1:15)*2]
x[x>10]
x[x<3 | x>27]
x[x<20 & x>15]
```

Es posible seleccionar también a través de un objeto de dimensiones similares:

```
color <- gl(2,15,30,labels=c("Blanco","Rojo"))
x[color=="Rojo"]
```

La función `split()` permite clasificar (particionar) los elementos de un vector en función de los niveles de un factor:

```
split(x,color)
```

Los datos faltantes se identifican con `NA`:

```
x  <-  c(1,5,6,2,NA)
is.na(x)
y <- x[!is.na(x)]
x[is.na(x)] <- 999
```

2.3.4. Matrices y Arrays

Un array es una colección de entradas de datos del mismo tipo, ya sea numérico, categórico o lógico.

Las matrices son un caso particular de arrays.

```
matrix(1:8,ncol=4)
matrix(ncol=2,nrow=2)
mat <- matrix(1:8,ncol=2,byrow=T)
dimnames(mat)=list(c("F1","F2","F3","F4"),c("Q1","Q2")); mat
```

Es posible definir matrices 'pegando vectores-matrices' por filas o por columnas:

```
cbind(1:6,7:8)
rbind(1:6,7:9)}
```

En general, los arrays son matrices multidimensionales.

```
a  <- array(c(1:8,11:18,111:118),dim= c(2,4,3))
```

y la selección de elementos se hace de forma análoga al caso de vectores: con corchetes:

```
a[1,1,2]
a[,,2]}
```

2.3.5. Listas

En una lista podemos mezclar elementos de diferentes tipos:

```
lista  <- list(array=a,matriz=mat,vector=x)
```

La selección de elementos se hace con doble corchete o con el nombre del elemento:

```
lista[[1]]
names(lista)
lista$array}
```

Se pueden concatenar varias listas en una sola:

```
lista.A <- list(xA=1:5,yA=c("rubio","moreno"))
lista.B<- list(xB=85,yB=gl(2,1,10,labels=c("ojo","oreja")))
lista.AB <-  c(lista.A,lista.B)}
```

2.3.6. Operaciones con vectores, matrices y listas

Las operaciones habituales (suma, resta, multiplicación, división) se denotan con sus respectivos símbolos (+,-,*,/).

Un producto interno entre dos vectores de idénticas dimensiones se calcula $x * y$. Un producto externo (matricial) se obtiene con $A\,\% * \%B$, donde A y B son matrices con las dimensiones apropiadas.

Otras operaciones de interés son:

t(A) matriz transpuesta de A

solve(A,b) resuelve la ecuación Ax=b

solve(A) matriz inversa de A

svd() proporciona la descomposición en valores singulares

qr() obtiene la descomposición QR

eigen() calcula valores y vectores propios

sort(b) ordena el vector b

diag(b) proporciona una matriz diagonal cuyos elementos (en la diagonal) son las componentes del vector b

diag(A) extrae un vector con los elementos de la diagonal de la matriz A

tapply(medidas,categorías,fun) aplica la función *fun* sobre los valores de la variable *medidas* clasificada en las categorías del factor *categorías*

sapply(split(medidas,categorías),fun)) tiene el mismo efecto que la anterior tapply

lapply(lista,fun) calcula la función fun en cada uno de los elementos de una lista

apply(A,index,fun) aplica la función fun sobre cada una de las filas (index=1) o columnas (index=2) de una matriz A.

2.3.7. Data Frames

Una hoja de datos es una lista que pertenece a la clase data.frame. Están caracterizadas por lo siguiente:

- las componentes han de ser vectores, factores, matrices numéricas, listas u otras hojas de datos.
- Las matrices, listas y hojas de datos contribuyen a la nueva hoja de datos con tantas variables como columnas, elementos o variables posean, respectivamente.
- Los vectores numéricos y los factores se incluyen sin modificar; los vectores no numéricos se fuerzan a factores cuyos niveles son los únicos valores que aparecen en el vector.
- Los vectores que constituyen la hoja de datos deben tener todos la misma longitud, y las matrices el mismo número de filas.

Las hojas de datos pueden tratarse generalmente como matrices cuyas columnas pueden tener diferentes modos y atributos. Pueden imprimirse en forma matricial y se pueden extraer sus filas o columnas según la indexación de matrices.

```
clima.cont <- c("no","no","si")
ciudades <-  c("Sevilla","Alicante","Albacete")
temp.max <-  c(41,35,39)
ciudad.datos <- data.frame(ciudades,clima.cont,temp.max)
```

Es posible cargar datos disponibles en R como hojas de datos (data.frame). Una vez cargadas, podemos trabajar con sus variables utilizando el comando `attach()`. Para olvidar estas variables, basta utilizar `detach()`:

```
data(infert)
infert$education
attach(infert)
education
detach(infert)
```

Podemos leer datos con formato de base de datos con el comando `read.table()`

```
df <-  data.frame(pelo=c("rubio","moreno"),talla=c(1.69,1.85),
CI=c(140,110))
sink(file="prob")
df
sink()
read.table("prob",header=T)
unlink("prob")
```

2.4. Ejercicios

Inicialmente especifica el directorio de trabajo en que quieres trabajar.

1. Crear un vector de 20 datos (var X) en el que los 10 primeros datos identifiquen a un tipo de individuos (A), los 4 siguientes a otro (B) y los restantes a un tercero (C).

2. Sean los datos:

```
ctl <-  c(4.17,5.58,5.18,6.11,4.50,4.61,5.17,4.53,5.33,5.14)
trt <-  c(4.81,4.17,4.41,3.59,5.87,3.83,6.03,4.89,4.32,4.69)
```

   que identifican las mediciones correspondientes a individuos de dos grupos: control (ctl) y tratamiento (trt). Crear un vector con todos los datos y un factor que identifique individuos de uno y otro grupo.

3. Transforma en data.frame los datos de los Ejercicios 1 y 2. Direcciónalo a un fichero externo y comprueba cómo quedó (sin salir de R).

4. Construye una matriz A cuya diagonal esté constituida por la secuencia de enteros del 1 al 6. Construye otra matriz B de idéntico tamaño en la que la primera fila sean todo 1, la segunda todo 2, y así hasta la última, con todos los elementos igual a 6. Construye un vector b de dimensión 6 con la diagonal de la matriz B. Realiza las siguientes operaciones:

   a) b'(A+B)

   b) b'(AB)

   c) $A^{-1}B$

   d) Resuelve (A+B)x=b

   e) A los elementos iguales a cero en la matriz A asígnales un valor muestreado al azar de entre los números del 0 al 9. (Nota: utiliza el comando *sample()*).

   f) Selecciona la segunda fila de B, llámala b2 y calcula b'b2 y b2'A.

5. Guarda la sintaxis y los objetos generados en la sesión. Sal de R y vuelve a acceder a R cargando todo lo que ejecutaste anteriormente. Comprueba que todo funciona.

Capítulo 3

Ejemplos y Modelización Estadística

3.1. Ejemplos

Ejemplo 3.1 (Regresión lineal simple) *Parece ser que el dinero gastado en la manutención de tractores es mayor a medida que aumenta la edad del tractor. Se pretende ratificar esta hipótesis utilizando los datos del Apéndice representados en la Figura 3.1 (de Draper y Smith, 1998, pag.100). Se aprecia cierta tendencia lineal, capturable con una recta procedente de un modelo de regresión lineal (también representada) para predecir el gasto en función de la edad del tractor.*

Ejemplo 3.2 (Regresión lineal múltiple) *Para estimar la producción en madera de un bosque se suele realizar un muestreo previo en el que se toman una serie de mediciones no destructivas. Disponemos de mediciones para 20 árboles, así como el volumen de madera que producen una vez cortados. Las variables observadas son:*

HT *= altura en pies*
DBH *= diámetro del tronco a 4 pies de altura (en pulgadas)*
D16 *= diámetro del tronco a 16 pies de altura (en pulgadas)*
VOL *= volumen de madera conseguida (en pies cúbicos).*

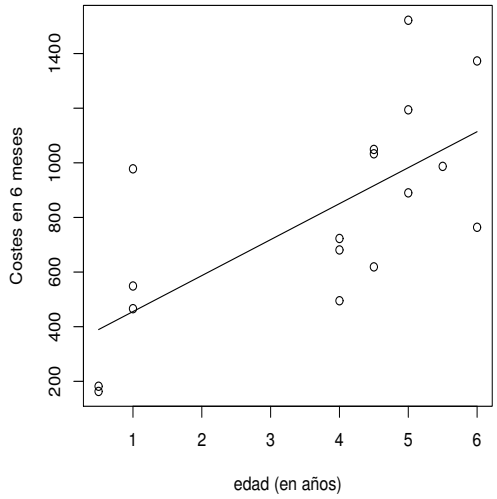


Figura 3.1: Regresión Lineal Simple.

El objetivo del análisis es determinar cuál es la relación entre dichas medidas y el volumen de madera, con el fin de poder predecir este último en función de las primeras. Los datos (Apéndice) están representados en la Figura 3.2 (datos de Freund y Wilson, 1998, pag.39). Un modelo de regresión múltiple nos proporciona en numerosas ocasiones una buena solución a problemas de este tipo.

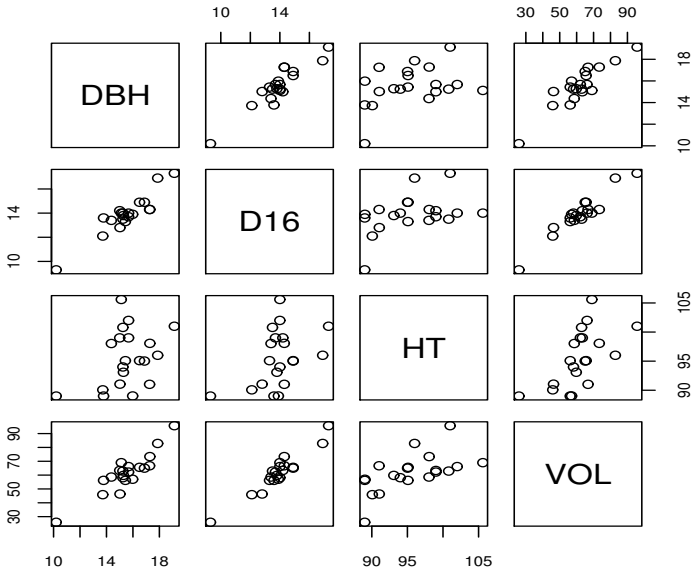


Figura 3.2: Regresión Lineal Múltiple.

Ejemplo 3.3 (Regresión polinómica) *En la Figura 3.3 están representados unos datos (Apéndice) sobre la relación existente entre la concentración de madera contenida en la pulpa, a partir de la que se elabora papel, y la resistencia (en términos de tensión que soporta) del papel resultante. El objetivo del análisis es describir la tendencia observada (claramente curva) y representada en el gráfico, a través de un modelo aceptable. Los datos provienen de Montgomery y Peck (1992), pag.205. Los modelos de regresión polinómica dan soluciones a este tipo de comportamiento en los datos.*

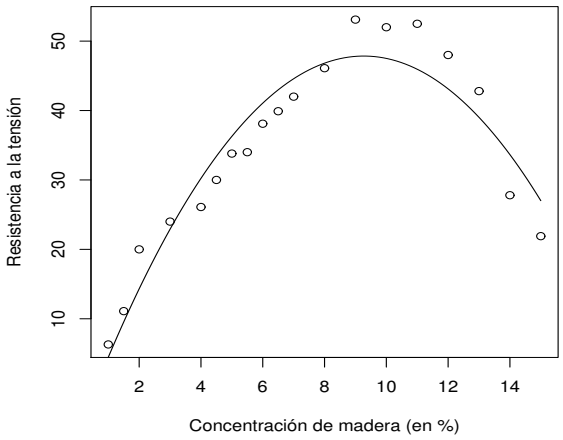


Figura 3.3: Regresión Polinómica.

Ejemplo 3.4 (Modelos de Anova) *Se lleva a cabo un experimento clínico en el que un grupo aleatorizado de pacientes, identificado como 'grupo T', prueba un nuevo fármaco contra la hipertensión, y otro grupo también aleatorizado y llamado 'grupo P' toma un placebo. A todos los pacientes se les mide la tensión arterial antes de administrar el tratamiento (fármaco o placebo) y después de finalizar el período de observación. El objetivo del análisis es investigar si el fármaco tiene un efecto sobre la reducción de la tensión arterial y cuantificar dicho efecto si existe. Las diferencias, para cada grupo de pacientes, entre la tensión arterial antes y después del tratamiento están representadas en la Figura 3.4. Se aprecian diferencias entre los dos grupos, que habrán de ser ratificadas estadísticamente a través de un Análisis de la Varianza o ANOVA.*

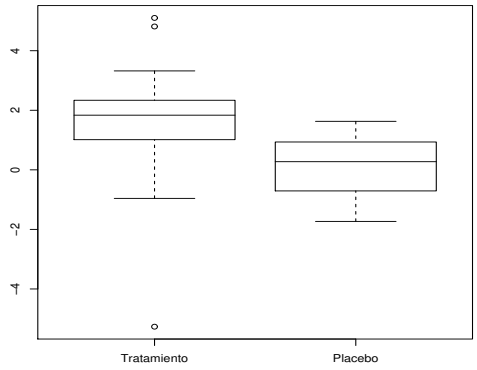


Figura 3.4: Modelo de Anova.

Ejemplo 3.5 (Modelos de Ancova) *En la Figura 3.5 están representados los datos sobre tiempo de vida de una pieza cortadora de dos tipos, A y B, en función de la velocidad del torno en el que está integrada (en revoluciones por segundo). Este ejemplo proviene de Montgomery y Peck (1992), pag.239. El objetivo del análisis es describir la relación entre el tiempo de vida de la pieza y la velocidad del torno, teniendo en cuenta de qué tipo es la pieza. El gráfico sugiere una tendencia lineal para cada tipo de herramienta. La cuestión es si dicha tendencia lineal es similar o no en los dos tipos de herramienta. Esta cuestión es contestada a través de un Análisis de la Covarianza o ANCOVA, a través del que se obtiene el mejor modelo de predicción (lineal).*

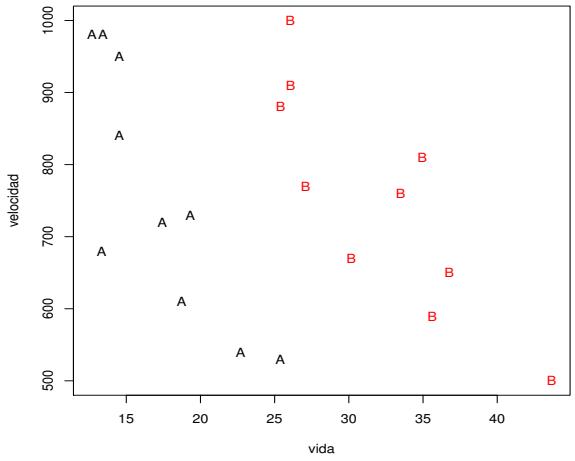


Figura 3.5: Modelo de Ancova.

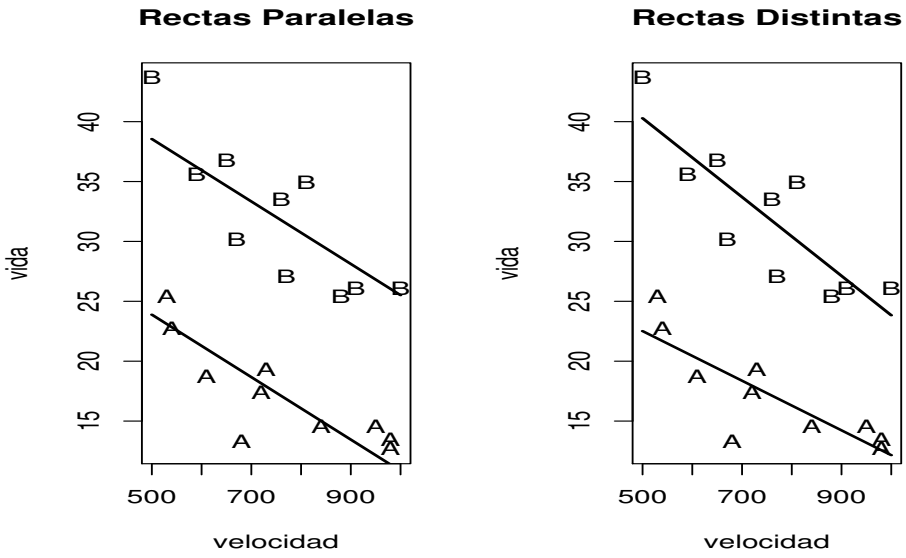


Figura 3.6: Modelo de Ancova.

3.2. Modelización Estadística

Cuando iniciamos un estudio estadístico, conviene definir con precisión la variable estadística y las unidades experimentales involucradas, ya que ambos elementos forman la base del concepto de población.

Una variable estadística es una característica observable (p.e., ingresos mensuales). La población es el conjunto de todas las observaciones que podemos registrar del valor de la variable estadística sobre todas las unidades experimentales de interés (los ingresos mensuales de todos los individuos sobre los que queremos concluir). Los parámetros son características numéricas que sintetizan la información sobre todos los elementos de la población, y que, como las poblaciones mismas, pueden ser conocidos o no (p.e., el ingreso mensual medio de la población, o el porcentaje de individuos en la población con ingresos mensuales superiores a 1000 euros). Una muestra es un subconjunto de la población; cuando es escogida al azar, se denomina muestra aleatoria (los ingresos mensuales de un subconjunto de individuos de la población elegidos al azar). Las muestras aleatorias son la herramienta primaria de la inferencia estadística y el motivo por el cual se puede utilizar la probabilidad para extraer conclusiones sobre la población de interés. Siempre es conveniente en un estudio estadístico sobre una población, garantizar lo máximo posible la representatividad de dicha población de interés en la muestra elegida para estudiar; para ello hay diversos métodos de muestreo (selección) aleatorio, que conviene saber utilizar adecuadamente. El método de muestreo aleatorio más común es el muestreo aleatorio simple, en el que todos los elementos de la población tienen la misma probabilidad de ser seleccionados y además, son seleccionados independientemente. Los estadísticos son características de una muestra y juegan el mismo papel sobre una muestra que los parámetros describiendo a una población (p.e., el ingreso mensual medio de la muestra, o el porcentaje de individuos en la muestra con ingresos mensuales superiores a 1000 euros).

Según Ferrándiz (1994), "la probabilidad está inmersa en el razonamiento científico general, y en particular en el estudio de fenómenos sociales, económicos, biológicos, ya que i) el azar se encuentra presente en muchos procesos, ii) los resultados experimentales u observacionales presentan siempre una cierta vari-

abilidad atribuible a factores no controlados y que varían aleatoriamente y iii) los investigadores utilizan mecanismos de selección aleatoria de unidades experimentales a la hora de diseñar experimentos. Las conclusiones de un análisis estadístico y la fiabilidad de las mismas se formulan en términos probabilísticos. Eso es debido, por un lado a las razones anteriores, y por otro al hecho de que los modelos probabilísticos fundamentan la justificación teórica de la inferencia estadística. Es decir, no hay inferencia estadística sin probabilidad".

Los "modelos estadísticos" son representaciones teóricas matemáticas de sucesos reales manifestables en la observación de fenómenos. Cuando podemos observar un fenómeno que es variable (varía de unos sujetos a otros y en función de ciertas condiciones) y recoger información cualitativa o numérica sobre lo que sucede, podemos emplear la Estadística. La modelización estadística de los datos recogidos nos permitirá representar la realidad de un modo fácil que nos facilite entenderla y predecirla.

El proceso de modelización y análisis estadístico de un banco de datos se puede sintetizar en las siguientes pautas de actuación:

1. Contextualización del problema. Definición de objetivos y variables.

2. Inspección gráfica e identificación de tendencias.

3. Consideración de hipótesis distribucionales y relacionales. Propuesta de modelos.

4. Ajuste y revisión (diagnóstico) de modelos. Comparación y selección del mejor modelo.

5. Valoración de la capacidad predictiva del modelo. Validación.

6. Interpretación y conclusiones.

Si la revisión del modelo nos lleva a descartarlo, será preciso una nueva propuesta, de modo que entraríamos en un bucle entre los puntos (4) y (5), que culminará cuando quedemos satisfechos con el diagnóstico y la validación del modelo.

3.3. Notación

En general, en esta asignatura, dispondremos de una variable respuesta que trataremos de explicar o predecir, y que denotaremos por Y; $y_1, y_2, \ldots, y_n$ serán las observaciones que tenemos en la muestra disponible. Las variables explicativas son aquellas que se utilizan para predecir la respuesta y las notaremos con X_i; asimismo $x_{i1}, x_{i2}, \ldots, x_{in}$ representarán los valores observados en la muestra. Con esta notación, un modelo estadístico lineal tendrá:

- Una componente sistemática, que representa la tendencia general manifestada entre la variable respuesta y sus predictores, esto es, entre lo que se espera observar para Y, $E(Y)$, y las condiciones "ambientales" $X_1, X_2, \ldots, X_{p-1}$:

  $$E(Y) = f(X_1, X_2, \ldots, X_{p-1})$$

  $f()$ será un funcional lineal en los modelos de regresión lineal. En particular, en un modelo de regresión múltiple (más de una variable explicativa), predeciremos la respuesta media a través de una expresión del tipo:

  $$f(X_1, X_2, \ldots, X_{p-1}) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \ldots + \beta_{p-1} X_{p-1}.$$

- Una componente aleatoria, que añade a la tendencia general la variabilidad que proviene de las diferencias entre las unidades de la población, la debida a factores y variables no considerados en el modelo y el error de medida. Dichas diferencias, a las que denominamos errores, ϵ, vendrán modelizadas por una distribución de probabilidad, que determinará las hipótesis distribucionales asumidas sobre la variable respuesta. Así, el modelo completo quedará especificado según:

  $$Y = f(X_1, X_2, \ldots, X_{p-1}) + \epsilon,$$

  con $\epsilon \sim F$, $E(\epsilon) = 0$ y $Var(\epsilon) = Var(Y)$.

Capítulo 4

Análisis de Correlación

4.1. Introducción

Cuando trabajamos en la modelización de una variable respuesta continua (con predictores continuos o categóricos), lo habitual será acudir a modelos de regresión que permitan predecir la primera en función de las restantes variables observadas que estén relacionadas con ella. Sin embargo, previamente a dicha modelización, convendrá llevar a cabo, aparte de la inspección gráfica, un análisis de asociación. Cuando las variables explicativas son de tipo continuo y se estudia si las relaciones son de tipo lineal, dicho análisis se denomina de correlación. Cuando disponemos de una única variable predictora, proponemos como medida de asociación lineal el coeficiente de correlación simple; cuando tenemos varios predictores, hemos de trabajar con los coeficientes de correlación parcial, pues el de correlación simple puede dar lugar a conclusiones engañosas.

4.2. Análisis gráfico de asociación

El primer paso a dar cuando pretendemos modelizar un banco de datos es llevar a cabo una inspección gráfica de los mismos, con el fin de descubrir de qué tipo son las relaciones entre las variables disponibles, si las hay. Básicamente, los gráficos de asociación son de dos tipos:

1. Gráficos de dispersión: sirven para visualizar relaciones entre un par de variables continuas.

2. Gráficos de cajas: sirven para visualizar relaciones entre una variable continua y un factor.

Así, por ejemplo, en la Figura 4.1 hemos representado varios pares de variables observadas. En los gráficos se aprecian distintos tipos de relación, más y menos lineal, entre pares de variables continuas.

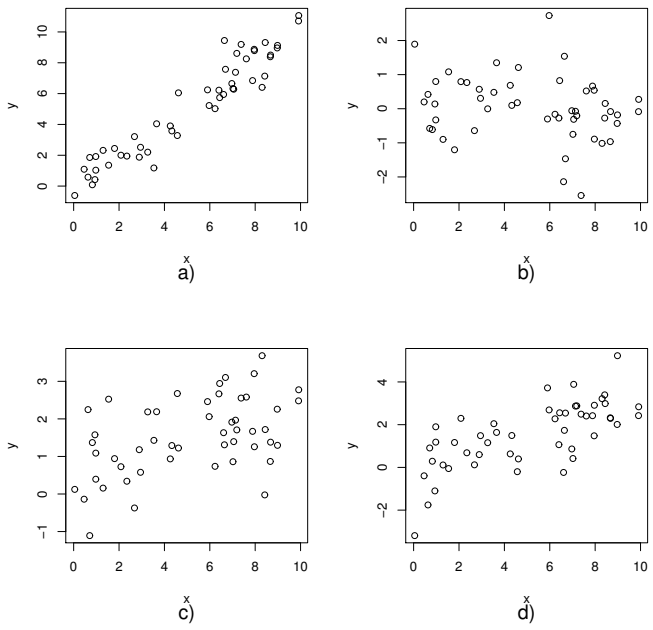


Figura 4.1: Diversos gráficos de dispersión.

Cuando la variable explicativa es de tipo factor (está categorizada), su asociación con la respuesta se detecta al comprobar si provoca diferentes respuestas en los diferentes niveles (categorías) observados. Tales diferencias se aprecian generalmente bien con los gráficos de cajas (boxplot). En los gráficos de cajas, la caja engloba todas las observaciones entre el primer y tercer cuartil; el segundo cuartil (mediana) viene representado por una rayita dentro de la caja. Los bigotes se extienden, generalmente, hasta las observaciones más pequeña y más

grande. Estos gráficos nos dan información sobre la dispersión de los datos respuesta (amplitud de la caja con bigotes, de la caja sola, de los bigotes solos,...), sobre la simetría (en función de que la mediana divida a la caja con bigotes en dos mitades iguales o no, de la desigualdad de las partes de la caja separadas por la mediana, de la desigualdad de los bigotes, ...). Cuando representamos una caja para cada uno de los grupos identificados por una variable factor, tendremos información sobre la diferencia entre dichos grupos en función de que las cajas queden encajadas en un mismo rango de valores, o aparezcan desencajadas a distintas alturas.

En la Figura 4.2 tenemos representadas diversas variables respuesta clasificadas en dos grupos (factor explicativo con dos niveles de clasificación), y encontramos situaciones de clara diferencia entre los grupos (d), hasta semejanzas manifiestas (b) entre ambos.

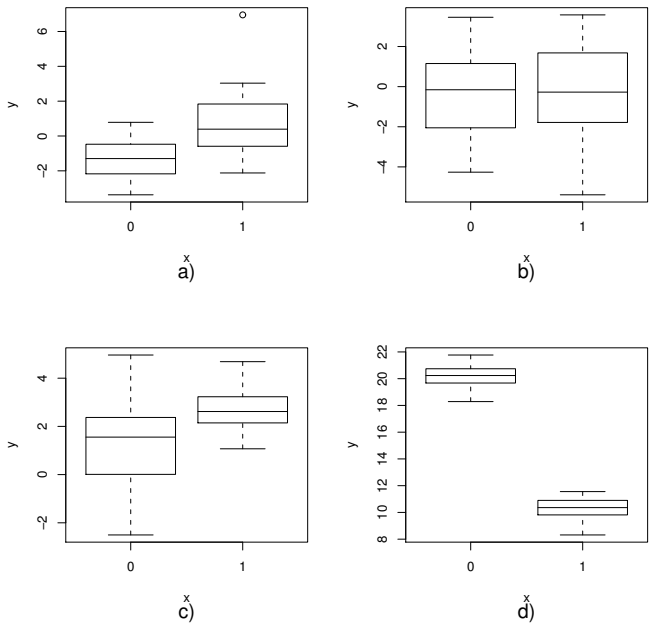


Figura 4.2: Diversos gráficos de cajas.

4.3. Análisis de Correlación

Nos concentramos ahora en el caso de que todas las variables involucradas son de naturaleza continua. Una vez hecha la inspección gráfica de los datos con los correspondientes diagramas de dispersión, hemos de valorar algo más objetivamente si el tipo de asociación se puede catalogar como lineal o no. En ocasiones, aun no apreciándose a priori una relación lineal, es posible transformar los datos con alguna función que linealice la relación. El conseguir una buena linealización del problema será resultado muchas veces de la experiencia acumulada.

Un análisis de correlación nos permitirá cuantificar el grado de asociación lineal entre variables, y en particular, entre las variables explicativas continuas disponibles y la respuesta de interés. Utilizaremos para ello el coeficiente de correlación simple cuando sólo estamos interesados en relacionar una variable explicativa con la respuesta. Cuando el número de variables explicativas sea superior, la medida a usar para medir el grado de asociación lineal será el coeficiente de correlación parcial.

4.4. Correlación Lineal Simple

Comenzamos con el caso más sencillo, en el que consideramos una variable respuesta continua Y observada y una variable explicativa continua X. Un análisis de correlación servirá para poner de manifiesto si existe una relación de tipo lineal entre ambas variables. Otro tipo de relaciones no serán manifiestas a través de la correlación lineal. Si tal relación lineal existe, tenemos la justificación para ajustar un modelo de regresión lineal simple.

Se define el coeficiente de correlación (ρ) de Pearson como:

$$\rho = \frac{Cov(X,Y)}{\sqrt{Var(X)Var(Y)}},$$

donde Var identifica la varianza y Cov la covarianza:

$$Cov(x,y) = E[(x - E(x))(y - E(y))].$$

Dada una muestra $(x_1, y_1), \ldots, (x_n, y_n)$ de dos variables X e Y, se calcula el

coeficiente de correlación lineal simple (r) de Pearson como:

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \sum_{i=1}^{n}(y_i - \bar{y})^2}}, \tag{4.1}$$

Este coeficiente es útil, no sólo para detectar relación lineal entre dos variables continuas, sino también para cuantificar el grado de asociación entre ellas.

Así tenemos que el coeficiente de correlación de Pearson es una medida de asociación lineal libre de escala, con valores comprendidos entre -1 y 1, invariante a transformaciones lineales de las variables. En particular,

- $r = 0 \rightsquigarrow$ nada de asociación (lineal)
- $r = 1$ ó $-1 \rightsquigarrow$ asociación lineal perfecta
- $r < 0 \rightsquigarrow$ correlación negativa: $\uparrow x \Rightarrow \downarrow y$, cuando una aumenta de valor, la otra disminuye
- $r > 0 \rightsquigarrow$ correlación positiva: $\uparrow x \Rightarrow \uparrow y$, cuando una aumenta de valor, la otra también.

Ejemplo 4.1 *[Continuación del Ejemplo 3.1] Investigamos la relación lineal entre el dinero gastado en la manutención de tractores y la edad de los mismos,*

```
# Calculamos la correlación lineal de Pearson:
cor(edad,costes)   #= 0.6906927
```

y obtenemos una correlación lineal de Pearson en principio alta.

Ejercicio 4.1 *Vamos a simular cuatro bancos de datos, compuestos cada uno de observaciones de un par de variables X e Y, más y menos relacionadas linealmente entre sí. En concreto, pretendemos generar observaciones $x_1, x_2, \ldots, x_n$ e $y_1, y_2, \ldots, y_n$, ligadas entre sí con una correlación lineal de: $\rho_1 = 0{,}2$, $\rho_2 = 0{,}8$, $\rho_3 = -0{,}5$ y $\rho_4 = -0{,}99$.*

```
library(mvtnorm)
rho<-c(0.2,0.8,-0.5,-0.99)
datos<-list()
par(mfrow=c(2,2))
for(i in 1:length(rho)){
datos[[i]]<-rmvnorm(50,c(0,0),matrix(c(1,rho[i],rho[i],1),ncol=2))
plot(datos[[i]][,1],datos[[i]][,2],
main=paste("rho=",rho[i]),xlab="X",ylab="Y")
}
```

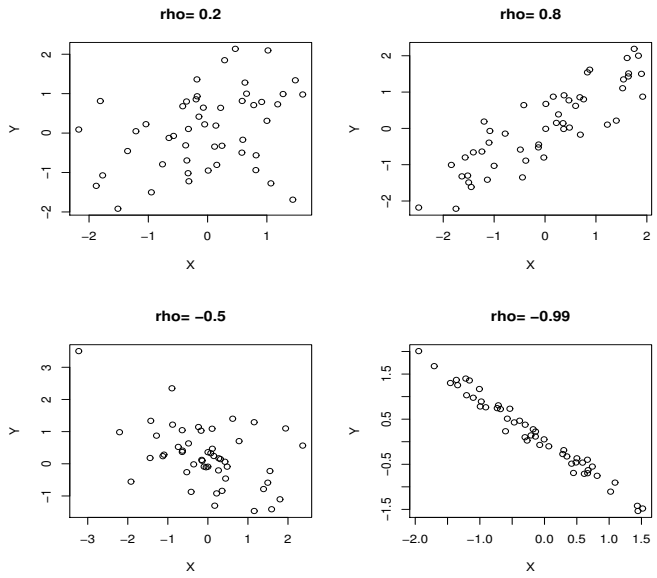


Figura 4.3: Correlación Lineal de Pearson.

Contraste de Hipótesis

Cuando queremos contrastar si dos variables X e Y están relacionadas linealmente, planteamos el contraste:

$$\begin{cases} H_0 & : \rho = 0 \\ H_1 & : \rho \neq 0 \end{cases}$$

Para resolver dicho contraste podemos utilizar el estadístico de la z-transformación de Fisher,

$$Z = arctanh\ r = \frac{1}{2}\, log\left(\frac{1+r}{1-r}\right), \tag{4.2}$$

que se distribuye para muestras moderadas ($n \geq 25$), aproximadamente según una normal $N(arctanh(\rho), 1/(n-3))$.

Sin embargo, generalmente se usa:

$$r_t = r\sqrt{\frac{n-2}{1-r^2}} \sim t_{n-2}, \tag{4.3}$$

de modo que se rechazará H_0 a favor de que ambas variables estén relacionadas linealmente cuando:

$$|r_t| > t_{n-2;1-\alpha/2}.$$

Podríamos pretender también corroborar si la correlación es positiva o negativa, en cuyo caso se plantearían, respectivamente, los contrastes:

$$(CORR+)\begin{cases} H_0 & : \rho = 0 \\ H_1 & : \rho > 0 \end{cases} \qquad (CORR-)\begin{cases} H_0 & : \rho = 0 \\ H_1 & : \rho < 0 \end{cases}$$

cuyas regiones críticas vienen dadas respectivamente por:

$$\begin{aligned} (CORR+) \qquad & r_t > t_{n-2;1-\alpha} \\ (CORR-) \qquad & r_t < t_{n-2;\alpha} = 1 - t_{n-2;1-\alpha}. \end{aligned}$$

Ejemplo 4.2 *[Continuación del Ejemplo 4.1] Queremos saber si es significativa la correlación entre edad del tractor y costes de manutención.*

```
cor.test(edad,costes)
#        Pearson's product-moment correlation
#
#data:  edad and costes
#t = 3.6992, df = 15, p-value = 0.002143
#alternative hypothesis: true correlation is not equal to 0
#95 percent confidence interval:
# 0.3144325 0.8793971
#sample estimates:
#      cor
#0.6906927
```

Aceptamos pues, la alternativa ($H_1 : \rho \neq 0$), lo cual implica que hemos de rechazar correlación nula a favor de reconocer una relación lineal entre ambas variables.

Dado que la correlación es positiva, ¿podemos afirmar estadísticamente (a un nivel de confianza del 99 %) que existe una relación directa entre edad y costes, esto es, a más edad del tractor, mayores costes de manutención?

```
cor.test(edad,costes,alternative="greater",conf.level=0.99)
#        Pearson's product-moment correlation
#
#data:  edad and costes
#t = 3.6992, df = 15, p-value = 0.001071
#alternative hypothesis: true correlation is greater than 0
#99 percent confidence interval:
# 0.2236894 1.0000000
#sample estimates:
#      cor
#0.6906927
```

La respuesta es claramente que sí.

4.5. Transformaciones para conseguir linealidad

Para comprobar linealidad entre las variables, tan importante es la inspección gráfica de los datos como el análisis de correlación. De hecho, este último puede resultar engañoso en ocasiones. Como ejemplo, observemos la Figura 4.4, donde aparecen cuatro bancos de datos (accesibles en el Apéndice), todos ellos con correlación alta y significativamente distinta de cero, pero no todos con una relación lineal manifiesta, como en los bancos 'datos1', 'datos2' y algo en 'datos4'.

Una vez investigada la relación lineal entre la variable respuesta y la explicativa, si ésta falla, y antes de abordar la modelización, es recomendable considerar la posibilidad de realizar alguna transformación sobre las variables con el fin de linealizar la relación. Elegir una transformación apropiada es fruto de la experiencia que se va adquiriendo en el análisis de datos. Transformaciones habituales son los logaritmos (especialmente útiles cuando la escala de medida tiene un rango muy grande), exponenciales, raíces, ... Con todo, en la Figura 4.5 hemos ilustrado algunas funciones que nos pueden ayudar a decidir qué transformaciones abordar

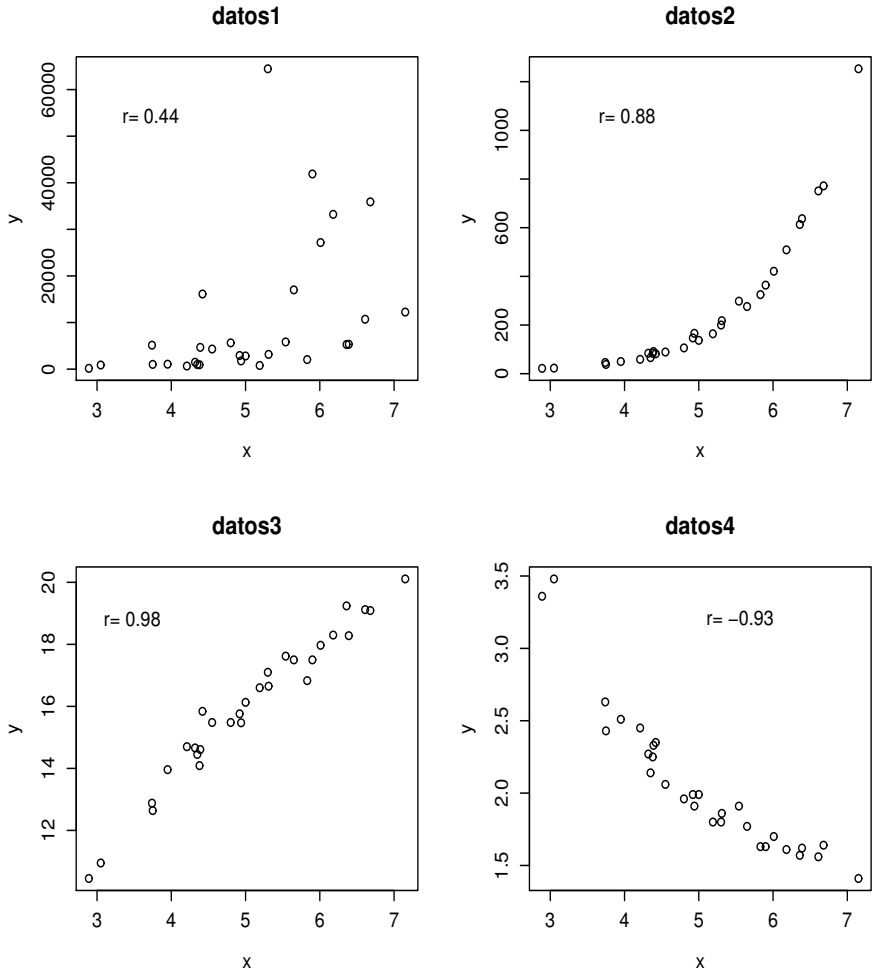


Figura 4.4: Transformaciones para conseguir linealidad.

con el fin de obtener un par de variables relacionadas linealmente y sobre las que formular un modelo lineal.

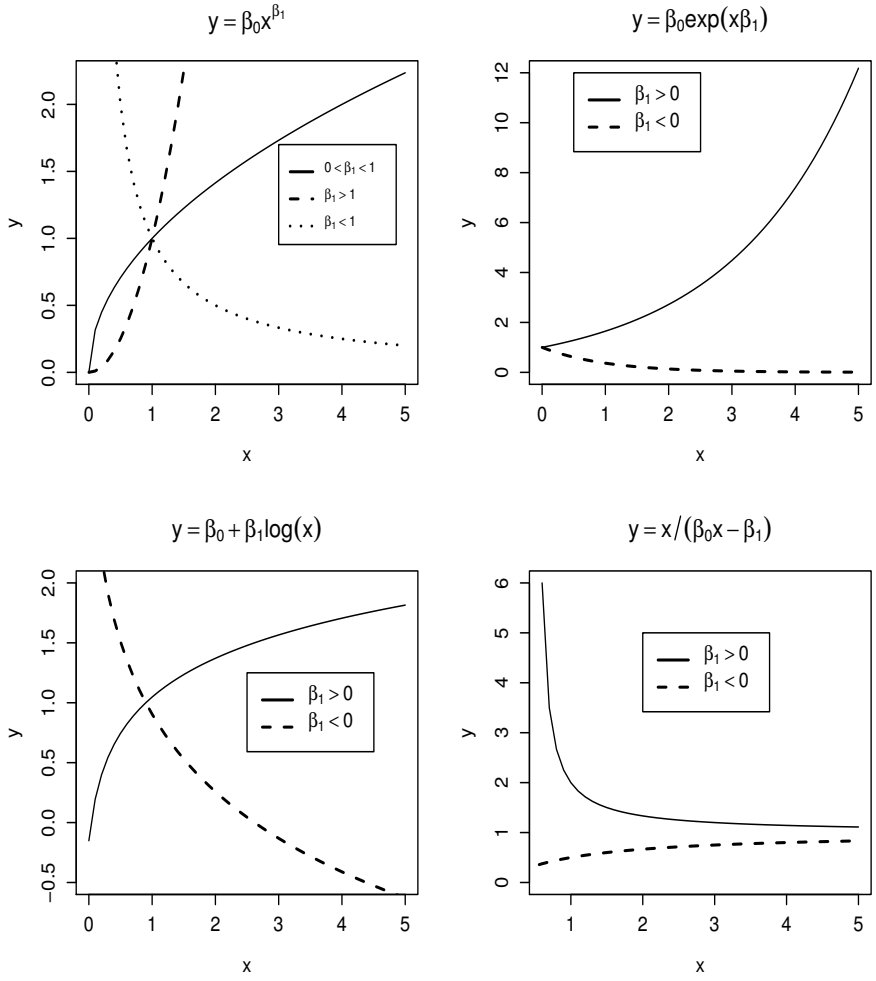


Figura 4.5: Relaciones linealizables.

Ejercicio 4.2 *Para las situaciones ilustradas en la Figura 4.5 sobre la relación entre un par de variables* x *e* y*, expresada en términos de la relación analítica correspondiente, formula transformaciones apropiadas para conseguir linealidad (de Montgomery y Peck, 1992, pag.90).*

Ejercicio 4.3 *Para las situaciones ilustradas en la Figura 4.4, vamos a contrastar correlación lineal y proponer transformaciones que linealicen la relación entre las variables cuando resulte necesario.*

```
# Para el banco 'datos1'
cor.test(x,y1)  # cor = 0.44126, p-valor = 0.01465
plot(log(x),log(y1))
cor.test(log(x),log(y1)) # cor=0.697845, p-valor =1.813e-05
text(locator(1),paste("r=",round(cor(log(x),log(y1)),3)))

# Para el banco 'datos2'
cor.test(x,y2)  # cor=0.8765235, p-valor=2.171e-10
plot(x,log(y2))
cor.test(x,log(y2))  # cor=0.9962347, p-valor<2.2e-16
text(locator(1),paste("r=",round(cor(x,log(y2)),3)))

# Para el banco 'datos3'
cor.test(x,y3)
plot(x,y3)
# La linealidad es bastante patente

# Para el banco 'datos4'
cor.test(x,y4)  # cor=0.979048, p-valor<2.2e-16
plot(1/x,y4)
cor.test(1/x,y4)    # cor=0.9815995, p-valor<2.2e-16
text(locator(1),paste("r=",round(cor(1/x,y4),3)))
```

4.6. Correlación Múltiple y Parcial

Se define el coeficiente de correlación múltiple muestral $r_{1\ldots k}$ para k variables explicativas como aquel que cuantifica el grado de relación lineal existente entre una variable respuesta y el conjunto de esas k variables explicativas. Si S representa la matriz de covarianzas entre todas las variables involucradas, el coeficiente de correlación múltiple se obtiene como:

$$r_{1\ldots k} = \frac{\left\{S_{12}S_{22}^{-1}S_{21}\right\}^{1/2}}{S_{11}^{1/2}}, \tag{4.4}$$

con S_{11} la parte de la matriz S correspondiente a la variable respuesta, S_{22} la parte de la matriz S correspondiente a las variables explicativas, S_{12} la parte de la

matriz S que corresponde a las covarianzas entre la respuesta y las explicativas, y S_{21} la traspuesta de la anterior, $S_{21} = S'_{12}$.

Podemos además, realizar el contraste para verificar si el conjunto de variables explicativas está relacionado lineal y significativamente con la respuesta,

$$H_0 : \rho_{1\ldots k} = 0, \quad H_1 : \rho_{1\ldots k} \neq 0,$$

para lo que se define como estadístico de contraste:

$$\frac{(n-k-1)r^2_{1\ldots k}}{k(1-r^2_{1\ldots k})} \sim F_{k,n-k-1}, \tag{4.5}$$

Ejemplo 4.3 *[Continuación del Ejemplo 3.2] En el Ejemplo que propusimos de regresión múltiple, teníamos como variable respuesta el volumen de madera y como variables explicativas diversas medidas sencillas del árbol.*

¿El conjunto de variables explicativas consideradas, está relacionado linealmente con la respuesta?

```
# Utilizamos la función rho.mult() del Apéndice.
rho.mult(bosque)   #=0.9793152
```

La correlación múltiple es pues significativamente distinta de 0, lo que da claros indicios de una relación lineal entre el conjunto de variables explicativas observadas y el volumen de madera producido.

La siguiente pregunta a hacer es cuál de las variables explicativas guarda más relación lineal con la respuesta. Para contestarla hemos de acudir al coeficiente de correlación parcial.

Se define el coeficiente de correlación parcial muestral entre una variable respuesta y una explicativa, dado un bloque adicional de variables explicativas, como aquel que cuantifica el grado de relación lineal existente entre las dos primeras considerando (descontando) la relación (lineal) entre ambas y el bloque de variables adicionales. Su utilidad es decisiva para el ajuste de modelos de regresión múltiple, en los que contamos con un grupo de variables explicativas a incorporar en el modelo de predicción. La correlación simple entre una variable explicativa y la respuesta sólo da información sobre la relación entre ellas, obviando toda

relación con otras variables. La correlación parcial aísla la parte de las variables respuesta y explicativa que no está relacionada linealmente con las otras variables explicativas y da información sobre si dichos restos están relacionados linealmente, esto es, si la covariable en cuestión aporta algo de información (lineal) adicional sobre la respuesta, que no hayan aportado las otras variables.

El coeficiente de correlación parcial lo denotamos por:

$$r_{y.k|(-k)},$$

donde k identifica la variable explicativa cuya relación con la respuesta queremos conocer, X_k, y $(-k)$ identifica el bloque de variables restantes cuya relación con la respuesta descontamos, X_{-k}.

El coeficiente de correlación parcial se calcula a partir de la matriz de covarianzas S según:

$$r_{y.k|(-k)} = \frac{[S_{11,2}]_{yl}}{[S_{11,2}]_{yy}^{1/2}\,[S_{11,2}]_{ll}^{1/2}},$$

con $S_{11,2} = S_{11} - S_{12}S_{22}^{-1}S_{21}$, donde S_{11} es la parte de la matriz S correspondiente a la variable respuesta Y y la explicativa de interés, X_k, S_{22} es la parte de la matriz S correspondiente a las variables explicativas restantes (X_{-k}), y S_{12} es la parte de S que corresponde a las covarianzas entre los bloques (Y, X_k) y X_{-k}.

A continuación podemos realizar el contraste sobre la correlación parcial,

$$H_0 : \rho_{y.l|(q+1,\ldots,k)} = 0, \quad H_1 : \rho_{y.l|(q+1,\ldots,k)} \neq 0,$$

con el estadístico de contraste:

$$\frac{(n-(k-q)-1)^{1/2} r_{y.k|(-k)}}{1 - r_{y.k|(-k)}^2} \sim t_{n-(k-q)-1}, \tag{4.6}$$

Ejemplo 4.4 *[Continuación del Ejemplo 4.3]*

Queremos identificar qué covariables están más relacionadas linealmente con la respuesta (VOL) en presencia de las restantes. Para ello podemos calcular todas las correlaciones parciales entre la respuesta y las covariables, en la primera fila (columna) de la siguiente matriz:

```
library(ggm)
parcor(cov(bosque))
#          VOL        DBH        D16         HT
#   VOL 1.0000000  0.3683119  0.7627127  0.7285511
```

Esto es,

$$r_{y.DBH|-DBH} = 0{,}3683119, \quad r_{y.D16|-D16} = 0{,}7627127, \quad r_{y.HT|-HT} = 0{,}7285511,$$

de modo que D16 es la covariable más relacionada linealmente con VOL en presencia de las restantes, y DBH la que menos. Eso significa que, cuando consideremos todas las covariables observadas y especifiquemos un modelo de predicción con regresión múltiple, DBH será la que menos explique sobre el volumen de madera producido.

Por contra, si simplemente observábamos las correlaciones simples:

```
cor(bosque)
#           VOL       DBH       D16        HT
#   VOL 1.0000000 0.9078088 0.9530963 0.6010862
```

$$r_{y,DBH} = 0{,}9078088, \quad R_{y,DB16} = 0{,}9530963, \quad r_{y,HT} = 0{,}6010862$$

obteníamos que la respuesta VOL parecía muy relacionada linealmente con DBH. Esto se produce a consecuencia de que aquí no tenemos en cuenta a las restantes variables. De hecho, VOL y DBH están muy relacionadas linealmente con el bloque (DB16,HT), como indican sus correlaciones múltiples:

```
#  La correlación múltiple entre VOL y (DB16,HT) es
rho.mult(bosque[,-2])   #=0.976029
# y entre DBH y (DB16,HT)
rho.mult(bosque[,-1])   #=0.9267678,
```
valores claramente altos y ambos significativos.

Si queremos calcular exclusivamente la correlación parcial entre un par de variables, considerando su relación con un conjunto de variables fijas, podemos utilizar el comando `pcor()`*, también en la librería* `ggm` *de R.*

```
pcor(1:4,cov(bosque))  # VOL versus DBH, dado el resto
pcor(c(1,3,2,4),cov(bosque))  # VOL versus D16, dado el resto
```

Resultado 4.1 *Si Y y X_k son ambas independientes del bloque de variables X_{-k}, entonces el coeficiente de correlación parcial $r_{y.k|(-k)}$ es igual al coeficiente de correlación simple $r_{y,k}$.*

Ejercicio 4.4 *Pretendemos corroborar la afirmación del Resultado 4.1. Para ello vamos a simular un banco de datos con tres variables Y, X_1, X_2, tales que X_2 sea independiente de Y y de X_1. Calcularemos $r_{y,1|-1}$ y $r_{y,1}$, para verificar que son muy similares, esto es, que en ese caso coinciden los coeficientes de correlación parcial y simple.*

```
# Construimos la matriz de covarianzas para (Y,X1,X2),
#con X2 independiente de Y y de  X1:
cov.mat<-matrix(c(1,0.8,0,0.8,1,0,0,0,1),ncol=3)

# simulamos 50 datos:
datos<-rmvnorm(50,mean=c(0,0,0),sigma=cov.mat)
# calculamos la correlación parcial entre Y y X1
pcor(1:3,cov(datos))    #=0.7540396
# y la correlación simple
cor(datos[,1],datos[,2])    #=  0.7532037
# que salen claramente similares.

# La función correlations(), en la librería ggm,
# proporciona a la vez correlaciones parciales
# (en el triángulo superior) y simples
# (en el triángulo inferior)
correlations(cov(datos))
```

4.7. Resumen

Hemos estudiado básicamente en este tema el modo de descubrir asociaciones lineales entre variables de tipo continuo. Una vez ratificada la linealidad, tendremos la justificación adecuada para formular un modelo de predicción lineal. Cuando algún predictor es categórico, los gráficos de cajas nos ayudan a discernir si la clasificación que proporciona dicha variable afecta a la respuesta.

Un análisis de correlación debería constituir la primera aproximación a los datos de naturaleza continua cuando nos planteamos su modelización. El análisis

de correlación consta de dos partes:

- Inspección gráfica de los datos: gráficos de dispersión.
- Análisis de correlación propiamente dicho, que consiste en el cálculo de las correlaciones y la realización de los contrastes pertinentes.

De hecho, ambas partes son imprescindibles, pues sólo utilizar una de ellas para ratificar linealidad y atreverse a formular un modelo lineal, puede ser peligroso en ocasiones.

Cuando tan sólo disponemos de dos variables y queremos descubrir si están relacionadas linealmente, hemos de utilizar el coeficiente de correlación simple de Pearson.

Cuando tenemos una variable respuesta y varias covariables continuas, hemos de inspeccionar la relación de todas ellas respecto de la respuesta, tanto individual como conjuntamente. Especialmente cuando las covariables guardan algo de relación entre sí, la correlación simple puede proporcionar resultados engañosos respecto de la linealidad existente entre cada una de ellas con la respuesta. El coeficiente de correlación múltiple permite dar una medida global de la relación lineal que existe entre todo el conjunto de covariables y la respuesta. El coeficiente de correlación parcial proporciona información sobre la linealidad entre la respuesta y una covariable en presencia de las restantes variables explicativas.

Ante problemas de linealidad, y antes de abordar una modelización lineal, conviene intentar linealizar mediante alguna transformación de las variables originales.

4.8. Ejercicios

1. Simula y representa apropiadamente las siguientes propuestas de datos. Concluye sobre el tipo de tendencia/relación apreciada.

   a) $\mathrm{x} \sim Bi(40, 0{,}6)$ e $\mathrm{y} \sim N(1 + 2\mathrm{x}, 2)$

   b) $\mathrm{x} \sim Ber(0{,}6)$ e $\mathrm{y} \sim N(1 + 2\mathrm{x}, 2)$

c) x $\sim Bi(40, 0{,}6)$ e y $\sim N(1 + 2log(\mathrm{x}), 3)$

d) x $\sim Un(0, 1)$ e y $\sim N(1 + 2exp(\mathrm{x}), 2)$

e) x $\sim Ber(0{,}6)$, z $\sim Un(0, 4)$ e y $\sim N(1 + 2\mathrm{zx}, 2)$

f) x $\sim Ber(0{,}6)$, z $\sim Un(0, 4)$ e y $\sim N(1 + 2\mathrm{x}\sqrt{\mathrm{z}}, 2)$

2. Para las situaciones presentadas en la Figura 4.6, sabemos que los coeficientes de correlación muestrales son $-0{,}85; -0{,}38; -1; 0{,}06; 0{,}97; 0{,}62$. Identifica cada coeficiente con el gráfico que corresponde.

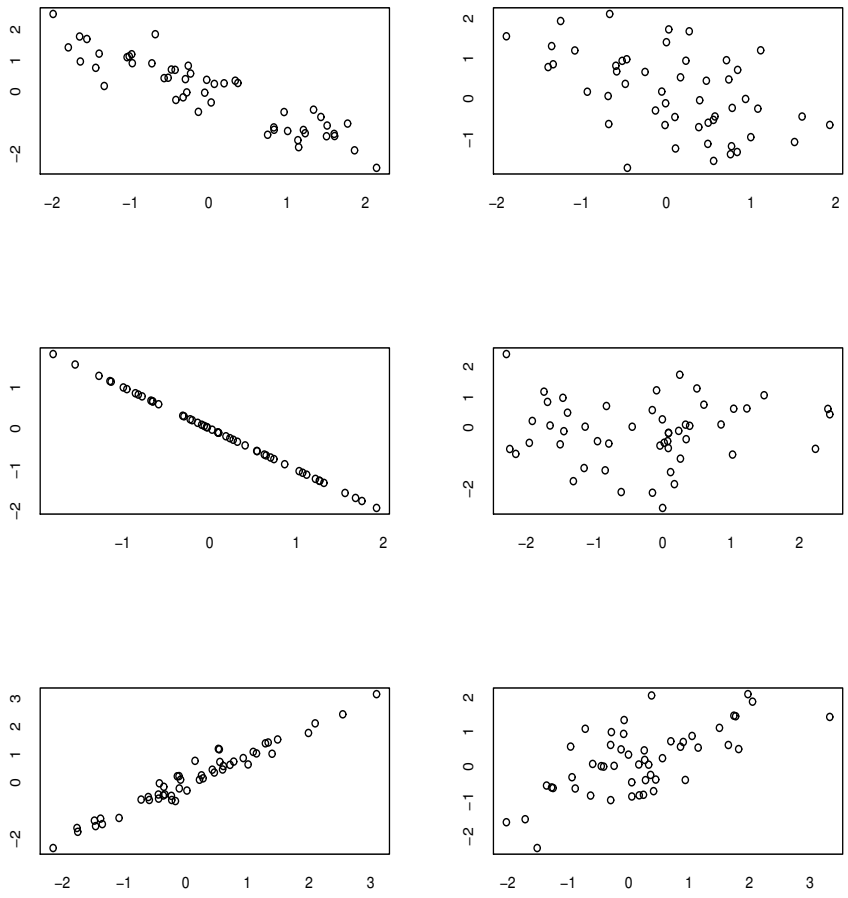


Figura 4.6: Correlación lineal.

Capítulo 5

El Modelo de Regresión Lineal Simple (RLS)

5.1. Introducción

En el Tema anterior nos referíamos al análisis de correlación como un paso previo a la modelización, útil para verificar relaciones lineales entre las variables. Pues bien, cabe resaltar aquí que, cuando uno lleva a cabo un análisis de correlación, no necesita tener clara la distinción entre variables respuesta y explicativas; simplemente se indaga la relación entre las variables y se concluye sobre si es lineal o no. Cuando uno pretende modelizar, ha de especificar, en base a los objetivos del estudio, cuál es la variable que pretende explicar o predecir y cuáles son las que le van a ayudar a hacerlo, bien porque sean causas o simplemente porque estén relacionadas con la primera y contengan información relevante para poder predecirla.

Nos preocupamos en este tema del Modelo de Regresión Lineal Simple (RLS), que podemos catalogar como el modelo lineal más sencillo. Tan sólo tenemos una variable respuesta Y que pretendemos predecir en función de una única variable continua explicativa X. La variable Y se denomina variable *dependiente* o *respuesta*. La variable X recibe el nombre de variable *independiente*, *regresora*, *explicativa* o *predictora*. Por supuesto, asumimos que existe una relación lineal entre ellas que intentamos predecir a través de una *recta de regresión*.

En el experimento o estudio del que obtenemos los datos, los valores de Y se han observado y los de X, bien se han observado, bien se han prefijado por parte del investigador. En cualquier caso, asumimos que la aleatoriedad (incertidumbre) está contenida sólo en la variable Y, mientras que la X carece de aleatoriedad y simplemente informa de lo que ocurre en los valores observados.

5.2. ¿Por qué el nombre de Regresión?

Como ya comentamos en el Tema 1, a principios del siglo XX, el estudioso de la genética Francis Galton descubrió un fenómeno llamado regresión a la media. Buscando leyes de herencia genética, descubrió que la estatura de los hijos solía ser una regresión a la estatura media poblacional, en comparación con la estatura de sus padres. Los padres altos solían tener hijos algo más bajos, y viceversa. Galton desarrolló el análisis de regresión para estudiar este fenómeno, al que se refirió de manera optimista como "regresión a la mediocridad".

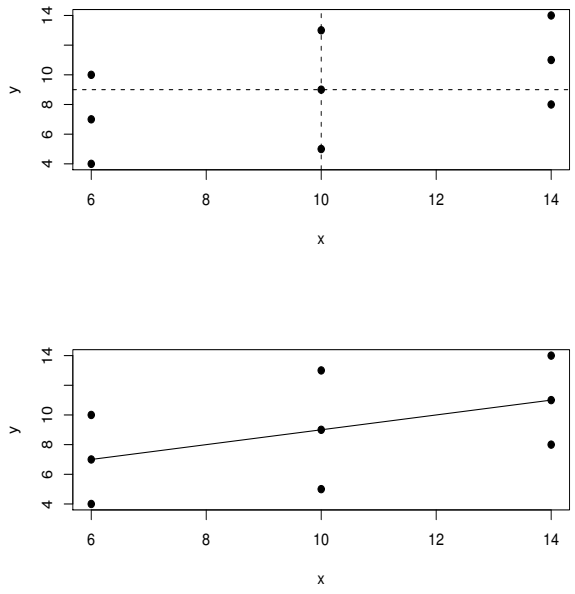


Figura 5.1: Regresión a la media.

Con el fin de mostrar fácilmente en qué consiste la recta de regresión, consi-

deremos los puntos representados en el gráfico superior de la Figura 5.1. Tenemos una serie de 9 observaciones de pares (x_i, y_i); en concreto, tan sólo tenemos tres valores fijos de la variable X. Para cada valor de X, hemos observado tres valores de Y, curiosamente equidistantes, de forma que el punto medio representa la media de los valores Y observados. La tendencia lineal se aprecia claramente en el gráfico. A la hora de ajustar una recta de regresión para captar dicha tendencia, la recta atravesará los puntos pasando por los puntos medios (regresión a la media), como se ilustra en el gráfico inferior de la Figura 5.1.

5.3. Formulación del modelo RLS

El modelo de Regresión lineal Simple de Y sobre X se formula según:

$$Y = \beta_0 + \beta_1 X + \epsilon, \tag{5.1}$$

donde ϵ representa, para un valor dado de $X = x$, una desviación aleatoria de la respuesta Y sobre el valor esperado según la recta de regresión

$$E(Y|X = x) = \beta_0 + \beta_1 x. \tag{5.2}$$

Dada una muestra de valores observados $\{(x_i, y_i)\}_{i=1}^n$, el modelo (5.1) significa que todas las observaciones responden a:

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i, \qquad i = 1, \ldots, n,$$

donde ϵ_i son errores aleatorios e incorrelados, con media cero y varianza constante σ^2.

5.4. Hipótesis Básicas del modelo RLS

Las hipótesis básicas del modelo de regresión lineal simple son las que formulamos sobre los errores aleatorios ϵ_i:

Incorrelación: $Corr(\epsilon_i, \epsilon_j) = 0$**.** Significa que las observaciones de la respuesta Y, $y_1, y_2, \ldots, y_n$ están incorreladas entre sí, esto es, los valores de unas no afectan a los de otras.

Media cero: $E(\epsilon_i) = 0$**.** Lo que implica que la respuesta esperada según el modelo RLS depende linealmente de los coeficientes de regresión β_0 y β_1, al tener como expresión (5.2).

Varianza constante: $Var(\epsilon_i) = \sigma^2$**.** Lo que significa que las observaciones $\{y_i, i = 1, \ldots, n\}$ provienen de una misma población cuya variabilidad respecto de sus medias $\{\beta_0 + \beta_1 x_i, i = 1, \ldots, n\}$ viene dada por σ^2.

Los coeficientes de la regresión, esto es, los parámetros que estimaremos para ajustar el modelo RLS son:

β_0**.-** la interceptación de la recta, esto es, la altura de la recta cuando $x = 0$.

β_1**.-** la pendiente de la recta, que refleja cuánto varía Y cuando en lugar de observar $X = x$, observamos $X = x + 1$.

5.5. Estimación de la recta de regresión

Estimar la recta de regresión consiste en estimar los coeficientes de la regresión, β_0 y β_1 para obtener la recta:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x. \tag{5.3}$$

Disponemos de dos criterios básicos de estimación, que proporcionan la misma solución. Utilizar uno u otro depende de nuestros intereses estadísticos. Si tan sólo queremos determinar la recta, basta con considerar el criterio de *Mínimos Cuadrados*. Si además pretendemos utilizarla con fines predictivos, hablaremos de que nuestra solución es la *máximo-verosímil*.

Criterio 1: Mínimos Cuadrados o minimización del error cuadrático medio. Consiste en minimizar las distancias entre los puntos observados y los predichos por la recta de ajuste, como se ilustra en la Figura 5.2. El error cuadrático medio de la recta se define como:

$$S(\beta) = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 = \sum_{i=1}^{n} [y_i - (\beta_0 + \beta_1 x_i)]^2 \tag{5.4}$$

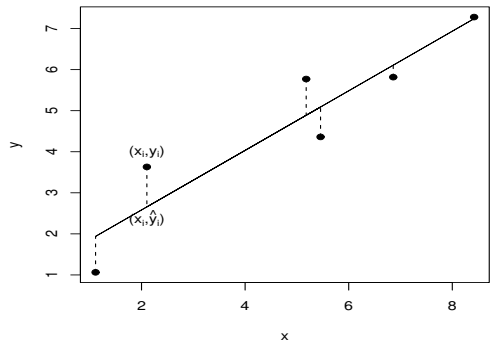


Figura 5.2: Mínimos cuadrados en regresión.

La solución de mínimos cuadrados $\hat{\beta} = (\hat{\beta}_0, \hat{\beta}_1)$ se obtiene maximizando $S(\beta)$, esto es, derivando respecto de β_0 y β_1 e igualando a cero:

$$\begin{aligned} \frac{\partial S(\beta)}{\partial \beta_0} \mid_{\hat{\beta}_0, \hat{\beta}_1} &= -2 \sum_{i=1}^{n} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \\ \frac{\partial S(\beta)}{\partial \beta_1} \mid_{\hat{\beta}_0, \hat{\beta}_1} &= -2 \sum_{i=1}^{n} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) x_i = 0. \end{aligned} \tag{5.5}$$

De ahí se obtienen las *ecuaciones normales*:

$$\begin{aligned} n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^{n} x_i &= \sum_{i=1}^{n} y_i \\ \hat{\beta}_0 \sum_{i=1}^{n} x_i + \hat{\beta}_1 \sum_{i=1}^{n} x_i^2 &= \sum_{i=1}^{n} y_i x_i \end{aligned} \tag{5.6}$$

de donde se resuelven las estimaciones para β_0 y β_1:

$$\begin{aligned} \hat{\beta}_0 &= \bar{y} - \hat{\beta}_1 \bar{x} \\ \hat{\beta}_1 &= \frac{S_{xy}}{S_{xx}}, \end{aligned} \tag{5.7}$$

con:

$$\bar{y} = \sum_{i=1}^{n} y_i/n \qquad \bar{x} = \sum_{i=1}^{n} x_i/n$$

$$S_{xx} = \sum_{i=1}^{n} (x_i - \bar{x})^2 \qquad S_{xy} = \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y}).$$

Ejemplo 5.1 *Obtener el ajuste de mínimos cuadrados para los datos del Ejemplo 3.1.*

```
x<-edad; y<-costes
mc<-lsfit(x,y)$coefficients;mc
plot(x,y)
abline(a=mc[1],b=mc[2])
```

Ejercicio 5.1 *Queremos verificar que, cuando la correlación entre un conjunto de valores x y otro y es fija, tenemos que:*

- *a mayor dispersión de las y's, mayor pendiente de la recta,*
- *a mayor dispersión de los x's, menor pendiente de la recta.*

Para ello, simulamos tres bancos de datos normales bivariantes $\{(x_i, y_i), i = 1, \ldots, 50\}$ con correlación 0.7, tales que:

B1 $Var(X) = 1 = Var(Y)$
B2 $Var(X) = 1$, $Var(Y) = 5$
B3 $Var(X) = 5$, $Var(Y) = 1$

Ajustamos rectas de regresión y las representamos sobre los gráficos de dispersión para apreciar el efecto sobre la pendiente (ver Figura 5.3)

```
library(mvtnorm)
rho<-0.7    # correlación
mu<-c(0,0)  # media

# Función para calcular la matriz de varianzas-covarianzas
# a partir de varianzas y correlación.
varcovar<-function(vx,vy,rho){
covar<-rho*sqrt(vx*vy)  # covarianza (X,Y)
sigma<-matrix(c(vx,covar,covar,vy),nrow=2)
return(sigma)
}

# Simulamos los datos y ajustamos una recta de regresión
b1<-rmvnorm(50,mu,varcovar(1,1,rho)); fit1<-lsfit(b1[,1],b1[,2])
b2<-rmvnorm(50,mu,varcovar(1,5,rho)); fit2<-lsfit(b2[,1],b2[,2])
b3<-rmvnorm(50,mu,varcovar(5,1,rho)); fit3<-lsfit(b3[,1],b3[,2])

#  Dibujamos dicha recta sobre los gráficos de dispersión
# para apreciar cómo cambia la pendiente:
par(mfrow=c(2,2))
plot(b1,xlim=c(-5,5),ylim=c(-5,5),xlab="X",ylab="Y",
main="Var(X)=1,Var(Y)=1")
abline(a=coef(fit1)[1],b=coef(fit1)[2])
plot(b2,xlim=c(-5,5),ylim=c(-5,5),xlab="X",ylab="Y",
main="Var(X)=5,Var(Y)=5")
abline(a=coef(fit2)[1],b=coef(fit2)[2])
plot(b1,xlim=c(-5,5),ylim=c(-5,5),xlab="X",ylab="Y",
main="Var(X)=1,Var(Y)=1")
abline(a=coef(fit1)[1],b=coef(fit1)[2])
plot(b3,xlim=c(-5,5),ylim=c(-5,5),xlab="X",ylab="Y",
main="Var(X)=1,Var(Y)=5")
abline(a=coef(fit3)[1],b=coef(fit3)[2])
```

Criterio 2: Máxima Verosimilitud**.** Habitualmente el objetivo de un análisis de regresión no consiste únicamente en estimar la recta, sino en *inferir* con ella, esto es, asociar un error a las estimaciones obtenidas, contrastar un determinado valor de los parámetros, o predecir la respuesta para un x dado junto con una banda de confianza. Entonces precisamos de distribuciones de probabilidad para controlar la incertidumbre. Añadimos pues, una hipótesis más sobre la distribución de la variable respuesta, o lo que es lo mismo, sobre el error aleatorio

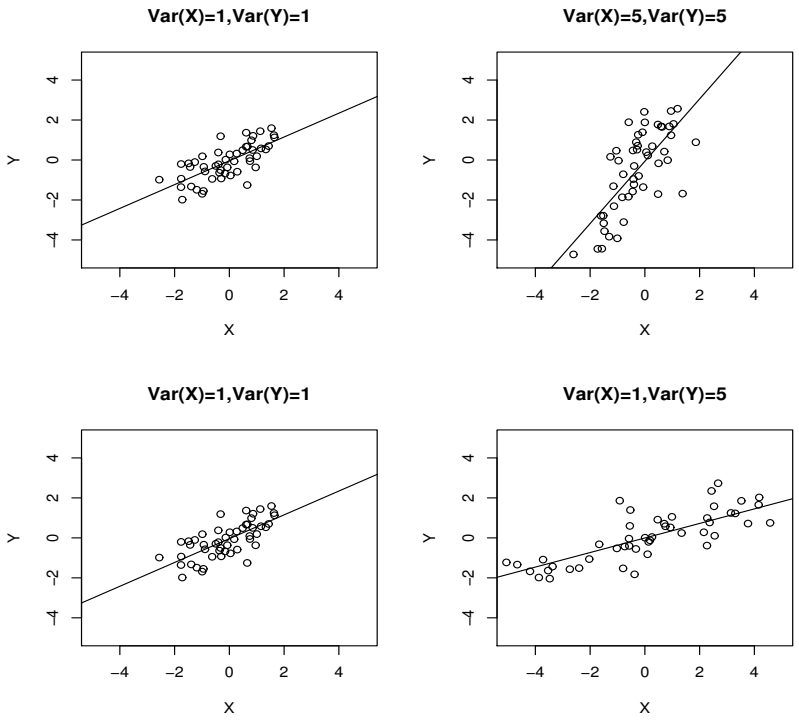


Figura 5.3: Influencia de la dispersión de las variables sobre la inclinación de la recta de regresión

ϵ. Dicha hipótesis es la de normalidad de los errores.

Así, el total de hipótesis básicas del modelo de regresión con fines inferenciales, viene resumido en la siguiente expresión:

$$\epsilon_i \overset{iid}{\sim} N(0, \sigma^2), \qquad i = 1, \ldots, n. \tag{5.8}$$

esto es, hablamos de errores aleatorios independientes e idénticamente distribuidos (iid) según una distribución Normal con media cero y varianza σ^2, lo que implica directamente que la distribución para la variable respuesta será:

$$Y_i \overset{iid}{\sim} N(\beta_0 + \beta_1 x_i, \sigma^2), \qquad i = 1, \ldots, n.$$

Desde este momento, los datos proporcionan información sobre los parámetros del modelo, $\beta = (\beta_0, \beta_1)$, a través de la verosimilitud conjunta:

$$L(\beta; \bar{y}) = exp\left\{ -\frac{\sum_{i=1}^{n}(y_i - \beta_0 - \beta_1 x_i)^2}{2\sigma^2} \right\}. \tag{5.9}$$

Obtener la solución más factible a la vista de los datos observados $\{(x_i, y_i), i = 1, \ldots, n\}$ equivale a obtener la solución máximo-verosímil, esto es, la que maximiza la verosimilitud (5.9). Puesto que maximizar la verosimilitud es equivalente a maximizar la log-verosimilitud $l(\beta, \bar{y})$, y ésta tiene una expresión más sencilla al eliminar la exponencial, la solución máximo-verosímil se obtiene derivando e igualando a cero la log-verosimilitud. Se obtienen así las ecuaciones normales (5.6), de donde resulta que la solución máximo-verosímil coincide con la de mínimos cuadrados (5.7)

Ejemplo 5.2 *Obtener el ajuste por máxima verosimilitud para los datos del Ejemplo 3.1.*

```
x<-edad; y<-costes
emv<-lm(y~x)$coefficients;emv
plot(x,y)
abline(a=emv[1],b=emv[2])
```

Ejercicio 5.2 *Comprobar, manualmente a partir de la expresión para la log-verosimilitud, que la estimación máximo-verosímil conduce a las ecuaciones normales* (5.6)*. Para ello, derivar e igualar a cero la log-verosimilitud.*

5.6. Propiedades del ajuste de la recta de regresión.

Las propiedades más relevantes y básicas del ajuste de la recta de regresión son las siguientes:

1. Las estimación de la respuesta para un valor de $X = x$ concreto según el modelo de regresión lineal simple (5.1) se obtiene de la recta de regresión ajustada:
$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x. \tag{5.10}$$

2. La suma de los residuos de una recta de regresión con término de interceptación β_0 es cero,
$$e_i = y_i - \hat{y} \rightsquigarrow \sum_i e_i = 0.$$

3. La media de los valores observados y_i coincide con la media de los valores predichos $\hat{y}_i$,
$$\frac{1}{n}\sum_i y_i = \frac{1}{n}\sum_i \hat{y}_i. \tag{5.11}$$

4. La recta de regresión pasa por el centroide de medias $(\bar{x}, \bar{y})$.

5. La suma de los residuos ponderados por el valor correspondiente de la variable predictora X es cero,
$$\sum_i x_i e_i = 0.$$

6. La suma de los residuos ponderados por el valor ajustado por la recta $\hat{Y}$ es cero,
$$\sum_i \hat{y}_i e_i = 0.$$

5.7. Estimación de σ^2.

La varianza σ^2 es una medida de la variabilidad (heterogeneidad) entre los individuos cuando el modelo RLS describe adecuadamente la tendencia entre las variables Y y X. Cuando el modelo de regresión (5.1) es bueno, es posible conseguir una estimación de la varianza σ^2 a partir de la *suma de cuadrados residual* SSE, también llamada *suma de cuadrados debida al error*:

$$SSE = \sum_i (y_i - \hat{y}_i)^2 = S_{yy} - \hat{\beta}_1 S_{xy}.$$

SSE da una medida de la desviación entre las observaciones y_i y las estimaciones que proporciona la recta de regresión (5.10), $\hat{y}_i$. Puesto que en el modelo de regresión lineal simple se estiman 2 parámetros, los grados de libertad asociados a SSE son $n-2$. Se define pues el *cuadrado medio residual*, MSE, como un estimador de σ^2, que además resulta ser insesgado (esto es, su valor esperado es σ^2):

$$s^2 = MSE = \frac{SSE}{n-2}. \tag{5.12}$$

```
# La estimación de la varianza se consigue a partir del
# resumen del ajuste, que se obtiene con el comando
sfit<-summary(fit)
# y es:
sfit$sigma^2
```

5.8. Inferencia sobre $\hat{\beta}_0$ y $\hat{\beta}_1$.

Los estimadores de mínimos cuadrados $\hat{\beta}_0$ y $\hat{\beta}_1$ son insesgados y de mínima varianza de entre todos los estimadores insesgados. El hecho de especificar una distribución normal sobre los errores para la estimación máximo-verosímil, permite derivar la distribución de dichos estimadores, que hereda la normalidad y es:

$$\begin{aligned} \hat{\beta}_0 &\sim N\left(\beta_0, \frac{\sum_{i=1}^n x_i^2}{nS_{xx}}\ \sigma^2\right) \\ \hat{\beta}_1 &\sim N\left(\beta_1, \frac{\sigma^2}{S_{xx}}\right). \end{aligned} \tag{5.13}$$

Puesto que las varianzas de $\hat{\beta}_0$ y $\hat{\beta}_1$ dependen de σ^2, cuando el modelo de regresión es adecuado, podemos estimarlas sustituyendo σ^2 por s^2. Resultan entonces los **estadísticos** t con los que construir intervalos de confianza y resolver los contrastes:

$$\begin{aligned} t_0 &= \frac{\hat{\beta}_0 - \beta_0}{s\ \sqrt{\sum_i x_i^2/nX_{xx}}} \\ t_1 &= \frac{\hat{\beta}_1 - \beta_1}{s/\sqrt{S_{xx}}}. \end{aligned} \tag{5.14}$$

Ambos se distribuyen según una distribución t con $n-2$ grados de libertad, que nos permite inferir (estimar y resolver contrastes de hipótesis) sobre los coeficientes del modelo, y así contestar preguntas relativas a la relación entre las variables respuesta y explicativa (si ésta es directa, inversa, o simplemente no existe).

Los **intervalos de confianza** para β_0 y β_1 resultan entonces:

$$IC(\beta_0; 1-\alpha) = \hat{\beta}_0 \pm t_{\left(n-2,1-\frac{\alpha}{2}\right)} \sqrt{\frac{\sum_{i=1}^n x_i^2}{nS_{xx}}\ s^2} \tag{5.15}$$

$$IC(\beta_1; 1-\alpha) = \hat{\beta}_1 \pm t_{\left(n-2,1-\frac{\alpha}{2}\right)} \sqrt{\frac{s^2}{S_{xx}}},$$

donde $t_{\left(n-2,1-\frac{\alpha}{2}\right)}$ es el cuantil $1-\alpha/2$ de una distribución t con $n-2$ grados de libertad (los correspondientes a s^2).

Ejemplo 5.3 (Modelización del Ejemplo 3.1) *Estimar una recta y obtener intervalos de confianza para β_0 y β_1.*

```
x<-edad;y<-costes
fit<-lm(y~x)
# Los coeficientes estimados se obtienen con:
coef(fit)

# Los errores estándar asociados a los coeficientes son:
sfit<-summary(fit)
sfit$coefficients[,2]
# Los intervalos de confianza para los parámetros:
confint(fit)
```

La recta ajustada es

$$\widetilde{costes} = 323{,}62 + 131{,}72\ edad.$$

Los intervalos de confianza para β_0 y β_1 al nivel de confianza del 95 % resultan:

$$IC(\beta_0, 95\,\%) = (10{,}42936, 636{,}8152)$$
$$IC(\beta_0, 95\,\%) = (55{,}82166, 207{,}6113),$$

ambos claramente alejados del cero, lo que habla positivamente de su significatividad estadística, esto es, predecimos los costes con la edad de los vehículos a través de una recta con interceptación y pendientes (significativamente) distintas de cero. De hecho, la relación entre costes y edad es directa, como se ve en el signo y la magnitud del coeficiente estimado β_1.

Si queremos **contrastar hipótesis** sobre los coeficientes de la regresión:

$$\begin{aligned} H_0 &: \beta_i = \beta^* \\ H_1 &: \beta_i \neq \beta^*, \quad i = 0, 1 \end{aligned} \tag{5.16}$$

basta con considerar los estadísticos correspondientes (5.14), sustituyendo el valor β_i por el que se pretende contrastar, β^*. Estos estadísticos, bajo H_0, tienen una distribución t con $n-2$ grados de libertad. La resolución del contraste consiste en calcular el p-valor asociado al valor absoluto de la estimación, $|t_0|$ o $|t_1|$, según el caso, esto es, $p - valor = Pr[t_{n-2} > |t_i|]$. El contraste se resuelve de la siguiente forma:

- se rechaza H_0 a nivel α cuando $p - valor \leq \alpha$,
- si $p - valor > \alpha$, se dice que los datos no proporcionan suficientes evidencias en contra de la hipótesis nula y ésta no se puede rechazar.

Cuando el contraste propuesto sobre β_0 o β_1 tiene $\beta^* = 0$, en realidad se está contrastando, respectivamente, si la recta de regresión tiene interceptación o pendiente nula. Contrastar $\beta_1 = 0$ es equivalente a contrastar correlación nula $\rho_{xy} = 0$ entre las variables X e Y, esto es, ausencia de relación lineal. Si conseguimos rechazar esta hipótesis con significatividad, concluiremos que la variable X está relacionada linealmente con Y y por lo tanto se puede utilizar para predecir Y a través de la recta de regresión ajustada.

Ejemplo 5.4 (Contraste de hipótesis sobre el ajuste del Ejemplo 3.1) . *Sobre el ajuste realizado, obtener los estadísticos t, concluir sobre los contrastes $\beta_0 = 0$ y $\beta_1 = 0$. Comprobar también que el último contraste es equivalente al contraste de correlación nula entre las variables 'coste' y 'edad'.*

```
x<-edad; y<-costes
fit<-lm(y~x)
# El descriptivo 'summary' proporciona estadísticos t y p-valores
sfit<-summary(fit)
sfit$coefficients
# o bien con:
library(gmodels)
ci(fit)
# que además proporciona intervalos de confianza,

# El test de correlación era
cor.test(costes,edad)
```

Comprobamos pues, que el test de correlación da el mismo estadístico t y p-valor que el test $\beta_1 = 0$*, esto es,* $t = 3{,}6992,\ p - value = 0{,}002143$.

En la Tabla de coeficientes tenemos las estimaciones, errores estándar (raíz cuadrada de la varianza), el estadístico t y el p-valor asociado al contraste $H_0 : \beta_i = 0$*:*

β_0 *(Intercept):* $\hat{\beta}_0 = 323{,}62, sd(\hat{\beta}_0) = 146{,}94$

$$t_0 = 2{,}202,\ p\text{-}valor\ = 0{,}04369 \rightsquigarrow\ \textit{Rechazo}\ \beta_0 = 0\ \textit{y acepto}\ \beta_0 \neq 0.$$

β_1 *(edad):* $\hat{\beta}_1 = 131{,}72, sd(\hat{\beta}_1) = 35{,}61$

$$t_1 = 3{,}699,\ p\text{-}valor\ = 0{,}00214 \rightsquigarrow\ \textit{Rechazo}\ \beta_1 = 0\ \textit{y acepto}\ \beta_1 \neq 0.$$

La conclusión del test es que tanto la interceptación de la recta como la influencia de la variable edad son significativas para predecir el coste asociado. Lo que más nos interesa: la edad explica significativamente el coste de manutención de los tractores. Hemos demostrado estadísticamente que la edad influye "linealmente" sobre el coste.

5.8.1. Estimación de la respuesta esperada

Si queremos estimar el *valor esperado* de la variable Y cuando la variable X toma un valor concreto $X = x_0$ dentro del rango de valores observados, basta con sustituir dicho valor en la recta de regresión ajustada:

$$\hat{y}_{x_0} = \hat{\beta}_0 + \hat{\beta}_1 x_0.$$

Un intervalo de confianza para la estimación del valor esperado de la respuesta para un x_0 dado es:

$$IC(E(\bar{Y}_n|x_0); 1-\alpha) = \hat{y}_{x_0} \pm t_{\left(n-2,1-\frac{\alpha}{2}\right)}\ s\ \sqrt{\frac{1}{n} + \frac{(x_0-\bar{x})^2}{S_{xx}}} \tag{5.17}$$

5.8.2. Predicción de nuevas observaciones

Predeciremos UNA futura observación de la variable Y para cierto valor de $X = x_0$, con

$$\hat{y}_{x_0} = \hat{\beta}_0 + \hat{\beta}_1 x_0 = \bar{y} + \hat{\beta}_1(x_0 - \bar{x}),$$

y el intervalo de confianza vendrá dado por:

$$IC(y_{x_0}; 1-\alpha) = \hat{y}_{x_0} \pm t_{\left(n-2,1-\frac{\alpha}{2}\right)}\ s\ \sqrt{1 + \frac{1}{n} + \frac{(x_0-\bar{x})^2}{S_{xx}}} \tag{5.18}$$

Notar que la predicción conlleva más incertidumbre que la estimación de la respuesta media.

Ejemplo 5.5 (Continuación del Ejemplo 3.1) *Estimar la respuesta media y la predicción de una nueva observación para una secuencia de 20 puntos equidistantes en el rango de valores observados para la variable explicativa. Representar las bandas de confianza y comparar los errores estándar de las estimaciones.*

```
y<-costes; x<-edad
fit<-lm(y~x)
# Queremos estimar y predecir con la recta de regresión
# los costes de manutención para diversas edades:
x0<-seq(min(x),max(x),length=20)

# La estimación completa de la respuesta media se obtiene con:
pred.m<-predict(fit,data.frame(x=x0),interval="confidence",se.fit=T)

# La predicción completa de una nueva observación se obtiene con:
pred.p<-predict(fit,data.frame(x=x0),interval="prediction",se.fit=T)

# Dibujamos los intervalos de confianza para estimación y predicción:
matplot(x0,cbind(pred.m$fit,pred.p$fit[,-1]),lty=c(1,2,2,3,3),
type="l",xlab="x",ylab="y predicha")
```

5.9. Ajuste del modelo. Descomposición de la varianza: Anova

Una medida de lo bueno que resulta un modelo para ajustar unos datos pasa por cuantificar cuánta de la variabilidad contenida en éstos ha conseguido ser explicada por dicho modelo. Un modelo es bueno si la variabilidad explicada es mucha, o lo que es lo mismo, si las diferencias entre los datos y las predicciones según el modelo son pequeñas.

Construir la tabla de ANOVA o Análisis de la Varianza consiste en

i) descomponer la variabilidad de los datos en la parte que es explicada por el modelo y la parte que se deja sin explicar, es decir, la variabilidad de los residuos, y

ii) compararlas y valorar estadísticamente si la variabilidad explicada por el modelo ajustado es suficientemente grande.

Si partimos de la identidad:

$$y_i - \bar{y} = (y_i - \hat{y}_i) + (\hat{y}_i - \bar{y})$$

y el hecho de que $\sum_i (y_i - \hat{y}_i)(\hat{y}_i - \bar{y}) = 0$, tenemos que:

$$\sum_{i=1}^{n} (y_i - \bar{y})^2 = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 + \sum_{i=1}^{n} (\hat{y}_i - \bar{y})^2$$

es decir,

$$\underbrace{\text{Variabilidad datos}}_{SST} = \underbrace{\text{Variabilidad residuos}}_{SSE} + \underbrace{\text{Variabilidad recta}}_{SSR}$$

Las abreviaturas SST, SSE y SSR provienen del inglés *Sum of Squares* (suma de cuadrados) Total, debida al Error (o residual) y debida a la Regresión, respectivamente. A partir de ellas se calculan las sumas de cuadrados medias dividiendo por sus grados de libertad asociados, $MSE = SSE/(n-2)$ y $MSR = SSR/1$.

Contrastar la bondad del ajuste de la recta de regresión:

H_0 :el modelo no ajusta bien los datos

H_1 :el modelo ajusta bien los datos,

es equivalente a contrastar $H_0 : \beta_1 = 0$, puesto que lo buena que sea la recta para predecir depende, en RLS, exclusivamente de la relación lineal que existe entre la variable explicativa y la respuesta. El estadístico de bondad de ajuste de la regresión está basado en las variabilidades explicadas y sin explicar, que resulta tener una distribución F cuando el modelo es correcto:

$$F = \frac{SSR/\sigma^2}{\frac{SSE/\sigma^2}{n-2}} = \frac{MSR}{MSE} \sim F_{1,n-2}. \tag{5.19}$$

En el modelo RLS, el estadístico F es igual al estadístico t asociado a β_1 elevado al cuadrado. Hemos dicho, de hecho, que el contraste de bondad de ajuste es equivalente al de $\beta_1 = 0$.

Concluiremos con que la recta de regresión es significativa al nivel $(1-\alpha)100\,\%$ para predecir la respuesta Y, cuando el valor que obtenemos para el estadístico F supera el valor crítico que se corresponde con el cuantil $1-\alpha$ de una distribución F con 1 y $n-2$ grados de libertad. O lo que es lo mismo, cuando el p-valor asociado a él resulta inferior a α. En otro caso, diremos que no hemos obtenido evidencias suficientes para rechazar que el modelo lineal no es útil para predecir la variable Y a través de X.

Todas estas sumas de cuadrados y estadísticos se suelen presentar en una tabla de Anova, cuya apariencia suele tener la forma de la Tabla 1.

Fuente	gl	SS	MS	estadístico F	p-valor
Regresión	1	SSR	$MSR = \frac{SSR}{1}$	$F = \frac{MSR}{MSE}$	$Pr(F_{1,n-2} > F)$
Error	$n-2$	SSE	$MSE = \frac{SSE}{n-2}$		
Total	$n-1$	S_{yy}			

Cuadro 1: Tabla de Análisis de la Varianza en Regresión Lineal Simple.

Ejemplo 5.6 (Continuación del Ejemplo 3.1) *Obtener la Tabla de Anova. Verificar que el error cuadrático medio MSE es la estimación de la varianza. Concluir sobre la bondad del ajuste.*

```
x<-edad;y<-costes
fit<-lm(y~x)
# La tabla de Anova se consigue con:
anova(fit)

sfit<-summary(fit)
# La MSE de la tabla Anova es la estimación de la varianza
sfit$sigma^2

# El estadístico F de la Tabla Anova es igual al estadístico t
# de beta1 al cuadrado, y sus p-valores coinciden:
sfit$coefficients
coef(sfit)["x",]

coef(sfit)["x",3]^2
sfit$fstatistic
```

Simplemente observando la Tabla de Anova, vemos que la variabilidad explicada por la recta, 1099635, es superior a la que queda por explicar, 80360. El estadístico F valora si dicha diferencia es suficientemente grande como para poder concluir que efectivamente la recta explica la mayor parte de la variabilidad existente. El valor del estadístico F es 13.684, y el p-valor asociado al contraste es de 0.002143. La conclusión es que podemos rechazar $H_0 : beta_1 = 0$*, o lo que es lo mismo,* H_0 *: el modelo no explica los datos, a favor de que la edad resulta útil para predecir los costes a través de la recta ajustada.*

5.9.1. El coeficiente de determinación

Otro estadístico útil para chequear la bondad del ajuste de la recta de regresión es el *coeficiente de determinación* R^2. Éste se define como la proporción de la varianza que es explicada por la recta de regresión,

$$R^2 = \frac{SSR}{SST} = \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{S_{yy}} = \frac{S_{xy}^2}{S_{xx}S_{yy}}. \tag{5.20}$$

De hecho, en RLS, R es la correlación lineal (4.1) entre la respuesta Y y el predictor X, $R^2 = r_{xy}^2$.

Puesto que $0 \leq R^2 \leq 1$, un valor cercano a 1 (entre 0.6 y 1) implicará que buena parte de la varianza es explicada por la recta de regresión, y $R^2 \approx 0$ que

prácticamente toda la variabilidad de los datos queda sin explicar por la recta. Sin embargo, R^2 no sirve para medir la idoneidad del modelo de regresión para describir los datos. De hecho, R^2 resultará con frecuencia grande a pesar de que la relación entre X e Y no sea lineal. Siempre ha de ser utilizado con cautela. Así por ejemplo, la magnitud de R^2 depende del rango de variabilidad de la variable explicativa. Cuando el modelo de regresión es adecuado, la magnitud de R^2 aumenta (o disminuye) cuando lo hace la dispersión de X. Por otro lado, podemos obtener un valor muy pequeño de R^2 debido a que el rango de variación de X es demasiado pequeño, y entonces impedirá que se detecte su relación con Y.

Ejemplo 5.7 (Continuación del Ejemplo 3.1) *Obtener el coeficiente de determinación del ajuste, comprobar que es igual al coeficiente de correlación múltiple y concluir sobre la bondad del ajuste en base a él.*

```
x<-edad;y<-costes
fit<-lm(y~x)

# El coeficiente de determinación se obtiene a partir de:
sfit<-summary(fit);sfit
# identificado como Multiple R-Squared:
sfit$r.squared

# Corroboramos que su valor es igual a la correlación al cuadrado:
cor(x,y)^2
```

En realidad no sale un valor excesivamente alto en nuestro modelo. Si miramos el gráfico de los datos, observamos que la tendencia lineal especialmente se aprecia para los vehículos que superan los cuatro años. En realidad, los camiones muy nuevos han tenido bastantes gastos, posiblemente debido a que sus reparaciones son más caras.

5.10. Diagnóstico Gráfico del Modelo. Análisis de los Residuos

El diagnóstico del modelo consiste en verificar, una vez ajustado un modelo y habiendo resultado significativo (test Anova), si satisface las hipótesis básicas del modelo de regresión, que son:

- linealidad entre las variables X e Y;
- para los errores del modelo, ϵ_i:
  1. media cero
  2. varianza constante
  3. incorrelación
  4. normalidad.

El análisis de los residuos nos permitirá identificar deficiencias en la verificación de estas hipótesis, así como detectar observaciones anómalas o influyentes en el ajuste.

Definimos los residuos de un modelo lineal como las desviaciones entre las observaciones y los valores ajustados:

$$e_i = y_i - \hat{y}_i, \quad i = 1, \ldots, n. \tag{5.21}$$

En ocasiones, es preferible trabajar con los residuos estandarizados, que tienen media cero y varianza aproximadamente unidad,

$$d_i = \frac{e_i}{\sqrt{MSE}}, \quad i = 1, \ldots, n. \tag{5.22}$$

```
x<-edad;y<-costes
fit<-lm(y~x)

# Los residuos e(i) se obtienen con:
fit$residuals
# o bien
e<-residuals(fit); e

# Los residuos estandarizados se obtienen con:
sfit<-summary(fit)
d<-e/sfit$sigma; d
```

El análisis de los residuos es fundamentalmente gráfico, si bien existen varios tests estadísticos útiles para detectar inadecuaciones del modelo, que no trataremos aquí (ver Draper y Smith, 1998).

Gráficos de Normalidad de los Residuos. Se dibujan los residuos ordenados $e_{[i]}$ versus los cuantiles correspondientes de una normal estándar, $\Phi^{-1}[(i-1)/n]$. Si es cierta la normalidad de los residuos, el gráfico resultante debería corresponderse con una recta (ver Figura 5.4).

La hipótesis de normalidad se puede chequear también con histogramas de los residuos cuando el tamaño muestral es grande.

```
opar<-par(mfrow=c(2,1))
#Los gráficos qq-plot de normalidad se obtienen con:
qqnorm(d)
qqline(d)
# los histogramas, con:
hist(d,probability=T)
d.seq<-seq(min(d),max(d),length=50)
lines(d.seq,dnorm(d.seq,mean(d),sd(d)))
par(opar)
```

Los residuos estandarizados también son útiles para detectar desviaciones de la normalidad, Si los errores se distribuyen según una normal, entonces aproximadamente el 68 % de los residuos estandarizados quedarán entre -1 y $+1$, y el 95 % entre -2 y $+2$.

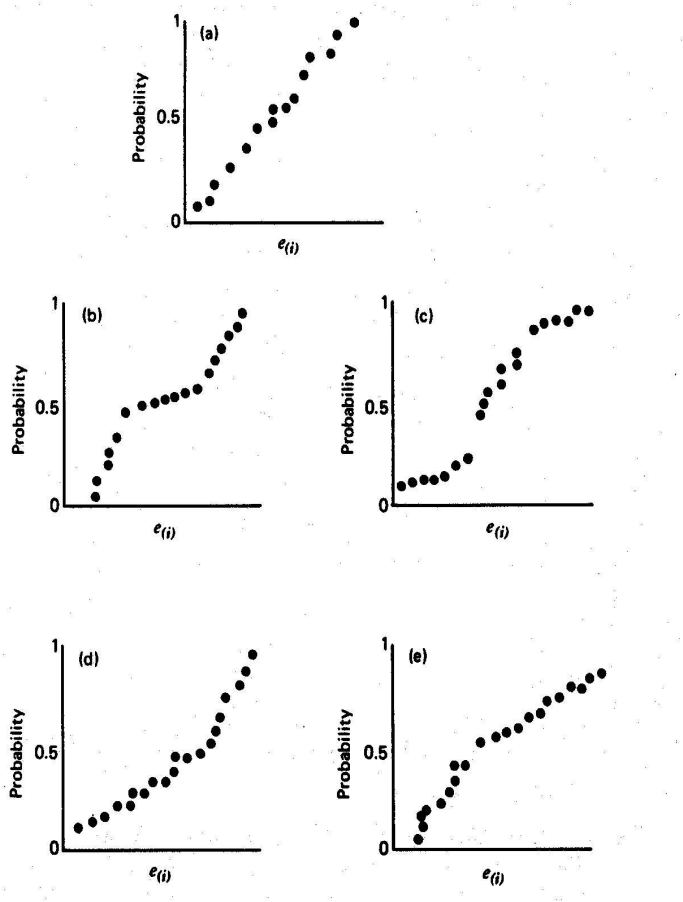


Figura 5.4: Gráficos qq-plot para verificar normalidad.

Los gráficos de residuos versus valores ajustados $\hat{y}_i$ permiten detectar otras deficiencias del modelo ajustado. Si los residuos están distribuidos alrededor del cero y el gráfico no presenta ninguna tendencia, entonces el modelo se considera adecuado. Cuando aparece alguna tendencia como una forma de embudo o un abombamiento, etc., entonces decimos que podemos tener algún problema con la violación de la hipótesis de varianza constante para los errores (heterocedasticidad). Ver Figura 5.5.

Los gráficos de residuos versus los valores de la variable predictora x_i son útiles para apreciar tendencias de los residuos que han quedado sin explicar por el modelo ajustado. Básicamente se interpretan como los gráficos de residuos

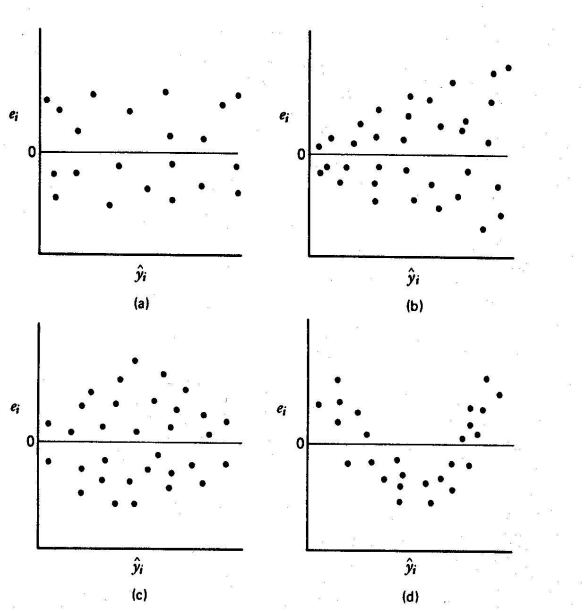


Figura 5.5: Gráficos de residuos versus valores ajustados. (a) Adecuación del modelo. (b) y (c) Heterocedasticidad. (d) Falta de linealidad.

versus valores ajustados $\hat{y}_i$. Es deseable que los residuos aparezcan representados en una banda horizontal sin tendencias alrededor del cero.

```
opar<-par(mfrow=c(2,1))
# El gráfico de residuos versus valores ajustados se obtiene con:
plot(fitted(fit),d,xlab="Valores ajustados",ylab="Residuos Estandarizados")
# y el de residuos versus el predictor:
plot(x,d,xlab="X",ylab="Residuos Estandarizados")
par(opar)
```

Los gráficos de los residuos versus otros posibles regresores omitidos en el modelo puede revelar la necesidad de incluirlos para conseguir explicar las tendencias detectadas.

Un gráfico de los residuos en función de la secuencia temporal en que se observaron los datos puede ayudar a apreciar un problema de correlación de los residuos (llamada *autocorrelación*), o de inestabilidad de la varianza a lo largo del tiempo. También los gráficos en que se representa un residuo versus el

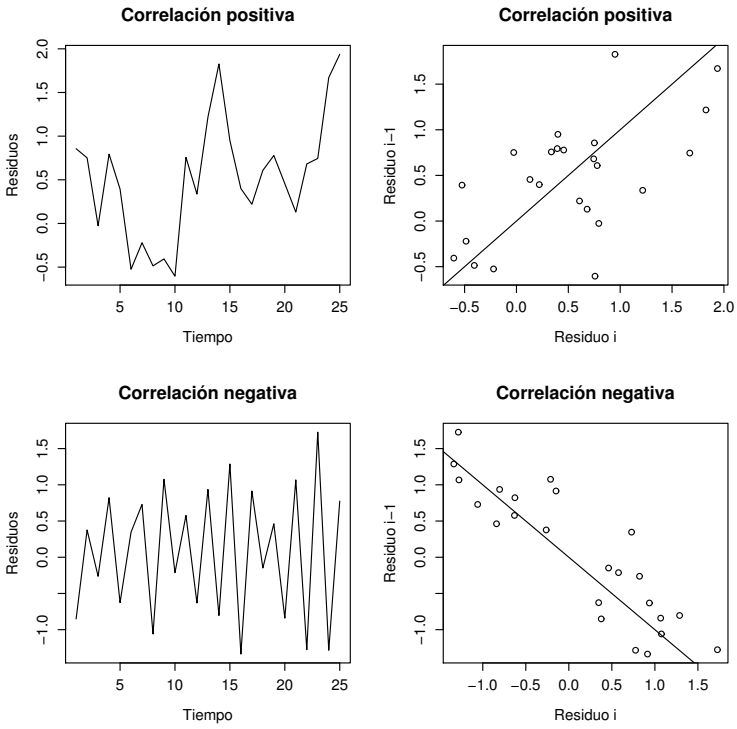


Figura 5.6: Autocorrelación de los residuos.

anterior en la secuencia; si hay correlación se apreciará tendencia. Detectar autocorrelación lleva a considerar otro tipo de modelos distintos. La correlación entre los datos es un proceso intrínseco al muestreo; saber cómo se ha llevado a cabo éste da información, generalmente suficiente, para poder hablar de correlación o incorrelación.

```
opar<-par(mfrow=c(2,1))
# La secuencia temporal de residuos se obtiene con:
plot(d)
# El gráfico de residuos versus el anterior será:
n<-length(d)
plot(d[1:(n-1)],d[2:n],xlab="Residuo i",ylab="Residuo i-1")
par(opar)
```

```
# En R, el comando 'plot(fit)' realiza algunos gráficos
# útiles para el diagnóstico del modelo:
opar<-par(mfrow=c(2,2))
plot(fit)
par(opar)
```

Ejemplo 5.8 (Diagnóstico del modelo RLS para el Ejemplo 3.1) *Calcular los residuos asociados al ajuste, estandarizados y normales, y llevar a cabo el diagnóstico del modelo.*

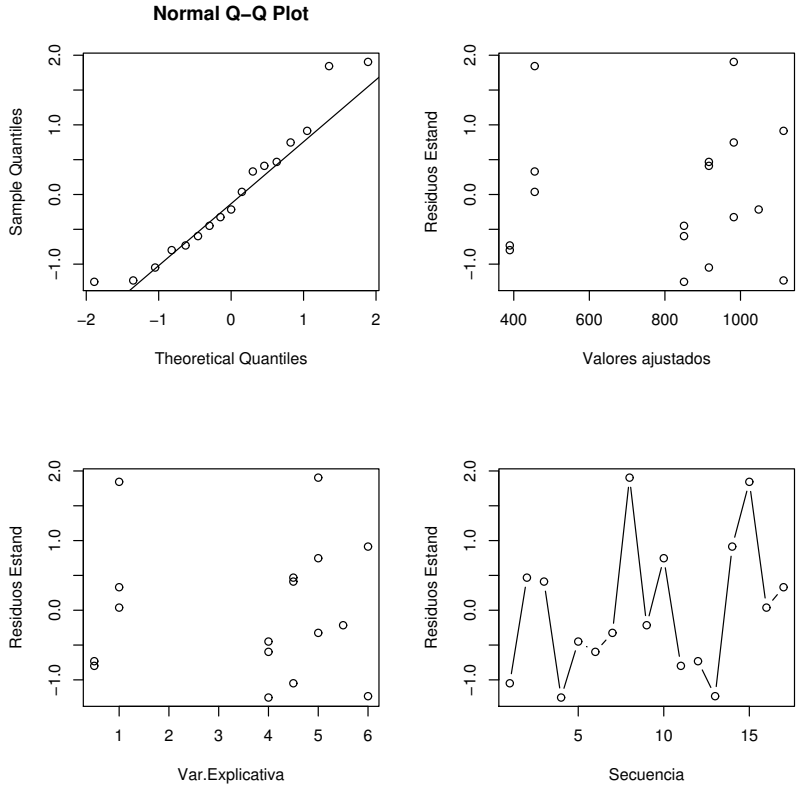
```
x<-edad;y<-costes
fit<-lm(y~x)
sfit<-summary(fit)

# Dibujamos varios gráficos de diagnóstico:
opar<-par(mfrow=c(2,2))
plot(fit)
par(opar)

# Otros gráficos adicionales propuestos son:
opar<-par(mfrow=c(2,2))
# Valores x versus residuos (linealidad, homocedasticidad)
d<-residuals(fit)/sfit$sigma
plot(x,d,xlab="Var.Explicativa",ylab="Residuos Estand")
par(opar)
# Incorrelación de los residuos (incorrelación):
plot(d,type="b",xlab="Secuencia",ylab="Residuos Estand")
```

Apreciamos desviación de normalidad en las observaciones más pequeñas y en las más grandes, a través del gráfico qq-plot. El gráfico de valores ajustados versus residuos acusa cierta falta de linealidad, así como el de residuos versus variable explicativa. No se aprecia ningún comportamiento periódico en los residuos a través del gráfico de secuencia temporal, por lo que en principio no descartamos la incorrelación. El resultado del análisis gráfico se visualiza en la Figura 5.8. La conclusión es que detectamos cierta faltas de normalidad y de linealidad.

Cuando, una vez realizado el diagnóstico del modelo, detectamos deficiencias, cabe reconsiderar la modelización, posiblemente con transformaciones de



los datos que corrijan los defectos encontrados. Propuesto un nuevo modelo corrector, los pasos a dar vuelven a ser los mismos: ajuste y diagnosis. En el tema siguiente hablaremos más de las soluciones a problemas en el diagnóstico, y de otro tema importante cuando un modelo ajustado cumple con todas las hipótesis del modelo RLS, como es el de validación.

Ejemplo 5.9 *[Continuación del diagnóstico del primer modelo RLS del Ejemplo 3.1.] Buscar alguna transformación de los datos que proporcione un mejor ajuste y corrija algo las deficiencias encontradas.*

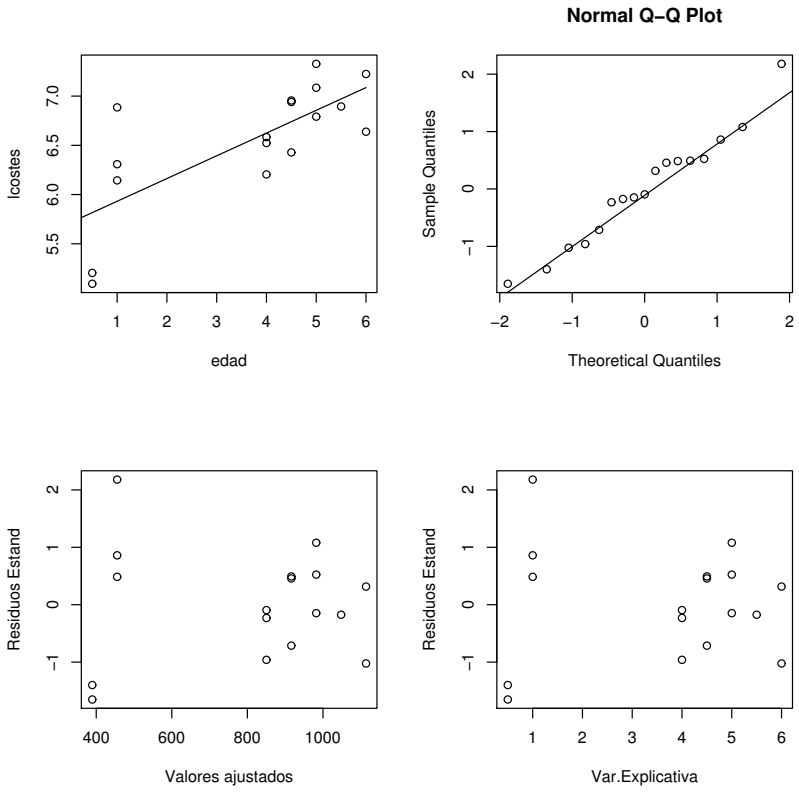
```
# Proponemos una primera transformación de los datos
# y testamos la correlación lineal, que dará buenos
# indicios de lo satisfactorio que resulta una RLS:
ly<-log(y)
cor.test(ly,x)  # cor=0.7353647
# proporciona algo de ganancia en linealidad.
# Recordemos:
cor.test(y,x)   # cor= 0.6906927

# Reajustamos otro modelo
fit.l<-lm(ly~x)
sfit.l<-summary(fit.l);sfit.l
d.l<-residuals(fit.l)/sfit.l$sigma

par(mfrow=c(2,2))
plot(x,ly)
abline(a=coef(fit.l)[1],b=coef(fit.l)[2])
qqnorm(d.l)
qqline(d.l)
plot(fitted(fit.l),d.l,xlab="Valores ajustados",ylab="Residuos Estand")
plot(x,d.l,xlab="Var.Explicativa",ylab="Residuos Estand")
```

Se sigue apreciando heterocedasticidad y cierta falta de linealidad (ver Figura 5.9), si bien la falta de normalidad ya no es tan acusada.

De hecho, se aprecian dos grupos de camiones con distinta variabilidad: los camiones con 1 o menos de 1 año y los camiones con 4 o más de cuatro años. Para resolver esto, podemos crear una nueva variable que identifique estos dos grupos y emplearla en el ajuste. Esto es, proponer un nuevo modelo de predicción que permita ajustar una recta de regresión para los camiones modernos y otra para los más viejos. Veremos cómo hacer esto en el Tema **??**.


lcostes
edad
Normal Q–Q Plot
Sample Quantiles
Theoretical Quantiles
Residuos Estand
Valores ajustados
Residuos Estand
Var.Explicativa

Apéndice

Sintaxis Tema 3

- **Ejemplo 3.1**

```
edad<-c(4.5,4.5,4.5,4.0,4.,4.,5,5,5.5,5,0.5,0.5,6,6,1,1,1)
costes<-c(619,1049,1033,495,723,681,890,1522,987,1194,
163,182,764,1373,978,466,549)
plot(edad,costes,xlab="edad (en años)",ylab="Costes en 6 meses")
fit<-lm(costes~edad)
edad.s<-seq(min(edad),max(edad),length=100)
lines(edad.s,predict(fit,data.frame(edad=edad.s)))
```

- **Ejemplo 3.2**

```
DBH <- c(10.2,13.72,15.43,14.37,15,15.02,15.12,15.24,15.24,15.28,
13.78,15.67,15.67,15.98,16.5,16.87,17.26,17.28,17.87,19.13)
D16 <-c(9.3,12.1,13.3,13.4,14.2,12.8,14,13.5,14,13.8,13.6,14,
13.7,13.9,14.9,14.9,14.3,14.3,16.9,17.3)
HT <-c(89,90.07,95.08,98.03,99,91.05,105.6,100.8,94,93.09,89,
102,99,89.02,95.09,95.02,91.02,98.06,96.01,101)
VOL <-c(25.93,45.87,56.2,58.6,63.36,46.35,68.99,62.91,58.13,
59.79,56.2,66.16,62.18,57.01,65.62,65.03,66.74,73.38,82.87,95.71)
bosque<-data.frame(VOL=VOL,DBH=DBH,D16=D16,HT=HT)
plot(bosque)
```

- **Ejemplo 3.3**

```
madera<-c(1,1.5,2,3,4,4.5,5,5.5,6,6.5,7,8,9,10,11,12,13,14,15)
tension<-c(6.3,11.1,20.0,24,26.1,30,33.8,34,38.1,39.9,42,46.1,
53.1,52,52.5,48,42.8,27.8,21.9)
plot(madera,tension,xlab="Concentración de madera (en %)",
ylab="Resistencia a la tensión")
fit<-lm(tension~madera+I(madera^2))
madera.sec<-seq(min(madera),max(madera),length=100)
lines(madera.sec,predict(fit,data.frame(madera=madera.sec)))
```

- **Ejemplo 3.4**

```
xt<-c(2.26,0.4,1.26,2.18,4.81,2.18,5.1,0.86,-0.44,1.79,2.73,
 -5.27,1.98,1.88,1.17,-0.96,2.4,2,1.63,3.32,1.64)
xc<-c(1.23,0.42,1.01,-0.11,-0.29,-1.73,1.63,-1.04,0.12,-0.69,
0.86,0.68,-1.26,0.56,0.79,-0.49,1.5,4,-0.73,-0.93,1.38)
datos<-c(xt,xc)
tratamiento<-gl(2,21,42,labels=c("Tratamiento","Placebo"))
boxplot(datos~tratamiento)
```

- **Ejemplo 3.5**

```
velocidad<-c(610,950,720,840,980,530,680,540,980,730,
670,770,880,1000,760,590,910,650,810,500)
vida<-c(18.73,14.52,17.43,14.54,13.44,25.39,13.34,22.71,12.68,
19.32,30.16,27.09,25.40,26.05,33.49,35.62,26.07,36.78,34.95,43.67)
herramienta<-gl(2,10,20,labels=c("A","B"))
plot(velocidad~vida,pch=as.character(herramienta),
col=as.numeric(herramienta))

# Ajustamos pues, dos modelos diferentes para el ejemplo de ANCOVA.
# Uno con interacción (rectas distintas) y otro sin (rectas paralelas):
fit1<-lm(vida~velocidad+herramienta,x=T); summary(fit1)
fit2<-lm(vida~velocidad*herramienta,x=T); summary(fit2)

x<-seq(min(velocidad),max(velocidad),length=50)
pred.A<-data.frame(velocidad=x,herramienta=factor(rep("A",50)))
pred.B<-data.frame(velocidad=x,herramienta=factor(rep("B",50)))
y1A<-predict(fit1,pred.A)
y1B<-predict(fit1,pred.B)
y2A<-predict(fit2,pred.A)
y2B<-predict(fit2,pred.B)

etiquetas<-as.character(herramienta)
par(mfrow=c(1,2))
plot(velocidad,vida,pch=etiquetas,main="Rectas Paralelas")
lines(x,y1A,lwd=2)
lines(x,y1B,lwd=2)

plot(velocidad,vida,pch=etiquetas,main="Rectas Distintas")
lines(x,y2A,lwd=2)
lines(x,y2B,lwd=2)
```

Sintaxis Tema 4

• Función para calcular el coeficiente de correlación múltiple.

```
#######################################
# coeficiente de correlacion multiple
#######################################

rho.mult<-function(datos)
# datos: matriz con las variables del problema.
# La primera columna debe ser la variable respuesta.
# Las restantes p-1 columnas son las variables explicativas.
{
matriz<-var(datos)
# calculo
n<-nrow(datos)
p<-ncol(matriz)
sxx<-matriz[2:p,2:p]
syx<-matrix(matriz[1,2:p],nrow=1)
sxy<-t(syx)
#coeficiente
rho.mult<-sqrt(syx%*%solve(sxx)%*%sxy)/sqrt(matriz[1,1])
cat("\n Coeficiente de correlación multile:  ",rho.mult,"\n")
#estadistico
if(abs(rho.mult)==1)
stop("Imposible resolver contraste.
Coeficiente de correlación múltiple igual a 1", call. = FALSE)
else{
est<-((n-(p-1)-1)*rho.mult)/((p-1)*(1-rho.mult^2))
#grafico
par(mfrow=c(1,1))
x<-seq(0,qf(0.999,p-1,n-(p-1)-1),length=500)
plot(x,df(x,p-1,n-(p-1)-1),type="l",ylab="densidad",
main="Contraste Correlación Múltiple")
abline(v=qf(0.975,p-1,n-(p-1)-1),col="red")
abline(v=qf(0.025,p-1,n-(p-1)-1),col="red")
abline(v=est,col="blue")
abline(h=0)
legend(qf(0.98,p-1,n-(p-1)-1),pf((p+3)/(n-p),p-1,n-(p-1)-1),
c("Estadístico","Región Crítica"),lty=rep(1,2),
col=c("blue","red"),bty="n")
cat("\n Estadístico de contraste:  ",round(est,3),"\n")
cat("\n p-valor:  ",round(2*(1-pf(est,p-1,n-(p-1)-1)),3),"\n\n")}
return(invisible())
}
```

- Sección 4.5

Datos

```
x<-c(4.94,5.9,3.05,6.61,6.36,4.92,5.83,4.21,3.75,4.8,3.95,5.3,
7.15,4.38,4.42,4.39,4.55,6.68,6.01,5.65,5.54,5.19,6.39,2.89,5,
5.31,6.18,3.74,4.35,4.32)

# Respuesta Banco de datos B1
y1<-c(1762.66,41885.33,883.73,10703.56,5294,2929.36,2049.4,
665.38,1017.73,5643.21,1062.86,64464.37,12246.12, 943.32,
16123.23,4674.16,4314.54, 35907.26,27171.17,17012.14,5833.36,
783.38,5330.68,168.06, 2823.49,3167.86,33221.36,5139.98,
982.27,1481.25)

# Respuesta Banco de datos B2

y2<-c(166,364,23,751,613,147,325,59,38,106,50,200,1253,84,82,
91,89,772,421,276,298,164,637,22,137,218,509,46,66,84)

# Respuesta Banco de datos B3

y3<-c(15.47,17.5,10.95,19.12,19.24,15.76,16.83,14.7,12.64,15.48,
13.96,17.1,20.11,14.09,15.84,14.61,15.48,19.09,17.97,17.5,17.62,
16.6,18.28,10.45,16.13,16.65,18.3,12.88,14.45,14.66)

# Respuesta Banco de datos B4

y4<-c(1.91,1.63,3.48,1.56,1.57,1.99,1.63,2.45,2.43,1.96,2.51,
1.8,1.41,2.25,2.35,2.33,2.06,1.64,1.7,1.77,1.91,1.8,1.62,3.36,
1.99,1.86,1.61,2.63,2.14,2.27)
```

Ejercicio 4.3

Los gráficos de la Figura 4.4 se han obtenido de la siguiente forma:

```
n<-30
x<-rnorm(n,5,1)

y1<-(x^4)*exp(rnorm(n,2))
plot(x,y)
plot(log(x),log(y))

y2<-rpois(n,exp(x))
plot(x,y)
plot(x,log(y))

y3<-rnorm(n,10*log(x),0.4)
plot(x,y)
plot(log(x),y)

y4<-rnorm(n,10/x,0.1)
plot(x,y)
plot(1/x,y)
```